



西安交通大学
XI'AN JIAOTONG UNIVERSITY

《优化方法基础》

2025-2026学年秋季学期

罗敏楠

计算机科学与技术学院

西安交通大学

基本概念、基本原理、基本方法

回顾

□ 范数定义：满足以下条件的函数 $f: \mathbb{R}^n \mapsto \mathbb{R}$, $\text{dom} f = \mathbb{R}^n$ 称为范数

✓ f 是非负的： $\forall x \in \mathbb{R}^n$, 有 $f(x) \geq 0$

✓ f 是正定的：若 $f(x) = 0$, 则 $x = 0$

✓ f 是齐次的： $\forall x \in \mathbb{R}^n$ 和 $t \in \mathbb{R}$, 有 $f(tx) = |t|f(x)$


✓ f 满足三角不等式： $\forall x, y \in \mathbb{R}^n$, 有 $f(x + y) \leq f(x) + f(y)$

□ l_p 范数 ($p \geq 1$): $\|x\|_p = (|x_1|^p + |x_2|^p + \cdots + |x_n|^p)^{1/p} = (\sum_{i=1}^n |x_i|^p)^{1/p}$


□ P - 二次范数 ($P \in S_{++}^n$): $\|x\|_P = (x^\top P x)^{1/2} = \|P^{1/2} x\|_2$ $p = \frac{1}{2}$

□ 任何有限维向量空间 $\mathbb{R}^n$ 上的范数 $\|\cdot\|_a, \|\cdot\|_b$ 都是等价的, 即存在正常数


α, β 对所有的 $x \in \mathbb{R}^n$, 有 $\alpha\|x\|_a \leq \|x\|_b \leq \beta\|x\|_a$




$p = 0$



$p = 1$



$p = 2$



$p = 1/2$

回顾

□ 定义：令 $\|\cdot\|$ 是 $\mathbb{R}^n$ 上的范数，其**对偶范数** $\|\cdot\|_*$ 定义为

$$\|z\|_* = \sup \{z^T x: \|x\| \leq 1\} = \sup \{z^T x: \|x\| = 1\}$$

□ ℓ_1 范数的对偶范数为 ℓ_∞ 范数：即 $\|z\|_* = \sup \{z^T x: \|x\|_1 = 1\} = \max \{z_1, z_2\} = \|z\|_\infty$

□ ℓ_∞ 范数的对偶范数为 ℓ_1 范数：即 $\|z\|_* = \sup \{z^T x: \|x\|_\infty = 1\} = \|z\|_1$

□ ℓ_p 范数的对偶范数为 ℓ_q 范数 ($p, q \geq 1$)：即 $\|z\|_* = \sup \{z^T x: \|x\|_p = 1\} = \|z\|_q$ **当且仅当**


$$\frac{1}{p} + \frac{1}{q} = 1$$

□ 思考 $\|z\|_* = \sup \{z^T x: \|x\|_P = 1\} = ?$, $P \in S_{++}^n$


回顾

□ 凸集

- 凸集的定义：如果 $\forall x, y \in C$ 及 $\forall \theta \in [0, 1]$ ，有 $z = \theta x + (1 - \theta)y \in C$ ，则集合 $C \subset R^n$ 称为凸集。
- 凸集的性质：集合的交运算、和运算、仿射运算及其逆运算保凸性。
- 凸集的判定：定义或保凸运算。



凸集



非凸集

凸集：任意两点的连线仍在集合中


回顾

□ 凸函数

- 定义：令集合 $C \subseteq \mathbb{R}^n$ 是一凸集。 $\forall x, y \in C, \forall \lambda \in [0, 1]$ ，如果函数 $f: C \rightarrow \mathbb{R}$ 满足以下条件

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y)$$

则 f 为凸函数。



凸函数图像上任意两点之间的连线（弦）都在函数图像之上

- 凹函数、严格凸函数、严格凹函数


回顾

□ 凸函数的一阶判定： $C \in \mathbb{R}^n$ 为凸集且函数 $f: C \rightarrow \mathbb{R}$ 在集合 C 上可微，那么

(1) 函数 f 是凸函数当且仅当 $\forall x, y \in C$, 有

$$f(y) \geq f(x) + \nabla^T f(x)(y - x) \quad \text{—— 一阶判定条件}$$

(2) 如果 $\forall x, y \in C$ 且 $x \neq y$, $f(y) > f(x) + \nabla^T f(x)(y - x)$, 那么 函数 f 是严格凸函数。



凸函数的二阶判定

定理： $C \in \mathbb{R}^n$ 为凸集（开集）且函数 $f: C \rightarrow \mathbb{R}$ 在集合 C 上二阶连续可微，那么

(1) 函数 f 是凸函数当且仅当 $\forall x \in C, \nabla^2 f(x)$ 为对称半正定矩阵

(2) 如果 $\forall x \in C, \nabla^2 f(x)$ 为对称正定矩阵，那么函数 f 是严格凸函数

这里， $\forall x = [x_1, x_2, \dots, x_n] \in C$ ，函数 f 的Hessian矩阵 $\nabla^2 f(x) \in \mathbb{R}^{n \times n}$ 定义为

$$(\nabla^2 f(x))_{ij} = \frac{\partial^2 f(x)}{\partial x_i \partial x_j} \quad (i, j = 1, 2, \dots, n)$$



凸函数的二阶判定

□ 推论： $C \in R^n$ 为凸集且二次函数 $f: C \rightarrow R$ 定义为 $f(x) = x^T Q x + 2p^T x + r$ ，这里， $Q \in S^n$ 为对称矩阵。那么


- (1) 函数 f 是凸函数当且仅当 Q 为对称半正定矩阵
- (2) 函数 f 是凹函数当且仅当 Q 为对称半负定矩阵
- (3) 函数 f 是严格凸（凹）函数当且仅当 Q 为对称正（负）定矩阵
- (4) 否则，函数 f 为非凸非凹函数

证明： $\forall x \in C$, 函数 f 的 Hessian 矩阵为

$$\nabla^2 f(x) = Q$$

凸函数的判定方法总结


□定义: $f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y)$



□一阶判定: $f(y) \geq f(x) + \nabla^T f(x)(y - x)$

□二阶判定: $\forall x \in C, \nabla^2 f(x)$ 对称半正定矩阵

二次函数 $f(x) = x^T P x + 2q^T x + r$



□保凸函数运算

凸优化问题

凸优化问题

$$\begin{array}{ll} \min_x & f_0(x) \longrightarrow \text{目标函数 } f_0: X \rightarrow \mathbb{R} \text{ 为凸函数} \\ \text{s.t.} & x \in C \longrightarrow \text{可行解集 } C \text{ 为凸集合} \end{array}$$

这里，可行解集 $C = \{x \in \mathbb{R}^n: f_i(x) \leq 0, i = 1, 2, \dots, m; h_j(x) = 0, j = 1, 2, \dots, n\}$



- ✓ 什么情况下，可行解集 C 为凸集合？
- ✓ 凸优化问题为什么重要？

凸优化问题数学标准形式

$$\begin{array}{ll} \min_x & f_0(x) \text{-----} \rightarrow \text{目标函数为凸函数} \\ \text{s. t.} & f_i(x) \leq 0 \quad (i = 1, 2, \dots, m) \text{-----} \rightarrow \text{不等式限制函数为凸函数} \\ & h_j(x) = 0, \quad (j = 1, 2, \dots, n) \text{-----} \rightarrow \text{等式限制函数为仿射函数} \end{array}$$



- ✓ 什么情况下，可行解集 C 为凸集合？
- ✓ 凸优化问题为什么重要？

凸优化问题为什么重要？

定理：凸优化问题局部极小解即全局最小解

$$\begin{array}{ll} \min_x & f_0(x) \\ \text{s.t.} & x \in C \end{array}$$

证明：“全局极小解是局部极小解”，显然；

“局部极小解是全局极小解”：（反证法）假设存在 $x \in C$ 是局部极小解，而非全局极小解，那么 $\exists y \neq x$ 使得 $f(y) < f(x)$. 由于函数 f 为凸函数，对所有的 $\lambda \in [0,1]$, 有

$$\begin{aligned} f((1-\lambda)x + \lambda y) &\leq (1-\lambda)f(x) + \lambda f(y) \\ &\leq (1-\lambda)f(x) + \lambda f(x) = f(x). \end{aligned}$$

对于足够小的 λ ，则 $z = (1-\lambda)x + \lambda y$ 属于 x 的 ϵ -邻域且满足 $f(z) < f(x)$. 该结论与 $x \in C$ 是局部极小解相矛盾。证毕。

回顾

标准形式优化问题

$$\begin{array}{ll}\min_x & f_0(x) \\ \text{s. t.} & f_i(x) \leq 0, i = 1, 2, \dots, m \\ & h_i(x) = 0, i = 1, 2, \dots, p \\ & x \in \mathcal{D}\end{array}$$

- $f_0: \mathbb{R}^n \mapsto \mathbb{R}$
- $f_i: \mathbb{R}^n \mapsto \mathbb{R}, i = 1, 2, \dots, m$
- $h_i: \mathbb{R}^n \mapsto \mathbb{R}, i = 1, 2, \dots, p$
- $\mathcal{D} = \bigcap_{i=1}^m \text{dom} f_i \cap \bigcap_{i=1}^p \text{dom} h_i$ 非空
- 最优值 p^*

□ 对不等式约束 $f_i(x) \leq 0$ 引入拉格朗日乘子 λ_i ，对等式约束 $h_i(x) = 0$ 引入拉格朗日乘子 v_i 。记 $\lambda = [\lambda_1, \lambda_2, \dots, \lambda_m]^\top \in \mathbb{R}^m, v = [v_1, v_2, \dots, v_p]^\top \in \mathbb{R}^p$

□ 拉格朗日函数: $L: \mathbb{R}^n \times \mathbb{R}^m \times \mathbb{R}^p \rightarrow \mathbb{R}$

$$L(x, \lambda, v) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x), \quad \text{dom } L = \mathcal{D} \times \mathbb{R}^m \times \mathbb{R}^p$$

□ 拉格朗日对偶函数: $g: \mathbb{R}^m \times \mathbb{R}^p \rightarrow \mathbb{R}$

$$g(\lambda, v) = \inf_{x \in \mathcal{D}} L(x, \lambda, v) = \inf_{x \in \mathcal{D}} [f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x)]$$

✓ $\text{dom } g = \{(\lambda, v): g(\lambda, v) > -\infty\}$

✓ $g(\lambda, v)$ 为凹函数

✓ 对偶可行点 (λ, v) 满足: $\lambda \geq 0$ 且 $(\lambda, v) \in \text{dom } g$

✓ $\forall \lambda \geq 0$, 对偶函数 $g(\lambda, v) \leq p^*$

回顾

标准形式优化问题

$$\min_x f_0(x)$$

$$\text{s. t. } \begin{aligned} f_i(x) &\leq 0, \quad i = 1, 2, \dots, m \\ h_i(x) &= 0, \quad i = 1, 2, \dots, p \\ x &\in \mathcal{D} \end{aligned}$$

- $f_0: \mathbb{R}^n \mapsto \mathbb{R}$
- $f_i: \mathbb{R}^n \mapsto \mathbb{R}, i = 1, 2, \dots, m$
- $h_i: \mathbb{R}^n \mapsto \mathbb{R}, i = 1, 2, \dots, p$
- $\mathcal{D} = \bigcap_{i=1}^m \text{dom} f_i \cap \bigcap_{i=1}^p \text{dom} h_i$ 非空
- 最优值 p^*

□ 对不等式约束 $f_i(x) \leq 0$ 引入拉格朗日乘子 λ_i ，对等式约束 $h_i(x) = 0$ 引入拉格朗日乘子 v_i 。记 $\lambda = [\lambda_1, \lambda_2, \dots, \lambda_m]^\top \in \mathbb{R}^m, v = [v_1, v_2, \dots, v_p]^\top \in \mathbb{R}^p$

□ 拉格朗日函数: $L: \mathbb{R}^n \times \mathbb{R}^m \times \mathbb{R}^p \rightarrow \mathbb{R}$

$$L(x, \lambda, v) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x), \quad \text{dom } L = \mathcal{D} \times \mathbb{R}^m \times \mathbb{R}^p$$

□ 拉格朗日对偶函数: $g: \mathbb{R}^m \times \mathbb{R}^p \rightarrow \mathbb{R}$

$$g(\lambda, v) = \inf_{x \in \mathcal{D}} L(x, \lambda, v) = \inf_{x \in \mathcal{D}} [f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x)]$$



□ 原函数: $\sup_{\lambda \geq 0} L(x, \lambda, v) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x)$

$$= \begin{cases} f_0(x), & f_i(x) \leq 0, h_j(x) = 0 \ (\forall i, j) \\ \infty, & \text{otherwise} \end{cases}$$



拉格朗日对偶

$$\min_x f_0(x) \text{ s.t. } f(x) \leq 0, \mathcal{D} = \text{dom } f \cap \text{dom } g \subseteq \mathbb{R}$$



- ✓ 可行解集: $[-0.46, 0.46]$
- ✓ 对偶函数: $g(\lambda) = \min_{x \in \mathcal{D}} L(x, \lambda)$

- ✓ 对偶函数是凹函数
- ✓ 对偶问题是凸优化问题

弱对偶与强对偶

p^*

$$\begin{array}{ll} \min_{x \in \mathcal{D}} & f_0(x) \\ \text{s. t.} & f_i(x) \leq 0, i = 1, 2, \dots, m \\ & h_i(x) = 0, i = 1, 2, \dots, p \end{array}$$

原问题



对偶问题

$$\begin{array}{ll} \max_{\lambda, v} & g(\lambda, v) \\ \text{s. t.} & \lambda \geq 0 \end{array}$$

d^*

□ 弱对偶 (Weak Duality): $d^* \leq p^*$, 即 $\min_{x \in \mathcal{D}} \max_{\lambda \geq 0} L(x, \lambda, v) \geq \max_{\lambda \geq 0} \min_{x \in \mathcal{D}} L(x, \lambda, v)$

✓ 总是成立

✓ 最优对偶间隙: $p^* - d^* \geq 0$

□ 强对偶 (Strong Duality): $d^* = p^*$, 即 $\min_{x \in \mathcal{D}} \max_{\lambda \geq 0} L(x, \lambda, v) = \max_{\lambda \geq 0} \min_{x \in \mathcal{D}} L(x, \lambda, v)$

✓ 一般情况下不成立

✓ 对凸优化问题成立 (通常), 特别地, 若 Slater 约束品性满足, 即存在集合 $\mathcal{D}$ 的一个内点 x_0 , 使得 $f_i(x_0) < 0 (i = 1, 2, \dots, m)$, $Ax_0 = b$, 则强对偶性成立.



回顾

$$\begin{array}{ll}
 \min_{x \in \mathcal{D}} & f_0(x) \quad \text{原问题} \\
 \text{s. t.} & f_i(x) \leq 0, \quad i = 1, 2, \dots, m \\
 & h_i(x) = 0, \quad i = 1, 2, \dots, p
 \end{array}
 \xrightarrow{g(\lambda, v) = \inf_{x \in \mathcal{D}} [f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x)]}
 \begin{array}{ll}
 \max_{\lambda, v} & g(\lambda, v) \quad \text{对偶问题} \\
 \text{s. t.} & \lambda \geq 0
 \end{array}$$

□ 假设原问题与对偶问题最优解可取得，分别为 x^* 和 (λ^*, v^*) ，且强对偶性成立，则

$$\begin{aligned}
 & f_0(x^*) \\
 &= g(\lambda^*, v^*) \\
 &= \min_{x \in X} f_0(x) + \sum_{i=1}^m \lambda_i^* f_i(x) + \sum_{i=1}^p v_i^* h_i(x) \\
 &= f_0(x^*) + \sum_{i=1}^m \lambda_i^* f_i(x^*) + \sum_{i=1}^p v_i^* h_i(x^*) \\
 &= f_0(x^*)
 \end{aligned}$$


凸
优
化
问
题

KKT 方程

$$\begin{aligned}
 & f_i(x^*) \leq 0, \quad i = 1, 2, \dots, m \\
 & h_i(x^*) = 0, \quad i = 1, 2, \dots, p \\
 & \lambda_i^* \geq 0, \quad i = 1, 2, \dots, m \\
 & \lambda_i^* f_i(x^*) = 0, \quad i = 1, 2, \dots, m \\
 & \nabla f_0(x^*) + \sum_{i=1}^m \lambda_i^* \nabla f_i(x^*) + \sum_{i=1}^k v_i^* \nabla h_i(x^*) = 0
 \end{aligned}$$

回顾：通过解对偶问题求解原问题

□ 定理：对于凸优化问题，若 $\tilde{x}, \tilde{\lambda}, \tilde{v}$ 是任意满足KKT条件的点，则 $\tilde{x}, (\tilde{\lambda}, \tilde{v})$ 分别是原问题和对偶问题的最优解，并且对偶间隙为0。



回顾

$$\min f(x)$$

- 函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$, 连续二阶导数的凸函数
- 最优解 $x^* = \operatorname{argmin} f(x)$
- 最优值 $p^* = f(x^*)$
- 最优性条件 $\nabla f(x^*) = 0$
- 迭代求解 x^*
 - ✓ 初始点 $x^0 \in \operatorname{dom} f$;
 - ✓ 产生序列点 $x^k \in \operatorname{dom} f, k = 0, 1, 2, \dots$, 使得
$$f(x^k) \rightarrow p^*;$$
 - ✓ 水平集合 $S = \{x: f(x) \leq f(x^0)\}$ 是闭集;

- 强凸性假设: 存在 $m > 0$ 满足 $\forall x \in S, \nabla^2 f(x) \geq mI$



$$f(y) \geq f(x) + \nabla f(x)^\top (y - x) + \frac{m}{2} \|y - x\|_2^2$$



$$f(x) - p^* \leq \frac{1}{2m} \|\nabla f(x)\|_2^2$$
$$\|x^* - x\|_2 \leq \frac{2}{m} \|\nabla f(x)\|_2$$

- 假设存在 $M > 0$ 使得 $\forall x \in S$, 有 $\nabla^2 f(x) \leq MI$
$$f(x) - p^* \geq \frac{1}{2M} \|\nabla f(x)\|_2^2$$



回顾：通用下降方法

$$\min f(x)$$



迭代求解最优性条件 $\nabla f(x^*) = 0$

- 从初始点 $x^0 \in \text{dom } f$ 出发，产生一组优化点列 $x^k, (k = 1, 2, \dots)$ 满足

$$x^{k+1} = x^k + t^k d^k, f(x^{k+1}) < f(x^k), x^k \in S = \{x: f(x) \leq f(x^0)\}$$

通用下降算法

1. 给定初始点 $x^0 \in \text{dom } f$ ，令 $k = 0$
2. 停止条件 $\|\nabla f(x^k)\| \leq \varepsilon$
3. 确定 x^k 处下降方向 d^k 使满足 $\exists \hat{t} > 0$,

$$f(x^k + t d^k) < f(x^k), \forall t \in (0, \hat{t})$$

4. 直线搜索：确定步长 $t^k > 0$ 使

$$f(x^k + t^k d^k) < f(x^k)$$

5. $x^{k+1} = x^k + t^k d^k, k = k + 1$ ，回2

- ✓ 搜索方向 d^k 为下降方向当且仅当 $\nabla f(x^k)^\top d^k < 0$;
- ✓ 搜索步长 $t^k \geq 0$ (标量);

➤ 精确直线搜索： $t = \operatorname{argmin}_{s \geq 0} f(x + s d)$

➤ 回溯直线搜索

4.1 $0 < \alpha < 0.5, 0 < \beta < 1, t = 1$

4.2 **While** $f(x + t d^k) > f(x) + \alpha t \nabla f(x)^\top d^k,$
 $t := \beta t$

End

梯度下降方法及收敛性-精确直线搜索

$$\min f(x)$$



迭代求解最优性条件 $\nabla f(x^*) = 0$

梯度下降精确直线搜索算法

1. 给定初始点 $x^0 \in \text{dom } f$, 令 $k = 0$

2. 停止条件 $\|\nabla f(x^k)\|_2 \leq \varepsilon$

3. $d^k = -\nabla f(x^k)$

4. 精确直线搜索:

$$t^k = \operatorname{argmin}_{s \geq 0} f(x^k + s d^k)$$

5. $x^{k+1} = x^k + t^k d^k$, $k = k + 1$, 回2

✓ 负梯度方向 $d^k = -\nabla f(x^k)$ 为“天然”下降方向

$$\nabla f(x^k) d^k = -\|\nabla f(x^k)\|^2 < 0$$

✓ 收敛性分析

假设: 存在 m, M 满足 $mI \leq \nabla^2 f(x) \leq MI$ ($\forall x \in S$)

➤ 目标值与最优值间偏差的上界

$$f(x) - p^* \leq \frac{1}{2m} \|\nabla f(x)\|^2$$

与下降方向无关

➤ 每次迭代目标改进值下界

$$f(x^k) - f(x^{k+1}) \geq \frac{1}{2M} \|\nabla f(x^k)\|^2$$

$$f(x^K) - p^* \leq \left(1 - \frac{m}{M}\right)^K (f(x^0) - p^*)$$

几何数列

➤ 算法收敛时, 迭代次数的上界

$$f(x^K) - p^* \leq \varepsilon \implies K \geq \frac{\log((f(x^0) - p^*)/\varepsilon)}{\log(1/c)}, \text{ 这里 } c = 1 - \frac{m}{M}$$



梯度下降方法及收敛性-回溯直线搜索

$$\min f(x)$$



迭代求解最优性条件 $\nabla f(x^*) = 0$

梯度下降回溯直线搜索算法

1. 给定初始点 $x^0 \in \text{dom } f$, 令 $k = 0$

2. 停止条件 $\|\nabla f(x^k)\| \leq \varepsilon$

3. $d^k = -\nabla f(x^k)$

4. 回溯直线搜索: $0 < \alpha < 0.5$, $0 < \beta < 1$, $t^k = 1$

While $f(x^k + t^k d^k) > f(x^k) + \alpha t^k \nabla f(x^k)^\top d^k$,

$$t^k := \beta t^k$$

End

5. $x^{k+1} = x^k + t^k d^k$, $k = k + 1$, 回2

✓ 收敛性分析

假设: 存在 m, M 满足 $mI \leq \nabla^2 f(x) \leq MI$ ($\forall x \in S$)

➤ 目标值与最优值间偏差的上界

$$f(x) - p^* \leq \frac{1}{2m} \|\nabla f(x)\|_2^2$$

➤ 每次迭代目标改进值下界

$$f(x^{k+1}) \leq f(x^k) - \min\{\alpha, \frac{\beta\alpha}{M}\} \|\nabla f(x^k)\|_2^2$$

➤ 算法收敛时, 迭代次数的上界

$$f(x^K) - p^* \leq \varepsilon \implies K \geq \frac{\log((f(x^0) - p^*)/\varepsilon)}{\log(1/c)}$$

$$\text{这里, } c = \left(1 - \min\left\{2m\alpha, \frac{2\beta\alpha m}{M}\right\}\right)$$



梯度下降方法及收敛性

$$\min f(x)$$



迭代求解最优性条件 $\nabla f(x^*) = 0$

梯度下降算法

1. 给定初始点 $x^0 \in \text{dom } f$, 令 $k = 0$

2. 停止条件 $\|\nabla f(x^k)\| \leq \varepsilon$

3. 下降方向 $d^k = -\nabla f(x^k)$

4. 直线搜索: 确定 $t^k > 0$ 使得

$$f(x^k + t^k d^k) < f(x^k)$$

5. $x^{k+1} = x^k + t^k d^k$, $k = k + 1$, 回2

收敛性分析

假设: 存在 m, M 满足 $mI \leq \nabla^2 f(x) \leq MI$ ($\forall x \in S$)

使 $f(x^K) - p^* \leq \varepsilon$ 成立的 K 只需要满足以下条件:

$$f(x^K) - p^* \leq \varepsilon \implies K \geq \frac{\log((f(x^0) - p^*)/\varepsilon)}{\log(1/c)}$$

✓ 采用精确直线搜索时 $c = 1 - \frac{m}{M}$

✓ 采用回溯直线搜索时 $c = \left(1 - \min\left\{2m\alpha, \frac{2\beta\alpha m}{M}\right\}\right)$



回顾——最速下降方法

□ 对 $f(x + v)$ 在 x 处一阶 Taylor 展开: $f(x + v) \approx f(x) + \boxed{\nabla f(x)^\top v}$ 方向导数

- 规范化的最速下降方向: $d_{nsd}^k = \arg \min_d \{ \nabla f(x^k)^\top d : \|d\| = 1 \}$
- 非规范化的最速下降方向: $d_{sd}^k = \|\nabla f(x^k)\|_* \times d_{nsd}^k$
- 性质: $\nabla f(x^k)^\top d_{sd}^k = -\|\nabla f(x^k)\|_*^2$

- 将 $\|\cdot\|$ 取为 Euclid 范数时, 最速下降方向就是负梯度方向;
- 负梯度方向是一种特殊的最速下降方向。
- ℓ_1 -范数下的规范化最速下降步径总能选为某个标准基向量 (某个负的标准基向量)
- ℓ_1 -范数下最速下降算法每步迭代, 选 $\nabla f(x^k)$ 绝对值最大的分量, 然后根据其符号减少或增加 x^k 的对应分量。
- 二次范数 $\|\cdot\|_p$ 下的最速下降方向为对原问题进行坐标变换 $\bar{x} = P^{1/2}x$ 后的梯度方向

回顾——最速下降方法

$$\min f(x)$$



迭代求解最优性条件 $\nabla f(x^*) = 0$

非规范化最速下降算法

1. 给定初始点 $x^0 \in \text{dom } f$, 令 $k = 0$
2. 判断: 如果 $\|\nabla f(x^k)\| \leq \varepsilon$, 停止
3. $d_{sd}^k = \|\nabla f(x^k)\|_* \times \arg \min \{\nabla f(x^k)^\top d : \|d\| = 1\}$
4. 直线搜索: 确定 $t^k > 0$ 满足
$$f(x^k + t^k d_{sd}^k) < f(x^k)$$
5. $x^{k+1} = x^k + t^k d_{sd}^k, k = k + 1$, 回2

- 若采用精确直线搜索方法

$$t = \operatorname{argmin}_{s \geq 0} f(x + sd)$$

下降方向的比例因子不起作用, 从而规范化和非规范化最速下降方向所起效果相同。

规范化最速下降算法

1. 给定初始点 $x^0 \in \text{dom } f$, 令 $k = 0$
2. 判断: 如果 $\|\nabla f(x^k)\| \leq \varepsilon$, 停止
3. $d_{nsd}^k = \arg \min \{\nabla f(x^k)^\top d \mid s.t. \|d\| = 1\}$
4. 直线搜索: 确定 $t^k > 0$ 满足
$$f(x^k + t^k d_{nsd}^k) < f(x^k)$$
5. $x^{k+1} = x^k + t^k d_{nsd}^k, k = k + 1$, 回2



回顾

- ✓假设1: 存在 m, M 满足 $mI \leq \nabla^2 f(x) \leq MI$ ($\forall x \in S$)
- ✓假设2: 存在常数 $\gamma, \tilde{\gamma} \in (0, 1]$, 使得 $\|x\| \geq \gamma\|x\|_2, \|x\|_* \geq \tilde{\gamma}\|x\|_2$
- 算法收敛时, 迭代次数的上界

$$f(x^K) - p^* \leq \varepsilon \implies K \geq \frac{\log((f(x^0) - p^*)/\varepsilon)}{\log(1/c)}$$

非规范化最速下降算法-回溯直线搜索

1. 给定初始点 $x^0 \in \text{dom } f$, 令 $k = 0$
2. 判断: 如果 $\|\nabla f(x^k)\| \leq \varepsilon$, 停止
3. $d_{sd}^k = \|\nabla f(x^k)\|_* \times \arg \min\{\nabla f(x^k)^\top d : \|d\| = 1\}$
4. 回溯直线搜索: $0 < \alpha < 0.5, 0 < \beta < 1, t^k = 1$
 $\text{While } f(x^k + t^k d_{sd}^k) > f(x^k) + \alpha t^k \nabla f(x^k)^\top d_{sd}^k,$
 $t^k := \beta t^k$
End
5. $x^{k+1} = x^k + t^k d^k, k = k + 1$, 回2

$$c = 1 - 2m\alpha\tilde{\gamma}^2 \min\left\{1, \frac{\beta\gamma^2}{M}\right\}$$

梯度下降回溯直线搜索算法

1. 给定初始点 $x^0 \in \text{dom } f$, 令 $k = 0$
2. 停止条件 $\|\nabla f(x^k)\| \leq \varepsilon$
3. $d^k = -\nabla f(x^k)$
4. 回溯直线搜索: $0 < \alpha < 0.5, 0 < \beta < 1, t^k = 1$
 $\text{While } f(x^k + t^k d^k) > f(x^k) + \alpha t^k \nabla f(x^k)^\top d^k,$
 $t^k := \beta t^k$
End
5. $x^{k+1} = x^k + t^k d^k, k = k + 1$, 回2

$$c = \left(1 - \min\left\{2m\alpha, \frac{2\beta\alpha m}{M}\right\}\right)$$

梯度下降精确直线搜索算法

1. 给定初始点 $x^0 \in \text{dom } f$, 令 $k = 0$
2. 停止条件 $\|\nabla f(x^k)\| \leq \varepsilon$
3. $d^k = -\nabla f(x^k)$
4. 精确直线搜索:
 $t^k = \arg \min_{s \geq 0} f(x^k + s d^k)$
5. $x^{k+1} = x^k + t^k d^k, k = k + 1$, 回2

$$c = 1 - \frac{m}{M}$$

$$\min f(x)$$



迭代求解最优性条件 $\nabla f(x^*) = 0$

回顾——牛顿方法

□ 牛顿方向: $d_{nt}^k = -\nabla^2 f(x^k)^{-1} \nabla f(x^k)$, 这里, $\nabla^2 f(x^k) \in S_{++}^n$, $\nabla f(x^k) \neq 0$

✓ 二阶近似最优解:

$$d_{nt}^k = \underset{v}{\operatorname{argmin}} \hat{f}(x^k + v) = f(x^k) + \nabla f(x^k)^\top v + \frac{1}{2} v^\top \nabla^2 f(x^k) v$$

✓ 线性化最优性条件的解:




$$\nabla f(x^k + v) \approx \nabla f(x^k) + \nabla^2 f(x^k) v = 0 \Rightarrow v = d_{nt}^k$$

✓ Hessian范数下的最速下降方向:

$$\begin{aligned} d_{nt}^k &= d_{sd}^k = \|\nabla f(x^k)\|_* \times d_{nsd}^k \\ &= \|\nabla f(x^k)\|_* \times \arg \min_d \{\nabla f(x^k)^\top d : \|d\|_{\nabla^2 f(x^k)} = 1\} \end{aligned}$$

□ Newton减少量: $\lambda(x^k) = \left(\nabla f(x^k)^\top \nabla^2 f(x^k)^{-1} \nabla f(x^k) \right)^{\frac{1}{2}}$

✓ 性质1: $\nabla f(x^k)^\top d_{nt}^k = -\lambda(x^k)^2$ ✓ 性质2: $\lambda(x^k)^2 = (d_{nt}^k)^\top \nabla^2 f(x^k) d_{nt}^k$



总结：牛顿下降回溯直线搜索算法

假设： $\forall x, y \in S$,

✓ 存在 m, M 满足 $mI \leq \nabla^2 f(x) \leq MI$

✓ 存在 L 满足 $\|\nabla^2 f(y) - \nabla^2 f(x)\|_F \leq L\|y - x\|_2$

牛顿下降回溯直线搜索算法

1. 给定初始点 $x^0 \in \text{dom } f$, 误差阈值 $\varepsilon > 0$, 令 $k = 0$

2. 计算Newton步径和增量

$$d_{nt}^k = -\nabla^2 f(x^k)^{-1} \nabla f(x^k); \quad \lambda(x^k)^2 = (d_{nt}^k)^\top \nabla^2 f(x^k) d_{nt}^k$$

3. 停止准则：若 $\frac{1}{2} \lambda(x^k)^2 \leq \varepsilon$, 退出

4. 回溯直线搜索： $0 < \alpha < 0.5, 0 < \beta < 1, t^k = 1$

$$\begin{aligned} &\text{While } f(x^k + t^k d_{nt}^k) > f(x^k) - \alpha t^k \lambda(x^k)^2 \\ &\quad t^k := \beta t^k \\ &\text{End} \end{aligned}$$

5. $x^{k+1} = x^k + t^k d_{nt}^k, k = k + 1$, 回2

➤ 目标值与最优值间偏差的上界: $f(x) - p^* \leq \frac{1}{2m} \|\nabla f(x^k)\|_2^2$

➤ 每次迭代目标改进值下界

✓ 阻尼牛顿阶段 ($0 < \eta \leq \frac{m^2}{L}, \|\nabla f(x^k)\|_2 \geq \eta$)

$$f(x^{k+1}) - f(x^k) \leq -\gamma, \quad \text{迭代次数} \leq \frac{f(x^0) - p^*}{\gamma}, \quad \gamma = \alpha \beta \eta^2 \frac{m}{M^2}$$

✓ 二次收敛阶段 ($\|\nabla f(x^k)\|_2 \leq \eta \leq 3(1 - 2\alpha) \frac{m^2}{L}$)

$$\text{回溯搜索 } t^k = 1, \quad \frac{L}{2m^2} \|\nabla f(x^{k+1})\|_2 \leq \left(\frac{L}{2m^2} \|\nabla f(x^k)\|_2 \right)^2$$

$$\text{迭代次数} \leq \log_2(\log_2(\epsilon_0/\epsilon)), \quad \epsilon_0 = \frac{2m^3}{L^2}$$

➤ 算法收敛时，迭代次数的上界

$$f(x^K) - p^* \leq \varepsilon \implies$$

$$K \geq 6 + \frac{M^2 L^2 / m^5}{\alpha \beta \min\{1, 9(1 - 2\alpha)^2\}} (f(x^0) - p^*)$$

等式约束凸优化问题



等式约束凸优化问题

$$\begin{array}{ll} \min & f(x) \\ \text{s. t.} & Ax = b \end{array}$$

KKT方程

$$Ax^* = b$$

$$\nabla f(x^*) + A^T v^* = 0$$

很少可以用解析的方法求解最优性条件.....

- 函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 为二次连续可微凸函数
- $A \in \mathbb{R}^{p \times n}$, $\text{rank}(A) = p < n$
- $p^* = \inf \{f(x): Ax = b\} = f(x^*)$

✓ 消除方法: $\min_{z \in \mathbb{R}^{n-p}} \tilde{f}(z) = f(Fz + \hat{x})$

✓ 对偶方法: $\min_x f(x) + (v^*)^T (Ax - b)$

破坏原问题结构

- 直接求解等式约束!

✓ 利用问题结构

✓ 可视为直接求解最优性条件(KKT方程)



牛顿方向——基于二阶近似的定义

$$\min f(x)$$

$$\text{s.t. } Ax = b$$

等式约束问题在可行点 x 处的 $\text{牛顿方向 } d_x$?

- 等式约束的二次极小问题：目标函数 $f(x)$ 在 x 附近的二阶Taylor近似模型

$$\min_v \hat{f}(x+v) = f(x) + \nabla f(x)^\top v + \frac{1}{2} v^\top \nabla^2 f(x) v$$

$$\text{s.t. } A(x+v) = b$$

$$Av = 0$$

- 假设有关的KKT矩阵非奇异，则定义在 x 处的牛顿方向 d_x 为以上二次问题的解，即

$$\begin{bmatrix} \nabla^2 f(x) & A^\top \\ A & 0 \end{bmatrix} \begin{bmatrix} d_x \\ w \end{bmatrix} = \begin{bmatrix} -\nabla f(x) \\ 0 \end{bmatrix}$$

$$\min_x f(x) = \frac{1}{2} x^\top P x + q^\top x + r$$

$$\text{s.t. } Ax = b$$

$$\Leftrightarrow \begin{bmatrix} P & A^\top \\ A & 0 \end{bmatrix} \begin{bmatrix} x^* \\ v^* \end{bmatrix} = \begin{bmatrix} -q \\ b \end{bmatrix}$$


KKT矩阵

这里， w 是该二次问题的最优对偶变量。



牛顿方向——线性化最优性的解

- 牛顿方向 d_x 及相关变量 w 解释为最优性条件的线性近似方程组的解



牛顿减少量

$$\begin{array}{ll} \min & f(x) \\ \text{s.t.} & Ax = b \end{array} \quad \begin{array}{l} \bullet \quad f: \mathbb{R}^n \rightarrow \mathbb{R} \text{ 二次连续可微凸函数} \\ \bullet \quad A \in \mathbb{R}^{p \times n}, \text{ rank}(A) = p < n \end{array}$$

- 等式约束优化问题牛顿减少量

$$\lambda(x) = \left(d_x^\top \nabla^2 f(x) d_x \right)^{\frac{1}{2}}$$

与无约束优化问题相同

基于二次模型对 $f(x) - p^*$ 做出的估计

函数 f 在 x 处的二次展开: $\hat{f}(x+v) = f(x) + \nabla f(x)^\top v + \frac{1}{2} v^\top \nabla^2 f(x) v$

$$\begin{aligned} f(x) - p^* &\approx f(x) - \inf\{\hat{f}(x+v): A(x+v) = b\} \\ &= \frac{1}{2} (\lambda(x))^2 \end{aligned}$$

- 函数 f 沿着方向 d_x 的方向导数为:

$$\left. \frac{\partial f(x+td_x)}{\partial t} \right|_{t=0} = \nabla f(x)^\top d_x = -\lambda(x)^2$$

与无约束优化问题相同



等式约束的牛顿方法

- 初始点必须可行: $Ax^0 = b$
- 牛顿方向必须是可行方向: $Ad_x^k = 0$

牛顿下降回溯直线搜索算法

1. 初始可行点 $x^0 \in \text{dom } f, Ax^0 = b$, 误差阈值 $\varepsilon > 0, k = 0$
2. 确定牛顿方向和牛顿减少量

$$\begin{bmatrix} \nabla^2 f(x) & A^\top \\ A & 0 \end{bmatrix} \begin{bmatrix} d_x^k \\ w \end{bmatrix} = \begin{bmatrix} -\nabla f(x) \\ 0 \end{bmatrix}; \lambda(x^k)^2 = (d_x^k)^\top \nabla^2 f(x^k) d_x^k$$

3. 停止准则: 若 $\frac{1}{2}\lambda(x^k)^2 \leq \varepsilon$, 退出
4. 回溯直线搜索: $0 < \alpha < 0.5, 0 < \beta < 1, t^k = 1$

$$\begin{array}{l} \text{While } f(x^k + t^k d_x^k) > \boxed{f(x^k) - \alpha t^k \lambda(x^k)^2} \\ \quad t^k := \beta t^k \\ \text{End} \end{array}$$

$$f(x^k) + \alpha t^k \nabla f(x^k)^\top d_x^k$$

5. $x^{k+1} = x^k + t^k d_x^k, k = k + 1$, 回2

$$\begin{array}{ll} \min & f(x) \\ \text{s.t.} & Ax = b \end{array}$$

注意:

- ✓ 所有迭代点都是可行的, 并满足 $f(x^{k+1}) < f(x^k)$;
- ✓ 牛顿方法需要每个 x 处的 KKT 矩阵可逆。

牛顿方法和消除法

$$\min_{z \in \mathbb{R}^{n-p}} \tilde{f}(z) = f(Fz + \hat{x}) \Leftrightarrow \min \{f(x) | s.t. Ax = b\}$$

总结：在已知 $Ax = b$ 的一个解的情况下，将等式约束变成无约束优化问题，并采用牛顿方法求解，等价于解下述线性方程组（其中 x 给定）确定搜索方向 d_x ，然后对原函数直线搜索

$$\begin{bmatrix} \nabla^2 f(x) & A^\top \\ A & 0 \end{bmatrix} \begin{bmatrix} d_x \\ v \end{bmatrix} = \begin{bmatrix} -\nabla f(x) \\ 0 \end{bmatrix}$$

停止准则同样可写成：
$$\frac{1}{2} d_z^\top \nabla^2 \tilde{f}(z) d_z = \frac{1}{2} d_x^\top \nabla^2 f(x) d_x \leq \varepsilon$$

总结

$$\begin{array}{ll} \min & f(x) \\ \text{s.t.} & Ax = b \end{array} \quad \longleftrightarrow \quad \text{KKT方程} \quad \begin{cases} Ax^* = b \\ \nabla f(x^*) + A^T v^* = 0 \end{cases}$$

梯度一阶近似

$$\nabla f(x + d) \approx \nabla f(x) + \nabla^2 f(x)d$$

$$A(x + d) = b$$

$$\nabla f(x) + \nabla^2 f(x)d + A^T w = 0$$

✓ 可行初始点的牛顿方向

$$\begin{bmatrix} \nabla^2 f(x) & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} d_x \\ w \end{bmatrix} = \begin{bmatrix} -\nabla f(x) \\ 0 \end{bmatrix}$$

✓ 不可行初始点的牛顿方向

$$\begin{bmatrix} \nabla^2 f(x) & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} d \\ w \end{bmatrix} = - \begin{bmatrix} \nabla f(x) \\ Ax - b \end{bmatrix}$$

✓ 原对偶残差

$$r(y) = \begin{bmatrix} r_{dual}(x, v) \\ r_{pri}(x, v) \end{bmatrix} = \begin{bmatrix} \nabla f(x) + A^T v \\ Ax - b \end{bmatrix}$$

$$r(y + z) \approx r(y) + Dr(y)z = 0$$

$$\Rightarrow \begin{bmatrix} \nabla^2 f(x) & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} d_x \\ d_v \end{bmatrix} = - \begin{bmatrix} \nabla f(x) + A^T v \\ Ax - b \end{bmatrix}$$

$$v^+ = v + d_v$$

$$\begin{bmatrix} \nabla^2 f(x) & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} d_x \\ v^+ \end{bmatrix} = - \begin{bmatrix} \nabla f(x) \\ Ax - b \end{bmatrix}$$

$$\begin{aligned} d_y &= - \begin{bmatrix} \nabla^2 f(x) & A^T \\ A & 0 \end{bmatrix}^{-1} r(y) \\ &= - Dr(y)^{-1} r(y) \end{aligned}$$



不可行初始点牛顿方法

牛顿下降回溯直线搜索算法（不可行初始点）

1. 初始点 $x^0 \in \text{dom } f, v^0$, 误差阈值 $\epsilon > 0, k = 0$

2. 停止准则: $Ax^k = b$ 且 $\|r(x^k, v^k)\|_2 \leq \epsilon$, 退出, 否则

3. 确定原对偶牛顿方向:
$$\begin{bmatrix} \nabla^2 f(x^k) & A^\top \\ A & 0 \end{bmatrix} \begin{bmatrix} d_x^k \\ d_v^k \end{bmatrix} = - \begin{bmatrix} \nabla f(x^k) + A^\top v^k \\ Ax^k - b \end{bmatrix}$$

4. 对原对偶残差 $\|r\|_2$ 进行回溯, 确定步长 t^k

$$0 < \alpha < 0.5, 0 < \beta < 1, t^k = 1,$$

While $\|r(x^k + td_x^k, v^k + td_v^k)\|_2 > (1 - \alpha t)\|r(x^k, v^k)\|_2$
 $t^k := \beta t^k$

End

5. $x^{k+1} = x^k + t^k d_x^k, v^{k+1} = v^k + t^k d_v^k, k = k + 1$, 回2

$$\begin{aligned} \min & f(x) \\ \text{s.t.} & Ax = b \end{aligned}$$

- 停止条件不仅要求原问题可行解被满足, 还要求原对偶残差的范数足够小
- 搜索方向包括额外的依赖原问题残差的修正值
- 直线搜索目标是残差的范数, 而不是函数 $f(x)$, 但是一定在有限次迭代后结束
- 一旦可行解满足, 可切换到可行初始点的牛顿方法, 即将直线搜索目标换成 f , 终止条件换成 $\frac{\lambda(x)^2}{2} \leq \epsilon$ 。
- 利用不可行初始点牛顿方法简化初始化

等式限制凸优化问题牛顿算法对比

$$\begin{array}{ll}\min & f(x) \\ \text{s.t.} & Ax = b\end{array}$$

牛顿下降回溯直线搜索算法（不可行初始点）

1. 初始点 $x^0 \in \text{dom } f, v$, 误差阈值 $\epsilon > 0, k = 0$
2. 停止准则: $Ax^k = b$ 且 $\|r(x^k, v^k)\|_2 \leq \epsilon$, 退出, 否则
3. 确定原对偶牛顿方向
$$\begin{bmatrix} \nabla^2 f(x^k) & A^\top \\ A & 0 \end{bmatrix} \begin{bmatrix} d_x^k \\ d_v^k \end{bmatrix} = - \begin{bmatrix} \nabla f(x^k) + A^\top v \\ Ax^k - b \end{bmatrix}$$
4. 对原对偶残差 $\|r\|_2$ 进行回溯, 确定步长 t^k :
 $0 < \alpha < 0.5, 0 < \beta < 1, t^k = 1$
While $\|r(x^k + td_x^k, v^k + td_v^k)\|_2 > (1 - \alpha t)\|r(x^k, v^k)\|_2$
 $t^k := \beta t^k$
End
5. $x^{k+1} = x^k + t^k d_x^k, v^{k+1} = v^k + t^k d_v^k, k = k + 1$, 回3

牛顿下降回溯直线搜索算法（已知可行初始点）

1. 初始点 $x^0 \in \text{dom } f, Ax^0 = b$, 误差阈值 $\epsilon > 0, k = 0$
2. 确定牛顿方向和牛顿减少量
$$\begin{bmatrix} \nabla^2 f(x) & A^\top \\ A & 0 \end{bmatrix} \begin{bmatrix} d_x^k \\ w \end{bmatrix} = \begin{bmatrix} -\nabla f(x) \\ 0 \end{bmatrix}; \lambda(x^k)^2 = (d_x^k)^\top \nabla^2 f(x^k) d_x^k$$
3. 停止准则: 若 $\frac{1}{2}\lambda(x^k)^2 \leq \epsilon$, 退出
4. 回溯直线搜索: $0 < \alpha < 0.5, 0 < \beta < 1, t^k = 1$
While $f(x^k + t^k d_x^k) > f(x^k) - \alpha t^k \lambda(x^k)^2$
 $t^k := \beta t^k$
End
5. $x^{k+1} = x^k + t^k d_x^k, k = k + 1$, 回2

总结：等式限制凸优化问题求解

$$\begin{array}{ll} \min & f(x) \\ \text{s. t.} & Ax = b \end{array}$$

KKT方程

$$\begin{cases} Ax^* = b \\ \nabla f(x^*) + A^T v^* = 0 \end{cases}$$

✓ 对偶方法: $\min_x f(x) + (v^*)^T (Ax - b)$

✓ 消除方法: $\min_{z \in \mathbb{R}^{n-p}} \tilde{f}(z) = f(Fz + \hat{x})$

牛顿方向:

$$d_z = - \left(\nabla^2 \tilde{f}(z) \right)^{-1} \nabla \tilde{f}(z)$$

$$= - (F^T \nabla^2 f(x) F)^{-1} F^T \nabla f(x)$$

$$d_x = F d_z, \quad \tilde{\lambda}(x) = \lambda(x)$$

梯度一阶近似

$$\nabla f(x + d) \approx \nabla f(x) + \nabla^2 f(x) d$$

$$\begin{cases} A(x + d) = b \\ \nabla f(x) + \nabla^2 f(x) d + A^T w = 0 \end{cases}$$

✓ 可行初始点牛顿方向:

$$\begin{bmatrix} \nabla^2 f(x) & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} d_x \\ w \end{bmatrix} = \begin{bmatrix} -\nabla f(x) \\ 0 \end{bmatrix}$$

✓ 不可行初始点的牛顿方向

$$\begin{bmatrix} \nabla^2 f(x) & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} d \\ w \end{bmatrix} = - \begin{bmatrix} \nabla f(x) \\ Ax - b \end{bmatrix}$$



回顾——等式不等式约束优化问题

$$\min f_0(x)$$

$$\text{s. t. } f_i(x) \leq 0, i = 1, 2, \dots, m$$

$$Ax = b$$

- 定义域 $D = \bigcap_{i=0}^m \text{dom } f_i$;
- $A \in \mathbb{R}^{p \times n}$, $\text{rank}(A) = p < n$;
- 函数 $f_i: \mathbb{R}^n \rightarrow \mathbb{R}$ ($i = 0, \dots, m$) 为二次连续可微凸函数
- $p^* = \inf \{f_0(x): Ax = b, f_i(x) \leq 0, i = 1, \dots, m\} = f(x^*)$

$$\text{KKT方程} \begin{cases} Ax = b, f_i(x) \leq 0 \quad (i = 1, 2, \dots, m) \\ \lambda_i \geq 0, \lambda_i f_i(x) = 0 \quad (i = 1, 2, \dots, m) \\ \nabla f_0(x) + \sum_{i=1}^m \lambda_i \nabla f_i(x) + A^T v = 0 \end{cases}$$

目标函数一般不可微,
不能使用牛顿方法

$$\min f_0(x)$$

$$\text{s. t. } f_i(x) \leq 0, i = 1, 2, \dots, m$$

$$Ax = b$$

$$I_-(u) = \begin{cases} 0 & u \leq 0 \\ \infty & u > 0 \end{cases}$$

$$\begin{aligned} \min & f_0(x) + \sum_{i=1}^m I_-(f_i(x)) \\ \text{s. t. } & Ax = b \end{aligned}$$



课前回顾——障碍方法

近似等式约束优化问题

p^*


$$\min f_0(x)$$

$$\text{s. t. } f_i(x) \leq 0, i = 1, 2, \dots, m$$

$$Ax = b$$

示性函数:

$$I_-(u) = \begin{cases} 0 & u \leq 0 \\ \infty & u > 0 \end{cases}$$



$$\begin{aligned} \min & f_0(x) + \sum_{i=1}^m I_-(f_i(x)) \\ \text{s. t. } & Ax = b \end{aligned}$$

$$\text{障碍函数: } \phi(x) = -\sum_{i=1}^m \log(-f_i(x))$$

$$\text{近似示性函数: } \hat{I}_-(u) = -\frac{1}{t} \log(-u)$$

$$\min tf_0(x) + \phi(x)$$

$$\text{s. t. } Ax = b$$

□ 中心路径点 $\{x^*(t): t > 0\}$ 满足:

✓ 严格可行性:

$$Ax^*(t) = b, f_i(x^*(t)) < 0 \quad (i = 1, 2, \dots, m);$$

✓ 存在 $v \in \mathbb{R}^p$,

$$0 = t \nabla f_0(x^*(t)) + \sum_{i=1}^m \frac{1}{-f_i(x^*(t))} \nabla f_i(x^*(t)) + A^T v$$



中心路径的对偶点

中心路径中的中心点 $x^*(t)$ 满足:

$Ax^*(t) = b$, $f_i(x^*(t)) < 0$ 且存在 $\hat{v} \in \mathbb{R}^p$, 使得

$$t \nabla f_0(x^*(t)) + \sum_{i=1}^m \frac{1}{-f_i(x^*(t))} \nabla f_i(x^*(t)) + A^\top \hat{v} = 0$$

$$\lambda_i^*(t) = \frac{1}{-tf_i(x^*(t))} > 0 \quad (i = 1, 2, \dots, m) \quad \text{中心点和相应的对偶点满足原对偶可行性}$$
$$v^*(t) = \frac{\hat{v}}{t}$$
$$\nabla f_0(x^*(t)) + \sum_{i=1}^m \lambda_i^*(t) \nabla f_i(x^*(t)) + A^\top v^*(t) = 0$$

□ $x^*(t)$ 使 $\lambda = \lambda_i^*(t), v = v^*(t)$ 时的 Lagrangian 函数 $L(x, \lambda, v)$ 达到极小, 所以 $\lambda_i^*(t), v^*(t)$ 是对偶可行解, 即

$$x^*(t) = \operatorname{argmin}_x L(x, \lambda_i^*(t), v^*(t)) = f_0(x) + \sum_{i=1}^m \lambda_i^*(t) f_i(x) + v^*(t)^\top (Ax - b)$$

□ $x^*(t)$ 和对偶可行解 $\lambda_i^*(t), v^*(t)$ 之间的对偶间隙为 $\frac{m}{t}$, 因为:

$$p^* \geq g(\lambda^*(t), v^*(t))$$

对偶函数 $g(\lambda_i^*(t), v^*(t))$ 是有限的

$$= L(x^*(t), \lambda_i^*(t), v^*(t))$$

$$= f_0(x^*(t)) + \sum_{i=1}^m \lambda_i^*(t) f_i(x^*(t)) + v^*(t)^\top (Ax^*(t) - b)$$

$$= f_0(x^*(t)) - \frac{m}{t}$$

$$f_0(x^*(t)) \rightarrow p^* \text{ 当 } t \rightarrow \infty$$

- 每个中心点 $x^*(t)$ 产生对偶可行解 $\lambda_i^*(t), v^*(t)$
- $f_0(x^*(t)) - p^* \leq \frac{m}{t}$, 即每个中心点 $x^*(t)$ 是和原优化问题最优值间偏差不大于 $\frac{m}{t}$ 的次优解

课前回顾——障碍方法

近似等式约束优化问题

p^*

$$\begin{aligned} \min & f_0(x) \\ \text{s.t. } & f_i(x) \leq 0, \quad i \\ & = 1, 2, \dots, m \end{aligned}$$

$$\text{障碍函数: } \phi(x) = -\sum_{i=1}^m \log(-f_i(x))$$

$$\text{近似示性函数: } \hat{I}_-(u) = -\frac{1}{t} \log(-u)$$


$$\min \quad tf_0(x) + \phi(x)$$

$$\text{s.t. } Ax = b$$

$$Ax = b$$

示性函数:

$$I_-(u) = \begin{cases} 0 & u \leq 0 \\ \infty & u > 0 \end{cases}$$



$$\begin{aligned} \min & f_0(x) + \sum_{i=1}^m I_-(f_i(x)) \\ \text{s.t. } & Ax = b \end{aligned}$$

$$f_0(x^*(t)) - p^* \leq \frac{m}{t}$$

等式不等式凸优化问题的障碍方法

给定严格可行初始点 x , $t = t^0 > 0, \mu > 1, \epsilon > 0$, 令 $k = 0$

1. 中心点步骤: 从 x 开始, 求解

$$x^*(t) = \operatorname{argmin} tf_0(x) + \phi(x) \text{ s.t. } Ax = b$$

2. 改进: $x := x^*(t)$

3. 停止准则: 若 $\frac{m}{t} \leq \epsilon$, 退出, 否则

4. 增加 t : $t = \mu t$, 回到步骤1

障碍函数的基本步骤

近似等式约束优化问题

p^*

$$\min f_0(x)$$

$$\text{s.t. } f_i(x) \leq 0, i$$

$$= 1, 2, \dots, m$$

$$Ax = b$$

$$\phi(x) = -\sum_{i=1}^m \log(-f_i(x))$$

$$f(x^*(t)) - p^* \leq \frac{m}{t}$$

$$\min tf_0(x) + \phi(x)$$

$$\text{s.t. } Ax = b$$

等式不等式凸优化问题的障碍方法

- 初始化步骤:

确定 x 满足: $f_i(x) < 0$ ($i = 1, 2, \dots, m$) 且 $Ax = b$

设定 $t = t^0 > 0$, $\mu > 1$, $\epsilon > 0$

% 阶段1: 为障碍方法计算严格可行初始解

- 中心点步骤:

从 x 开始, 对当前的 t 求解近似等式约束优化问题

$$x^*(t) = \operatorname{argmin} tf_0(x) + \phi(x) \text{ s.t. } Ax = b$$

- 停止或迭代:

若 $\frac{m}{t} \leq \epsilon$, 退出, 否则令 $x = x^*(t)$, $t = \mu t$, 继续迭代



不可行初始点牛顿方法求解阶段1问题

$$\begin{aligned} \min & f_0(x) \\ \text{s.t.} & f_i(x) \leq 0, i \\ & = 1, 2, \dots, m \\ & Ax = b \end{aligned}$$

可行性问题：寻找满足不等式和等式方程： $f_i(x) \leq 0, i = 1, 2, \dots, m; Ax = b$ 的严格可行解或确定解不存在

- 情况1：已知 $x^0 \in \text{dom}f_0 \cap \dots \cap \text{dom}f_m$ 满足 $Ax^0 = b$

$$\begin{aligned} \min_{s, x} & s \\ \text{s.t.} & f_i(x) \leq s (i = 1, 2, \dots, m) \\ & Ax = b \end{aligned}$$

- 情况2：已知 $x^0 \in \text{dom}f_0 \cap \dots \cap \text{dom}f_m$ 不满足 $Ax^0 =$

$$\begin{aligned} b \quad \min_{s, x} & f_0(x) \\ \text{s.t.} & f_i(x) \leq s (i = 1, 2, \dots, m) \\ & Ax = b, \quad s = 0 \end{aligned} \quad \rightarrow \quad \begin{aligned} \min_{s, x} & t^0 f_0(x) - \sum_{i=1}^m \log(s - f_i(x)) \\ \text{s.t.} & Ax = b, \quad s = 0 \end{aligned}$$

- 情况3：不能在函数公共定义域 $D = \text{dom}f_0 \cap \dots \cap \text{dom}f_m$ 中确定一点

$$\begin{aligned} \min_{s, x, z_0, \dots, z_m} & f_0(x + z_0) \\ \text{s.t.} & f_i(x + z_i) \leq s (i = 1, 2, \dots, m) \\ & Ax = b, s = 0, z_0 = 0, \dots, z_m = 0 \end{aligned} \quad \rightarrow \quad \begin{aligned} \min_{s, x} & t^0 f_0(x + z_0) - \sum_{i=1}^m \log(s - f_i(x + z_i)) \\ \text{s.t.} & Ax = b, s = 0, z_0 = 0, \dots, z_m = 0 \end{aligned}$$



障碍函数法求解不等式约束问题

等式不等式凸优化问题的障碍方法

- 初始化步骤:

确定 x 满足 $f_i(x) < 0$ ($i = 1, 2, \dots, m$), $Ax = b$.

设定 $t = t^0 > 0$, $\mu > 1$, $\epsilon > 0$

- 中心点步骤:

从 x 开始, 对当前的 t 求解近似等式约束优化问题

$$x^*(t) = \operatorname{argmin} t f_0(x) + \phi(x) \text{ s.t. } Ax = b$$

- 停止或迭代:

若 $\frac{m}{t} \leq \epsilon$, 退出, 否则令 $x = x^*(t)$, $t = \mu t$, 继续迭代

阶段1: 为障碍方法计算严格可行初始解

$$\begin{cases} t \nabla f_0(x(t)) + \sum_{i=1}^m \frac{1}{-f_i(x)} \nabla f_i(x(t)) + A^T \hat{v} = 0 \\ Ax(t) = b \end{cases} \quad \text{KKT 条件}$$



$$\lambda_i = -\frac{1}{t f_i(x(t))}, \quad v = \frac{\hat{v}}{t}$$

修改的KKT 条件

$$\begin{cases} \nabla f_0(x(t)) + \sum_{i=1}^m \lambda_i \nabla f_i(x(t)) + A^T v = 0 \\ -\lambda_i f_i(x(t)) = \frac{1}{t} \quad (i = 1, 2, \dots, m) \\ Ax(t) = b \end{cases}$$



回顾——中心路径基于KKT条件的解释

- 中心路径条件是KKT最优性条件的连续变形

$$\begin{aligned} \min & f_0(x) \\ \text{s.t.} & f_i(x) \leq 0, i \\ & = 1, 2, \dots, m \end{aligned}$$

$$Ax = b$$

$$\min tf_0(x) + \phi(x)$$

$$\text{s.t. } Ax = b$$

→ KKT方程

$$Ax^* = b, f_i(x^*) \leq 0 \quad (i = 1, 2, \dots, m)$$

$$\lambda_i^* \geq 0, \lambda_i^* f_i(x^*) = 0 \quad (i = 1, 2, \dots, m)$$

$$\nabla f_0(x^*) + \sum_{i=1}^m \lambda_i^* \nabla f_i(x^*) + A^T v^* = 0$$

→ 中心路径点 $x^*(t)$ 满足

$$Ax^*(t) = b, f_i(x^*(t)) < 0 \quad (i = 1, 2, \dots, m)$$

$$t \nabla f_0(x^*(t)) + \sum_{i=1}^m \frac{1}{-f_i(x^*(t))} \nabla f_i(x^*(t)) + A^T v = 0$$

- 点 x 是中心路径上的点的充要条件为存在 λ, v 满足修改的KKT方程

$$Ax = b, f_i(x) \leq 0 \quad (i = 1, 2, \dots, m)$$

$$\lambda \geq 0, -\lambda_i f_i(x) = \frac{1}{t} \quad (i = 1, 2, \dots, m)$$

$$\nabla f_0(x) + \sum_{i=1}^m \lambda_i \nabla f_i(x) + A^T v = 0$$



原对偶搜索方向

修改的KKT 条件

$$\begin{aligned} \nabla f_0(x) + \sum_{i=1}^m \lambda_i \nabla f_i(x) + A^\top v &= 0 \\ -\lambda_i f_i(x) &= \frac{1}{t} \quad (i = 1, 2, \dots, m) \\ Ax &= b \end{aligned}$$

□ 固定 t ，从满足 $f(x) < 0, \lambda > 0$ 的点 $y = (x, \lambda, v)$ 开始求解非线性方程

$r_t(x, \lambda, v) = 0$ ，从而，原对偶搜索方向 $\Delta y_{pd} = (\Delta x_{pd}, \Delta \lambda_{pd}, \Delta v_{pd})$ 为以下方程组的解

$$\begin{bmatrix} \nabla f_0(x) + \sum_{i=1}^m \lambda_i \nabla f_i(x) & Df(x)^\top & A^\top \\ -diag(\lambda) Df(x) & -diag(f(x)) & 0 \\ A & 0 & 0 \end{bmatrix} \begin{bmatrix} d_x \\ d_\lambda \\ d_v \end{bmatrix} = -r_t(x, \lambda, v) = -\begin{bmatrix} r_{dual} \\ r_{cent} \\ r_{pri} \end{bmatrix} = \begin{bmatrix} \nabla f_0(x) + Df(x)^\top \lambda + A^\top v \\ -diag(\lambda) f(x) - \frac{1}{t} \mathbf{1} \\ Ax - b \end{bmatrix}$$

□ 第 k 次迭代时 $y^k = (x^k, \lambda^k, v^k)$ ，在其收敛到极限值以前不一定是对偶可行的；

□ 对任何满足 $f_i(x) < 0$ ($i = 1, 2, \dots, m$)和 $\lambda \geq 0$ 的 x 定义代理对偶间隙： $\eta(x, \lambda) = -f(x)^\top \lambda$

✓ 如果 x 是原可行的， λ, v 是对偶可行的，即 $r_{pri} = 0$ 和 $r_{dual} = 0$ ，则代理对偶间隙为对偶间隙，即

$$\eta(x, \lambda) = -f(x)^\top \lambda = \frac{m}{t} \quad \rightarrow \quad t = \frac{m}{\eta(x, \lambda)}$$

原对偶内点法

原对偶内点方法

- 初始化步骤：确定 x 满足 $f_i(x) < 0$ ($i = 1, 2, \dots, m$), $\lambda > 0, \mu > 1, \epsilon_{feas} > 0, \epsilon > 0$

- 重复基本步骤

- 确定 t ：令 $t := \frac{\mu m}{\eta(x, \lambda)} = \frac{\mu m}{-f(x)^\top \lambda}$ 当前的代理对偶间隙对应的 t 值

- 计算原对偶搜索方向 $\Delta y_{pd} = (\Delta x_{pd}, \Delta \lambda_{pd}, \Delta v_{pd})$

$$\begin{bmatrix} \nabla f_0(x) + \sum_{i=1}^m \lambda_i \nabla^2 f_i(x) & Df(x)^\top & A^\top \\ -diag(\lambda) Df(x) & -diag(f(x)) & 0 \\ A & 0 & 0 \end{bmatrix} \begin{bmatrix} \Delta x_{pd} \\ \Delta \lambda_{pd} \\ \Delta v_{pd} \end{bmatrix} = - \begin{bmatrix} r_{dual} \\ r_{cent} \\ r_{pri} \end{bmatrix}$$

- 以减少 $\|r_t(y + s\Delta y_{pd})\|_2$ 为目标进行直线搜索，确定步长 $s > 0$ ，令 $y = y + s\Delta y_{pd}$

- 停止准则： $\|r_{pri}\|_2 \leq \epsilon_{feas}$ ， $\|r_{dual}\|_2 \leq \epsilon_{feas}$ 和 $\eta(x, \lambda) = -f(x)^\top \lambda \leq \epsilon$



原对偶内点法与障碍方法对比

- ✓ 原对偶方法仅有一次迭代，每次迭代同时更新原对偶变量
- ✓ 通过将牛顿方法应用于修改的KKT方程（对数障碍中心点问题的最优性条件）确定原对偶内点法的搜索方向
- ✓ 原对偶方法中，原对偶迭代值不需要是可行的，一般更有效，展现超线性收敛性质

原对偶内点方法

- 初始化步骤：确定 x 满足 $f_i(x) < 0$ ($i = 1, 2, \dots, m$), $v, \lambda > 0, \mu > 1, \epsilon_{feas} > 0, \epsilon > 0$
- 重复基本步骤
 1. 确定 t 。令 $t := \frac{\mu m}{\eta(x, \lambda)} = \frac{\mu m}{-f(x)^T \lambda}$
 2. 计算原对偶搜索方向 $\Delta y = (\Delta x, \Delta \lambda, \Delta v)$
 3. 以减少 $\|r_t(y + s\Delta y)\|_2$ 为目标进行直线搜索，确定步长 $s > 0$ ，令 $y = y + s\Delta y$
- 停止准则： $\|r_{pri}\|_2 \leq \epsilon_{feas}$ ， $\|r_{dual}\|_2 \leq \epsilon_{feas}$ 和 $\eta(x, \lambda) \leq \epsilon$

障碍方法

- 初始化步骤：确定 x 满足 $f_i(x) < 0$ ($i = 1, 2, \dots, m$), $Ax = b$ 1. 设定 $t = t^0 > 0, \mu > 1, \epsilon > 0$
- 中心点步骤：
从 x 开始，对当前的 t 求解近似等式约束优化问题
$$x^*(t) = \operatorname{argmin} t f_0(x) + \phi(x) \text{ s.t. } Ax = b$$
- 停止或迭代：若 $\frac{m}{t} \leq \epsilon$ ，退出，否则令 $x = x^*(t)$ ， $t = \mu t$ ，继续迭代

