



西安交通大学
XI'AN JIAOTONG UNIVERSITY

《优化方法基础》

2025-2026学年秋季学期

罗敏楠

计算机科学与技术学院

西安交通大学

课程基本信息

教师：罗敏楠（西一楼440房间）

Email: minnluo@xjtu.edu.cn

助教：孔祥政、平博文

考试成绩

10%平时作业+20%大作业+70%期末考试

参考书目

[1] Boyd, Stephen and Lieven Vandenberghe. Convex optimization. Cambridge University Press, 2009. (https://web.stanford.edu/~boyd/cvxbook/bv_cvxbook.pdf)

[2]王书宁等翻译版本，《凸优化》，清华大学出版社

<http://web.stanford.edu/~boyd/cvxbook/>


The screenshot displays two web pages. The top page is the Cambridge University Press website for 'Convex Optimization' by Stephen Boyd and Lieven Vandenberghe. It includes a download link for the book and a list of catalog links. The bottom page is a JD.com (京东) product page for the Chinese translation of the book, '凸优化' (Convex Optimization) by Stephen Boyd and Lieven Vandenberghe, translated by Wang Shuning (王书宁). The JD.com page shows the book's price as ¥77.80 (7.9折), a promotional price of ¥70.02, and a '一键购' (One-click purchase) button. It also displays the book's cover and a list of related books.

基本概念、基本原理、基本方法



优化方法与基础2025...

776952081



扫一扫二维码，入群聊



优化的重要意义

□ 最优化是工程技术、经济管理、科学研究中经常遇到的问题。例如：

- ✓ 结构设计
- ✓ 资源分配
- ✓ 生产计划
- ✓ 运输方案
- ✓ 模式识别、数据挖掘、机器学习
- ✓ 深度学习、强化学习、人工智能

[CMU 《Convex Optimization》](https://scs.hosted.panopto.com/Panopto/Pages/Sessions/List.aspx#folderID=%2222e05ff30-48ba-4598-9f70-a9430132b706%22)

<https://scs.hosted.panopto.com/Panopto/Pages/Sessions/List.aspx#folderID=%2222e05ff30-48ba-4598-9f70-a9430132b706%22>

□ 解决优化问题的手段

经验积累
主观判断

做实验
比优劣

建立数学模型
求解最优策略



Optimization problems underlie nearly **everything** we do in Machine Learning and Statistics. In many courses, you learn how to:

translate



Conceptual idea

into

$$P : \min_{x \in D} f(x)$$

Optimization problem

Examples of this?

Examples of the contrary?

This course: **how to solve P** , and **why this is a good skill** to have



西安交通大学
XI'AN JIAOTONG UNIVERSITY


例1

□ 投资组合优化

- 变量：投资于不同财产的数目
- 限制条件：预算、各项财产最大/最小投资额、最小收益
- 目标：总投资风险最小或者总收益最大

□ 数值拟合

- 变量：模型参数
- 限制条件：先验信息，参数取值范围
- 目标：最小化拟合误差或者预测误差



优化问题数学标准形式



$$\begin{aligned} \min_{x} \quad & f_0(x) \quad \text{--- -- -- -- --} \rightarrow \text{目标函数} \\ \text{s.t.} \quad & f_i(x) \leq 0 \quad (i = 1, 2, \dots, m) \quad \text{--- -- --} \rightarrow \text{不等式限制} \\ & h_j(x) = 0, \quad (j = 1, 2, \dots, n) \quad \text{--- -- --} \rightarrow \text{等式限制} \end{aligned}$$

- 可行解集 $X = \{x \in \mathbb{R}^n: f_i(x) \leq 0, i = 1, 2, \dots, m; h_j(x) = 0, j = 1, 2, \dots, n\}$
- 最优值 $p^* = \inf\{f_0(x): x \in X\}$
- 最优解 $x^* \in X: f_0(x^*) = p^*$
- 最优解不唯一
- 局部极小解**: $\exists \epsilon > 0$, 使得 $\forall x \in X, \|x - \hat{x}\|_2 < \epsilon$, 有 $f(\hat{x}) \leq f(x)$, 称 $\hat{x}$ 为 f 的局部极小解
- 全局最小解**: 如果 $\forall x \in X$, 有 $f(\hat{x}) \leq f(x)$ 成立, 称 $\hat{x}$ 为 f 的全局最小解。

求解优化问题




$$\begin{aligned} \min_x \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 0 \quad (i = 1, 2, \dots, m) \\ & h_j(x) = 0, \quad (j = 1, 2, \dots, n) \end{aligned}$$

□ 一般优化问题

- 难于求解
- 计算复杂度高、需要时间长、不总能找到最优解

□ 特定的优化问题能够有效、可靠的求解，例如

- 线性规划问题
- 二次规划问题（最小二乘问题）
- 图优化问题
- 凸优化问题



线性规划问题 (Linear Programming)

□ 目标函数和限制函数都为线性函数，即

$$\min \quad c_1x_1 + c_2x_2 + \cdots + c_nx_n$$

$$s.t. \quad a_{i1}x_1 + a_{i2}x_2 + \cdots + a_{in}x_n \leq b_i \quad (i = 1, 2, \cdots, m)$$

$$x_j \geq 0 \quad (j = 1, 2, \cdots, n)$$

□ 矩阵形式：

$$\min \quad c^T x$$

$$s.t. \quad Ax \leq b$$

$$x \geq 0$$

这里， $A \in \mathbb{R}^{m \times n}$, $c, x \in \mathbb{R}^n$, $b \in \mathbb{R}^m$.


线性规划问题 (Linear Programming)

例1、某公司生产产品P1 x_1 件，生产产品P2 x_2 件，利润最大化函数为

$$\max z = 3x_1 + 5x_2$$

限制条件为

$$\begin{aligned} x_1 &\leq 180 \\ 2x_2 &\leq 150 \\ 3x_1 + 2x_2 &\leq 300 \\ x_1 &\geq 0 \\ x_2 &\geq 0 \end{aligned}$$



线性规划问题 (Linear Programming)

□ 求解线性规划

- 无分析解（闭式解）

- 有效的算法及成熟的软件

- 计算时间复杂度：如果 $m \leq n$ ，则 $O(n^2m)$ ，这里 $x \in \mathbb{R}^n$.

□ 使用线性规划

- 通过一些标准技巧，一些复杂问题能转化成线性规划问题。例如，含有 ℓ_1 -范数或 ℓ_∞ -范数的优化问题、分段线性优化问题等。

$$\begin{array}{ll} \min_x & c^\top x \\ \text{s.t.} & Ax \leq b \end{array}$$

$$A \in \mathbb{R}^{m \times n}, c, x \in \mathbb{R}^n, b \in \mathbb{R}^m$$

非线性优化问题(Nonlinear Optimization)

$$\begin{array}{ll}\min & f_0(x) \\ \text{s.t.} & f_i(x) \leq b_i, \quad i = 1, 2, \dots, m\end{array}$$

□ 举例：球面 $S = \{(x, y, z) \in \mathbb{R}^3 : x^2 + y^2 + z^2 = 1\}$

$$\text{椭球面 } E = \{(x, y, z) \in \mathbb{R}^3 : \frac{(x-p)^2}{a^2} + \frac{(y-q)^2}{b^2} + \frac{(z-r)^2}{c^2} = 1\}$$

求从球面到椭球面最近欧氏距离：

$$d(S, E) = \min\{d((x_1, y_1, z_1), (x_2, y_2, z_2)) : (x_1, y_1, z_1) \in S, (x_2, y_2, z_2) \in E\}$$

求解优化问题：

$$\begin{array}{ll}\min & (x_1 - x_2)^2 + (y_1 - y_2)^2 + (z_1 - z_2)^2 \\ \text{s.t.} & x_1^2 + y_1^2 + z_1^2 = 1, \\ & \frac{(x_2-p)^2}{a^2} + \frac{(y_2-q)^2}{b^2} + \frac{(z_2-r)^2}{c^2} = 1.\end{array}$$

二次规划问题 (Quadratic Programming)

$$\begin{array}{ll}\min_x & \frac{1}{2}x^\top Qx + c^\top x + r \\ \text{s.t.} & Ax = b \\ & x \geq 0\end{array}$$

这里, $Q \in \mathbb{R}^{n \times n}$ 为对称矩阵, 矩阵 $A \in \mathbb{R}^{m \times n}$, $c, x \in \mathbb{R}^n$, $b \in \mathbb{R}^m$, $r \in \mathbb{R}$ 。



最小二乘问题(Least Square Problem)

$$\min \|Ax - b\|_2^2$$

□求解最小二乘问题

- 分析解（闭式解）： $x^* = (A^T A)^{-1} A^T b$
- 有效的算法及成熟的软件
- 计算时间复杂度 $O(n^2 m)$ ， $A \in \mathbb{R}^{m \times n}$ 。

使用最小二乘

- 一些标准的技术提高其适应性。例如，增加权重、增加调整项等。

凸优化问题

$$\begin{aligned} \min_x \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 0 \quad (i = 1, 2, \dots, m) \\ & h_j(x) = 0, \quad (j = 1, 2, \dots, n) \end{aligned}$$

□求解凸优化问题

- 无分析解
- 有效、可靠的算法

□使用凸优化

- 通过一些技巧，许多问题可以转化为凸优化问题
- 凸优化问题有一套理论较为完善的求解方法

① 什么是凸优化问题？

答：目标函数 f_0 和不等式限制函数 $f_i (i = 1, 2, \dots, m)$ 为定义在凸集上的凸函数， $h_j(x)$ ($j = 1, 2, \dots, n$) 为仿射函数。

② 什么是凸集？

③ 什么是凸函数？

④ 凸优化问题为什么重要？

有关的数学知识

- 范数
- 导数
- 线性代数
- 求解不确定线性方程组 $Ax = b$



内积和范数

□ n 维实向量集合 $\mathbb{R}^n$ 上的标准内积: $\forall x = (x_1, x_2, \dots, x_n) \in \mathbb{R}^n, y = (y_1, y_2, \dots, y_n) \in \mathbb{R}^n,$

$$\langle x, y \rangle = x^\top y = \sum_{i=1}^n x_i y_i$$

□ Euclid范数(ℓ_2 -范数): $\forall x = (x_1, x_2, \dots, x_n) \in \mathbb{R}^n,$

$$\|x\|_2 = (x^\top x)^{1/2} = \left(\sum_{i=1}^n x_i^2 \right)^{1/2}$$

□ 两个非零向量 $x, y \in \mathbb{R}^n$ 的夹角:

$$\angle(x, y) = \arccos \left(\frac{x^\top y}{\|x\|_2 \|y\|_2} \right) \in [0, \pi]$$

□ Cauchy-Schwartz不等式: $\forall x, y \in \mathbb{R}^n, |x^\top y| \leq \|x\|_2 \|y\|_2$

内积和范数

□ $n \times n$ 对称矩阵集合 S^n 上的标准内积为, $\forall X, Y \in S^n$,

$$\langle X, Y \rangle = \text{tr}(X^T Y) = \sum_{i=1}^n \sum_{j=1}^n x_{ij} y_{ij} = \sum_{i=1}^n x_{ii} y_{ii} + 2 \sum_{i < j} x_{ij} y_{ij}$$

□ 矩阵 $X = [x_{ij}] \in \mathbb{R}^{m \times n}$ 的Frobenius范数定义为

$$\|X\|_F = (\text{tr}(X^T X))^{1/2} = \left(\sum_{i=1}^m \sum_{j=1}^n x_{ij}^2 \right)^{1/2}$$



范数

□ 范数定义：满足以下条件的函数 $f: \mathbb{R}^n \mapsto \mathbb{R}$, $\text{dom} f = \mathbb{R}^n$ 称为范数

✓ f 是**非负**的： $\forall x \in \mathbb{R}^n$, 有 $f(x) \geq 0$

✓ f 是**正定**的：若 $f(x) = 0$, 则 $x = 0$

✓ f 是**齐次**的： $\forall x \in \mathbb{R}^n$ 和 $t \in \mathbb{R}$, 有 $f(tx) = |t|f(x)$

✓ f 满足**三角不等式**： $\forall x, y \in \mathbb{R}^n$, 有 $f(x + y) \leq f(x) + f(y)$

□ 范数采用符号 $f(x) = \|x\|$, 范数是对向量 $x \in \mathbb{R}^n$ 的长度的度量。

□ 两个向量 $x, y \in \mathbb{R}^n$ 之间用范数 $\|\cdot\|$ 表示的**距离**定义为：

$$\text{dist}(x, y) = \|x - y\|$$

l_p -范数

□ l_p 范数 ($p \geq 1$)

$$\|x\|_p = (|x_1|^p + |x_2|^p + \cdots + |x_n|^p)^{1/p} = \left(\sum_{i=1}^n |x_i|^p \right)^{1/p}$$


✓ l_1 范数: $\|x\|_1 = |x_1| + |x_2| + \cdots + |x_n| = \sum_{i=1}^n |x_i|$

✓ l_2 范数 (Euclid 范数): $\|x\|_2 = (\sum_{i=1}^n x_i^2)^{1/2}$


✓ Chebyshev 或 l_∞ 范数: $\|x\|_\infty = \max\{|x_1|, |x_2|, \cdots, |x_n|\}$

□ “ l_0 范数” $\|x\|_0$ = 向量 x 中非零元素的个数


$$\|x\|_p \leq 1$$




$p = 0$



$p = 1/2$



$p = 1$



$p = 2$

二次范数

□ 对 $P \in S_{++}^n$, 定义 P -二次范数如下:

$$\|x\|_P = (x^\top P x)^{1/2} = \|P^{1/2} x\|_2$$

1. 二次范数的单位球是椭圆;
2. 如果一个范数的单位球是椭圆, 该范数是二次范数



矩阵范数

□ 矩阵 $X = [x_{ij}] \in \mathbb{R}^{m \times n}$ 的Frobenius范数

$$\|X\|_F = (tr(X^T X))^{1/2} = \left(\sum_{i=1}^m \sum_{j=1}^n x_{ij}^2 \right)^{1/2}$$

□ 矩阵 $X = [x_{ij}] \in \mathbb{R}^{m \times n}$ 的绝对值之和范数

$$\|X\|_{sav} = \sum_{i=1}^m \sum_{j=1}^n |x_{ij}|$$

□ 矩阵 $X = [x_{ij}] \in \mathbb{R}^{m \times n}$ 的最大绝对值范数

$$\|X\|_{max} = \max\{|x_{ij}| : i = 1, 2, \dots, m; j = 1, 2, \dots, n\}$$

范数的等价性

□ 令 $\|\cdot\|_a$ 和 $\|\cdot\|_b$ 是 $\mathbb{R}^n$ 上的范数，则存在正常数 α, β 对所有的 $x \in \mathbb{R}^n$ ，有

$$\alpha\|x\|_a \leq \|x\|_b \leq \beta\|x\|_a$$

- ✓ 任何有限维向量空间上的范数都是等价的
- ✓ 推论：任意范数可由Euclid范数进行界定，即存在常数 $\gamma \in (0,1]$ ，使得

$$\|x\| \geq \gamma\|x\|_2$$



对偶范数

□ Cauchy-Schwartz不等式: $\forall x, y \in \mathbb{R}^n, |x^T y| \leq \|x\|_2 \|y\|_2$


□ 定义: 令 $\|\cdot\|$ 是 $\mathbb{R}^n$ 上的范数, 其**对偶范数** $\|\cdot\|_*$ 定义为

$$\|z\|_* = \sup\{z^T x: \|x\| \leq 1\} = \sup\{z^T x: \|x\| = 1\}$$

□ 例1: ℓ_2 范数的对偶: $\|z\|_* = \sup\{z^T x: \|x\|_2 = 1\} = \|z\|_2$

因为: 当向量 x 与 z 同方向时, 两个向量的内积最大, 即

$$\arg \sup_x \{z^T x: \|x\|_2 = 1\} = \frac{z}{\|z\|_2}$$



ℓ_2 范数的对偶范数为自身, 即: $\|z\|_* = \sup\{z^T x: \|x\|_2 = 1\} = \|z\|_2$

范数的对偶

$$\begin{aligned} \max_x \quad & z^T x \\ \text{s.t.} \quad & \|x\|_1 \leq 1 \end{aligned}$$

□ 例子2: ℓ_1 范数对偶: $\|z\|_* = \sup\{z^T x: \|x\|_1 = 1\}$

- 当向量 $z = (z_1, z_2)$ 在实线位置。两个向量的内积最大时，向量 $x = (1, 0)$ ，则


$$z^T x = \|z\|_2 \|x\|_2 \cos\theta = \|z\|_2 \cos\theta = z_1$$

- 当向量 $z = (z_1, z_2)$ 在虚线位置。两个向量的内积最大时，向量 $x = (0, 1)$ ，则

$$z^T x = \|z\|_2 \|x\|_2 \cos\theta = \|z\|_2 \cos\theta = z_2$$

所以， ℓ_1 范数的对偶范数为 ℓ_∞ 范数，即

$$\|z\|_* = \sup\{z^T x: \|x\|_1 = 1\} = \max\{z_1, z_2\} = \|z\|_\infty$$



范数的对偶

- ℓ_2 范数的对偶为其自身: $\|z\|_* = \sup\{z^T x: \|x\|_2 = 1\} = \|z\|_2$
- ℓ_1 范数的对偶范数为 ℓ_∞ 范数: $\|z\|_* = \sup\{z^T x: \|x\|_1 = 1\} = \max\{z_1, z_2\} = \|z\|_\infty$;
- ℓ_∞ 范数的对偶范数为 ℓ_1 范数: $\|z\|_* = \sup\{z^T x: \|x\|_\infty = 1\} = \|z\|_1$;
- ℓ_p 范数的对偶范数为 ℓ_q 范数 ($p, q \geq 1$): $\|z\|_* = \sup\{z^T x: \|x\|_p = 1\} = \|z\|_q$ 当且仅当

$$\frac{1}{p} + \frac{1}{q} = 1$$

作业

1、证明：范数 $\|\cdot\|$ 的对偶范数满足范数的定义

$$\|z\|_* = \sup\{z^T x: \|x\| \leq 1\} = \sup\{z^T x: \|x\| = 1\}$$

2、证明： $z^T x \leq \|x\| \|z\|_*$



对偶范数的性质

定义：令 $\|\cdot\|$ 是 $\mathbb{R}^n$ 上的范数，其对应的对偶范数 $\|\cdot\|_*$ 定义为 $\|z\|_* = \sup\{z^T x: \|x\| = 1\}$ 。

- 性质1： $z^T x \leq \|x\| \cdot \|z\|_*$ ($\forall x$)；

$$\|z\|_* \geq z^T \frac{x}{\|x\|}$$

- 性质2：对偶范数的对偶为原范数，即 $\|x\|_{**} = \|x\|$ ；



导数

□ 假定: $f: \mathbb{R}^n \rightarrow \mathbb{R}^m, x \in \text{int dom } f$ 。函数 f 在 x 处可微, 则存在矩阵 $Df(x) \in \mathbb{R}^{m \times n}$ 满足

$$\lim_{z \in \text{dom } f, z \neq x, z \rightarrow x} \frac{\|f(z) - f(x) - Df(x)(z - x)\|_2}{\|z - x\|_2} = 0$$

- $Df(x) \in \mathbb{R}^{m \times n}$ 称为 f 在 x 处的导数 (或Jacobian矩阵)
- 偏导数: $Df(x)_{ij} = \frac{\partial f_i(x)}{\partial x_j}, i = 1, 2, \dots, m; j = 1, 2, \dots, n$

□ f 在 x 处以 z 为变量的一次逼近为: $\bar{f}(z) = f(x) + Df(x)(z - x)$

梯度

□ 实函数: $f: \mathbb{R}^n \rightarrow \mathbb{R}, x \in \text{int dom } f$ 的导数为行向量 $Df(x) \in \mathbb{R}^{1 \times n}$, 其转置称为函数的梯度, 即

$$\nabla f(x) = Df(x)^\top \in \mathbb{R}^n, \text{ 这里 } \nabla f(x)_i = \frac{\partial f(x)}{\partial x_i}, i = 1, 2, \dots, n$$

□ f 在 $x \in \text{int dom } f$ 处以 z 为变量的一次逼近: $\bar{f}(z) = f(x) + \nabla f(x)^\top (z - x)$ 。

□ 例子: 二次函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}, f(x) = \frac{1}{2}x^\top Px + q^\top x + r$, 其中 $P \in S^n, q \in \mathbb{R}^n, r \in \mathbb{R}$,

- x 处的导数: $Df(x) = x^\top P + q^\top$
- x 处的梯度: $\nabla f(x) = Px + q$ 。

链式规则

□ 假定： $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 在 $x \in \text{int dom } f$ 处可微， $g: \mathbb{R}^m \rightarrow \mathbb{R}^p$ 在 $f(x) \in \text{int dom } g$ 处可微。

定义复合函数 $h: \mathbb{R}^n \rightarrow \mathbb{R}^p$ 为 $h(z) = g(f(z))$ ，则函数 h 在 x 处可微，导数为

$$Dh(x) = Dg(f(x))Df(x)$$

□ 若以上 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ ， $g: \mathbb{R} \rightarrow \mathbb{R}$ 为实值函数，则函数 h 在 x 处梯度为

$$\nabla h(x) = g'(f(x))\nabla f(x)$$

□ 若 $g: \mathbb{R}^m \rightarrow \mathbb{R}^p$ 是可微函数， $A \in \mathbb{R}^{n \times m}$ ， $b \in \mathbb{R}^m$ ，则函数 $h: \mathbb{R}^n \rightarrow \mathbb{R}^p$ ， $h(x) = g(Ax + b)$ 的导数为 $Dh(x) = Dg(Ax + b)A$ 。当 $m = 1$ 时，其梯度为

$$\nabla h(x) = A^\top \nabla g(Ax + b)$$

二阶导数

□ 实函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 在 $x \in \text{int dom } f$ 的二阶导数（Hessian矩阵）为

$$\nabla^2 f(x)_{ij} = \frac{\partial^2 f(x)}{\partial x_i \partial x_j}, i = 1, 2, \dots, n; j = 1, 2, \dots, n$$

□ f 在 $x \in \text{int dom } f$ 处以 z 为变量的二次逼近为：

$$\hat{f}(z) = f(x) + \nabla f(x)^\top (z - x) + \frac{1}{2} (z - x)^\top \nabla^2 f(x) (z - x)$$

□ 该二次逼近满足

$$\lim_{z \in \text{dom } f, z \neq x, z \rightarrow x} \frac{|f(x) - \hat{f}(z)|}{\|z - x\|_2^2} = 0$$



二阶导数链式法则

□ 假定 $f: \mathbb{R}^n \rightarrow \mathbb{R}$, $g: \mathbb{R} \rightarrow \mathbb{R}$ 以及复合函数 $h(x) = g(f(x))$, 则

$$\nabla^2 h(x) = g'(f(x)) \nabla^2 f(x) + g''(f(x)) \nabla f(x) \nabla f(x)^\top$$

□ 若 $g: \mathbb{R}^n \rightarrow \mathbb{R}$ 是可微函数, $A \in \mathbb{R}^{n \times m}$, $b \in \mathbb{R}^n$, 定义 $h(x) = g(Ax + b)$, 则

$$\nabla^2 h(x) = A^\top \nabla^2 g(Ax + b) A$$



作业

$f: \mathbb{R}^n \rightarrow \mathbb{R}$, $f(x) = \log \sum_{i=1}^m \exp(a_i^\top x + b_i)$, 其中 $a_1, a_2, \dots, a_m \in \mathbb{R}^n$, $b_1, b_2, \dots, b_m \in \mathbb{R}$

1、求函数 f 的梯度 $\nabla f(x)$

2、求函数 f 的二阶导数 $\nabla^2 f(x)$



凸优化问题

$$\begin{aligned} \min_x \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 0 \quad (i = 1, 2, \dots, m) \\ & h_j(x) = 0, \quad (j = 1, 2, \dots, n) \end{aligned}$$

□求解凸优化问题

- 无分析解
- 有效、可靠的算法

□使用凸优化

- 通过一些技巧，许多问题可以转化为凸优化问题
- 凸优化问题有一套理论较为完善的求解方法。

① 什么是凸优化问题？

答：目标函数 f_0 和不等式限制函数 $f_i (i = 1, 2, \dots, m)$ 为定义在凸集上的凸函数， $h_j(x)$ ($j = 1, 2, \dots, n$) 为仿射函数。

② 什么是凸集？

③ 什么是凸函数？


④ 凸优化问题为什么重要？

凸集


□ 凸集的定义：集合 $C \subset \mathbb{R}^n$ 称为凸集，如果 $\forall x, y \in C$ 及 $\forall \lambda \in [0, 1]$ ，有

$$z = \lambda x + (1 - \lambda)y \in C$$

点 x 和点 y 的凸组合



凸集



非凸集

□ 凸集中任意两点的连线仍在该集合中

□ 多个点 $x_1, x_2, \dots, x_m \in C$ 的凸组合定义为：


$$\{z: z = \lambda_1 x_1 + \lambda_2 x_2 + \dots + \lambda_m x_m, \forall \lambda_1, \lambda_2, \dots, \lambda_m \geq 0, \lambda_1 + \lambda_2 + \dots + \lambda_m = 1 \ (m \geq 2)\}$$

例2

- $\forall n \geq 1$, $\mathbb{R}^n$ 空间为凸集合;
- 非负象限 $\mathbb{R}_+^n = \{x \in \mathbb{R}^n: x_i \geq 0, \forall i = 1, 2, \dots, n\}$ 是凸集合
- 集合 $X = \{x \in \mathbb{R}^n: \|x\|_2 \leq 1\}$ 是凸集

证明: $\forall x, y \in X, \forall \lambda \in [0, 1]$,

$$\begin{aligned}\|\lambda x + (1 - \lambda)y\|_2 &\leq \|\lambda x\|_2 + \|(1 - \lambda)y\|_2 \quad \leftarrow \text{范数的三角不等式} \\ &= \lambda\|x\|_2 + (1 - \lambda)\|y\|_2 \\ &\leq 1\end{aligned}$$



$p = 2$

凸集的判断

□ 根据定义

$$\forall x_1, x_2 \in C, \forall \lambda \in [0,1] \implies z = \lambda x_1 + (1 - \lambda)x_2 \in C$$

□ 例子：令 $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$ ，集合 $C = \{x \in \mathbb{R}^n : Ax = b\}$ 是凸集吗？为什么？

作业

- 令 $A \in \mathbb{R}^{m \times n}, B \in \mathbb{R}^{p \times n}, b \in \mathbb{R}^m, d \in \mathbb{R}^p$, 集合

$$P = \{x \in \mathbb{R}^n : Ax \leq b \text{ 且 } Bx = d\}$$

是凸集吗？为什么？

凸集的性质


- 凸集合的交运算：令 $\{C_i: i \in I\}$ 是凸集的集合，那么 $\cap_{i \in I} C_i$ 是凸集。
- 凸集合的和运算：令 C_1, C_2 为凸集合，则 $\{x_1 + x_2: x_1 \in C_1, x_2 \in C_2\}$ 是凸集。
- 仿射函数保凸集：仿射函数 $f(x) = Ax + b$ ，这里， $A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m$ ，有
 - $X \subseteq \mathbb{R}^n$ 是凸集 $\Rightarrow f(X) = \{f(x): x \in X\}$ 是凸集
 - $S \subseteq \mathbb{R}^m$ 是凸集 $\Rightarrow f^{-1}(S) = \{x: f(x) \in S\}$ 是凸集

凸函数


□ 凸函数(Convex Function): 令集合 $C \subseteq \mathbb{R}^n$ 是凸集。 $\forall x, y \in C, \forall \lambda \in [0, 1]$, 如果函数 $f: C \rightarrow \mathbb{R}$ 满足

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y)$$

则 f 为凸函数。



凸函数：函数图像上任意两点之间的连线（弦）都在函数图像之上。



非凸函数

凹函数

□ 凹函数（Concave Function）的定义：令集合 $C \subseteq \mathbb{R}^n$ 是凸集。 $\forall x, y \in C, \forall \lambda \in [0, 1]$ ，如果函数 $f: C \rightarrow \mathbb{R}$ 满足以下条件

$$f(\lambda x + (1 - \lambda)y) \geq \lambda f(x) + (1 - \lambda)f(y)$$

则 f 为凹函数。

□ 定理：函数 $f: C \rightarrow \mathbb{R}$ 是凹函数当且仅当函数 $-f$ 是凸函数。

严格凸函数/严格凹函数

□ 严格凸函数 (Strictly Convex) 的定义: 令集合 $C \subseteq \mathbb{R}^n$ 是凸集。 $\forall x, y \in C$, $\forall \lambda \in (0,1)$, 如果函数 $f: C \rightarrow \mathbb{R}$ 满足以下条件

$$f(\lambda x + (1 - \lambda)y) < \lambda f(x) + (1 - \lambda)f(y)$$

则 f 为严格凸函数.

□ 严格凹函数 (Strictly Concave) 的定义: 令集合 $C \subseteq \mathbb{R}^n$ 是一凸集。 $\forall x, y \in C$, $\forall \lambda \in (0,1)$, 如果函数 $f: C \rightarrow \mathbb{R}$ 满足以下条件

$$f(\lambda x + (1 - \lambda)y) > \lambda f(x) + (1 - \lambda)f(y)$$

则 f 为严格凹函数.

例3

□ 仿射函数 $f(x) = Ax + b$ 既是凸函数，又是凹函数。

证明： $\forall x, y \in \mathbb{R}^n, \forall \lambda \in [0, 1]$ ，有

$$\begin{aligned} f(\lambda x + (1 - \lambda)y) &= A(\lambda x + (1 - \lambda)y) + b \\ &= \lambda(Ax + b) + (1 - \lambda)(Ay + b) \\ &= \lambda f(x) + (1 - \lambda)f(y) \end{aligned}$$

□ p -范数 $f(x) = \|x\|_p (p \geq 1, x \in \mathbb{R}^n)$ 为凸函数，如 $\|x\|_1, \|x\|_2, \|x\|_\infty$ 。

证明：根据范数的三角不等式和正齐性， $\forall x, y \in \mathbb{R}^n, \forall \lambda \in [0, 1]$ ，有

$$\begin{aligned} f(\lambda x + (1 - \lambda)y) &= \|\lambda x + (1 - \lambda)y\|_p \\ &\leq \lambda\|x\|_p + (1 - \lambda)\|y\|_p \\ &= \lambda f(x) + (1 - \lambda)f(y) \end{aligned}$$

作业

证明：最大值函数 $f(x) = \max\{x_1, x_2, \dots, x_n\}$, $x = [x_1, x_2, \dots, x_n]^T \in \mathbb{R}^n$ 为凸函数





□ 二次函数 $f(x) = \frac{1}{2}x^T Qx + p^T x + r, x \in \mathbb{R}^n$ 是否为凸函数？是否为凹函数？是否为严格凸函数？是否为严格凹函数？




凸函数的一阶判定

□ 定理： $C \in \mathbb{R}^n$ 为凸集且函数 $f: C \rightarrow \mathbb{R}$ 在集合 C 上可微，那么

(1) 函数 f 是凸函数当且仅当 $\forall x, y \in C$, 有

$$f(y) \geq f(x) + \nabla^T f(x)(y - x) \quad \leftarrow \text{一阶判定条件}$$

(2) 如果 $\forall x, y \in C$ 且 $x \neq y$, $f(y) > f(x) + \nabla^T f(x)(y - x)$, 那么 函数 f 是严格凸函数。



凸函数的一阶判定

函数 f 是凸函数当且仅当 $\forall x, y \in C$, 有 $f(y) \geq f(x) + \nabla^\top f(x)(y - x)$

证明：“ $\Rightarrow$ ”：函数 f 是凸函数，那么 $\forall x, y \in C, \forall \lambda \in [0, 1]$ ，那么

$$f(x + \lambda(y - x)) = f((1 - \lambda)x + \lambda y) \leq (1 - \lambda)f(x) + \lambda f(y)$$

因此，有
$$\frac{f(x + \lambda(y - x)) - f(x)}{\lambda} \leq f(y) - f(x)$$

进一步，因为

$$\frac{f(x + \lambda(y - x)) - f(x)}{\lambda} \rightarrow \nabla^\top f(x)(y - x) \text{ 当 } \lambda \rightarrow 0_+$$

所以 $\nabla^\top f(x)(y - x) \leq f(y) - f(x)$ 成立。证毕。

凸函数的一阶判定

函数 f 是凸函数当且仅当 $\forall x, y \in C$, 有 $f(y) \geq f(x) + \nabla^\top f(x)(y - x)$

证明: “ $\Leftarrow$ ” : $\forall x, y \in C, \forall \lambda \in [0, 1]$, 令 $z = \lambda x + (1 - \lambda)y$ 。因为

$x - z = (1 - \lambda)(x - y)$, 有

$$f(x) \geq f(z) + \nabla^\top f(z)(x - z) = f(z) + \nabla^\top f(z)(1 - \lambda)(x - y) \quad (1)$$

因为 $y - z = -\lambda(x - y)$, 有

$$f(y) \geq f(z) + \nabla^\top f(z)(y - z) = f(z) + \nabla^\top f(z)(-\lambda)(x - y) \quad (2)$$

做 $\lambda * (1) + (1 - \lambda) * (2)$, 有

$$\lambda f(x) + (1 - \lambda)f(y) \geq f(z) = f(\lambda x + (1 - \lambda)y)$$

证毕!



二次函数 $f(x) = \frac{1}{2}x^\top Qx + p^\top x + r, x \in \mathbb{R}^n$ 是否为凸函数？是否为凹函数？是否为严格凸函数？是否为严格凹函数？



凸函数的二阶判定

定理： $C \subseteq \mathbb{R}^n$ 为凸集（开集）且函数 $f: C \rightarrow \mathbb{R}$ 在集合 C 上二阶连续可微，那么

(1) 函数 f 是凸函数当且仅当 $\forall x \in C, \nabla^2 f(x)$ 为对称半正定矩阵

作业：证明！

(2) 如果 $\forall x \in C, \nabla^2 f(x)$ 为对称正定矩阵，那么函数 f 是严格凸函数

这里， $\forall x = [x_1, x_2, \dots, x_n] \in C$ ，函数 f 的Hessian矩阵 $\nabla^2 f(x) \in \mathbb{R}^{n \times n}$ 定义为

$$(\nabla^2 f(x))_{ij} = \frac{\partial^2 f(x)}{\partial x_i \partial x_j} \quad (i, j = 1, 2, \dots, n)$$

凸函数的二阶判定

□ 推论： $C \subseteq \mathbb{R}^n$ 为凸集且二次函数 $f: C \rightarrow \mathbb{R}$ 定义为 $f(x) = \frac{1}{2}x^\top Qx + p^\top x + r$,

这里, $Q \in S^n$ 为对称矩阵。那么

- (1) 函数 f 是凸函数当且仅当 Q 为对称半正定矩阵
- (2) 函数 f 是凹函数当且仅当 Q 为对称半负定矩阵
- (3) 函数 f 是严格凸（凹）函数当且仅当 Q 为对称正（负）定矩阵
- (4) 否则, 函数 f 为非凸非凹函数

证明： $\forall x \in C$, 函数 f 的 Hessian 矩阵为

$$\nabla^2 f(x) = Q$$

凸函数的二阶判定

□ 推论： $C \subseteq \mathbb{R}^n$ 为凸集且二次函数 $f: C \rightarrow \mathbb{R}$ 定义为 $f(x) = \frac{1}{2}x^\top Qx + p^\top x + r$,

这里, $Q \in S^n$ 为对称矩阵。那么

- (1) 函数 f 是凸函数当且仅当 Q 为对称半正定矩阵
- (2) 函数 f 是凹函数当且仅当 Q 为对称半负定矩阵
- (3) 函数 f 是严格凸（凹）函数当且仅当 Q 为对称正（负）定矩阵
- (4) 否则, 函数 f 为非凸非凹函数

证明： $\forall x \in C$, 函数 f 的 Hessian 矩阵为

$$\nabla^2 f(x) = Q$$

例4

□ 指数函数 $f: \mathbb{R} \rightarrow \mathbb{R}, f(x) = e^{ax}, \forall a \in \mathbb{R}$ 为凸函数, 因为 $\forall x \in \mathbb{R}$, 有

$$f''(x) = a^2 e^{ax} > 0$$

□ 负对数函数 $f, \forall x \in \mathbb{R}_{++} = \{x \in \mathbb{R}: x > 0\}, f(x) = -\log x$ 为凸函数, 因为 $\forall x \in \mathbb{R}_{++}$, 有

$$f''(x) = \frac{1}{x^2} > 0$$

□ 最小二乘函数 $f(x) = \|Ax - b\|_2^2$ 为凸函数, 因为 $\forall x \in \mathbb{R}$, 有

$$\nabla f(x) = 2A^\top(Ax - b), \quad \nabla^2 f(x) = 2A^\top A$$

凸函数的性质

- 非负乘积保持凸性: $\forall \alpha \geq 0$, 如果函数 f 是定义在 C 上的凸函数, 则函数 $g(x) = \alpha f(x)$ 是凸函数。
- 和运算保持凸性: 如果函数 f_1, f_2 为凸函数, 那么函数 $g(x) = f_1(x) + f_2(x)$ 为凸函数。
- $C \subseteq \mathbb{R}^n$ 为凸集且 $\{f_i: C \rightarrow \mathbb{R} | i \in I\}$ 是凸函数的集合, 则其非负权重和 $f = \sum_{i \in I} w_i f_i$ 是凸函数, 其中权重 $w_i \geq 0, \forall i \in I$ 。

凸函数的性质

□ f 是定义在凸集 $C \subseteq \mathbb{R}^n$ 上的凸函数, 则 $g: B \rightarrow \mathbb{R}$, $g(x) = f(Ax + b)$, $B = \{Ax + b: x \in C\}$ 是凸函数。

例如: 1. 由于 $f(x) = \|x\|$ 是凸函数, 那么, $\|y - Ax\|$ 也是凸函数。

2. 由于 $f_i(x) = -\log x$ ($i = 1, 2, \dots, n$) 是凸函数, 那么, 函数 $g: C \rightarrow \mathbb{R}$

$$g(x) = -\sum_{i=1}^m \log(b_i - a_i^\top x)$$

是凸函数, 其中, 函数 g 的定义域为: $\text{dom } g = \{x: a_i^\top x < b_i, i = 1, 2, \dots, m\}$.

凸函数的性质

- 函数 $f(x, y)$ 是定义在集合 $Z = \{z = (x^\top, y^\top)^\top \in \mathbb{R}^{m+n} : x \in \mathbb{R}^m, y \in \mathbb{R}^n\}$ 上的凸函数。对凸集合 C ，有

$$g(x) = \inf_{y \in C} f(x, y)$$

是凸函数。

- 例如：到凸集合 S 的距离函数： $D(x, S) = \inf_{y \in S} \|x - y\|$ 是凸函数。



凸函数的性质

□ 如果对于任意的 $y \in A$, $f(x, y)$ 是关于 x 的凸函数, 那么

$$g(x) = \sup_{y \in A} f(x, y)$$

是凸函数。

例如：1. 集合 C 的支持函数 (Support Function) : $S_C(x) = \sup_{y \in C} y^T x$ 是凸函数；

2. 集合 C 上距离 x 最远的点： $f(x) = \sup_{y \in C} \|x - y\|$ 是凸函数；

凸函数的性质

□ 共轭函数：函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 的共轭函数 $f^*: \mathbb{R}^n \rightarrow \mathbb{R}$ 定义为：仿射函数 $\mathbf{y}^\top \mathbf{x}$ 与 $f(\mathbf{x})$ 之间的最大差值，即


$$f^*(\mathbf{y}) = \sup_{x \in \text{dom } f} (\mathbf{y}^\top \mathbf{x} - f(\mathbf{x}))$$

□ 如果函数 f 可微，在满足 $f'(x) = y$ 的点 x 处差值最大。

□ 对于任意函数 f ，其共轭函数 f^* 为凸函数。为什么？

例如：函数 $f(x) = -\log x$ 的共轭函数 f^* 为凸函数，这里

$$f^*(y) = \sup_{x>0} (xy + \log x) = \begin{cases} -1 - \log(-y), & y < 0 \\ \infty, & y \geq 0 \end{cases}$$



凸函数的性质


□ 令 $\{f_i: C \rightarrow \mathbb{R} | i \in I\}$ 为定义在凸集 $C \subseteq \mathbb{R}^n$ 上凸函数的集合，则函数 $h: C \rightarrow \mathbb{R}$,

$h(x) = \sup_{i \in I} f_i(x)$ 是凸函数。当 I 是有限指标集合时，

$$h(x) = \sup_{i \in I} f_i(x) = \max\{f_1(x), f_2(x), \dots, f_n(x)\}$$

□ 例如，分段线性函数是凸函数

$$h(x) = \max_{i=1,2,\dots,n} (a_i^\top x + b_i)$$



Jensen's Inequality

□ 令 $f(x)$ 为定义在凸集 $C \subseteq \mathbb{R}^n$ 上的凸函数, 则 $\forall x_1, x_2, \dots, x_k \in C, \forall \lambda_1, \lambda_2, \dots, \lambda_k \geq 0$ 且 $\lambda_1 + \lambda_2 + \dots + \lambda_k = 1$ ($k \geq 2$), 有

$$f\left(\sum_{i=1}^k \lambda_i x_i\right) \leq \sum_{i=1}^k \lambda_i f(x_i)$$


□ 当 $k = 2$ 时, 即 $f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y)$;

□ 积分形式: $f\left(\int p(x)xdx\right) \leq \int p(x)f(x)dx$, 这里 $\int p(x)dx = 1, p(x) \geq 0, \forall x \in C$.

□ 概率形式: $f(E[x]) \leq E[f(x)]$

透视图函数

- 透视函数 $P: \mathbb{R}^{n+1} \rightarrow \mathbb{R}^n$ 定义为: $P(z, t) = \frac{z}{t}$, $\text{dom } P = \mathbb{R}^n \times \mathbb{R}_{++}$
- 透视函数对向量进行伸缩, 或称为规范化, 使得最后一维分量为1并舍弃之。
- 定义在凸集上的透视函数的象仍然是凸集。



透视函数的小孔成像解释

凸函数的性质

□ 函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 的透视函数 $g: \mathbb{R}^n \times \mathbb{R} \rightarrow \mathbb{R}$ 定义为:

$$g(x, t) = tf\left(\frac{x}{t}\right), \quad \text{dom } g = \{(x, t): \frac{x}{t} \in \text{dom } f, t > 0\}$$

□ 如果函数 f 是凸函数, 那么其透视函数 g 也是凸函数。

例如: 1. 函数 $f(x) = x^\top x$ 是凸函数; 因此, 函数 $g(x, t) = \frac{x^\top x}{t} (t > 0)$ 是凸函数;


2. 函数 $f(x) = -\log x$ 是凸函数, 那么其透视函数

$$g(x, t) = t \log t - t \log x \longrightarrow \text{相对熵}$$

在集合 $\mathbb{R}_{++} \times \mathbb{R}_{++}$ 上是凸函数;

凸函数的判定方法总结


□定义: $f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y)$



□一阶判定: $f(y) \geq f(x) + \nabla^T f(x)(y - x)$

□二阶判定: $\forall x \in C, \nabla^2 f(x)$ 对称半正定矩阵

二次函数 $f(x) = x^T P x + 2q^T x + r$



□保凸函数运算

优化问题

□ 优化问题数学标准形式

$$\min_x f_0(x) \text{ -----> 目标函数}$$

$$s.t. \quad f_i(x) \leq 0 \quad (i = 1, 2, \dots, m) \text{ -----> 不等式限制}$$

$$h_j(x) = 0, \quad (j = 1, 2, \dots, n) \text{ -----> 等式限制}$$



可行解集

$$C = \{x \in \mathbb{R}^n: f_i(x) \leq 0, i = 1, 2, \dots, m; h_j(x) = 0, j = 1, 2, \dots, n\}$$



$$\begin{array}{ll} \min_x & f_0(x) \\ s.t. & x \in C \end{array}$$

凸优化问题

凸优化问题

$$\begin{array}{ll} \min_x & f_0(x) \longrightarrow \text{目标函数 } f_0: X \rightarrow \mathbb{R} \text{ 为凸函数} \\ \text{s.t.} & x \in C \longrightarrow \text{可行解集 } C \text{ 为凸集合} \end{array}$$

这里，可行解集 $C = \{x \in \mathbb{R}^n: f_i(x) \leq 0, i = 1, 2, \dots, m; h_j(x) = 0, j = 1, 2, \dots, n\}$



- ✓ 什么情况下，可行解集 C 为凸集合？
- ✓ 凸优化问题为什么重要？




若函数 f 是定义在凸集 X 上的凸函数，则对于任意的 α ，水平集合 $X_\alpha = \{x \in X: f(x) \leq \alpha\}$ 为凸集

可行解集 $C = \{x \in \mathbb{R}^n: f_i(x) \leq 0, i = 1, 2, \dots, m; h_j(x) = 0, j = 1, 2, \dots, n\}$

$$= \{x \in \mathbb{R}^n: f_i(x) \leq 0, i = 1, 2, \dots, m; h_j(x) \leq 0, h_j(x) \geq 0, j = 1, 2, \dots, n\}$$
$$= \{x \in \mathbb{R}^n: f_i(x) \leq 0, i = 1, 2, \dots, m; h_j(x) \leq 0, -h_j(x) \leq 0, j = 1, 2, \dots, n\}$$



- ✓ $f_i(x) (i = 1, 2, \dots, m)$ 为凸函数
- ✓ $h_j(x) (j = 1, 2, \dots, n)$ 为凸函数
- ✓ $-h_j(x) (j = 1, 2, \dots, n)$ 为凸函数



- ✓ $f_i(x) (i = 1, 2, \dots, m)$ 为凸函数
- ✓ $h_j(x) (j = 1, 2, \dots, n)$ 为仿射函数

凸优化问题数学标准形式

$$\begin{array}{ll} \min_x & f_0(x) \text{ -----> 目标函数为凸函数} \\ \text{s.t.} & f_i(x) \leq 0 \ (i = 1, 2, \dots, m) \text{ -----> 不等式限制函数为凸函数} \\ & h_j(x) = 0, \ (j = 1, 2, \dots, n) \text{ -----> 等式限制函数为仿射函数} \end{array}$$



- ✓ 什么情况下，可行解集 C 为凸集合？
- ✓ 凸优化问题为什么重要？

凸优化问题为什么重要？

$$\begin{array}{ll} \min_x f_0(x) & \longrightarrow \text{目标函数 } f_0: X \rightarrow \mathbb{R} \text{ 为凸函数} \\ \text{s.t. } x \in C & \longrightarrow \text{可行解集 } C \text{ 为凸集合} \end{array}$$

- 局部极小解：如果 $\exists \epsilon > 0$ ，使得 $\forall x$ 满足 $\|x - \hat{x}\| < \epsilon$ ，有 $f(\hat{x}) \leq f(x)$ ， $\forall x \in X$ ，称向量 $\hat{x}$ 为 f 的局部极小解。
- 全局最小解：如果 $\forall x \in X$ ，有 $f(\hat{x}) \leq f(x)$ 成立，称向量 $\hat{x}$ 为 f 的全局最小解。

定理：凸优化问题局部极小解即全局最小解

凸优化问题为什么重要？

定理：凸优化问题局部极小解即全局最小解

$$\begin{array}{ll} \min_x & f_0(x) \\ \text{s.t.} & x \in C \end{array}$$

证明：“全局最小解是局部极小解”，显然；

“局部极小解是全局最小解”：（反证法）假设存在 $x \in C$ 是局部极小解，而非全局最小解，那么 $\exists y \neq x$ 使得 $f(y) < f(x)$. 由于函数 f 为凸函数，对所有的 $\lambda \in [0,1]$, 有

$$\begin{aligned} f((1-\lambda)x + \lambda y) &\leq (1-\lambda)f(x) + \lambda f(y) \\ &< (1-\lambda)f(x) + \lambda f(x) = f(x). \end{aligned}$$

对于足够小的 λ ，则 $z = (1-\lambda)x + \lambda y$ 属于 x 的 ϵ -邻域且满足 $f(z) < f(x)$. 该结论与 $x \in C$ 是局部极小解相矛盾。证毕。

凸优化问题最优解的性质

□ 无限制凸优化问题： $\min f_0(x)$ 。 x^* 是最优解，即 $x^* = \operatorname{argmin} f_0(x)$

当且仅当

$$x^* \in \operatorname{dom} f_0 \text{ 且 } \nabla f_0(x^*) = 0$$

□ 等式限制凸优化问题： $\min f_0(x) \text{ s.t. } Ax = b$ 。 x^* 是最优解，即

$x^* = \operatorname{argmin} f_0(x)$ 当且仅当

$$x^* \in \operatorname{dom} f_0, Ax^* = b \text{ 且 } \nabla f_0(x^*) + A^\top \nu = 0$$

作业

作业：对于凸优化问题

$$\min f(x)$$


$$s.t. \ x \in X$$

如果目标函数 f 是可微的，那么可行解 x^* 是最优解**当且仅当** $\forall y \in X$ ，有

$$\nabla f(x^*)^\top (y - x^*) \geq 0$$

凸函数一阶判定条件：

$$f(y) \geq f(x) + \nabla f(x)^\top (y - x)$$



作业2

证明 $x^* = \left(1, \frac{1}{2}, -1\right)^T$ 是如下优化问题的最优解

$$\begin{aligned} \min & \frac{1}{2} x^T P x + q^T x + r \\ \text{s.t.} & -1 \leq x_i \leq 1, i = 1, 2, 3 \end{aligned}$$

其中,

$$P = \begin{bmatrix} 13 & 12 & -2 \\ 12 & 17 & 6 \\ -2 & 6 & 12 \end{bmatrix}, \quad q = \begin{bmatrix} -22 \\ -14.5 \\ 13 \end{bmatrix}, \quad r = 1$$

凸优化问题举例

□ 线性规划

$$\begin{aligned} \min \quad & c^\top x + d \\ \text{s.t.} \quad & Gx \leq h \\ & Ax = b \end{aligned}$$

$P \in S_+^n$ 为对称半正定矩阵

□ 二次规划:

$$\begin{aligned} \min \quad & \frac{1}{2} x^\top P x + c^\top x + d \\ \text{s.t.} \quad & Gx \leq h \\ & Ax = b \end{aligned}$$

□ 二次函数限制的二次规划:

$$\begin{aligned} \min \quad & \frac{1}{2} x^\top P x + c^\top x + d \\ \text{s.t.} \quad & \frac{1}{2} x^\top Q_i x + r_i^\top x + s_i \leq 0 \quad (i = 1, 2, \dots, m) \\ & Ax = b \end{aligned}$$

$P, Q_i (i = 1, 2, \dots, m) \in S_+^n$
为对称半正定矩阵

凸优化问题举例

□ 有限制最小二乘优化问题:

$$\begin{aligned} \min \quad & \frac{1}{2} \|Ax - b\|_2^2 \\ \text{s.t.} \quad & l \leq x \leq u \end{aligned}$$



$$\begin{aligned} \min \quad & \frac{1}{2} x^\top P x + c^\top x + d \\ \text{s.t.} \quad & G(x; x) \leq h \end{aligned}$$

这里, $A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m$.

□ 以上优化问题实际上为二次规划问题

$$P \in \mathbb{R}^{n \times n} = \frac{1}{2} A^T A, \quad c \in \mathbb{R}^n = -b^T A, \quad d \in \mathbb{R} = \frac{1}{2} b^T b,$$

$$G \in \mathbb{R}^{2n \times 2n} = \begin{bmatrix} -I & 0 \\ 0 & I \end{bmatrix}, \quad h \in \mathbb{R}^{2n} = \begin{bmatrix} -l \\ u \end{bmatrix}.$$

凸优化问题举例

□ 以下优化问题是凸优化问题吗？为什么？

$$\begin{array}{ll} \min & x_1^2 + x_2^2 \\ \text{s.t.} & \frac{x_1}{1 + x_2^2} \leq 0 \\ & (x_1 + x_2)^2 = 0 \end{array} \quad \longrightarrow \quad \begin{array}{ll} \min & x_1^2 + x_2^2 \\ \text{s.t.} & x_1 \leq 0 \\ & x_1 = -x_2 \end{array}$$

□ 目标函数是凸函数；

□ 等式限制不是仿射函数。但其可以等价的改写线性等式限制 $x_1 = -x_2$ ；

□ 不等式限制不是凸函数，但其可以等价的改写为 $x_1 \leq 0$

优化问题的等价转换

□ 凸优化问题一般形式

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 0 \quad (i = 1, 2, \dots, m) \\ & Ax = b \end{aligned}$$

令 $f_0(x) \leq t$ ，则以上优化问题等价于：

$$\begin{aligned} \min_{t \in \mathbb{R}, x \in \mathbb{R}^n} \quad & t \\ \text{s.t.} \quad & f_0(x) - t \leq 0 \\ & f_i(x) \leq 0 \quad (i = 1, 2, \dots, m) \\ & Ax = b \end{aligned}$$

回顾：凸优化问题

$$\begin{array}{ll} \min_x & f_0(x) \text{ -----> 目标函数为凸函数} \\ \text{s.t.} & f_i(x) \leq 0 \ (i = 1, 2, \dots, m) \text{ -----> 不等式限制函数为凸函数} \\ & h_j(x) = 0, \ (j = 1, 2, \dots, n) \text{ -----> 等式限制函数为仿射函数} \end{array}$$



$$\begin{array}{ll} \min_x & f_0(x) \text{ -----> 目标函数 } f_0: X \rightarrow \mathbb{R} \text{ 为凸函数} \\ \text{s.t.} & x \in C \text{ -----> 可行解集 } C \text{ 为凸集合} \\ & C = \{x \in \mathbb{R}^n: f_i(x) \leq 0, i = 1, 2, \dots, m; h_j(x) = 0, j = 1, 2, \dots, n\} \end{array}$$

□ 定理：凸优化问题局部极小解即全局最小解

优化问题的等价转换

□ ℓ_1 -范数最小化问题:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & \|x\|_1 \\ \text{s.t.} \quad & Gx \leq h \\ & Ax = b \end{aligned}$$

令 $|x_i| \leq t_i$, 则以上优化问题等价于线性规划问题:

$$\begin{aligned} \min_{x, t \in \mathbb{R}^n} \quad & \sum_i t_i \\ \text{s.t.} \quad & -t \leq x \leq t \\ & Gx \leq h \\ & Ax = b \end{aligned}$$

这里, $t = [t_1, t_2, \dots, t_n] \in \mathbb{R}^n$

优化问题的等价转换

□ ℓ_∞ -范数最小化问题:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & \|x\|_\infty \\ \text{s.t.} \quad & Gx \leq h \\ & Ax = b \end{aligned}$$

令 $\|x\|_\infty \leq t$, 以上优化问题等价于线性规划问题:

$$\begin{aligned} \min_{x \in \mathbb{R}^n, t \in \mathbb{R}} \quad & t \\ \text{s.t.} \quad & -t\mathbf{1} \leq x \leq t\mathbf{1} \\ & Gx \leq h \\ & Ax = b \end{aligned}$$

这里, $\mathbf{1} = [1, 1, \dots, 1]^\top \in \mathbb{R}^n$ 。

优化问题的等价转换

□ 定义在 (x, y) 上的优化问题：

$$\begin{aligned} \min_{x,y} \quad & f_0(x, y) \\ \text{s.t.} \quad & f_i(x) \leq 0 \quad (i = 1, 2, \dots, m) \end{aligned}$$

只对变量 x 有限制

令 $g_0(x) = \inf_y f_0(x, y)$ ，则以上优化问题等价于：

$$\begin{aligned} \min_x \quad & g_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 0 \quad (i = 1, 2, \dots, m) \end{aligned}$$

优化问题的等价转换

□ 含有仿射函数不等式的优化问题：

$$\begin{array}{ccc} \min_x f_0(x) & & \min_{x,s} f_0(x) + \sum_{i=1}^m s_i \\ \text{s.t. } a_i^\top x \leq b_i \ (i = 1, 2, \dots, m) & \xleftarrow{\text{逼近}} & \text{s.t. } a_i^\top x \leq b_i + s_i \ (i = 1, 2, \dots, m) \\ & & s_i \geq 0 \ (i = 1, 2, \dots, m) \end{array}$$

增加松弛变量 s_i ($i = 1, 2, \dots, m$), 等价于等式限制优化问题：

$$\begin{array}{ll} \min_{x,s} f_0(x) \\ \text{s.t. } a_i^\top x + s_i = b_i \ (i = 1, 2, \dots, m) \\ s_i \geq 0 \ (i = 1, 2, \dots, m) \end{array}$$

寻找可行解问题

$$\begin{array}{ll} \text{find} & x \\ \text{s.t.} & f_i(x) \leq 0 \quad (i = 1, 2, \dots, m) \\ & h_j(x) = 0, \quad (j = 1, 2, \dots, n) \end{array}$$

$$\begin{array}{ll} \min_x & f_0(x) \\ \text{s.t.} & x \in C \end{array}$$

这里, 可行解集 $C = \{x \in \mathbb{R}^n: f_i(x) \leq 0, i = 1, 2, \dots, m; h_j(x) = 0, j = 1, 2, \dots, n\}$

□ 该问题可写成特殊情况优化问题

$$\begin{array}{ll} \min_x & 0 \\ \text{s.t.} & f_i(x) \leq 0 \quad (i = 1, 2, \dots, m) \\ & h_j(x) = 0, \quad (j = 1, 2, \dots, n) \end{array}$$

此时, 如果可行解存在, 则最优值 $p^* = 0$; 否则 $p^* = \infty$.

局部最优解

$$\begin{aligned} \min_x \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 0 \quad (i = 1, 2, \dots, m) \\ & h_j(x) = 0, \quad (j = 1, 2, \dots, n) \end{aligned} \quad (1)$$

□ 如果存在常数 $r > 0$ ，使得 x 是以下优化问题

$$\begin{aligned} \min_z \quad & f_0(z) \\ \text{s.t.} \quad & f_i(z) \leq 0 \quad (i = 1, 2, \dots, m), \quad h_j(z) = 0, \quad (j = 1, 2, \dots, n) \\ & \|z - x\|_2 \leq r \end{aligned}$$

的最优解，则 x 是优化问题 (1) 的局部最优解。