



西安交通大学
XI'AN JIAOTONG UNIVERSITY

第三章：无约束凸优化问题



无约束凸优化问题

$$\min f(x)$$

- 函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$, 定义域 $\text{dom } f$;
- 基本假设: 函数 f 是具有连续二阶导数的凸函数。
- 求解最优条件: $\nabla f(x^*) = 0$
- 最优解 $x^* = \operatorname{argmin} f(x)$
- 最优值 $p^* = f(x^*)$



例子

- 二次规划

$$\min f(x) = \frac{1}{2}x^{\top}Qx + p^{\top}x + r \quad (1)$$

这里, $\text{dom } f = \mathbb{R}^n$, $Q \in S_+^n$ (对称半正定矩阵集合)。

- 凸函数二阶判定 $\Rightarrow f$ 为凸函数

- $\nabla f(x) = 0 \Leftrightarrow Qx + p = 0$

- ✓ 如果 $Q \in S_{++}^n$, f 是严格凸函数, 优化问题 (1) 有唯一最优解;
- ✓ 如果 $Q \in S_+^n$, 方程组 $Qx + p = 0$ 有解时, 优化问题 (1) 有无穷多最优解;
- ✓ 否则, 优化问题 (1) 无最优解。



例子

- 几何规划 $\min f(x) = \log(\sum_{i=1}^m \exp(a_i^\top x + b_i))$, 其中, $\text{dom } f = \mathbb{R}^n$.
- 函数 f 是凸函数: 凸函数二阶判定 $\Rightarrow g(y) = \log(\sum_{i=1}^m \exp(y_i))$ 为凸函数, 并且凸函数和仿射函数的复合函数还是凸函数;

$$\nabla f(x) = 0 \Leftrightarrow \frac{1}{\sum_{i=1}^m \exp(a_i^\top x + b_i)} \sum_{i=1}^m \exp(a_i^\top x + b_i) a_i = 0$$

一般情况下该方程组没有解析解, 须使用迭代算法。

- 线性不等式的解析中心点 $\min f(x) = -\log \sum_{i=1}^m (b_i - a_i^\top x)$, 其中 $\text{dom } f = \{x | a_i^\top x < b_i\}$.
- 函数 f 是凸函数。因为凸函数二阶判定 $\Rightarrow g(y) = -\log(y_i)$ 为严格凸函数, 并且凸函数和仿射函数的复合函数还是凸函数;

$$\nabla f(x) = 0 \Leftrightarrow \sum_{i=1}^m \frac{1}{b_i - a_i^\top x} a_i = 0$$

采用迭代算法, 初始点 $x^{(0)}$ 必须满足严格不等式 $a_i^\top x^{(0)} < b_i$ ($i = 1, 2, \dots, m$)



无约束凸优化问题

$\min f(x)$

- 函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$, 定义域 $\text{dom } f$;
- 基本假设: 函数 f 是具有连续二阶导数的凸函数。
- 最优解 $x^* = \operatorname{argmin} f(x)$
- 最优值 $p^* = f(x^*)$

□ 无约束凸优化问题最小化方法: 迭代方法求解最优性条件 $\nabla f(x^*) = 0$

- ✓ 初始点 $x^0 \in \text{dom } f$;
- ✓ 水平集合 $S = \{x: f(x) \leq f(x^0)\}$ 是闭集;
- ✓ 产生序列点 $x^k \in \text{dom } f, k = 0, 1, 2, \dots$, 使得 $f(x^k) \rightarrow p^*$;



强凸性及其含义

$$S = \{x: f(x) \leq f(x^0)\}$$

- **强凸性假设**: 目标函数 f 在 S 上是强凸的, 即存在 $m > 0$ 使得 $\forall x \in S, \nabla^2 f(x) \geq mI$
- 若强凸性假设成立, 则 $\forall x, y \in S, f(y) \geq f(x) + \nabla f(x)^\top (y - x) + \frac{m}{2} \|y - x\|_2^2$

证明: $\forall x, y \in S$, 存在 $z \in [x, y]$, 使得

$$f(y) = f(x) + \nabla f(x)^\top (y - x) + \frac{1}{2} (y - x)^\top \nabla^2 f(z) (y - x)$$

根据强凸性假设, 有

$$f(y) \geq f(x) + \nabla f(x)^\top (y - x) + \frac{m}{2} \|y - x\|_2^2$$

- (1) $m = 0$ 时, 即凸性的基本不等式;
- (2) $m > 0$ 时, 对 $f(y)$ 的下界得到比单独利用凸性更好的结果

强凸性及其含义

$$S = \{x: f(x) \leq f(x^0)\}$$

- 强凸性假设：目标函数 f 在 S 上是强凸的，即存在 $m > 0$ 使得 $\forall x \in S$, $\nabla^2 f(x) \geq mI$ 。
- 强凸性假设成立，则 $f(x) - p^* \leq \frac{1}{2m} \|\nabla f(x)\|_2^2$

证明： $\forall y \in S$, $f(y) \geq f(x) + \nabla f(x)^\top (y - x) + \frac{m}{2} \|y - x\|_2^2$ — 关于 y 的凸函数。令其关于 y 求导为零，有 $\tilde{y} = x - \frac{1}{m} \nabla f(x)$

$$\geq f(x) + \nabla f(x)^\top (\tilde{y} - x) + \frac{m}{2} \|\tilde{y} - x\|_2^2$$

$$= f(x) - \frac{1}{2m} \|\nabla f(x)\|_2^2$$

$$f(x) - f(y) \leq \frac{1}{2m} \|\nabla f(x)\|_2^2$$

$\forall y \in S$ 成立

$$f(x) - p^* \leq \frac{1}{2m} \|\nabla f(x)\|_2^2$$

✓ 最优性条件 $\nabla f(x^*) = 0$

✓ 任意梯度足够小的点都是近似最优解，即

$$\|\nabla f(x)\|_2 \leq (2m\epsilon)^{1/2} \Rightarrow f(x) - p^* \leq \epsilon$$

✓ 次优性条件（概念上的停止准则）

强凸性及其含义

$$\forall y, \text{ 有 } f(y) \geq f(x) + \nabla f(x)^\top (y - x) + \frac{m}{2} \|y - x\|_2^2$$

任意 x 和最优解 x^* 之间的距离 $\|x - x^*\|_2$ 正比于 $\|\nabla f(x)\|_2$ 的上界, 即

$$\|x - x^*\|_2 \leq \frac{2}{m} \|\nabla f(x)\|_2$$

证明: $p^* = f(x^*) \geq f(x) + \nabla f(x)^\top (x^* - x) + \frac{m}{2} \|x - x^*\|_2^2$

$$\geq f(x) - \|\nabla f(x)\|_2 \|x - x^*\|_2 + \frac{m}{2} \|x - x^*\|_2^2$$

Cauchy-Schwarz不等式
 $|x^\top y| \leq \|x\|_2 \|y\|_2$

$\forall x, p^* \leq f(x)$, 从而, $-\|\nabla f(x)\|_2 \|x - x^*\|_2 + \frac{m}{2} \|x - x^*\|_2^2 \leq 0$



$$\|x - x^*\|_2 \leq \frac{2}{m} \|\nabla f(x)\|_2$$



$\nabla^2 f(x)$ 的上界

- 假设：目标函数 f 在 S 上有上界，即存在 $M > 0$ 使得 $\forall x \in S$ ，有 $\nabla^2 f(x) \leq MI$
- $f(x) - p^* \geq \frac{1}{2M} \|\nabla f(x)\|_2^2$

证明： $\forall x, y \in S$ ，存在 $z \in [x, y]$ ，使得

$$f(y) = f(x) + \nabla f(x)^\top (y - x) + \frac{1}{2} (y - x)^\top \nabla^2 f(z) (y - x)$$


$$f(y) \leq f(x) + \nabla f(x)^\top (y - x) + \frac{M}{2} \|y - x\|_2^2$$

为什么?

两边对 y 求极小


$$f(x) - p^* \geq \frac{1}{2M} \|\nabla f(x)\|_2^2$$

$$\forall x \in S, mI \leq \nabla^2 f(x) \leq MI$$


$$f(x) - \frac{1}{2m} \|\nabla f(x)\|_2^2 \leq p^* \leq f(x) - \frac{1}{2M} \|\nabla f(x)\|_2^2$$

下降方法

$$\min f(x)$$



迭代求解最优性条件


$$\nabla f(x^*) = 0$$

- 产生一个优化点列 x^k , $k = 1, 2, \dots$, 其中

$$x^{k+1} = x^k + t^k d^k$$


- ✓ 初始点 $x^0 \in \text{dom } f$; $S = \{x: f(x) \leq f(x^0)\}$
- ✓ 第 k 次迭代的搜索方向 $d^k \in \mathbb{R}^n$, 满足 $\nabla f(x^k)^\top d^k < 0$;
- ✓ 第 k 次迭代的步长 $t^k \geq 0$ (标量), 当 $\|d^k\| = 1$, $t^k = \|x^{k+1} - x^k\|$;
- ✓ 下降方法中, 只要 x^k 不是最优点, 则

$$f(x^{k+1}) = f(x^k + t^k d^k) < f(x^k), \quad x^k \in S;$$



下降方向充要条件

搜索方向 d^k 为下降方向当且仅当 $\nabla f(x^k)^\top d^k < 0$



✓ $\nabla f(x^k)^\top d^k = \|\nabla f(x^k)\| \times \|d^k\| \cos\theta < 0$, 这里 θ 是 $\nabla f(x^k)$ 与 d^k 的夹角。

✓ $\nabla f(x^k)^\top d^k < 0$, 即下降方向和负梯度方向的夹角必须是锐角。

证明:

“ $\Leftarrow$ ”: $\nabla f(x^k)^\top d^k < 0$, 则 $\exists \hat{t}$ 使得 $\nabla f(x^k + td^k)^\top d^k < 0, \forall t \in (0, \hat{t})$, 有

$$f(x^k + td^k) \leq f(x^k) + t \nabla f(x^k + td^k)^\top d^k < f(x^k), \forall t \in (0, \hat{t})$$

“ $\Rightarrow$ ”: (反证)若 $\nabla f(x^k)^\top d^k \geq 0$, $f(x^k + td^k) \geq f(x^k) + t \nabla f(x^k)^\top d^k \geq f(x^k), \forall t > 0$, 矛盾。

通用下降方法

1. 给定初始点 $x^0 \in \text{dom } f$, 令 $k = 0$

2. 判断是否停止: 若 $\|\nabla f(x^k)\|_2 \leq \varepsilon$, 停止

3. 确定 x^k 处下降方向 d^k 使满足

$$\exists \hat{t} > 0 \Rightarrow f(x^k + t d^k) < f(x^k), \forall t \in (0, \hat{t})$$

4. 确定步长 $t^k > 0$ 使满足

$$f(x^k + t^k d^k) < f(x^k)$$


5. $x^{k+1} = x^k + t^k d^k$, $k = k + 1$, 回2

• 判断次优性条件

$$\nabla f(x^k)^T d^k < 0$$

• 直线搜索: 决定从直线 $\{x^k + t d^k: t \in \mathbb{R}_+\}$ 上哪一点开始下步迭代 (射线搜索)

• 精确直线搜索和回溯直线搜索。



回顾

$$\min f(x)$$

- 函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$, 连续二阶导数的凸函数
 - 最优解 $x^* = \operatorname{argmin} f(x)$
 - 最优值 $p^* = f(x^*)$
 - 最优性条件 $\nabla f(x^*) = 0$
- 迭代求解 x^*
- 初始点 $x^0 \in \operatorname{dom} f$;
 - 产生序列点 $x^k \in \operatorname{dom} f, k = 0, 1, 2, \dots$, 使得
 - $f(x^k) \rightarrow p^*$;
 - 水平集合 $S = \{x: f(x) \leq f(x^0)\}$ 是闭集;

- 强凸性假设: 存在 $m > 0$ 满足 $\forall x \in$

$$S, \nabla^2 f(x) \geq mI$$

$\forall x, y \in S$

$$f(y) \geq f(x) + \nabla f(x)^\top (y - x) + \frac{m}{2} \|y - x\|_2^2$$

$$f(x) - p^* \leq \frac{1}{2m} \|\nabla f(x)\|_2^2, \quad \|x^* - x\|_2 \leq \frac{2}{m} \|\nabla f(x)\|_2$$

- 假设存在 $M > 0$ 使得 $\forall x \in S$, 有 $\nabla^2 f(x) \leq MI$, 则 $f(x) - p^* \geq \frac{1}{2M} \|\nabla f(x)\|_2^2$

$$\forall x \in S, mI \leq \nabla^2 f(x) \leq MI$$

$$f(x) - \frac{1}{2m} \|\nabla f(x)\|_2^2 \leq p^* \leq f(x) - \frac{1}{2M} \|\nabla f(x)\|_2^2$$

回顾：通用下降方法

$$\min f(x)$$



迭代求解最优性条件 $\nabla f(x^*) = 0$

通用下降算法

1. 给定初始点 $x^0 \in \text{dom } f$, 令 $k = 0$

2. 停止条件 $\|\nabla f(x^k)\|_2 \leq \varepsilon$

3. 确定 x^k 处下降方向 d^k 使满足 $\exists \hat{t} > 0$,

$$f(x^k + td^k) < f(x^k), \forall t \in (0, \hat{t})$$

4. 直线搜索：确定步长 $t^k > 0$ 使

$$f(x^k + t^k d^k) < f(x^k)$$

5. $x^{k+1} = x^k + t^k d^k$, $k = k + 1$, 回2

□ 从初始点 $x^0 \in \text{dom } f$ 出发, 产生一组优化点列

$$x^k, (k = 1, 2, \dots) \text{ 满足 } x^{k+1} = x^k + t^k d^k$$

$$f(x^{k+1}) < f(x^k), x^k \in S = \{x: f(x) \leq f(x^0)\}$$

□ $\forall x \in S, \nabla^2 f(x) \geq mI$,

$$f(x) - p^* \leq \frac{1}{2m} \|\nabla f(x)\|_2^2$$

□ 搜索方向 d^k

为下降方向当且仅当 $\nabla f(x^k)^\top d^k < 0$

□ 射线 $\{x^k + td^k: t \in \mathbb{R}_+\}$ 搜索

✓ 精确直线搜索

✓ 回溯直线搜索

通用下降方法之精确直线搜索

1. 给定初始点 $x^0 \in \text{dom } f$, 令 $k = 0$
2. 判断是否停止: 若 $\|\nabla f(x^k)\|_2 \leq \varepsilon$, 停止
3. 确定 x^k 处下降方向 d^k 使满足

$$\exists \hat{t} > 0 \Rightarrow f(x^k + t d^k) < f(x^k), \forall t \in (0, \hat{t})$$

4. 确定步长 $t^k > 0$ 使满足

$$f(x^k + t^k d^k) < f(x^k)$$

5. 令 $x^{k+1} = x^k + t^k d^k$, $k = k + 1$, 回2

- 精确直线搜索: 步长 t 通过沿着射线 $\{x + t \Delta x: t \geq 0\}$ 优化目标函数 f 而确定

$$t = \operatorname{argmin}_{s \geq 0} f(x^k + s d^k)$$

- 如果解以上单变量优化问题的计算成本小于计算搜索方向的成本时, 适合进行精确直线搜索。

通用下降方法之回溯直线搜索

□ 非精确直线搜索方法：沿着射线 $\{x^k + td^k: t \geq 0\}$ 的近似优化目标函数 f 而确定步长，甚至只要求目标函数 f 有“足够的减少”即可。

1. 给定初始点 $x^0 \in \text{dom } f$ ，令 $k = 0$
2. 判断是否停止：若 $\|\nabla f(x^k)\| \leq \varepsilon$ ，停止
3. 确定 x^k 处下降方向 d^k 使满足

$$\exists \hat{t} > 0 \Rightarrow f(x^k + td^k) < f(x^k), \forall t \in (0, \hat{t})$$

4. 确定步长 $t^k > 0$ 使满足

$$f(x^k + t^k d^k) < f(x^k)$$

5. 令 $x^{k+1} = x^k + t^k d^k$ ， $k \Rightarrow k + 1$ ，回2

回溯直线搜索

- 4.1 给定 f 在 $x \in \text{dom } f$ 处的下降方向 d^k ，参数
 $0 < \alpha < 0.5, 0 < \beta < 1$

- 4.2 $t^k = 1$

- 4.3 **While** $f(x^k + t^k d^k) > f(x^k) + \alpha t^k \nabla f(x^k)^\top d^k$
 $t^k := \beta t^k$
End

□ 回溯直线搜索：从单位步长开始，按比例逐渐缩小，直到满足 $f(x^k + t^k d^k) \leq f(x^k) + \alpha t^k \nabla f(x^k)^\top d^k$

□ d 是下降方向， $\nabla f(x)^\top d < 0$ ，只要 t 足够小，就一定有


$$f(x + td) \approx f(x) + t \nabla f(x)^\top d < f(x) + \alpha t \nabla f(x)^\top d$$

回溯直线搜索
方法终会停止



通用下降方法之回溯直线搜索

f 在待搜索直线上的图像



□ 回溯终止不等式

$$f(x + td) \leq f(x) + \alpha t \nabla f(x)^T d$$

将在区间 $(0, t_0]$ 中的某个 $t \geq 0$ 处被满足

□ 回溯方法停止时，步长 t 满足

$$t = 1, \quad \text{或者} \quad t \in (\beta t_0, t_0]$$

↓
 $t_0 \geq 1$

□ 由回溯直线搜索方法确定的步长

$$t \geq \min\{1, \beta t_0\}$$

注意：实际应用中，先通过用 β 乘以 t 直到 $x + td \in \text{dom } f$ ，再开始检测回溯不等式。

通用下降方法之回溯直线搜索

作业：假设函数 f 是满足 $mI \leq \nabla^2 f(x) \leq MI$ 的强凸函数。令 d 为 x 处的下降方向。证明对于

$$0 < t \leq -\frac{\nabla f(x)^\top d}{M\|d\|_2^2}$$

回溯终止条件能够满足。



回顾：通用下降方法

$$\min f(x)$$



迭代求解最优性条件 $\nabla f(x^*) = 0$

- 从初始点 $x^0 \in \text{dom } f$ 出发，产生一组优化点列 $x^k, (k = 1, 2, \dots)$ 满足

$$x^{k+1} = x^k + t^k d^k, f(x^{k+1}) < f(x^k), x^k \in S = \{x: f(x) \leq f(x^0)\}$$

通用下降算法

1. 给定初始点 $x^0 \in \text{dom } f$ ，令 $k = 0$
2. 停止条件 $\|\nabla f(x^k)\| \leq \varepsilon$
3. 确定 x^k 处下降方向 d^k 使满足 $\exists \hat{t} > 0$,

$$f(x^k + t d^k) < f(x^k), \forall t \in (0, \hat{t})$$

4. 直线搜索：确定步长 $t^k > 0$ 使

$$f(x^k + t^k d^k) < f(x^k)$$

5. $x^{k+1} = x^k + t^k d^k, k = k + 1$ ，回2

- ✓ 搜索方向 d^k 为下降方向当且仅当 $\nabla f(x^k)^\top d^k < 0$;
- ✓ 搜索步长 $t^k \geq 0$ (标量);

➤ 精确直线搜索： $t = \operatorname{argmin}_{s \geq 0} f(x + s d)$

➤ 回溯直线搜索

4.1 $0 < \alpha < 0.5, 0 < \beta < 1, t = 1$

4.2 **While** $f(x + t d^k) > f(x) + \alpha t \nabla f(x)^\top d^k,$
 $t := \beta t$

End

梯度下降方法及收敛性

下降方向满足: $\nabla f(x^k)^T d^k < 0$

1. 给定初始点 $x^0 \in \text{dom } f$, 令 $k = 0$
2. 判断是否停止: 如果 $\|\nabla f(x^k)\|_2 \leq \varepsilon$, 停止
3. $d^k = -\nabla f(x^k)$
4. 直线搜索: 确定 $t^k > 0$ 满足
$$f(x^k + t^k d^k) < f(x^k)$$
5. 更新 $x^{k+1} = x^k + t^k d^k$, $k = k + 1$, 回2

负梯度方向: $d^k = -\nabla f(x^k)$

$$\nabla f(x^k) \neq 0$$

$$\Rightarrow \nabla f(x^k)^T d^k = -\|\nabla f(x^k)\|_2^2 < 0$$

$\Rightarrow$ 负梯度方向为“天然”下降方向



梯度下降方法及收敛性

1. 给定初始点 $x^0 \in \text{dom } f$, 令 $k = 0$
2. 判断是否停止: 如果 $\|\nabla f(x^k)\|_2 \leq \varepsilon$, 停止
3. $d^k = -\nabla f(x^k)$
4. 直线搜索: 确定 $t^k > 0$ 满足

$$f(x^k + t^k d^k) < f(x^k)$$

更新 $x^{k+1} = x^k + t^k d^k$, $k \Rightarrow k + 1$, 回2

➤ 回溯直线搜索

4.1 $0 < \alpha < 0.5, 0 < \beta < 1, t = 1$

4.2 While $f(x + t d^k) > f(x) + \alpha t \nabla f(x)^\top d^k$,
 $t := \beta t$

End

✓ 回溯直线搜索

4.1 $0 < \alpha < 0.5, 0 < \beta < 1, t^k = 1$

4.2 While $f(x^k - t^k \nabla f(x^k)) > f(x^k) - \alpha t^k \|\nabla f(x^k)\|_2^2$,
 $t^k := \beta t^k$

End

✓ 精确直线搜索:

$$t^k = \operatorname{argmin}_{s \geq 0} f(x^k - s \nabla f(x^k))$$

收敛性如何确定?

梯度下降方法及收敛性-精确直线搜索

$$\min f(x)$$



迭代求解最优性条件 $\nabla f(x^*) = 0$

梯度下降精确直线搜索算法

1. 给定初始点 $x^0 \in \text{dom } f$, 令 $k = 0$

2. 停止条件 $\|\nabla f(x^k)\|_2 \leq \varepsilon$

3. $d^k = -\nabla f(x^k)$

4. 精确直线搜索:

$$t^k = \operatorname{argmin}_{s \geq 0} f(x^k + sd^k)$$

5. $x^{k+1} = x^k + t^k d^k$, $k = k + 1$, 回2

□ 负梯度方向 $d^k = -\nabla f(x^k)$ 为“天然”下降方向

$$\nabla f(x^k) d^k = -\|\nabla f(x^k)\|^2 < 0$$

收敛性分析

假设: 存在 m, M 满足 $mI \leq \nabla^2 f(x) \leq MI$ ($\forall x \in S$)

➤ 目标值与最优值间偏差的上界

$$f(x) - p^* \leq \frac{1}{2m} \|\nabla f(x)\|^2$$

与下降方向无关

➤ 每次迭代目标改进值下界

$$f(x^k) - f(x^{k+1}) \geq \frac{1}{2M} \|\nabla f(x^k)\|^2$$

$$f(x^K) - p^* \leq \left(1 - \frac{m}{M}\right)^K (f(x^0) - p^*)$$

几何数列

➤ 算法收敛时, 迭代次数的上界

$$f(x^K) - p^* \leq \varepsilon \Rightarrow K \geq \frac{\log((f(x^0) - p^*)/\varepsilon)}{\log(1/c)}, \text{ 这里 } c = 1 - \frac{m}{M}$$



梯度下降方法及收敛性-精确直线搜索

- 假设 f 是 S 上的强凸函数，因此存在 m, M 满足 $mI \leq \nabla^2 f(x) \leq MI$ ($\forall x \in S$).

梯度下降，采用精确直线搜索： $f(x^k) - f(x^{k+1}) \geq \frac{1}{2M} \|\nabla f(x^k)\|_2^2$

证明：
$$f(x^k - t\nabla f(x^k)) \leq f(x^k) - t\|\nabla f(x^k)\|_2^2 + \frac{Mt^2}{2} \|\nabla f(x^k)\|_2^2$$

梯度下降精确直线搜索：

$$t = \operatorname{argmin}_{s \geq 0} f(x^k - s\nabla f(x^k))$$

两边
同时
关于
 t
求
最小

关于 t 的二次函数求最小：

$$t = \frac{1}{M}$$

$$f(x^{k+1}) \leq f(x^k) - \frac{1}{2M} \|\nabla f(x^k)\|_2^2$$



梯度下降方法及收敛性-精确直线搜索

- 利用目标值和最优值之间偏差的上界: $f(x) - p^* \leq \frac{1}{2m} \|\nabla f(x)\|_2^2$ 及每次迭代目标函数改进值的下界: $f(x^k) - f(x^{k+1}) \geq \frac{1}{2M} \|\nabla f(x^k)\|_2^2$, 有

$$\|\nabla f(x)\|_2^2 \geq 2m(f(x) - p^*)$$

$$\begin{aligned} f(x^k) - p^* &\geq f(x^{k+1}) - p^* + \frac{m}{M} (f(x^k) - p^*) \\ \Rightarrow f(x^{k+1}) - p^* &\leq \left(1 - \frac{m}{M}\right) (f(x^k) - p^*) \end{aligned}$$

$$\Rightarrow f(x^K) - p^* \leq \left(1 - \frac{m}{M}\right)^K (f(x^0) - p^*)$$

$$0 < 1 - \frac{m}{M} < 1$$

$$f(x^K) \rightarrow p^* \text{ as } K \rightarrow \infty$$

$$f(x^K) - p^* \leq \varepsilon \Rightarrow K \geq \frac{\log((f(x^0) - p^*)/\varepsilon)}{|\log(1 - \frac{m}{M})|}$$

迭代次数的上界: 至多经过 K 次迭代可满足 $f(x^K) - p^* \leq \varepsilon$



梯度下降方法及收敛性-精确直线搜索

精确直线搜索的梯度下降方法迭代次数的上界

$$K \geq \frac{\log((f(x^0) - p^*)/\varepsilon)}{|\log(1 - \frac{m}{M})|}$$

分子: 初始次优性和最终次优性的比值的对数

分母: $|\log(1 - \frac{m}{M})| = -\log(1 - \frac{m}{M}) \approx \frac{m}{M}$

- 初始次优性: $\log((f(x^0) - p^*)/\varepsilon)$, 即 $f(x^0)$ 和最优值 p^* 之间的缺口;
- 最终次优性: $f(x^K) - p^* \leq \varepsilon$, 即 $f(x^K)$ 和最优值 p^* 之间的缺口;
- 所需要迭代次数依赖于初始点的质量和最终解的精度要求;
- 迭代次数的上界将随着 $\frac{M}{m}$ 的增大而近似线性的增大。



梯度下降方法及收敛性-精确直线搜索

$$\min f(x)$$



迭代求解最优性条件 $\nabla f(x^*) = 0$

梯度下降精确直线搜索算法

1. 给定初始点 $x^0 \in \text{dom } f$, 令 $k = 0$

2. 停止条件 $\|\nabla f(x^k)\|_2 \leq \varepsilon$

3. $d^k = -\nabla f(x^k)$

4. 精确直线搜索:

$$t^k = \operatorname{argmin}_{s \geq 0} f(x^k + sd^k)$$

5. $x^{k+1} = x^k + t^k d^k$, $k = k + 1$, 回2

✓ 负梯度方向 $d^k = -\nabla f(x^k)$ 为“天然”下降方向

$$\nabla f(x^k) d^k = -\|\nabla f(x^k)\|^2 < 0$$

✓ 收敛性分析

假设: 存在 m, M 满足 $mI \leq \nabla^2 f(x) \leq MI$ ($\forall x \in S$)

➤ 目标值与最优值间偏差的上界

$$f(x) - p^* \leq \frac{1}{2m} \|\nabla f(x)\|^2$$

与下降方向无关

➤ 每次迭代目标改进值下界

$$f(x^k) - f(x^{k+1}) \geq \frac{1}{2M} \|\nabla f(x^k)\|^2$$

$$f(x^K) - p^* \leq \left(1 - \frac{m}{M}\right)^K (f(x^0) - p^*)$$

几何数列

➤ 算法收敛时, 迭代次数的上界

$$f(x^K) - p^* \leq \varepsilon \Rightarrow K \geq \frac{\log((f(x^0) - p^*)/\varepsilon)}{\log(1/c)}, \text{ 这里 } c = 1 - \frac{m}{M}$$



梯度下降方法及收敛性-回溯直线搜索

$$\min f(x)$$



迭代求解最优性条件 $\nabla f(x^*) = 0$

梯度下降回溯直线搜索算法

1. 给定初始点 $x^0 \in \text{dom } f$, 令 $k = 0$

2. 停止条件 $\|\nabla f(x^k)\| \leq \varepsilon$

3. $d^k = -\nabla f(x^k)$

4. 回溯直线搜索: $0 < \alpha < 0.5$, $0 < \beta < 1$, $t^k = 1$

While $f(x^k + t^k d^k) > f(x^k) + \alpha t^k \nabla f(x^k)^\top d^k$,

$$t^k := \beta t^k$$

End

5. $x^{k+1} = x^k + t^k d^k$, $k = k + 1$, 回2

✓ 收敛性分析

假设: 存在 m, M 满足 $mI \leq \nabla^2 f(x) \leq MI$ ($\forall x \in S$)

➤ 目标值与最优值间偏差的上界

$$f(x) - p^* \leq \frac{1}{2m} \|\nabla f(x)\|_2^2$$

➤ 每次迭代目标改进值下界

$$f(x^{k+1}) \leq f(x^k) - \min\{\alpha, \frac{\beta\alpha}{M}\} \|\nabla f(x^k)\|_2^2$$

➤ 算法收敛时, 迭代次数的上界

$$f(x^K) - p^* \leq \varepsilon \implies K \geq \frac{\log((f(x^0) - p^*)/\varepsilon)}{\log(1/c)}$$

$$\text{这里, } c = \left(1 - \min\left\{2m\alpha, \frac{2\beta\alpha m}{M}\right\}\right)$$



梯度下降方法及收敛性-回溯直线搜索

□ 梯度下降方法中采用回溯直线搜索时，只要 $0 \leq t \leq \frac{1}{M}$ 就能满足回溯停止条件


$$f(x^k - t \nabla f(x^k)) \leq f(x^k) - \alpha t \|\nabla f(x^k)\|_2^2$$

证明：

$$\begin{aligned} f(x^k - t \nabla f(x^k)) &\leq f(x^k) - t \|\nabla f(x^k)\|_2^2 + \frac{M t^2}{2} \|\nabla f(x^k)\|_2^2 \\ &\leq f(x^k) - \frac{t}{2} \|\nabla f(x^k)\|_2^2 \quad \Leftarrow 0 \leq t \leq \frac{1}{M} \\ &\leq f(x^k) - \alpha t \|\nabla f(x^k)\|_2^2 \quad \Leftarrow \alpha \in \left(0, \frac{1}{2}\right) \end{aligned}$$

回溯方法停止时，步长 t 满足 $t = 1$ ，或者 $t \in (\beta t_0, t_0]$

f 在待搜索直线上的图像



推论：梯度下降方法中，回溯直线搜索将终止于 $t = 1$ 或者 $t \geq \frac{\beta}{M}$ 。

梯度下降方法及收敛性-回溯直线搜索

- 梯度下降方法中回溯直线搜索将终止于 $t = 1$ 或者 $t \geq \frac{\beta}{M}$

✓ $t = 1$ 时, $f(x^{k+1}) \leq f(x^k) - \alpha \|\nabla f(x^k)\|_2^2$

✓ $t \geq \frac{\beta}{M}$ 时, $f(x^{k+1}) \leq f(x^k) - \frac{\beta\alpha}{M} \|\nabla f(x^k)\|_2^2$

- 梯度下降方法回溯直线搜索时

$$f(x^{k+1}) \leq f(x^k) - \min\{\alpha, \frac{\beta\alpha}{M}\} \|\nabla f(x^k)\|_2^2$$

$$f(x^{k+1}) - p^* \leq f(x^k) - p^* - \min\{\alpha, \frac{\beta\alpha}{M}\} \|\nabla f(x^k)\|_2^2$$

$$f(x^k) - p^* \leq \frac{1}{2m} \|\nabla f(x^k)\|_2^2$$

$$f(x^{k+1}) - p^* \leq \left(1 - \min\left\{2m\alpha, \frac{2\beta\alpha m}{M}\right\}\right) (f(x^k) - p^*)$$

$$1 - \min\left\{2m\alpha, \frac{2\beta\alpha m}{M}\right\} < 1$$

$$f(x^k) - p^* \leq \left(1 - \min\left\{2m\alpha, \frac{2\beta\alpha m}{M}\right\}\right)^k (f(x^0) - p^*)$$

4. 回溯直线搜索: $0 < \alpha < 0.5, 0 < \beta < 1, t^k = 1$

While $f(x^k + t^k d^k) > f(x^k) + \alpha t^k \nabla f(x^k)^\top d^k,$

$$t^k := \beta t^k$$

End

几何数列



梯度下降方法及收敛性-回溯直线搜索

- 利用目标函数值和最优值间偏差的上界 $f(x) - p^* \leq \frac{1}{2m} \|\nabla f(x^k)\|_2^2$ 及每次迭代目标函数改进值的下界 $f(x^{k+1}) \leq f(x^k) - \min\{\alpha, \frac{\beta\alpha}{M}\} \|\nabla f(x^k)\|_2^2$, 有

$$f(x^k) - p^* \leq \left(1 - \min\left\{2m\alpha, \frac{2\beta\alpha m}{M}\right\}\right)^k (f(x^0) - p^*)$$

- 算法收敛时, 迭代次数的上界

$$f(x^K) - p^* \leq \varepsilon \implies K \geq \frac{\log((f(x^0) - p^*)/\varepsilon)}{\log(1/c)} \quad \text{这里, } c = \left(1 - \min\left\{2m\alpha, \frac{2\beta\alpha m}{M}\right\}\right)$$

梯度下降方法及收敛性

$$\min f(x)$$



迭代求解最优性条件 $\nabla f(x^*) = 0$

- 从初始点 $x^0 \in \text{dom } f$ 出发, 产生一组优化点列 $x^k, (k = 1, 2, \dots)$ 满足

$$x^{k+1} = x^k + t^k d^k, f(x^{k+1}) < f(x^k), x^k \in S = \{x: f(x) \leq f(x^0)\}$$

梯度下降算法

1. 给定初始点 $x^0 \in \text{dom } f$, 令 $k = 0$

2. 停止条件 $\|\nabla f(x^k)\| \leq \varepsilon$

3. 下降方向 $d^k = -\nabla f(x^k)$

4. 直线搜索: 确定 $t^k > 0$ 使得

$$f(x^k + t^k d^k) < f(x^k)$$

5. $x^{k+1} = x^k + t^k d^k, k = k + 1$, 回2

收敛性分析

假设: 存在 m, M 满足 $mI \leq \nabla^2 f(x) \leq MI (\forall x \in S)$

使 $f(x^K) - p^* \leq \varepsilon$ 成立的 K 只需要满足以下条件:

$$f(x^K) - p^* \leq \varepsilon \implies K \geq \frac{\log((f(x^0) - p^*)/\varepsilon)}{\log(1/c)}$$

✓ 采用精确直线搜索时 $c = 1 - \frac{m}{M}$

✓ 采用回溯直线搜索时 $c = \left(1 - \min\left\{2m\alpha, \frac{2\beta\alpha m}{M}\right\}\right)$

例1 两个变量的二次规划问题: $\min f(x) = \frac{1}{2}(x_1^2 + \gamma x_2^2)$, $\gamma > 0$, 最优解 $x^* = (0,0)$ 。

- 其Hessian矩阵 $\nabla^2 f(x)$ 是常值, 其特征值为1和 γ , 则 $\frac{M}{m} = \frac{\max\{1,\gamma\}}{\min\{1,\gamma\}} = \max\left\{\gamma, \frac{1}{\gamma}\right\}$
- 采用精确直线搜索梯度下降: 选初始值 $x^0 = (\gamma, 1)$, 第 k 次迭代时 $\nabla f(x^k) = \begin{bmatrix} x_1^k \\ \gamma x_2^k \end{bmatrix}$
- 确定精确搜索下降步长: $t = \arg\min_{t>0} f(x^k - t\nabla f(x^k)) = \frac{2}{1+\gamma}$

$$x^k = x^{k-1} - t\nabla f(x^{k-1})$$

$$= \begin{bmatrix} (1-t)x_1^{k-1} \\ (1-\gamma t)x_2^{k-1} \end{bmatrix}$$

$$= \left(\frac{\gamma-1}{\gamma+1}\right) \begin{bmatrix} x_1^{k-1} \\ -x_2^{k-1} \end{bmatrix}$$

$$= \left(\frac{\gamma-1}{\gamma+1}\right)^k \begin{bmatrix} \gamma \\ (-1)^k \end{bmatrix}$$

$$x_1^k = \gamma \left(\frac{\gamma-1}{\gamma+1}\right)^k$$

$$x_2^k = \left(-\frac{\gamma-1}{\gamma+1}\right)^k$$

$$f(x^k) = \frac{\gamma(\gamma+1)}{2} \left(\frac{\gamma-1}{\gamma+1}\right)^{2k} = \left(\frac{\gamma-1}{\gamma+1}\right)^{2k} f(x^0)$$


每次迭代
收缩因子



例1 两个变量的二次规划问题： $\min f(x) = \frac{1}{2}(x_1^2 + \gamma x_2^2)$ ， $\gamma > 0$ ，最优解 $x^* = (0,0)$ 。

$$x^k = \left(\frac{\gamma - 1}{\gamma + 1}\right)^k \begin{bmatrix} \gamma \\ (-1)^k \end{bmatrix}$$

- 其Hessian矩阵 $\nabla^2 f(x)$ 是常值，其特征值为1和 γ ，则 $\frac{M}{m} = \frac{\max\{1, \gamma\}}{\min\{1, \gamma\}} = \max\left\{\gamma, \frac{1}{\gamma}\right\}$
- $\gamma = 1$ 时，一次迭代可得到最优解；
- 对于 γ 离1不远的情况，如 $\frac{1}{3}$ 和3之间，收敛速度很快
- 如果 $\gamma \gg 1$ 或 $\gamma \ll 1$ 时，收敛速度将会非常慢



$\gamma = 10$ 时迭代过程


作业：编程证明以上结论

例2 $\mathbb{R}^2$ 空间非二次规划问题


$$\min f(x) = e^{x_1+3x_2-0.1} + e^{x_1-3x_2-0.1} + e^{-x_1-0.1}$$

- 回溯直线搜索梯度方法, 令 $\alpha = 0.1$, $\beta = 0.7$


$$x^{k+1} = x^k - t^k \nabla f(x^k)$$



回溯直线搜索梯度方法目标函数迭代过程



精确直线搜索梯度方法目标函数迭代过程




直线搜索的迭代误差随迭代次数改变

例3

$\mathbb{R}^{100}$ 维空间优化问题

$$\min f(x) = c^T x - \sum_{i=1}^{500} \log(b_i - a_i^T x), \quad x \in \mathbb{R}^{100}$$

- ✓ 回溯直线搜索 $\alpha = 0.1, \beta = 0.5$;
- ✓ 精确直线搜索



直线搜索的迭代误差随迭代次数改变

关于梯度下降法算法的若干结论

- 梯度方法通常呈现近似线性收敛性质，即误差 $f(x^k) - p^*$ 以类似于几何数列的方式收敛于零。
- 回溯参数 α, β 的取值对收敛性有明显的影响，但不会产生戏剧性效果。
- 精确直线搜索有时可以改变梯度方法的收敛性，但是效果不是很大。实际上，其或许不能抵消进行精确直线搜索增加的计算量；
- 收敛速度强烈依赖于Hessian矩阵的条件数，即其最小最大特征根的比值。



大作业

对于 $\mathbb{R}^2$ 空间非二次规划问题 $\min f(x) = e^{x_1+3x_2-0.1} + e^{x_1-3x_2-0.1} + e^{-x_1-0.1}$ ，使用梯度下降方法求解，分析：

- (1) 精确直线搜索时，目标函数值随迭代次数改变的情况
- (2) 回溯直线搜索时，设置不同的 α, β 值，目标函数值随迭代次数改变的情况

注：初始值相同。

通用下降方法

$$\min f(x)$$



迭代求解最优性条件 $\nabla f(x^*) = 0$

1. 给定初始点 $x^0 \in \text{dom } f$, 令 $k = 0$

2. 判断: 若 $\|\nabla f(x^k)\| \leq \varepsilon$, 停止

3. 计算 x^k 处的下降方向: 确定 d^k 满足

$$\exists \hat{t} > 0 \Rightarrow f(x^k + td^k) < f(x^k), \forall t \in (0, \hat{t})$$

4. 直线搜索: 确定 $t^k > 0$ 满足

$$f(x^k + t^k d^k) < f(x^k)$$

$$\text{令 } x^{k+1} = x^k + t^k d^k, k \Rightarrow k + 1, \text{ 回2}$$

$$x^{k+1} = x^k + t^k d^k$$

下降方向满足

$$\nabla f(x^k)^T d^k < 0$$

✓ 负梯度方向 $d^k = -\nabla f(x^k)$ 为
“天然”下降方向



最速下降方法

$$x^{k+1} = x^k + t^k d^k$$

对 $f(x + v)$ 在 x 处一阶Taylor展开,

$$f(x + v) \approx f(x) + \nabla f(x)^\top v$$

如何选择步径 v 使其方向导数尽可能的小?

- 方向导数: $\nabla f(x)^\top v$ 称为 f 在 x 处沿步径 v 的方向导数;
- 方向导数近似的给出了 f 沿着步径 v 会发生的变化;
- 若方向导数为负数 $\nabla f(x)^\top v < 0$, 步径 v 就是下降方向。

- 方向导数 $\nabla f(x)^\top v$ 是 v 的线性函数, 在 v 是下降方向的前提下, 将 v 取的充分大, 就可以使其方向导数充分小。

$$\nabla f(x)^\top v < 0$$

规范 v 的长度



规范化最速下降方法



最速下降方向唯一吗？

对 $f(x + v)$ 在 x 处一阶Taylor展开,

$$f(x + v) \approx f(x) + \nabla f(x)^\top v$$

□ 规范化的最速下降方向：一个能使目标函数的线性近似下降最多的具有单位范数的步径

$$d_{nsd}^k = \arg \min_d \{ \nabla f(x^k)^\top d : \|d\| = 1 \} \cdot \cdot \cdot$$

可能有多个最优解

□ d_{nsd}^k 是否为下降方向？

$$\nabla f(x^k) \neq 0 \implies \nabla f(x^k)^\top d_{nsd}^k < \nabla f(x^k)^\top \frac{-\nabla f(x^k)}{\|\nabla f(x^k)\|} \cdot \cdot \cdot$$

$$= -\frac{\|\nabla f(x^k)\|_2^2}{\|\nabla f(x^k)\|} < 0$$

$$\left\| \frac{-\nabla f(x^k)}{\|\nabla f(x^k)\|} \right\| = 1$$

$\implies d_{nsd}^k$ 是下降方向！

回顾——梯度下降方法及收敛性

$$\min f(x)$$



迭代求解最优性条件 $\nabla f(x^*) = 0$

- 从初始点 $x^0 \in \text{dom } f$ 出发, 产生一组优化点列 $x^k, (k = 1, 2, \dots)$ 满足

$$x^{k+1} = x^k + t^k d^k, f(x^{k+1}) < f(x^k), x^k \in S = \{x: f(x) \leq f(x^0)\}$$

梯度下降算法

1. 给定初始点 $x^0 \in \text{dom } f$, 令 $k = 0$

2. 停止条件 $\|\nabla f(x^k)\| \leq \varepsilon$

3. 下降方向 $d^k = -\nabla f(x^k)$

4. 直线搜索: 确定 $t^k > 0$ 使得

$$f(x^k + t^k d^k) < f(x^k)$$

5. $x^{k+1} = x^k + t^k d^k, k = k + 1$, 回2

收敛性分析

假设: 存在 m, M 满足 $mI \leq \nabla^2 f(x) \leq MI (\forall x \in S)$

使 $f(x^K) - p^* \leq \varepsilon$ 成立的 K 只需要满足以下条件:

$$f(x^K) - p^* \leq \varepsilon \implies K \geq \frac{\log((f(x^0) - p^*)/\varepsilon)}{\log(1/c)}$$

✓ 采用精确直线搜索时 $c = 1 - \frac{m}{M}$

✓ 采用回溯直线搜索时 $c = \left(1 - \min\left\{2m\alpha, \frac{2\beta\alpha m}{M}\right\}\right)$



规范化最速下降方法

对 $f(x + v)$ 在 x 处一阶Taylor展开,

$$f(x + v) \approx f(x) + \nabla f(x)^T v$$

- **方向导数**: $\nabla f(x)^T v$ 称为 f 在 x 处沿方向 v 的方向导数
- 方向导数近似的给出了 f 沿着步径 v 会发生的变化
- 若方向导数为负数 $\nabla f(x)^T v < 0$, 步径 v 就是下降方向

□ **规范化的最速下降方向**: 一个能使目标函数的线性近似下降最多的具有单位范数的步径

$$d_{nsd}^k = \arg \min_d \{ \nabla f(x^k)^T d : \|d\| = 1 \}$$

可能有多个最优解

□ d_{nsd}^k 是否为下降方向?

$$\nabla f(x^k) \neq 0 \implies \nabla f(x^k)^T d_{nsd}^k < \nabla f(x^k)^T \frac{-\nabla f(x^k)}{\|\nabla f(x^k)\|}$$

$$= -\|\nabla f(x^k)\| < 0$$

$\implies d_{nsd}^k$ 是下降方向!

$$\left\| \frac{-\nabla f(x^k)}{\|\nabla f(x^k)\|} \right\| = 1$$



回顾——范数的对偶

$$\begin{aligned} \max_x \quad & z^T x \\ \text{s.t.} \quad & \|x\|_1 \leq 1 \end{aligned}$$


□ 例子2: ℓ_1 范数对偶: $\|z\|_* = \sup \{z^T x: \|x\|_1 = 1\}$

- 当向量 $z = (z_1, z_2)$ 在实线位置。两个向量的内积最大时，向量 $x = (1, 0)$ ，则

$$z^T x = \|z\|_2 \|x\|_2 \cos \theta = \|z\|_2 \cos \theta = z_1$$

- 当向量 $z = (z_1, z_2)$ 在虚线位置。两个向量的内积最大时，向量 $x = (0, 1)$ ，则

$$z^T x = \|z\|_2 \|x\|_2 \cos \theta = \|z\|_2 \cos \theta = z_2$$



- ✓ ℓ_1 范数的对偶范数为 ℓ_∞ 范数: 即 $\|z\|_* = \sup \{z^T x: \|x\|_1 = 1\} = \max \{z_1, z_2\} = \|z\|_\infty$;
- ✓ ℓ_∞ 范数的对偶范数为 ℓ_1 范数: 即 $\|z\|_* = \sup \{z^T x: \|x\|_\infty = 1\} = \|z\|_1$;
- ✓ ℓ_p 范数的对偶范数为 ℓ_q 范数 ($p, q \geq 1$): 即 $\|z\|_* = \sup \{z^T x: \|x\|_p = 1\} = \|z\|_q$ 当且仅当 $\frac{1}{p} + \frac{1}{q} = 1$

规范化最速下降方法

$$\min f(x)$$



迭代求解最优性条件 $\nabla f(x^*) = 0$

1. 给定初始点 $x^0 \in \text{dom } f$, 令 $k = 0$
2. 判断: 如果 $\|\nabla f(x^k)\| \leq \varepsilon$, 停止
3. $d_{nsd}^k = \arg \min \left\{ \nabla f(x^k)^\top d \mid s.t. \|d\| = 1 \right\}$

4. 直线搜索: 确定 $t^k > 0$ 满足
$$f(x^k + t^k d^k) < f(x^k)$$

更新 $x^{k+1} = x^k + t^k d^k, k \Rightarrow k + 1$, 回2

✓ 回溯直线搜索

- 4.1 给定 f 在 $x \in \text{dom } f$ 处的下降方向 d^k , 参数

$$0 < \alpha < 0.5, 0 < \beta < 1$$

- 4.2 $t^k = 1$

- 4.3 **While** $f(x^k + t^k d^k) > f(x^k) + \alpha t^k \nabla f(x^k)^\top d^k$
 $t^k := \beta t^k$

End

✓ 精确直线搜索

$$t^k = \arg \min_{s \geq 0} f(x^k + s d^k)$$



非规范化最速下降方向

□ 规范化最速下降方向: $d_{nsd}^k = \arg \min \{ \nabla f(x^k)^\top d : \|d\| = 1 \}$

□ $\nabla f(x^k)^\top d_{nsd}^k = - \|\nabla f(x^k)\|_*$

对偶范数: $\|z\|_* = \sup \{ z^\top x : \|x\| = 1 \}$

□ 非规范化的最速下降方向 d_{sd}^k : 规范化最速下降方向乘以一个特殊的比例因子 $\|\nabla f(x^k)\|_*$

$$d_{sd}^k = \|\nabla f(x^k)\|_* \times d_{nsd}^k = \|\nabla f(x^k)\|_* \times \arg \min \{ \nabla f(x^k)^\top d : \|d\| = 1 \}$$

□ d_{sd}^k 是否为下降方向?

$$\nabla f(x^k)^\top d_{sd}^k = \|\nabla f(x^k)\|_* \nabla f(x^k)^\top d_{nsd}^k = - \|\nabla f(x^k)\|_*^2 < 0 \Rightarrow \text{下降方向!}$$



最速下降方法

$$\min f(x)$$



迭代求解最优性条件 $\nabla f(x^*) = 0$

非规范化最速下降算法

1. 给定初始点 $x^0 \in \text{dom } f$, 令 $k = 0$
2. 判断: 如果 $\|\nabla f(x^k)\| \leq \varepsilon$, 停止
3. $d_{sd}^k = \|\nabla f(x^k)\|_*^{-1} \times \arg \min \{\nabla f(x^k)^\top d : \|d\| = 1\}$
4. 直线搜索: 确定 $t^k > 0$ 满足
$$f(x^k + t^k d_{sd}^k) < f(x^k)$$
5. $x^{k+1} = x^k + t^k d_{sd}^k, k = k + 1$, 回2

规范化最速下降算法

1. 给定初始点 $x^0 \in \text{dom } f$, 令 $k = 0$
2. 判断: 如果 $\|\nabla f(x^k)\| \leq \varepsilon$, 停止
3. $d_{nsd}^k = \arg \min \{\nabla f(x^k)^\top d \mid s.t. \|d\| = 1\}$
4. 直线搜索: 确定 $t^k > 0$ 满足
$$f(x^k + t^k d_{nsd}^k) < f(x^k)$$
5. $x^{k+1} = x^k + t^k d_{nsd}^k, k = k + 1$, 回2

□ 若采用精确直线搜索方法

$$t^k = \operatorname{argmin}_{s \geq 0} f(x^k + s d_{sd}^k), \quad t^k = \operatorname{argmin}_{s \geq 0} f(x^k + s d_{nsd}^k)$$

下降方向的比例因子不起作用, 从而规范化和非规范化最速下降方向所起效果相同。



采用Euclid范数的最速下降方向

□ 采用Euclid范数的最速下降方向

$$✓ d_{nsd}^k = \arg \min \{ \nabla f(x^k)^\top d : \|d\|_2 = 1 \}$$

$$= - \arg \max \{ \nabla f(x^k)^\top d : \|d\|_2 = 1 \}$$
$$= - \frac{\nabla f(x^k)}{\|\nabla f(x^k)\|_2}$$

$$\|z\|_* = \sup \{ z^\top x : \|x\|_2 = 1 \} = \|z\|_2$$

$$\|\nabla f(x^k)\|_* = - \|\nabla f(x^k)\|_2$$

$$✓ d_{sd}^k = \|\nabla f(x^k)\|_* d_{nsd}^k = \|\nabla f(x^k)\|_2 d_{nsd}^k = - \nabla f(x^k)$$

✓ 将 $\|\cdot\|$ 取为Euclid范数时，最速下降方向就是负梯度方向

✓ 负梯度方向是一种特殊的最速下降方向

采用 ℓ_1 范数的最速下降方向

$$\|z\|_* = \sup \{z^T x: \|x\|_1 = 1\} = \|z\|_\infty$$

□ 采用 ℓ_1 -范数的规范化最速下降方向

$$d_{nsd}^k = \arg \min \{ \nabla f(x^k)^T d: \|d\|_1 = 1 \} = - \arg \max \{ \nabla f(x^k)^T d: \|d\|_1 = 1 \}$$

令 i 满足 $\|\nabla f(x^k)\|_\infty = |(\nabla f(x^k))_i|$, 则

$$d_{nsd}^k = - \operatorname{sign} \left(\frac{\partial f(x^k)}{\partial x_i} \right) e_i$$

第 i 个标准基向量

$$d_{sd}^k = \|\nabla f(x^k)\|_\infty d_{nsd}^k = - \frac{\partial f(x^k)}{\partial x_i} e_i$$

每次迭代只有 x 的一个分量被修改, 称为坐标下降算法

- ℓ_1 -范数下的规范化最速下降步径总能选为某个标准基向量 (某个负的标准基向量)
- ℓ_1 -范数下最速下降算法每步迭代, 选 $\nabla f(x^k)$ 绝对值最大的分量, 然后根据其符号减少或增加 x^k 的对应分量。

采用二次范数的最速下降方向

$$\|z\|_P = (z^T P z)^{1/2} = \|P^{1/2} z\|_2$$
$$\|z\|_* = \sup \{z^T x : \|x\|_P = 1\} = \|P^{-1/2} z\|_2$$

□ 采用二次范数的规范化最速下降方向

$$d_{nsd}^k = \arg \min \{ \nabla f(x^k)^T d : \|d\|_P = 1 \} = - \arg \max \{ \nabla f(x^k)^T d : \|d\|_P = 1 \}$$
$$= - \left(\nabla f(x^k)^T P^{-1} \nabla f(x^k) \right)^{-1/2} P^{-1} \nabla f(x^k)$$

□ 采用二次范数的非规范化最速下降方向

$$d_{sd}^k = \|\nabla f(x^k)\|_* d_{nsd}^k = - P^{-1} \nabla f(x^k)$$

✓ 令 $\bar{u} = P^{1/2} u$, 则有 $\|u\|_P = \|\bar{u}\|_2$, 定义 $\bar{f}(\bar{u}) = f(P^{-1/2} \bar{u}) = f(u)$, 则 $\bar{f}$ 在 $\bar{x}^k$ 处的负梯度方向为

$$\bar{d}^k = - \nabla \bar{f}(\bar{x}^k) = - P^{-1/2} \nabla f(P^{-1/2} \bar{x}^k) = - P^{-1/2} \nabla f(x^k)$$

✓ 负梯度方向 $\bar{d}^k$ 对应于原变量 x 处的直线搜索方向

$$d^k = P^{-1/2} \bar{d}^k = P^{-1/2} (- P^{-1/2} \nabla f(x^k)) = - P^{-1} \nabla f(x^k)$$

二次范数 $\|\cdot\|_P$ 下的最速下降方向为对原问题进行坐标变换 $\bar{x} = P^{1/2} x$ 后的梯度方向

最速下降方法收敛性分析-以回溯直线搜索为例

$$\min f(x)$$



迭代求解最优性条件 $\nabla f(x^*) = 0$

非规范化最速下降算法-回溯直线搜索

1. 给定初始点 $x^0 \in \text{dom } f$, 令 $k = 0$

2. 判断: 如果 $\|\nabla f(x^k)\|_2 \leq \varepsilon$, 停止

3. $d_{sd}^k = \|\nabla f(x^k)\|_* \times \arg \min \{\nabla f(x^k)^\top d: \|d\| = 1\}$

4. 回溯直线搜索: $0 < \alpha < 0.5$, $0 < \beta < 1$, $t^k = 1$

While $f(x^k + t^k d_{sd}^k) > f(x^k) + \alpha t^k \nabla f(x^k)^\top d_{sd}^k$,

$$t^k := \beta t^k$$

End

5. $x^{k+1} = x^k + t^k d^k$, $k = k + 1$, 回2

假设:

✓ 存在 m, M 满足 $mI \leq \nabla^2 f(x) \leq MI$ ($\forall x \in S$)

✓ 存在常数 $\gamma, \tilde{\gamma} \in (0, 1]$, 使得 $\|x\| \geq \gamma \|x\|_2$, $\|x\|_* \geq \tilde{\gamma} \|x\|_2$

➤ 目标值与最优值间偏差的上界

$$f(x) - p^* \leq \frac{1}{2m} \|\nabla f(x)\|_2^2$$

➤ 每次迭代目标改进值下界

$$f(x^{k+1}) \leq f(x^k) - \alpha \tilde{\gamma}^2 \min \left\{ 1, \frac{\beta \gamma^2}{M} \right\} \|\nabla f(x^k)\|_2^2$$

➤ 算法收敛时, 迭代次数的上界

$$f(x^K) - p^* \leq \varepsilon \Rightarrow K \geq \frac{\log((f(x^0) - p^*)/\varepsilon)}{\log(1/c)}$$

$$\text{这里, } c = 1 - 2m\alpha\tilde{\gamma}^2 \min \left\{ 1, \frac{\beta \gamma^2}{M} \right\} < 1$$



最速下降方法收敛性分析-以回溯直线搜索为例

✓ 存在 m, M 满足 $mI \leq \nabla^2 f(x) \leq MI$ ($\forall x \in S$)

✓ 存在常数 $\gamma, \tilde{\gamma} \in (0, 1]$, 使得 $\|x\| \geq \gamma \|x\|_2$, $\|x\|_* \geq \tilde{\gamma} \|x\|_2$

$$\begin{aligned} f(x^k + t d_{sd}^k) &\leq f(x^k) + t \nabla f(x^k)^\top d_{sd}^k + \frac{M \|d_{sd}^k\|_2^2}{2} t^2 \\ &\leq f(x^k) + t \nabla f(x^k)^\top d_{sd}^k + \frac{M \|d_{sd}^k\|^2}{2 \gamma^2} t^2 \\ &= f(x^k) - t \|\nabla f(x^k)\|_*^2 + \frac{M t^2}{2 \gamma^2} \|\nabla f(x^k)\|_*^2 \end{aligned}$$

$$\begin{aligned} f(x^k + t_{min} d_{sd}^k) &\leq f(x^k) - \frac{1}{2} t_{min} \|\nabla f(x^k)\|_*^2 \\ &\leq f(x^k) + \alpha t_{min} \nabla f(x^k)^\top d_{sd}^k \end{aligned}$$

$$t_{min} = \frac{\gamma^2}{M}$$

$$\alpha < \frac{1}{2}$$

$$\nabla f(x^k)^\top d_{sd}^k = - \|\nabla f(x^k)\|_*^2$$

$$\begin{aligned} \|d_{sd}^k\| &= \|\|\nabla f(x^k)\|_* \times d_{nsd}^k\| \\ &= \|\nabla f(x^k)\|_* \|d_{nsd}^k\| \\ &= \|\nabla f(x^k)\|_* \end{aligned}$$

□ 回溯直线搜索停止 $t \geq \min\left\{1, \frac{\beta \gamma^2}{M}\right\}$ 时, 有

$$f(x^{k+1}) = f(x^k + t d_{sd}^k) \leq f(x^k) - \alpha \min\left\{1, \frac{\beta \gamma^2}{M}\right\} \|\nabla f(x^k)\|_*^2 \leq f(x^k) - \alpha \tilde{\gamma}^2 \min\left\{1, \frac{\beta \gamma^2}{M}\right\} \|\nabla f(x^k)\|_2^2$$



最速下降方法收敛性分析-以回溯直线搜索为例

□ 回溯直线搜索停止: $t \geq \min\left\{1, \frac{\beta\gamma^2}{M}\right\}$ 时, 有

$$f(x^{k+1}) = f(x^k + td_{sd}^k) \leq f(x^k) - \alpha\tilde{\gamma}^2 \min\left\{1, \frac{\beta\gamma^2}{M}\right\} \|\nabla f(x^k)\|_2^2$$

$$f(x^{k+1}) - p^* \leq f(x^k) - p^* - \alpha\tilde{\gamma}^2 \min\left\{1, \frac{\beta\gamma^2}{M}\right\} \|\nabla f(x^k)\|_2^2$$

$$f(x^k) - p^* \leq \frac{1}{2m} \|\nabla f(x^k)\|_2^2$$

$$f(x^{k+1}) - p^* \leq \left(1 - 2m\alpha\tilde{\gamma}^2 \min\left\{1, \frac{\beta\gamma^2}{M}\right\}\right) (f(x^k) - p^*)$$

$$c = 1 - 2m\alpha\tilde{\gamma}^2 \min\left\{1, \frac{\beta\gamma^2}{M}\right\} < 1$$

$$f(x^k) - p^* \leq c^k (f(x^0) - p^*)$$

几何数列
线性收敛

最速下降方法收敛性分析-以回溯直线搜索为例

- ✓ 存在 m, M 满足 $mI \leq \nabla^2 f(x) \leq MI$ ($\forall x \in S$)
- ✓ 存在常数 $\gamma, \tilde{\gamma} \in (0, 1]$, 使得 $\|x\| \geq \gamma\|x\|_2, \|x\|_* \geq \tilde{\gamma}\|x\|_2$

□ 利用目标函数值和最优值间偏差的上界 $f(x) - p^* \leq \frac{1}{2m} \|\nabla f(x)\|_2^2$, 及每次迭代目标函数改进值的下界 $f(x^k + td_{sd}^k) \leq f(x^k) - \alpha\tilde{\gamma}^2 \min\left\{1, \frac{\beta\gamma^2}{M}\right\} \|\nabla f(x^k)\|_2^2$, 有

$$f(x^k) - p^* \leq \left(1 - 2m\alpha\tilde{\gamma}^2 \min\left\{1, \frac{\beta\gamma^2}{M}\right\}\right)^k (f(x^0) - p^*)$$

□ 算法收敛时, 迭代次数的上界

$$f(x^K) - p^* \leq \varepsilon \implies K \geq \frac{\log((f(x^0) - p^*)/\varepsilon)}{\log(1/c)} \quad \text{这里, } c = 1 - 2m\alpha\tilde{\gamma}^2 \min\left\{1, \frac{\beta\gamma^2}{M}\right\}$$

最速下降方法收敛性分析-以回溯直线搜索为例

$$\min f(x)$$



迭代求解最优性条件 $\nabla f(x^*) = 0$

非规范化最速下降算法-回溯直线搜索

1. 给定初始点 $x^0 \in \text{dom } f$, 令 $k = 0$

2. 判断: 如果 $\|\nabla f(x^k)\|_2 \leq \varepsilon$, 停止

3. $d_{sd}^k = \|\nabla f(x^k)\|_* \times \arg \min \{\nabla f(x^k)^\top d: \|d\| = 1\}$

4. 回溯直线搜索: $0 < \alpha < 0.5$, $0 < \beta < 1$, $t^k = 1$

While $f(x^k + t^k d_{sd}^k) > f(x^k) + \alpha t^k \nabla f(x^k)^\top d_{sd}^k$,

$$t^k := \beta t^k$$

End

5. $x^{k+1} = x^k + t^k d^k$, $k = k + 1$, 回2

假设:

✓ 存在 m, M 满足 $mI \leq \nabla^2 f(x) \leq MI$ ($\forall x \in S$)

✓ 存在常数 $\gamma, \tilde{\gamma} \in (0, 1]$, 使得 $\|x\| \geq \gamma \|x\|_2$, $\|x\|_* \geq \tilde{\gamma} \|x\|_2$

➤ 目标值与最优值间偏差的上界

$$f(x) - p^* \leq \frac{1}{2m} \|\nabla f(x)\|_2^2$$

➤ 每次迭代目标改进值下界

$$f(x^{k+1}) \leq f(x^k) - \alpha \tilde{\gamma}^2 \min \left\{ 1, \frac{\beta \gamma^2}{M} \right\} \|\nabla f(x^k)\|_2^2$$

➤ 算法收敛时, 迭代次数的上界

$$f(x^K) - p^* \leq \varepsilon \Rightarrow K \geq \frac{\log((f(x^0) - p^*)/\varepsilon)}{\log(1/c)}$$

$$\text{这里, } c = 1 - 2m\alpha\tilde{\gamma}^2 \min \left\{ 1, \frac{\beta \gamma^2}{M} \right\} < 1$$




例

$\mathbb{R}^2$ 空间非二次规划问题


$$\min f(x) = e^{x_1+3x_2-0.1} + e^{x_1-3x_2-0.1} + e^{-x_1-0.1}$$

应用以下两个二次范数导出的最速下降方法，进行回溯直线搜索，令 $\alpha = 0.1$, $\beta = 0.7$


$$P_1 = \begin{bmatrix} 2 & 0 \\ 0 & 8 \end{bmatrix}, \quad P_2 = \begin{bmatrix} 8 & 0 \\ 0 & 2 \end{bmatrix}$$



采用 $\|\cdot\|_{P_1}$ 的最速下降方法



采用 $\|\cdot\|_{P_2}$ 的最速下降方法



采用二次范数 $\|\cdot\|_{P_1}$ 和 $\|\cdot\|_{P_2}$ 的最速下降方法误差 $f(x^k) - p^*$ 和迭代次数 k 之间的关系

作业

$$\min f(x)$$



迭代求解最优性条件 $\nabla f(x^*) = 0$

假设:

- ✓ 存在 m, M 满足 $mI \leq \nabla^2 f(x) \leq MI$ ($\forall x \in S$)
- ✓ 存在常数 $\gamma, \tilde{\gamma} \in (0, 1]$, 使得 $\|x\| \geq \gamma \|x\|_2, \|x\|_* \geq \tilde{\gamma} \|x\|_2$

证明:

1. 精确直线搜索时, 非规范化最速下降方法的收敛性;
2. 回溯直线搜索时, 非规范化最速下降方法的收敛性;



课前回顾——最速下降方法

□ 对 $f(x + v)$ 在 x 处一阶Taylor展开: $f(x + v) \approx f(x) + \boxed{\nabla f(x)^\top v}$ 方向导数

- 规范化的最速下降方向: $d_{nsd}^k = \arg \min_d \{ \nabla f(x^k)^\top d : \|d\| = 1 \}$
- 非规范化的最速下降方向: $d_{sd}^k = \|\nabla f(x^k)\|_* \times d_{nsd}^k$
- 性质: $\nabla f(x^k)^\top d_{sd}^k = -\|\nabla f(x^k)\|_*^2$

- 将 $\|\cdot\|$ 取为Euclid范数时, 最速下降方向就是负梯度方向;
- 负梯度方向是一种特殊的最速下降方向。
- ℓ_1 -范数下的规范化最速下降步径总能选为某个标准基向量 (某个负的标准基向量)
- ℓ_1 -范数下最速下降算法每步迭代, 选 $\nabla f(x^k)$ 绝对值最大的分量, 然后根据其符号减少或增加 x^k 的对应分量。
- 二次范数 $\|\cdot\|_p$ 下的最速下降方向为对原问题进行坐标变换 $\bar{x} = P^{1/2}x$ 后的梯度方向

回顾——最速下降方法

$$\min f(x)$$



迭代求解最优性条件 $\nabla f(x^*) = 0$

非规范化最速下降算法

1. 给定初始点 $x^0 \in \text{dom } f$, 令 $k = 0$
2. 判断: 如果 $\|\nabla f(x^k)\| \leq \varepsilon$, 停止
3. $d_{sd}^k = \|\nabla f(x^k)\|_* \times \arg \min \{\nabla f(x^k)^\top d : \|d\| = 1\}$
4. 直线搜索: 确定 $t^k > 0$ 满足
$$f(x^k + t^k d_{sd}^k) < f(x^k)$$
5. $x^{k+1} = x^k + t^k d_{sd}^k, k = k + 1$, 回2

- 若采用精确直线搜索方法

$$t = \operatorname{argmin}_{s \geq 0} f(x + sd)$$

下降方向的比例因子不起作用, 从而规范化和非规范化最速下降方向所起效果相同。

规范化最速下降算法

1. 给定初始点 $x^0 \in \text{dom } f$, 令 $k = 0$
2. 判断: 如果 $\|\nabla f(x^k)\| \leq \varepsilon$, 停止
3. $d_{nsd}^k = \arg \min \{\nabla f(x^k)^\top d \mid s.t. \|d\| = 1\}$
4. 直线搜索: 确定 $t^k > 0$ 满足
$$f(x^k + t^k d_{nsd}^k) < f(x^k)$$
5. $x^{k+1} = x^k + t^k d_{nsd}^k, k = k + 1$, 回2



牛顿方法

$$\min f(x)$$



迭代求解最优性条件 $\nabla f(x^*) = 0$

□ 牛顿方向:

$$d_{nt}^k = -\nabla^2 f(x^k)^{-1} \nabla f(x^k), \text{ 这里, } \nabla^2 f(x^k) \in S_{++}^n, \nabla f(x^k) \neq 0$$

□ 牛顿方向是下降方向, 因为:

$$\nabla f(x^k)^\top d_{nt}^k = -\nabla f(x^k)^\top \nabla^2 f(x^k)^{-1} \nabla f(x^k) < 0$$




牛顿方向的理解1：二阶近似的最优解

□ 目标函数 f 在 x 处二阶Taylor近似模型： $\hat{f}(x+v) = f(x) + \nabla f(x)^\top v + \frac{1}{2} v^\top \nabla^2 f(x) v$

$$\begin{aligned} \operatorname{argmin}_v \hat{f}(x^k + v) \\ = -\nabla^2 f(x^k)^{-1} \nabla f(x^k) \\ = d_{nt}^k \end{aligned}$$

关于 v 的二次凸函数，在
 $v = -\nabla^2 f(x^k)^{-1} \nabla f(x^k)$
处达到最小值。



□ 当 x^k 靠近 x^* 时，点 $x^k + d_{nt}^k$ 是最优解 x^* 一个很好的估计值

- ✓ 若 f 为二次函数，则 $x^k + d_{nt}^k$ 是 f 的精确最优解；
- ✓ 若 f 为近似二次函数， $x^k + d_{nt}^k$ 是 x^* 一个很好的估计值；
- ✓ f 是二次可微的，当 x 靠近 x^* 时 f 的二次模型应该非常准确。

牛顿方向的理解2：线性化最优性条件的解

- f 是二次可微的，在 x^k 附近对最优性条件 $\nabla f(x^*) = 0$ 进行线性化，即：

$$\nabla f(x^k + v) \approx \nabla f(x^k) + \nabla^2 f(x^k)v = 0$$

$$\text{令 } \widehat{f'}(v) = \nabla f(x^k) + \nabla^2 f(x^k)v$$


$$\min f(x)$$

迭代求解最优性条件 $\nabla f(x^*) = 0$

关于 v 的线性方程，其解为

$$v = -\nabla^2 f(x^k)^{-1} \nabla f(x^k) = d_{nt}^k$$

- 对于 x^* 附近的 x^k （此时最优性条件接近成立）
加上牛顿步径 d_{nt}^k 就能满足线性化的最优性条件；



牛顿方法的理解：对于 x^* 附近的 x^k ，修正量 $x^k + d_{nt}^k$ 是 x^* 的一个很好的近似值

牛顿方向的理解3: Hessian范数下的最速下降方向

牛顿步经是 x^k 处采用Hessian矩阵 $\nabla^2 f(x^k)$ 定义的二次范数导出的最速下降方向

□ Hessian矩阵 $\nabla^2 f(x^k)$ 定义的二次范数: $\|u\|_{\nabla^2 f(x^k)} = (u^\top \nabla^2 f(x^k) u)^{1/2}$

$$\|z\|_* = \sup \{z^\top x: \|x\|_P = 1\} \\ = \|P^{-1/2} z\|_2$$

□ 规范化的最速下降方向:

$$\begin{aligned} d_{nsd}^k &= \arg \min_d \{ \nabla f(x^k)^\top d: \|d\|_{\nabla^2 f(x^k)} = 1 \} \\ &= - \arg \max \{ \nabla f(x^k)^\top d: \|d\|_{\nabla^2 f(x^k)} = 1 \} \\ &= - \left(\nabla f(x^k)^\top (\nabla^2 f(x^k))^{-1} \nabla f(x^k) \right)^{-1/2} (\nabla^2 f(x^k))^{-1} \nabla f(x^k) \end{aligned}$$

□ 非规范化的最速下降方向:

$$\begin{aligned} d_{sd}^k &= \|\nabla f(x^k)\|_* \times d_{nsd}^k \\ &= \left\| (\nabla^2 f(x^k))^{-1/2} \nabla f(x^k) \right\|_2 \times \left(- \left(\nabla f(x^k)^\top (\nabla^2 f(x^k))^{-1} \nabla f(x^k) \right)^{-1/2} (\nabla^2 f(x^k))^{-1} \nabla f(x^k) \right) \\ &= - (\nabla^2 f(x^k))^{-1} \nabla f(x^k) \end{aligned}$$

牛顿 (Newton) 减少量

牛顿方向

$$d_{nt}^k = -\nabla^2 f(x^k)^{-1} \nabla f(x^k)$$

□ Newton减少量 $\lambda(x^k) = \left(\nabla f(x^k)^\top \nabla^2 f(x^k)^{-1} \nabla f(x^k) \right)^{\frac{1}{2}}$

□ Newton减少量是 f 在 x^k 处的二阶近似对 $f(x) - p^*$ 做出的估计

$$f \text{ 在 } x \text{ 处二阶Taylor近似模型: } \hat{f}(x^k + v) = f(x^k) + \nabla f(x^k)^\top v + \frac{1}{2} v^\top \nabla^2 f(x^k) v$$

$$\begin{aligned} f(x^k) - p^* &\approx f(x^k) - \min_v \hat{f}(x^k + v) \\ &= f(x^k) - \hat{f}(x^k + d_{nt}^k) \\ &= \frac{1}{2} \lambda(x^k)^2 \end{aligned}$$

牛顿方法停止准则:

$$\frac{1}{2} \lambda(x^k)^2 \leq \varepsilon$$

✓ 性质1: $\nabla f(x^k)^\top d_{nt}^k = -\lambda(x^k)^2$

✓ 性质2: $\lambda(x^k)^2 = (d_{nt}^k)^\top \nabla^2 f(x^k) d_{nt}^k$



回顾

- ✓假设1: 存在 m, M 满足 $mI \leq \nabla^2 f(x) \leq MI$ ($\forall x \in S$)
- ✓假设2: 存在常数 $\gamma, \tilde{\gamma} \in (0, 1]$, 使得 $\|x\| \geq \gamma\|x\|_2, \|x\|_* \geq \tilde{\gamma}\|x\|_2$
- 算法收敛时, 迭代次数的上界

$$f(x^K) - p^* \leq \varepsilon \implies K \geq \frac{\log((f(x^0) - p^*)/\varepsilon)}{\log(1/c)}$$

非规范化最速下降算法-回溯直线搜索

1. 给定初始点 $x^0 \in \text{dom } f$, 令 $k = 0$
2. 判断: 如果 $\|\nabla f(x^k)\| \leq \varepsilon$, 停止
3. $d_{sd}^k = \|\nabla f(x^k)\|_* \times \arg \min\{\nabla f(x^k)^\top d : \|d\| = 1\}$
4. 回溯直线搜索: $0 < \alpha < 0.5, 0 < \beta < 1, t^k = 1$
 $\text{While } f(x^k + t^k d_{sd}^k) > f(x^k) + \alpha t^k \nabla f(x^k)^\top d_{sd}^k,$
 $t^k := \beta t^k$
End
5. $x^{k+1} = x^k + t^k d^k, k = k + 1$, 回2

$$c = 1 - 2m\alpha\tilde{\gamma}^2 \min\left\{1, \frac{\beta\gamma^2}{M}\right\}$$

梯度下降回溯直线搜索算法

1. 给定初始点 $x^0 \in \text{dom } f$, 令 $k = 0$
2. 停止条件 $\|\nabla f(x^k)\| \leq \varepsilon$
3. $d^k = -\nabla f(x^k)$
4. 回溯直线搜索: $0 < \alpha < 0.5, 0 < \beta < 1, t^k = 1$
 $\text{While } f(x^k + t^k d^k) > f(x^k) + \alpha t^k \nabla f(x^k)^\top d^k,$
 $t^k := \beta t^k$
End
5. $x^{k+1} = x^k + t^k d^k, k = k + 1$, 回2

$$c = \left(1 - \min\left\{2m\alpha, \frac{2\beta\alpha m}{M}\right\}\right)$$

梯度下降精确直线搜索算法

1. 给定初始点 $x^0 \in \text{dom } f$, 令 $k = 0$
2. 停止条件 $\|\nabla f(x^k)\| \leq \varepsilon$
3. $d^k = -\nabla f(x^k)$
4. 精确直线搜索:
 $t^k = \arg \min_{s \geq 0} f(x^k + s d^k)$
5. $x^{k+1} = x^k + t^k d^k, k = k + 1$, 回2

$$c = 1 - \frac{m}{M}$$

$$\min f(x)$$



迭代求解最优性条件 $\nabla f(x^*) = 0$

回顾——牛顿方法

□ 牛顿方向: $d_{nt}^k = -\nabla^2 f(x^k)^{-1} \nabla f(x^k)$, 这里, $\nabla^2 f(x^k) \in S_{++}^n$, $\nabla f(x^k) \neq 0$

✓ 二阶近似最优解:


$$d_{nt}^k = \underset{v}{\operatorname{argmin}} \hat{f}(x^k + v) = f(x^k) + \nabla f(x^k)^\top v + \frac{1}{2} v^\top \nabla^2 f(x^k) v$$

✓ 线性化最优性条件的解:

$$\nabla f(x^k + v) \approx \nabla f(x^k) + \nabla^2 f(x^k) v = 0 \Rightarrow v = d_{nt}^k$$

✓ Hessian范数下的最速下降方向:

$$\begin{aligned} d_{nt}^k &= d_{sd}^k = \|\nabla f(x^k)\|_* \times d_{nsd}^k \\ &= \|\nabla f(x^k)\|_* \times \arg \min_d \{ \nabla f(x^k)^\top d : \|d\|_{\nabla^2 f(x^k)} = 1 \} \end{aligned}$$



Newton下降方法收敛性分析-以回溯直线搜索为例

$$\min f(x)$$

迭代求解最优性条件 $\nabla f(x^*) = 0$

牛顿下降回溯直线搜索算法

1. 给定初始点 $x^0 \in \text{dom } f$, 误差阈值 $\varepsilon > 0$, 令 $k = 0$
2. 计算Newton步径和增量

$$d_{nt}^k = -\nabla^2 f(x^k)^{-1} \nabla f(x^k); \quad \lambda(x^k)^2 = (d_{nt}^k)^\top \nabla^2 f(x^k) d_{nt}^k$$

3. 停止准则: 若 $\frac{1}{2} \lambda(x^k)^2 \leq \varepsilon$, 退出

4. 回溯直线搜索: $0 < \alpha < 0.5, 0 < \beta < 1, t^k = 1$

$$\text{While } f(x^k + t^k d_{nt}^k) > \begin{cases} f(x^k) - \alpha t^k \lambda(x^k)^2 \\ f(x^k) + \alpha t^k \nabla f(x^k)^\top d_{nt}^k \end{cases}$$

End

5. $x^{k+1} = x^k + t^k d_{nt}^k, k = k + 1$, 回2

假设: $\forall x, y \in S$,

✓ 存在 m, M 满足 $mI \leq \nabla^2 f(x) \leq MI$

✓ 存在 L 满足 $\|\nabla^2 f(y) - \nabla^2 f(x)\|_2 \leq L\|y - x\|_2$

➤ 目标值与最优值间偏差的上界

$$f(x) - p^* \leq \frac{1}{2m} \|\nabla f(x)\|_2^2$$

➤ 每次迭代目标改进值下界

✓ 阻尼牛顿阶段:

✓ 二次收敛阶段:

➤ 算法收敛时, 迭代次数的上界

$$f(x^K) - p^* \leq \varepsilon \Rightarrow$$

$$K \geq 6 + \frac{M^2 L^2 / m^5}{\alpha \beta \min\{1, 9(1 - 2\alpha)^2\}} (f(x^0) - p^*)$$

Newton下降方法收敛性分析-以回溯直线搜索为例

□ 假设：函数 f 的Hessian矩阵以 L 为常数的Lipschitz 连续，即存在 $L > 0$ ，使得

$$\|\nabla^2 f(y) - \nabla^2 f(x)\|_2 \leq L\|y - x\|_2, \quad \forall x, y \in S$$

Spectral norm: https://en.wikipedia.org/wiki/Matrix_norm

- When $p = 2$, $\|\mathbf{A}\|_2$ is the spectral norm, the greatest singular value of $\mathbf{A}$, which is the square root of the greatest eigenvalue of $\mathbf{A}^* \mathbf{A}$, i.e., its spectral radius $\rho(\mathbf{A}^* \mathbf{A}) = \lambda_{\max}(\mathbf{A}^* \mathbf{A})$,

$$\|\mathbf{A}\|_2 = \sigma_{\max}(\mathbf{A}) = \sqrt{\lambda_{\max}(\mathbf{A}^* \mathbf{A})} = \sqrt{\rho(\mathbf{A}^* \mathbf{A})}$$

where $\lambda_{\max}(\mathbf{A}^* \mathbf{A}) = \sigma_{\max}^2(\mathbf{A})$ is the maximal eigenvalue of $\mathbf{A}^* \mathbf{A}$, and $\sigma_{\max}(\mathbf{A}) = \sqrt{\lambda_{\max}(\mathbf{A}^* \mathbf{A})}$ the maximal singular value of $\mathbf{A}$. In

Matlab this norm is implemented by the function `norm(A, 2)` or simply `norm(A)`.

- ✓ L 是和变量 x 无关的常数；
- ✓ L 可解释为函数 f 三阶导数的界，对于二次函数可以为0；
- ✓ L 是函数 f 与其二次模型之间近似程度的一种度量，将对Newton方法的性能起关键作用；
- ✓ 若一个函数的二次模型变化缓慢（ L 值较小），Newton方法应该比较有效。

Newton下降方法收敛性分析-以回溯直线搜索为例

$$\min f(x)$$

迭代求解最优性条件 $\nabla f(x^*) = 0$

$$d_{nt}^k = -\nabla^2 f(x^k)^{-1} \nabla f(x^k)$$

$$\lambda(x^k) = \left(\nabla f(x^k)^\top \nabla^2 f(x^k)^{-1} \nabla f(x^k) \right)^{\frac{1}{2}}$$

□ 存在满足 $0 < \eta \leq \frac{m^2}{L}$ 和 $\gamma > 0$ 的 η 和 γ 使得以下式子成立,

✓ 阻尼牛顿阶段: 如果 $\|\nabla f(x^k)\|_2 \geq \eta$, 则 $f(x^{k+1}) - f(x^k) \leq -\gamma$

✓ 二次收敛阶段: 如果 $\|\nabla f(x^k)\|_2 < \eta$, 则回溯直线搜索产生 $t^k = 1$, 并且

$$\frac{L}{2m^2} \|\nabla f(x^{k+1})\|_2 \leq \left(\frac{L}{2m^2} \|\nabla f(x^k)\|_2 \right)^2$$



阻尼牛顿阶段

假设: $\forall x \in S$, 存在 m, M 满足

$$mI \leq \nabla^2 f(x) \leq MI$$

□ 阻尼牛顿阶段: 存在满足 $0 < \eta \leq \frac{m^2}{L}$, $\|\nabla f(x^k)\|_2 \geq \eta$,
$$f(x^{k+1}) - f(x^k) \leq -\gamma$$

4. 回溯直线搜索: $0 < \alpha < 0.5, 0 < \beta < 1, t^k = 1$

While $f(x^k + t^k d_{nt}^k) > \boxed{f(x^k) - \alpha t^k \lambda(x^k)^2}$
 $t^k := \beta t^k$
End $f(x^k) + \alpha t^k \nabla f(x^k)^\top d_{nt}^k$

证明:
$$f(x^k + t d_{nt}^k) \leq f(x^k) + t \nabla f(x^k)^\top d_{nt}^k + \frac{M \|d_{nt}^k\|_2^2}{2} t^2$$

$$\leq f(x^k) - t \lambda(x^k)^2 + \frac{M}{2m} t^2 \lambda(x^k)^2$$

$$f(x^k + t_{min} d_{nt}^k) \leq f(x^k) - \frac{m}{2M} \lambda(x^k)^2$$

$$\leq f(x^k) - \alpha \frac{m}{M} \lambda(x^k)^2$$

$$t_{min} = \frac{m}{M}$$

$$\alpha < \frac{1}{2}$$

性质1: $\nabla f(x^k)^\top d_{nt}^k = -\lambda(x^k)^2$

性质2: $\lambda(x^k)^2 = (d_{nt}^k)^\top \nabla^2 f(x^k) d_{nt}^k$
$$\geq m \|d_{nt}^k\|_2^2$$



阻尼牛顿阶段

假设: $\forall x \in S$, 存在 m, M 满足

$$mI \leq \nabla^2 f(x) \leq MI$$

□ 阻尼牛顿阶段: 存在 $0 < \eta \leq \frac{m^2}{L}$, $\|\nabla f(x^k)\|_2 \geq \eta$, $f(x^k + t_{\min} d_{nt}^k) \leq f(x^k) - \alpha t_{\min} \lambda(x^k)^2$, $t_{\min} = \frac{m}{M}$

□ 回溯直线搜索停止, $t \geq \beta t_{\min} = \beta \frac{m}{M}$ 时, 有

$$t \geq \min\left\{1, \frac{m}{M}\right\}$$

$$\begin{aligned} f(x^{k+1}) - f(x^k) &= f(x^k + t d_{nt}^k) - f(x^k) \\ &\leq -\alpha t \lambda(x^k)^2 \\ &\leq -\alpha \beta \frac{m}{M} \lambda(x^k)^2 \\ &\leq -\alpha \beta \frac{m}{M^2} \|\nabla f(x^k)\|_2^2 \\ &\leq -\left(\alpha \beta \eta^2 \frac{m}{M^2}\right) \gamma \end{aligned}$$

$$\begin{aligned} &\lambda(x^k)^2 \\ &= \nabla f(x^k)^\top \nabla^2 f(x^k)^{-1} \nabla f(x^k) \\ &\geq \frac{1}{M} \|\nabla f(x^k)\|_2^2 \end{aligned}$$

阻尼牛顿阶段: 如果 $\|\nabla f(x^k)\|_2 \geq \eta$, 则 $f(x^{k+1}) - f(x^k) \leq -\gamma$, 即每次迭代目标函数至少减少 γ , 阻尼牛顿阶段迭代次数小于等于 $\frac{f(x^0) - p^*}{\gamma}$, 这里 $\gamma = \alpha \beta \eta^2 \frac{m}{M^2}$, $0 < \eta \leq \frac{m^2}{L}$ 。

二次收敛阶段

二次收敛阶段: $\|\nabla f(x^k)\|_2 < \eta$, 则 $t^k = 1$, $\frac{L}{2m^2} \|\nabla f(x^{k+1})\|_2 \leq \left(\frac{L}{2m^2} \|\nabla f(x^k)\|_2\right)^2$

□ 如果 $\|\nabla f(x^k)\|_2 \leq \eta \leq 3(1-2\alpha)\frac{m^2}{L}$, 则 $t = 1$ 满足回溯直线搜索停止条件, 即

$$f(x^{k+1}) = f(x^k + d_{nt}^k) \leq f(x^k) + \alpha \nabla f(x^k)^\top d_{nt}^k$$

证明:

$$\|\nabla^2 f(x^k + td_{nt}^k) - \nabla^2 f(x^k)\|_2 \leq tL\|d_{nt}^k\|_2$$

$$\left| (d_{nt}^k)^\top (\nabla^2 f(x^k + td_{nt}^k) - \nabla^2 f(x^k)) d_{nt}^k \right| \leq tL\|d_{nt}^k\|_2^3$$

$$|\tilde{f}''(t) - \tilde{f}''(0)| \leq tL\|d_{nt}^k\|_2^3$$

$$\tilde{f}''(t) \leq \tilde{f}''(0) + tL\|d_{nt}^k\|_2^3 \leq \lambda(x^k)^2 + \frac{tL}{m^{3/2}} \lambda(x^k)^3$$

$$\tilde{f}'(t) \leq \tilde{f}'(0) + t\lambda(x^k)^2 + \frac{t^2L}{2m^{3/2}} \lambda(x^k)^3 = -\lambda(x^k)^2 + t\lambda(x^k)^2 + \frac{t^2L}{2m^{3/2}} \lambda(x^k)^3$$

$$\tilde{f}(t) \leq \tilde{f}(0) - t\lambda(x^k)^2 + \frac{1}{2}t^2\lambda(x^k)^2 + \frac{t^3L}{6m^{3/2}} \lambda(x^k)^3$$

假设: $\forall x, y \in S$, 存在 m, M, L 满足

✓ $mI \leq \nabla^2 f(x) \leq MI$;

✓ $\|\nabla^2 f(y) - \nabla^2 f(x)\|_2 \leq L\|y - x\|_2$

令 $\tilde{f}(t) = f(x^k + td_{nt}^k)$

✓ $\tilde{f}''(t) = (d_{nt}^k)^\top \nabla^2 f(x^k + td_{nt}^k) d_{nt}^k$

✓ $\tilde{f}''(0) = \lambda(x^k)^2 \geq m\|d_{nt}^k\|_2^2$

✓ $\tilde{f}'(0) = -\lambda(x^k)^2$



二次收敛阶段



□ 如果 $\|\nabla f(x^k)\|_2 \leq \eta \leq 3(1 - 2\alpha) \frac{m^2}{L}$, 则 $t = 1$ 满足回溯直线搜索停止条件, 即

$$f(x^{k+1}) = f(x^k + d_{nt}^k) \leq f(x^k) + \alpha \nabla f(x^k)^\top d_{nt}^k$$

证明: $\tilde{f}(t) \leq \tilde{f}(0) - t\lambda(x^k)^2 + \frac{1}{2}t^2\lambda(x^k)^2 + \frac{t^3L}{6m^{3/2}}\lambda(x^k)^3$

$t = 1$ 

$$f(x^k + d_{nt}^k) \leq f(x^k) - \lambda(x^k)^2 \left(\frac{1}{2} - \frac{L\lambda(x^k)}{6m^{3/2}} \right)$$

$$\leq f(x^k) - \alpha \lambda(x^k)^2$$

$$= f(x^k) + \alpha \nabla f(x^k)^\top d_{nt}^k$$

$$\rightarrow x^{k+1} = x^k + d_{nt}^k$$

若 $\|\nabla f(x^k)\|_2 \leq \eta \leq 3(1 - 2\alpha) \frac{m^2}{L}$, 则

$$\lambda(x^k) = \left(\nabla f(x^k)^\top \nabla^2 f(x^k)^{-1} \nabla f(x^k) \right)^{1/2}$$
$$\leq \frac{1}{m^{1/2}} \|\nabla f(x^k)\|_2$$
$$\leq 3(1 - 2\alpha) \frac{m^{3/2}}{L}$$

二次收敛阶段: $\|\nabla f(x^k)\|_2 < \eta \leq 3(1 - 2\alpha) \frac{m^2}{L}$, 则回溯直线搜索产生 $t^k = 1$

二次收敛阶段

二次收敛阶段: $\|\nabla f(x^k)\|_2 < \eta$, 则回溯直线搜索产生 $t^k = 1$, 并且

$$\frac{L}{2m^2} \|\nabla f(x^{k+1})\|_2 \leq \left(\frac{L}{2m^2} \|\nabla f(x^k)\|_2 \right)^2$$

假设: $\forall x, y \in S$, 存在 m, M, L 满足

✓ $mI \leq \nabla^2 f(x) \leq MI$;

✓ $\|\nabla^2 f(y) - \nabla^2 f(x)\|_2 \leq L\|y - x\|_2$

□ 二次收敛阶段: $\frac{L}{2m^2} \|\nabla f(x^{k+1})\|_2 \leq \left(\frac{L}{2m^2} \|\nabla f(x^k)\|_2 \right)^2$

$$\nabla f(x^{k+1}) = \nabla f(x^k + d_{nt}^k) = \nabla f(x^k + d_{nt}^k) - \nabla f(x^k) - \nabla^2 f(x^k) d_{nt}^k$$

$$\|\nabla f(x^{k+1})\|_2 = \left\| \int_0^1 \left(\nabla^2 f(x^k + td_{nt}^k) - \nabla^2 f(x^k) \right) d_{nt}^k dt \right\|_2$$

$$\leq \int_0^1 Lt \|d_{nt}^k\|_2^2 dt = \frac{L}{2} \|d_{nt}^k\|_2^2$$

$$= \frac{L}{2} \left\| \nabla^2 f(x^k)^{-1} \nabla f(x^k) \right\|_2^2 \leq \frac{L}{2m^2} \|\nabla f(x^k)\|_2^2$$

$$\begin{aligned} & \frac{d(\nabla f(x^k + td_{nt}^k))}{dt} \\ &= \nabla^2 f(x^k + td_{nt}^k) d_{nt}^k \end{aligned}$$

二次收敛阶段: $\|\nabla f(x^k)\|_2 < \eta$, 算法将选择单位步长, 并且

$$\frac{L}{2m^2} \|\nabla f(x^{k+1})\|_2 \leq \left(\frac{L}{2m^2} \|\nabla f(x^k)\|_2 \right)^2, \text{ 这里 } \eta = \min\{1, 3(1 - 2\alpha)\} \frac{m^2}{L}$$

二次收敛阶段

二次收敛阶段: $\|\nabla f(x^k)\|_2 < \eta$, 则回溯直线搜索产生 $t^k = 1$, 并且


$$\frac{L}{2m^2} \|\nabla f(x^{k+1})\|_2 \leq \left(\frac{L}{2m^2} \|\nabla f(x^k)\|_2 \right)^2$$

假设: $\forall x, y \in S$, 存在 m, M, L 满足

$$\checkmark \quad mI \leq \nabla^2 f(x) \leq MI;$$

$$\checkmark \quad \|\nabla^2 f(y) - \nabla^2 f(x)\|_F \leq L\|y - x\|_2$$

□ 二次收敛过程迭代次数 k_2 的上界



□ 记 $\epsilon_0 = \frac{2m^3}{L^2}$, $K_2 = K - \hat{k} + 1$,

$$f(x^K) - p^* \leq \frac{1}{2m} \|\nabla f(x^K)\|_2^2 \leq \epsilon \quad \Leftarrow \quad \frac{2m^3}{L^2} \left(\frac{1}{2} \right)^{2^{K - \hat{k} + 1}} \leq \epsilon \quad \boxed{K_2 \geq \log_2(\log_2(\epsilon_0/\epsilon))}$$

Newton下降方法收敛性分析-以回溯直线搜索为例

□ 存在满足 $0 < \eta \leq \frac{m^2}{L}$ 和 $\gamma > 0$ 的 η 和 γ 使得以下式子成立,

✓ 阻尼牛顿阶段: 如果 $\|\nabla f(x^k)\|_2 \geq \eta$, 则 $f(x^{k+1}) - f(x^k) \leq -\gamma$, $\gamma = -\alpha\beta\eta^2 \frac{m}{M^2}$, 即每次迭代目标函数至少减少 γ , 阻尼牛顿阶段迭代次数小于等于 $\frac{f(x^0) - p^*}{\gamma}$ 。

✓ 二次收敛阶段: 如果 $\|\nabla f(x^k)\|_2 < \eta$, 则回溯直线搜索产生 $t^k = 1$, 有

$$\frac{L}{2m^2} \|\nabla f(x^{k+1})\|_2 \leq \left(\frac{L}{2m^2} \|\nabla f(x^k)\|_2 \right)^2, \quad \eta = \min\{1, 3(1 - 2\alpha)\} \frac{m^2}{L}$$

并且二次收敛阶段迭代次数不超过 $\log_2(\log_2(\epsilon_0/\epsilon))$, 这里 $\epsilon_0 = \frac{2m^3}{L^2}$ 。

✓ 回溯直线搜索的牛顿下降方法能够满足 $f(x^K) - p^* \leq \epsilon$ 的总迭代次数 K 满足

$$\begin{aligned} K &\geq \frac{f(x^0) - p^*}{\gamma} + \log_2(\log_2(\epsilon_0/\epsilon)) \\ &\approx \frac{f(x^0) - p^*}{\gamma} + 6 \\ &\approx \frac{M^2 L^2 / m^5}{\alpha \beta \min\{1, 9(1 - 2\alpha)^2\}} (f(x^0) - p^*) + 6 \end{aligned}$$

随着误差阈值 ϵ 的减小极其缓慢地增长, 一般视作常数5或6。实际上, 二次迭代阶段的6次迭代可达到 $\epsilon = 5 \cdot 10^{-20} \epsilon_0$ 。

总结：牛顿下降回溯直线搜索算法

假设： $\forall x, y \in S$,

✓ 存在 m, M 满足 $mI \leq \nabla^2 f(x) \leq MI$

✓ 存在 L 满足 $\|\nabla^2 f(y) - \nabla^2 f(x)\|_F \leq L\|y - x\|_2$

牛顿下降回溯直线搜索算法

1. 给定初始点 $x^0 \in \text{dom } f$, 误差阈值 $\varepsilon > 0$, 令 $k = 0$

2. 计算Newton步径和增量

$$d_{nt}^k = -\nabla^2 f(x^k)^{-1} \nabla f(x^k); \quad \lambda(x^k)^2 = (d_{nt}^k)^\top \nabla^2 f(x^k) d_{nt}^k$$

3. 停止准则：若 $\frac{1}{2} \lambda(x^k)^2 \leq \varepsilon$, 退出

4. 回溯直线搜索： $0 < \alpha < 0.5, 0 < \beta < 1, t^k = 1$

$$\begin{aligned} &\text{While } f(x^k + t^k d_{nt}^k) > f(x^k) - \alpha t^k \lambda(x^k)^2 \\ &\quad t^k := \beta t^k \\ &\text{End} \end{aligned}$$

5. $x^{k+1} = x^k + t^k d_{nt}^k$, $k = k + 1$, 回2

➤ 目标值与最优值间偏差的上界: $f(x) - p^* \leq \frac{1}{2m} \|\nabla f(x^k)\|_2^2$

➤ 每次迭代目标改进值下界

✓ 阻尼牛顿阶段 ($0 < \eta \leq \frac{m^2}{L}$, $\|\nabla f(x^k)\|_2 \geq \eta$)

$$f(x^{k+1}) - f(x^k) \leq -\gamma, \quad \gamma = \alpha \beta \eta^2 \frac{m}{M^2}$$

$$\text{迭代次数} \leq \frac{f(x^0) - p^*}{\gamma}$$

✓ 二次收敛阶段 ($\|\nabla f(x^k)\|_2 \leq \eta \leq 3(1 - 2\alpha) \frac{m^2}{L}$)

$$\text{回溯搜索 } t^k = 1, \frac{L}{2m^2} \|\nabla f(x^{k+1})\|_2 \leq \left(\frac{L}{2m^2} \|\nabla f(x^k)\|_2 \right)^2$$

$$\text{迭代次数} \leq \log_2(\log_2(\epsilon_0/\epsilon)) \approx 6, \quad \epsilon_0 = \frac{2m^3}{L^2}$$

➤ 算法收敛时，迭代次数的上界


$$f(x^K) - p^* \leq \varepsilon \Rightarrow$$

$$K \geq 6 + \frac{M^2 L^2 / m^5}{\alpha \beta \min\{1, 9(1 - 2\alpha)^2\}} (f(x^0) - p^*)$$


例1：两个变量的非二次规划问题，第二次大作业补充

$$\min_x f(x) = e^{x_1+3x_2-0.1} + e^{x_1-3x_2-0.1} + e^{-x_1-0.1}$$

□ 使用Newton下降方法，令回溯直线搜索时 $\alpha = 0.1$ ， $\beta = 0.7$ 。



开始几次迭代过程




误差和迭代次数的关系

经过5次就收敛到了
很高的精度


例2：高维变量的问题

$$f(x) = c^T x - \sum_{i=1}^{500} \log(b_i - a_i^T x), \quad x \in \mathbb{R}^{100}$$

□ 分别使用精确直线搜索和回溯直线搜索 $\alpha = 0.01$, $\beta = 0.5$



梯度下降方法迭代过程




牛顿方法的迭代过程

- ✓ 在第三次迭代后二次收敛表现明显
- ✓ 精确直线搜索通常只对收敛速度有很小的改进

例2：高维变量的问题

$$f(x) = c^T x - \sum_{i=1}^{500} \log(b_i - a_i^T x), \quad x \in \mathbb{R}^{100}$$

□ 分别使用精确直线搜索和回溯直线搜索 $\alpha = 0.01$, $\beta = 0.5$




迭代步长随迭代次数变化

✓ 采用回溯直线搜索，在两次阻尼步长后，回溯直线搜索就采用完全步长，即 $t^k = 1$.

例3：大规模问题

$$f(x) = -\sum_{i=1}^{10000} \log(1 - x_i^2) - \sum_{i=1}^{10000} \log(b_i - a_i^T x), \quad x \in \mathbb{R}^{10000}$$

□ 牛顿下降方法：回溯直线搜索 $\alpha = 0.01$, $\beta = 0.5$



误差与迭代次数的关系

- ✓ 最初的线性收敛阶段大约迭代了13次，随后的二次收敛过程经过4或5次迭代就获得了非常高的精度
- ✓ 即使对于大规模问题，Newton方法只需要18次迭代就获得了很高的精度

作业

$$\min f(x)$$



迭代求解最优性条件 $\nabla f(x^*) = 0$

假设:

- ✓ 存在 m, M 满足 $mI \leq \nabla^2 f(x) \leq MI$ ($\forall x \in S$)
- ✓ 存在 L 满足 $\|\nabla^2 f(y) - \nabla^2 f(x)\|_2 \leq L\|y - x\|_2$

证明: 回溯直线搜索时牛顿方法的收敛性。



回顾：无约束优化问题

$$\min f(x)$$

- 无约束最小化方法
- ✓ 相当于迭代方法求解最优性条件 $\nabla f(x^*) = 0$
- ✓ 产生序列点 $x^k \in \text{dom } f, k = 0, 1, 2, \dots$, 使得 $f(x^k) \rightarrow p^*$;
- ✓ 初始点 $x^0 \in \text{dom } f$;
- ✓ 水平集合 $S = \{x: f(x) \leq f(x^0)\}$ 是闭集;
- 强凸性假设：目标函数 f 在 S 上是强凸的，即存在 $m > 0$ 使得 $\forall x \in S, \nabla^2 f(x) \geq mI$
- 若强凸性假设成立，则 $f(y) \geq f(x) + \nabla f(x)^\top (y - x) + \frac{m}{2} \|y - x\|_2^2$
 - (1) $m = 0$ 时，即凸性的基本不等式;
 - (2) $m > 0$ 时，对 $f(y)$ 的下界得到比单独利用凸性更好的结果

- 函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$, 定义域 $\text{dom } f$;
- 函数 f 是具有连续二阶导数的凸函数;
- 最优解 $x^* = \operatorname{argmin} f(x)$
- 最优值 $p^* = f(x^*)$

回顾：梯度下降方法及收敛性-精确直线搜索

精确直线搜索的梯度下降方法迭代次数的上界

$$K \geq \frac{\log((f(x^0) - p^*)/\varepsilon)}{|\log(1 - \frac{m}{M})|}$$

分子: 初始次优性和最终次优性的比值的对数

分母: $|\log(1 - \frac{m}{M})| = -\log(1 - \frac{m}{M}) \approx \frac{m}{M}$

- 初始次优性: $\log((f(x^0) - p^*)/\varepsilon)$, 即 $f(x^0)$ 和最优值 p^* 之间的缺口;
- 最终次优性: $f(x^K) - p^* \leq \varepsilon$, 即 $f(x^K)$ 和最优值 p^* 之间的缺口;
- 所需要迭代次数依赖于初始点的质量和最终解的精度要求;
- 迭代次数的上界将随着 $\frac{M}{m}$ 的增大而近似线性的增大。

回顾：梯度下降方法及收敛性-回溯直线搜索

$$\min f(x)$$



迭代求解最优性条件 $\nabla f(x^*) = 0$

梯度下降回溯直线搜索算法

1. 给定初始点 $x^0 \in \text{dom } f$, 令 $k = 0$

2. 停止条件 $\|\nabla f(x^k)\| \leq \varepsilon$

3. $d^k = -\nabla f(x^k)$

4. 回溯直线搜索: $0 < \alpha < 0.5$, $0 < \beta < 1$, $t^k = 1$

While $f(x^k + t^k d^k) > f(x^k) + \alpha t^k \nabla f(x^k)^\top d^k$,

$$t^k := \beta t^k$$

End

5. $x^{k+1} = x^k + t^k d^k$, $k = k + 1$, 回2

✓ 收敛性分析

假设: 存在 m, M 满足 $mI \leq \nabla^2 f(x) \leq MI$ ($\forall x \in S$)

➤ 目标值与最优值间偏差的上界

$$f(x) - p^* \leq \frac{1}{2m} \|\nabla f(x)\|_2^2$$

➤ 每次迭代目标改进值下界

$$f(x^{k+1}) \leq f(x^k) - \min\{\alpha, \frac{\beta\alpha}{M}\} \|\nabla f(x^k)\|_2^2$$

➤ 算法收敛时, 迭代次数的上界

$$f(x^K) - p^* \leq \varepsilon \implies K \geq \frac{\log((f(x^0) - p^*)/\varepsilon)}{\log(1/c)}$$

这里, $c = \left(1 - \min\left\{2m\alpha, \frac{2\beta\alpha m}{M}\right\}\right)$

仿射不变性

牛顿方向: $d_{nt}^k = -\nabla^2 f(x^k)^{-1} \nabla f(x^k)$, 这里, $\nabla^2 f(x^k) \in S_{++}^n$, $\nabla f(x^k) \neq 0$

✓ 牛顿步经对坐标的线性（或仿射）变换的独立性: $\forall T \in \mathbb{R}^{n \times n}$ 非奇异矩阵, 令 $x = Ty$, $\bar{f}(y) = f(Ty)$, 有

$$\nabla \bar{f}(y) = T^\top \nabla f(x), \quad \nabla^2 \bar{f}(y) = T^\top \nabla^2 f(x) T$$

$\bar{f}$ 在 y 处的牛顿步经: $d_{nt}^y = -(\nabla^2 \bar{f}(y))^{-1} \nabla \bar{f}(y)$

$$= - (T^\top \nabla^2 f(x) T)^{-1} (T^\top \nabla f(x))$$

$$= T^{-1} \left[-(\nabla^2 f(x))^{-1} \nabla f(x) \right] \quad f \text{ 在 } x \text{ 处的牛顿步经 } d_{nt}^x$$

$$= T^{-1} d_{nt}^x$$

函数 f 和 $\bar{f}$ 的牛顿步经由相同的线性变换相联系, 并且 $x + d_{nt}^x = T(y + d_{nt}^y)$

回顾

□ Newton减少量:

$$\lambda(x^k) = \left(\nabla f(x^k)^\top \nabla^2 f(x^k)^{-1} \nabla f(x^k) \right)^{\frac{1}{2}}$$

✓ 性质1: $\nabla f(x^k)^\top d_{nt}^k = -\lambda(x^k)^2$

✓ 性质2: $\lambda(x^k)^2 = (d_{nt}^k)^\top \nabla^2 f(x^k) d_{nt}^k$



回顾：Newton下降方法收敛性分析-回溯直线搜索

$$\min f(x)$$

迭代求解最优性条件 $\nabla f(x^*) = 0$

牛顿下降回溯直线搜索算法

1. 给定初始点 $x^0 \in \text{dom } f$, 误差阈值 $\varepsilon > 0$, 令 $k = 0$
2. 计算Newton步径和增量

$$d_{nt}^k = -\nabla^2 f(x^k)^{-1} \nabla f(x^k); \quad \lambda(x^k)^2 = (d_{nt}^k)^\top \nabla^2 f(x^k) d_{nt}^k$$

3. 停止准则：若 $\frac{1}{2} \lambda(x^k)^2 \leq \varepsilon$, 退出

4. 回溯直线搜索： $0 < \alpha < 0.5, 0 < \beta < 1, t^k = 1$

While $f(x^k + t^k d_{nt}^k) > f(x^k) - \alpha t^k \lambda(x^k)^2$
 $t^k := \beta t^k$
End

5. $x^{k+1} = x^k + t^k d_{nt}^k, k = k + 1$, 回2

假设： $\forall x, y \in S$,

- ✓ 存在 m, M 满足 $mI \leq \nabla^2 f(x) \leq MI$
- ✓ 存在 L 满足 $\|\nabla^2 f(y) - \nabla^2 f(x)\|_F \leq L\|y - x\|_2$
- 目标值与最优值间偏差的上界

$$f(x) - p^* \leq \frac{1}{2m} \|\nabla f(x)\|_2^2$$

- 每次迭代目标改进值下界
- ✓ 阻尼牛顿阶段： $0 < \eta \leq \frac{m^2}{L}, \|\nabla f(x^k)\|_2 \geq \eta$
- ✓ 二次收敛阶段： $\|\nabla f(x^k)\|_2 \leq \eta \leq 3(1 - 2\alpha) \frac{m^2}{L}$
- 算法收敛时，迭代次数的上界

$$f(x^K) - p^* \leq \varepsilon \Rightarrow$$

$$K \geq 6 + \frac{M^2 L^2 / m^5}{\alpha \beta \min\{1, 9(1 - 2\alpha)^2\}} (f(x^0) - p^*)$$

回顾：阻尼牛顿阶段

假设： $\forall x \in S$ ，存在 m, M 满足

$$mI \leq \nabla^2 f(x) \leq MI$$

4. 回溯直线搜索： $0 < \alpha < 0.5, 0 < \beta < 1, t^k = 1$

```
While  $f(x^k + t^k d_{nt}^k) > f(x^k) - \alpha t^k \lambda(x^k)^2$   
     $t^k := \beta t^k$   
End
```

- 阻尼牛顿阶段：存在满足 $0 < \eta \leq \frac{m^2}{L}$ ， $\|\nabla f(x^k)\|_2 \geq \eta$ ，

$$f(x^k + t_{min} d_{nt}^k) \leq f(x^k) - \alpha t_{min} \lambda(x^k)^2, \text{ 这里, } t_{min} = \frac{m}{M}$$

➤ 回溯直线搜索停止， $t \geq \beta t_{min} = \beta \frac{m}{M}$ 时，有

$$\begin{aligned} f(x^k + t d_{nt}^k) - f(x^k) &\leq -\alpha t \lambda(x^k)^2 \leq -\alpha \beta \frac{m}{M} \lambda(x^k)^2 \\ &\leq -\alpha \beta \frac{m}{M^2} \|\nabla f(x^k)\|_2^2 \\ &\leq -\left(\alpha \beta \eta^2 \frac{m}{M^2}\right) \gamma \end{aligned}$$

$$\begin{aligned} \lambda(x^k)^2 &= \nabla f(x^k)^\top \nabla^2 f(x^k)^{-1} \nabla f(x^k) \\ &\geq \frac{1}{M} \|\nabla f(x^k)\|_2^2 \end{aligned}$$

阻尼牛顿阶段：如果 $\|\nabla f(x^k)\|_2 \geq \eta$ ，则 $f(x^{k+1}) - f(x^k) \leq -\gamma$ ，即每次迭代目标函数至少减少 γ ，
阻尼牛顿阶段迭代次数小于等于 $\frac{f(x^0) - p^*}{\gamma}$ ，这里 $\gamma = \alpha \beta \eta^2 \frac{m}{M^2}$ ， $0 < \eta \leq \frac{m^2}{L}$ 。

回顾

□ 假设：函数 f 的Hessian矩阵以 L 为常数的Lipschitz 连续，即存在 $L > 0$ ，使得

$$\|\nabla^2 f(y) - \nabla^2 f(x)\|_2 \leq L\|y - x\|_2, \quad \forall x, y \in S$$

Spectral norm: https://en.wikipedia.org/wiki/Matrix_norm

- When $p = 2$, $\|\mathbf{A}\|_2$ is the spectral norm, the greatest singular value of $\mathbf{A}$, which is the square root of the greatest eigenvalue of $\mathbf{A}^* \mathbf{A}$, i.e., its spectral radius $\rho(\mathbf{A}^* \mathbf{A}) = \lambda_{\max}(\mathbf{A}^* \mathbf{A})$,

$$\|\mathbf{A}\|_2 = \sigma_{\max}(\mathbf{A}) = \sqrt{\lambda_{\max}(\mathbf{A}^* \mathbf{A})} = \sqrt{\rho(\mathbf{A}^* \mathbf{A})}$$

where $\lambda_{\max}(\mathbf{A}^* \mathbf{A}) = \sigma_{\max}^2(\mathbf{A})$ is the maximal eigenvalue of $\mathbf{A}^* \mathbf{A}$, and $\sigma_{\max}(\mathbf{A}) = \sqrt{\lambda_{\max}(\mathbf{A}^* \mathbf{A})}$ the maximal singular value of $\mathbf{A}$. In

Matlab this norm is implemented by the function `norm(A, 2)` or simply `norm(A)`.

- ✓ L 是和变量 x 无关的常数；
- ✓ L 可解释为函数 f 三阶导数的界，对于二次函数可以为0；
- ✓ L 是函数 f 与其二次模型之间近似程度的一种度量，将对Newton方法的性能起关键作用；
- ✓ 若一个函数的二次模型变化缓慢（ L 值较小），Newton方法应该比较有效。

回顾——牛顿方法

□ 牛顿方向: $d_{nt}^k = -\nabla^2 f(x^k)^{-1} \nabla f(x^k)$, 这里, $\nabla^2 f(x^k) \in S_{++}^n$, $\nabla f(x^k) \neq 0$

✓ 二阶近似最优解:

$$d_{nt}^k = \underset{v}{\operatorname{argmin}} \hat{f}(x^k + v) = f(x^k) + \nabla f(x^k)^\top v + \frac{1}{2} v^\top \nabla^2 f(x^k) v$$

✓ 线性化最优性条件的解:




$$\nabla f(x^k + v) \approx \nabla f(x^k) + \nabla^2 f(x^k) v = 0 \Rightarrow v = d_{nt}^k$$

✓ Hessian范数下的最速下降方向:

$$\begin{aligned} d_{nt}^k &= d_{sd}^k = \|\nabla f(x^k)\|_* \times d_{nsd}^k \\ &= \|\nabla f(x^k)\|_* \times \arg \min_d \{\nabla f(x^k)^\top d : \|d\|_{\nabla^2 f(x^k)} = 1\} \end{aligned}$$

□ Newton减少量: $\lambda(x^k) = \left(\nabla f(x^k)^\top \nabla^2 f(x^k)^{-1} \nabla f(x^k) \right)^{\frac{1}{2}}$

✓ 性质1: $\nabla f(x^k)^\top d_{nt}^k = -\lambda(x^k)^2$ ✓ 性质2: $\lambda(x^k)^2 = (d_{nt}^k)^\top \nabla^2 f(x^k) d_{nt}^k$



回顾

$$\min f(x)$$

迭代求解最优性条件 $\nabla f(x^*) = 0$

牛顿下降回溯直线搜索算法

1. 给定初始点 $x^0 \in \text{dom } f$, 误差阈值 $\varepsilon > 0$, 令 $k = 0$
2. 计算Newton步径和增量

$$d_{nt}^k = -\nabla^2 f(x^k)^{-1} \nabla f(x^k); \quad \lambda(x^k)^2 = (d_{nt}^k)^\top \nabla^2 f(x^k) d_{nt}^k$$

3. 停止准则: 若 $\frac{1}{2} \lambda(x^k)^2 \leq \varepsilon$, 退出

4. 回溯直线搜索: $0 < \alpha < 0.5, 0 < \beta < 1, t^k = 1$

$$\text{While } f(x^k + t^k d_{nt}^k) > \begin{cases} f(x^k) - \alpha t^k \lambda(x^k)^2 \\ f(x^k) + \alpha t^k \nabla f(x^k)^\top d_{nt}^k \end{cases}$$

End

5. $x^{k+1} = x^k + t^k d_{nt}^k, k = k + 1$, 回2

假设: $\forall x, y \in S$,

- ✓ 存在 m, M 满足 $mI \leq \nabla^2 f(x) \leq MI$
- ✓ 存在 L 满足 $\|\nabla^2 f(y) - \nabla^2 f(x)\|_2 \leq L\|y - x\|_2$
 - 目标值与最优值间偏差的上界

$$f(x) - p^* \leq \frac{1}{2m} \|\nabla f(x)\|_2^2$$

- 每次迭代目标改进值下界
 - ✓ 阻尼牛顿阶段:
 - ✓ 二次收敛阶段:
- 算法收敛时, 迭代次数的上界

$$f(x^K) - p^* \leq \varepsilon \Rightarrow$$

$$K \geq 6 + \frac{M^2 L^2 / m^5}{\alpha \beta \min\{1, 9(1 - 2\alpha)^2\}} (f(x^0) - p^*)$$