



西安交通大学
XI'AN JIAOTONG UNIVERSITY

第二章：对偶与最优性条件



优化问题的对偶

标准形式优化问题

$$\begin{aligned} \min_{x \in \mathcal{D}} \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 0, i = 1, 2, \dots, m \\ & h_i(x) = 0, i = 1, 2, \dots, p \end{aligned}$$

- 目标函数 $f_0: \mathbb{R}^n \mapsto \mathbb{R}$
- 不等式约束函数 $f_i: \mathbb{R}^n \mapsto \mathbb{R}, i = 1, 2, \dots, m$
- 等式约束函数 $h_i: \mathbb{R}^n \mapsto \mathbb{R}, i = 1, 2, \dots, p$
- $\mathcal{D} = \bigcap_{i=1}^m \text{dom} f_i \cap \bigcap_{i=1}^p \text{dom} h_i$ 非空
- 最优值 p^*

□ 对不等式约束 $f_i(x) \leq 0$ 引入拉格朗日乘子 λ_i ，对等式约束 $h_i(x) = 0$ 引入拉格朗日乘子 v_i 。记

$$\lambda = [\lambda_1, \lambda_2, \dots, \lambda_m]^\top \in \mathbb{R}^m, v = [v_1, v_2, \dots, v_p]^\top \in \mathbb{R}^p。$$

□ 拉格朗日函数: $L: \mathbb{R}^n \times \mathbb{R}^m \times \mathbb{R}^p \rightarrow \mathbb{R}$,

$$L(x, \lambda, v) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x), \quad \text{dom } L = \mathcal{D} \times \mathbb{R}^m \times \mathbb{R}^p$$

□ 拉格朗日对偶函数: $g: \mathbb{R}^m \times \mathbb{R}^p \rightarrow \mathbb{R}$

$$g(\lambda, v) = \inf_{x \in \mathcal{D}} L(x, \lambda, v) = \inf_{x \in \mathcal{D}} [f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x)]$$

拉格朗日对偶

回顾：如果对于任意的 $x \in A$, $f(x, y)$ 是关于 y 的凸函数，那么

$$g(y) = \sup_{x \in A} f(x, y) \text{ 是凸函数。}$$

- 定理：拉格朗日对偶函数 $g(\lambda, v) = \inf_{x \in \mathcal{D}} L(x, \lambda, v)$ 是凹函数。

证明：

$$g(\lambda, v) = \inf_{x \in \mathcal{D}} L(x, \lambda, v)$$

$$= - \sup_{x \in \mathcal{D}} -L(x, \lambda, v)$$

$$= - \sup_{x \in \mathcal{D}} \left[-f_0(x) - \sum_{i=1}^m \lambda_i f_i(x) - \sum_{i=1}^p v_i h_i(x) \right]$$

关于 (λ, v) 的凸函数

凸函数



拉格朗日对偶

$$\begin{aligned} \min_{x \in \mathcal{D}} \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 0, i = 1, 2, \dots, m \\ & h_i(x) = 0, i = 1, 2, \dots, p \end{aligned}$$

$$\begin{aligned} g(\lambda, v) &= \inf_{x \in \mathcal{D}} L(x, \lambda, v) \\ &= \inf_{x \in \mathcal{D}} [f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x)] \end{aligned}$$

可行解集: $C = \{x \in \mathbb{R}^n: f_i(x) \leq 0, i = 1, 2, \dots, m; h_j(x) = 0, j = 1, 2, \dots, p\}$

□ 定理: 对任意的 $\lambda \geq 0$ 和 v , 对偶函数 $g(\lambda, v)$ 是优化问题最优值 p^* 的下界, 即 $\forall \lambda \geq 0, g(\lambda, v) \leq p^*$ 。

证明: 令可行解集 $C = \{x \in \mathbb{R}^n: f_i(x) \leq 0, i = 1, 2, \dots, m; h_j(x) = 0, j = 1, 2, \dots, p\}$, $\forall \lambda \geq 0$, 有

$$\begin{aligned} p^* &= \min\{f_0(x): x \in C\} \\ &\geq \min\{f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x): x \in C\} \\ &\geq \min\{f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x): x \in \mathcal{D}\} \\ &= g(\lambda, v) \end{aligned}$$

□ 推论: $p^* \geq \max_{\lambda \geq 0} g(\lambda, v)$, 即 $p^* \geq \max_{\lambda \geq 0} \min_{x \in \mathcal{D}} L(x, \lambda, v)$ 。

拉格朗日对偶——线性逼近的理解

$$\begin{array}{ll}\min_{x \in \mathcal{D}} & f_0(x) \\ \text{s.t.} & f_i(x) \leq 0, i = 1, 2, \dots, m \\ & h_i(x) = 0, i = 1, 2, \dots, p\end{array}$$

非正实数的示性函数 $I_-: \mathbb{R} \rightarrow \mathbb{R}$, $I_-(u) = \begin{cases} 0, & u \leq 0 \\ \infty, & u > 0 \end{cases}$

集合 $\{0\}$ 的示性函数 $I_0: \mathbb{R} \rightarrow \mathbb{R}$, $I_0(u) = \begin{cases} 0, & u = 0 \\ \infty, & u \neq 0 \end{cases}$

□ 线性函数是示性函数的一个下估计, 即 $\forall \lambda \geq 0$,

$\lambda u \leq I_-(u)$, $v u \leq I_0(u)$, 因此

$$L(x, \lambda, v) \leq f(x)$$

$$g(\lambda, v) = \inf_{x \in \mathcal{D}} L(x, \lambda, v) \leq \min_{x \in \mathcal{D}} f(x) = p^*$$

□ 对偶函数是原优化问题最优值的一个下界。

$$\min_{x \in \mathcal{D}} f(x) = f_0(x) + \sum_{i=1}^m I_-(f_i(x)) + \sum_{i=1}^p I_0(h_i(x))$$

线性逼近示性函数

$$\lambda_i f_i(x) \quad v_i h_i(x)$$



$$\min_{x \in \mathcal{D}} L(x, \lambda, v) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x)$$

求最优值

$$\begin{aligned} g(\lambda, v) &= \inf_{x \in \mathcal{D}} L(x, \lambda, v) \\ &= \inf_{x \in \mathcal{D}} [f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x)] \end{aligned}$$

拉格朗日对偶

$$\min_x f_0(x) \text{ s.t. } f(x) \leq 0, \mathcal{D} = \text{dom}f_0 \cap \text{dom}f \subseteq \mathbb{R}$$



- 可行解集: $[-0.46, 0.46]$
- 对偶函数: $g(\lambda) = \min_{x \in \mathcal{D}} L(x, \lambda)$

- 对偶函数是凹函数

例1

□ 非线性规划问题:

$$\begin{aligned} \min_x \quad & x_1^2 + x_2^2 \\ \text{s.t.} \quad & x_1 + x_2 \geq 1 \end{aligned}$$

- $f_0(x) = x_1^2 + x_2^2$, $f(x) = 1 - x_1 - x_2$
- 拉格朗日函数: $L(x, \lambda) = f_0(x) + \lambda f(x) = x_1^2 + x_2^2 + \lambda(1 - x_1 - x_2)$
- 对偶函数 $g(\lambda) = \min_x x_1^2 + x_2^2 + \lambda(1 - x_1 - x_2) = \lambda - \frac{1}{2}\lambda^2$.

$$\frac{\partial L(x, \lambda)}{\partial x} = \begin{pmatrix} 2x_1 - \lambda \\ 2x_2 - \lambda \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \Rightarrow \begin{cases} x_1 = 0.5\lambda \\ x_2 = 0.5\lambda \end{cases}$$

凹函数

- $\forall \lambda \geq 0$, $p^* \geq g(\lambda) = \lambda - \frac{1}{2}\lambda^2$

例2

□ 优化问题:

$$\begin{aligned} \min_x \quad & x^\top x \\ \text{s.t.} \quad & Ax = b \end{aligned}$$

- $f_0(x) = x^\top x, f(x) = Ax - b$
- 拉格朗日函数: $L(x, v) = f_0(x) + v^\top f(x) = x^\top x + v^\top (Ax - b)$
- 对偶函数 $g(\lambda) = \min_x L(x, \lambda) = x^\top x + v^\top (Ax - b) = -\frac{1}{4} v^\top AA^\top v - b^\top v$

$$\frac{\partial L(x, v)}{\partial x} = 2x + A^\top v = 0 \Rightarrow x = -\frac{1}{2} A^\top v$$

凹函数

- $\forall v, p^* \geq g(v) = -\frac{1}{4} v^\top AA^\top v - b^\top v$

例3：极大熵问题

□ 优化问题： $\min\{\sum_{i=1}^n x_i \log x_i \mid s.t. Ax \leq b, \sum_{i=1}^n x_i = 1\}, \quad \text{dom} f = R_{++}^n$

✓ 拉格朗日函数 (记 $A = [a_1, \dots, a_n]$)

$$\begin{aligned} L(x, \lambda, v) &= \sum_{i=1}^n x_i \log x_i + \lambda^\top (Ax - b) + v(1^\top x - 1) \\ &= \sum_{i=1}^n (x_i \log x_i + (\lambda^\top a_i + v)x_i) - \lambda^\top b - v \end{aligned}$$

✓ 对偶函数： $g(\lambda, v) = -\lambda^\top b - v - e^{-(v+1)} \sum_{i=1}^n e^{-\lambda^\top a_i}$ 是凹函数




回顾：共轭函数

□ 共轭函数：函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 的共轭函数 $f^*: \mathbb{R}^n \rightarrow \mathbb{R}$ 定义为：仿射函数 $\mathbf{y}^\top \mathbf{x}$ 与 $f(\mathbf{x})$ 之间的最大差值，即

$$f^*(\mathbf{y}) = \sup_{x \in \text{dom } f} (\mathbf{y}^\top \mathbf{x} - f(\mathbf{x}))$$

□ 如果函数 f 可微，在满足 $f'(x) = y$ 的点 x 处差值最大。

□ 对于任意函数 f ，其共轭函数 f^* 为凸函数。



例如：函数 $f(x) = -\log x$ 的共轭函数 f^* 为凸函数，这里

$$f^*(y) = \sup_{x>0} (xy + \log x) = \begin{cases} -1 - \log(-y), & y < 0 \\ \infty, & y \geq 0 \end{cases}$$

拉格朗日对偶函数与共轭函数

函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 的共轭函数 $f^*: \mathbb{R}^n \rightarrow \mathbb{R}$, $f^*(y) = \sup_{x \in \text{dom } f} (y^\top x - f(x))$

□ 例1、优化问题 $\min_{x \in \mathbb{R}} f_0(x) \text{ s.t. } x \leq 0$

✓ 拉格朗日函数: $L(x, \lambda) = f_0(x) + \lambda^\top x$;

✓ 拉格朗日对偶函数: $g(\lambda) = \min_{x \in \mathbb{R}} f_0(x) + \lambda^\top x$
 $= -\sup_{x \in \mathbb{R}} ((-\lambda)^\top x - f_0(x))$
 $= -f_0^*(-\lambda)$



拉格朗日对偶函数与共轭函数

函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 的共轭函数 $f^*: \mathbb{R}^n \rightarrow \mathbb{R}$, $f^*(y) = \sup_{x \in \text{dom } f} (y^\top x - f(x))$

□ 优化问题 $\min_x f_0(x) \text{ s.t. } Ax \leq b; Cx = d$

✓ 拉格朗日对偶函数: $g(\lambda, v) = \inf_x f_0(x) + \lambda^\top (Ax - b) + v^\top (Cx - d)$

若共轭函数已知, 则可简化对偶函数的求得

$$= \inf_x (f_0(x) + (A^\top \lambda + C^\top v)^\top x) - b^\top \lambda - d^\top v$$

$$= -\sup_x ((-A^\top \lambda - C^\top v)x - f_0(x)) - b^\top \lambda - d^\top v$$

$$= -f_0^*(-A^\top \lambda - C^\top v) - b^\top \lambda - d^\top v$$

拉格朗日对偶问题

$$\begin{array}{ll} \min_{x \in \mathcal{D}} & f_0(x) \\ \text{s.t.} & f_i(x) \leq 0, i = 1, 2, \dots, m \\ & h_i(x) = 0, i = 1, 2, \dots, p \end{array} \quad p^*$$

□ 拉格朗日对偶函数: $g: \mathbb{R}^m \times \mathbb{R}^p \rightarrow \mathbb{R}$

$$g(\lambda, v) = \inf_{x \in \mathcal{D}} L(x, \lambda, v) = \inf_{x \in \mathcal{D}} [f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x)]$$

□ 定理: 对任意的 $\lambda \geq 0$ 和 v , 对偶函数 $g(\lambda, v)$ 是优化问题最优值 p^* 的下界, 即 $\forall \lambda \geq 0, g(\lambda, v) \leq p^*$

$$\begin{array}{ll} \text{拉格朗日对偶问题} & \max_{\lambda, v} g(\lambda, v) \\ & \text{s.t. } \lambda \geq 0 \end{array}$$

从拉格朗日函数能够得到的
最好下界是什么?

□ 对偶可行解 (λ, v) 满足: $\lambda \geq 0$ 且 $(\lambda, v) \in \text{dom } g$

✓ $g(\lambda, v) = -\infty$ 意义不大, 故 $\text{dom } g = \{(\lambda, v): g(\lambda, v) > -\infty\}$

✓ 当 $\lambda \geq 0$ 且 $(\lambda, v) \in \text{dom } g$ 时, 对偶函数给出 p^* 的一个非平凡下界



□ 拉格朗日对偶问题是凸优化问题

✓ (λ^*, v^*) : 对偶最优解或最优拉格朗日乘子

✓ 最优值 d^*

拉格朗日对偶

$$\min_x f_0(x) \text{ s.t. } f(x) \leq 0, \mathcal{D} = \text{dom}f_0 \cap \text{dom}f \subseteq \mathbb{R}$$



✓ 可行解集: $[-0.46, 0.46]$

✓ 对偶函数: $g(\lambda) = \min_{x \in \mathcal{D}} L(x, \lambda)$

✓ 对偶函数是凹函数

✓ 对偶问题是凸优化问题

例4

$$\begin{aligned} \text{优化问题} \quad & \min_x c^\top x \\ & s.t. Ax = b, x \geq 0 \end{aligned} \quad A \in \mathbb{R}^{m \times n}$$

- 拉格朗日函数: $L(x, \lambda, v) = c^\top x - \lambda^\top x + v^\top (Ax - b) = -b^\top v + (c + A^\top v - \lambda)^\top x$
- 拉格朗日对偶函数 $g(\lambda, v) = \inf_x L(x, \lambda, v) = \begin{cases} -b^\top v, & A^\top v - \lambda + c = 0 \\ -\infty, & \text{otherwise} \end{cases}$
- 对偶问题
$$\begin{aligned} \max_{v \in \mathbb{R}^m} \quad & -b^\top v \\ s.t. \quad & A^\top v + c \geq 0 \end{aligned}$$

弱对偶与强对偶

p^*

$$\begin{array}{ll} \min_{x \in \mathcal{D}} & f_0(x) \\ \text{s.t.} & f_i(x) \leq 0, i = 1, 2, \dots, m \\ & h_i(x) = 0, i = 1, 2, \dots, p \end{array}$$

原问题



对偶问题

$$\begin{array}{ll} \max_{\lambda, v} & g(\lambda, v) \\ \text{s.t.} & \lambda \geq 0 \end{array}$$

d^*

□ 弱对偶 (Weak Duality): $d^* \leq p^*$ 。

□ 对于任意的函数优化问题, $d^* = \sup_{\lambda \geq 0, v} \inf_{x \in \mathcal{D}} L(x, \lambda, v) \leq \inf_{x \in \mathcal{D}} \sup_{\lambda \geq 0} L(x, \lambda, v)$ 成立。

证明: $\sup_{\lambda \geq 0, v} L(x, \lambda, v) = \sup_{\lambda \geq 0, v} f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x)$

$$= \begin{cases} f_0(x), & f_i(x) \leq 0, h_i(x) = 0 \\ \infty, & \text{otherwise} \end{cases} \quad \longrightarrow \quad \inf_{x \in \mathcal{D}} \sup_{\lambda \geq 0} L(x, \lambda, v) = p^*$$



弱对偶与强对偶

p^*

$$\begin{array}{ll} \min_{x \in \mathcal{D}} & f_0(x) \\ \text{s.t.} & f_i(x) \leq 0, i = 1, 2, \dots, m \\ & h_i(x) = 0, i = 1, 2, \dots, p \end{array}$$

原问题



对偶问题

$$\begin{array}{ll} \max_{\lambda, v} & g(\lambda, v) \\ \text{s.t.} & \lambda \geq 0 \end{array}$$

d^*

- 弱对偶 (Weak Duality): $d^* \leq p^*$, 即 $\max_{\lambda \geq 0} \min_{x \in \mathcal{D}} L(x, \lambda, v) \leq \min_{x \in \mathcal{D}} \max_{\lambda \geq 0} L(x, \lambda, v)$
 - ✓ 总是成立
 - ✓ 最优对偶间隙: $p^* - d^* \geq 0$
- 强对偶 (Strong Duality): $d^* = p^*$, 即 $\max_{\lambda \geq 0} \min_{x \in \mathcal{D}} L(x, \lambda, v) = \min_{x \in \mathcal{D}} \max_{\lambda \geq 0} L(x, \lambda, v)$
 - ✓ 一般情况下不成立
 - ✓ 对凸优化问题成立 (通常)



强对偶性和Slater's 约束品性

凸优化问题

$$\begin{aligned} \min_{x \in \mathcal{D}} \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 0, i = 1, 2, \dots, m \\ & Ax = b, A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m \end{aligned}$$

□ Slater 约束品性: 存在集合 $\mathcal{D}$ 的一个内点 x_0 , 使得 $f_i(x_0) < 0 (i = 1, 2, \dots, m), Ax_0 = b$

□ 凸优化问题, 若Slater 约束品性满足, 则强对偶性成立.

□ 例1

原问题	$\min_x c^\top x$	$g(\lambda) = \inf_x L(x, \lambda) = \inf_x ((c + A^\top \lambda)^\top x - b^\top \lambda)$		对偶问题	$\max_{\lambda \geq 0} -b^\top \lambda$
p^*	$\text{s.t. } Ax \leq b$	$= \begin{cases} -b^\top \lambda, & A^\top \lambda + c = 0 \\ -\infty, & \text{otherwise} \end{cases}$		d^*	$\text{s.t. } A^\top \lambda + c = 0$

✓ Slater's 约束品性: 存在 x_0 满足 $Ax_0 < b$, 强对偶性成立, 即 $d^* = p^*$

强对偶性和Slater's 约束品性

凸优化问题

$$\begin{aligned} \min_{x \in \mathcal{D}} \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 0, i = 1, 2, \dots, m \\ & Ax = b, A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m \end{aligned}$$

□ Slater 约束品性: 存在集合 $\mathcal{D}$ 的一个内点 x_0 , 使得 $f_i(x_0) < 0 (i = 1, 2, \dots, m), Ax_0 = b$

□ 凸优化问题, 若Slater 约束品性满足, 则强对偶性成立.

□ 例2

原问题	$\min_x x^\top P x$	$g(\lambda) = \inf_x L(x, \lambda) = \inf_x (x^\top P x + \lambda^\top (Ax - b))$	对偶问题	$\max_{\lambda \geq 0} -\frac{1}{4} \lambda^\top A P^{-1} A^\top \lambda - b^\top \lambda$
p^*	$\text{s.t. } Ax \leq b, \\ P \in S_{++}^n$	$= -\frac{1}{4} \lambda^\top A P^{-1} A^\top \lambda - b^\top \lambda$		d^*



✓ Slater's 约束品性: 存在 x_0 满足 $Ax_0 < b$, 强对偶性成立, 即 $d^* = p^*$

例1

$$\square x^* = (0.5, 0.5)^\top, p^* = 0.5$$

非线性规划问题
$$\begin{aligned} \min_x f_0(x) &= x_1^2 + x_2^2 \\ \text{s.t. } x_1 + x_2 &\geq 1 \end{aligned}$$

这里, $f_0(x) = x_1^2 + x_2^2$, $f(x) = 1 - x_1 - x_2$ 为凸函数

关于 x 的凸函数

$\square$ 拉格朗日函数 $L(x, \lambda) = x_1^2 + x_2^2 + \lambda(1 - x_1 - x_2)$

$\square$ 对偶函数 $g(\lambda) = \min_x x_1^2 + x_2^2 + \lambda(1 - x_1 - x_2) = \lambda - \frac{1}{2}\lambda^2$


$$\frac{\partial L(x, y)}{\partial x} = \begin{pmatrix} 2x_1 - \lambda \\ 2x_2 - \lambda \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \Rightarrow \begin{cases} x_1 = 0.5\lambda \\ x_2 = 0.5\lambda \end{cases}$$

$\square$ 对偶问题 $\max_{\lambda \geq 0} g(\lambda) = \max_{\lambda \geq 0} (\lambda - \frac{1}{2}\lambda^2) \Rightarrow \text{最优解 } \lambda^* = 1$

$$\Rightarrow g(\lambda^*) = 0.5 = p^*$$

几何理解

凸优化问题: $\min_x f_0(x)$ s.t. $f(x) \leq 0$, $x \in \mathcal{D} \subseteq \mathbb{R}^2$, 其中, $f_0: \mathbb{R}^2 \mapsto \mathbb{R}$, $f: \mathbb{R}^2 \mapsto \mathbb{R}$.



$$\begin{aligned} \square g(\lambda) &= \min_{x \in \mathcal{D}} f_0(x) + \lambda f(x) \\ &= \min_{(f, f_0) \in H} f_0 + \lambda f \end{aligned}$$


□ 对固定 $\lambda \geq 0$, 当贴近至集合 H 最低处时, 优化问题取得最小值

□ $g(\lambda)$ 的值是支撑超平面 $f_0 + \lambda f = \text{常数}(g(\lambda))$ 与 f_0 轴的交点。

□ 对偶问题旨在于找到最大的 $g(\lambda)$, 即使得超平面 $f_0 + \lambda f = g(\lambda)$ 与 f_0 轴的交点最高

几何理解

非凸优化问题: $\min_x f_0(x) \text{ s.t. } f(x) \leq 0, x \in \mathcal{D} \subseteq \mathbb{R}^2$, 其中, $f_0: \mathbb{R}^2 \mapsto \mathbb{R}, f: \mathbb{R}^2 \mapsto \mathbb{R}$



$$\begin{aligned} \square \quad g(\lambda) &= \min_{x \in \mathcal{D}} f_0(x) + \lambda f(x) \\ &= \min_{(f, f_0) \in H} f_0 + \lambda f \end{aligned}$$

□ 对偶间隙非0, 即

$$\min_{x \in \mathcal{D}} \max_{\lambda \geq 0} L(x, \lambda) - \max_{\lambda \geq 0} \min_{x \in \mathcal{D}} L(x, \lambda) > 0$$

$$f_0^* - g(\lambda^*) > 0$$

最优性条件

原问题

$$\begin{array}{ll} \min_x & f_0(x) \\ \text{s.t.} & f_i(x) \leq 0, i = 1, 2, \dots, m \\ & h_i(x) = 0, i = 1, 2, \dots, p \\ & x \in \mathcal{D} \end{array} \quad p^*$$

$$g(\lambda, v) = \inf_{x \in \mathcal{D}} L(x, \lambda, v) = [f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x)]$$

对偶可行的 (λ, v) , $g(\lambda, v) \leq p^*$

对偶问题

$$\begin{array}{ll} \max_{\lambda, v} & g(\lambda, v) \\ \text{s.t.} & \lambda \geq 0 \end{array} \quad d^*$$

□ 原问题可行解 x 与对偶可行解 (λ, v) 的对偶间隙 $\epsilon = f_0(x) - g(\lambda, v)$, 此时称 x 是 ϵ -次优的, 即

$$f_0(x) - p^* \leq f_0(x) - g(\lambda, v) = \epsilon \quad \Rightarrow \quad f_0(x) - p^* \leq \epsilon$$

✓ 对偶间隙为0, 则 x 是原问题的最优解且 (λ, v) 是对偶问题的最优解, 即 $x^* = x, (\lambda^*, v^*) = (\lambda, v)$

✓ 非启发式停止准则: 令可行解 x^k 及对偶可行解 (λ^k, v^k) , $k = 1, 2, \dots$, 绝对精度 $\epsilon_{abs} > 0$, 停止准则

$$f_0(x^k) - g(\lambda^k, v^k) \leq \epsilon_{abs}$$

□ 一对原问题可行解 x 与对偶可行解 (λ, v) 将原问题 (对偶问题) 的最优解限制在一个区间上, 即

$$p^*, d^* \in [g(\lambda, v), f_0(x)]$$

Karush-Kuhn-Tucker (KKT) 方程

$\min_{x \in \mathcal{D}} f_0(x)$ 原问题

s. t. $f_i(x) \leq 0, i = 1, 2, \dots, m$

$h_i(x) = 0, i = 1, 2, \dots, p$

对偶问题

$\max_{\lambda, v} g(\lambda, v)$

s. t. $\lambda \geq 0$

□ 假设原问题与对偶问题最优解可取得，分别为 x^* 和 (λ^*, v^*) ，且强对偶性成立，则

$$f_0(x^*)$$

$$= g(\lambda^*, v^*)$$

对偶间隙为0

$$= \min_{x \in \mathcal{D}} f_0(x) + \sum_{i=1}^m \lambda_i^* f_i(x) + \sum_{i=1}^p v_i^* h_i(x)$$

对偶函数的定义

$$\leq f_0(x^*) + \sum_{i=1}^m \lambda_i^* f_i(x^*) + \sum_{i=1}^p v_i^* h_i(x^*)$$

拉格朗日函数关于 x 的下确界小于等于其在 $x = x^*$ 处的值

$$\leq f_0(x^*)$$

$$\lambda_i^* \geq 0, f_i(x^*) \leq 0 (\forall i = 1, 2, \dots, m), h_i(x^*) = 0 (\forall i = 1, 2, \dots, p)$$

Karush-Kuhn-Tucker (KKT) 方程

$\min_{x \in \mathcal{D}} f_0(x)$ 原问题

s. t. $f_i(x) \leq 0, i = 1, 2, \dots, m$

$h_i(x) = 0, i = 1, 2, \dots, p$

对偶问题

$\max_{\lambda, v} g(\lambda, v)$

s. t. $\lambda \geq 0$

□ 假设原问题与对偶问题最优解可取得，分别为 x^* 和 (λ^*, v^*) ，且强对偶性成立，则

$$f_0(x^*)$$

$$= g(\lambda^*, v^*)$$

$$= \min_{x \in \mathcal{D}} f_0(x) + \sum_{i=1}^m \lambda_i^* f_i(x) + \sum_{i=1}^p v_i^* h_i(x)$$

$$= f_0(x^*) + \sum_{i=1}^m \lambda_i^* f_i(x^*) + \sum_{i=1}^p v_i^* h_i(x^*)$$

$$= f_0(x^*)$$

- 拉格朗日函数 $L(x, \lambda^*, v^*)$ 关于 x 求极小值时在 x^* 处取得最小值，即

$$\frac{\partial L(x, \lambda^*, v^*)}{\partial x} \Big|_{x=x^*} = 0$$



$$\nabla f_0(x^*) + \sum_{i=1}^m \lambda_i^* \nabla f_i(x^*) + \sum_{i=1}^p v_i^* \nabla h_i(x^*) = 0$$

Karush-Kuhn-Tucker (KKT) 方程

$\min_{x \in X} f_0(x)$ 原问题

s. t. $f_i(x) \leq 0, i = 1, 2, \dots, m$

$h_i(x) = 0, i = 1, 2, \dots, p$



对偶问题

$\max_{\lambda, v} g(\lambda, v)$

s. t. $\lambda \geq 0$

□ 假设原问题与对偶问题最优解可取得，分别为 x^* 和 (λ^*, v^*) ，且强对偶性成立，则

$$f_0(x^*)$$

$$= g(\lambda^*, v^*)$$

$$= \min_{x \in X} f_0(x) + \sum_{i=1}^m \lambda_i^* f_i(x) + \sum_{i=1}^p v_i^* h_i(x)$$

$$= f_0(x^*) + \sum_{i=1}^m \lambda_i^* f_i(x^*) + \sum_{i=1}^p v_i^* h_i(x^*)$$

$$= f_0(x^*)$$

• 互补松弛性: $\sum_{i=1}^m \lambda_i^* f_i(x^*) = 0$



$$\lambda_i^* f_i(x^*) = 0 \quad (\forall i = 1, 2, \dots, m)$$

Karush-Kuhn-Tucker (KKT) 方程

□ 假设原问题与对偶问题最优解可取得，分别为 x^* 和 (λ^*, v^*) ，且强对偶性成立，则

$$\begin{aligned} & f_0(x^*) \\ &= g(\lambda^*, v^*) \\ &= \min_{x \in X} f_0(x) + \sum_{i=1}^m \lambda_i^* f_i(x) + \sum_{i=1}^p v_i^* h_i(x) \\ &= f_0(x^*) + \sum_{i=1}^m \lambda_i^* f_i(x^*) + \sum_{i=1}^p v_i^* h_i(x^*) \\ &= f_0(x^*) \end{aligned}$$

该组等式和不等式方程称为KKT 方程

$$\begin{aligned} f_i(x^*) &\leq 0, & i = 1, 2, \dots, m \\ \lambda_i^* f_i(x^*) &= 0, & i = 1, 2, \dots, m \\ \lambda_i^* &\geq 0, & i = 1, 2, \dots, m \\ h_i(x^*) &= 0, & i = 1, 2, \dots, p \\ \nabla f_0(x^*) + \sum_{i=1}^m \lambda_i^* \nabla f_i(x^*) + \sum_{i=1}^k v_i^* \nabla h_i(x^*) &= 0 \end{aligned}$$

对于目标函数和约束函数可微的任意优化问题，若强对偶性成立（对偶间隙为0），则任意一对原问题最优解和对偶问题最优解必须满足KKT条件。

凸优化问题的KKT条件

□ 定理：若 $\tilde{x}, \tilde{\lambda}, \tilde{v}$ 满足凸优化问题的KKT条件，则 $\tilde{x}, (\tilde{\lambda}, \tilde{v})$ 分别是原问题和对偶问题的最优解且对偶间隙为0

$$\begin{array}{ll} \min_{x \in \mathcal{D}} & f_0(x) \\ \text{s.t.} & f_i(x) \leq 0, i = 1, 2, \dots, m \\ & h_i(x) = 0, i = 1, 2, \dots, p \end{array} \xrightarrow{\text{凸优化问题}} L(x, \tilde{\lambda}, \tilde{v}) = f_0(x) + \sum_{i=1}^m \tilde{\lambda}_i f_i(x) + \sum_{i=1}^p \tilde{v}_i h_i(x) \text{ 为关于 } x \text{ 的凸函数}$$

$$\tilde{x}, \tilde{\lambda}, \tilde{v} \text{ 是任意满足KKT条件的点 } \longrightarrow \nabla f_0(\tilde{x}) + \sum_{i=1}^m \tilde{\lambda}_i \nabla f_i(\tilde{x}) + \sum_{i=1}^p \tilde{v}_i \nabla h_i(\tilde{x}) = 0$$

$$g(\tilde{\lambda}, \tilde{v}) = \inf_{x \in \mathcal{D}} L(x, \tilde{\lambda}, \tilde{v}) = L(\tilde{x}, \tilde{\lambda}, \tilde{v}) = f_0(\tilde{x}) + \sum_{i=1}^m \tilde{\lambda}_i f_i(\tilde{x}) + \sum_{i=1}^p \tilde{v}_i h_i(\tilde{x}) = f_0(\tilde{x})$$

目标函数和约束函数可微的任意凸函数问题，任意满足KKT条件的点分别是原、对偶最优解且对偶间隙为零

若对偶间隙为0，则解凸优化问题等价于解相应的KKT方程

例1：等式约束二次凸优化问题求极小

$$\min \quad \frac{1}{2}x^\top Px + q^\top x + r$$

$$s.t. \quad Ax = b$$

这里 $P \in S_{++}^n$ 。

此问题KKT条件为 $\begin{cases} Ax^* = b \\ Px^* + q + A^\top u^* = 0 \end{cases}$ ，即

$$\begin{bmatrix} P & A^\top \\ A & 0 \end{bmatrix} \begin{bmatrix} x^* \\ u^* \end{bmatrix} = \begin{bmatrix} -q \\ b \end{bmatrix}$$

求解变量 x^*, u^* 的 $m + n$ 个方程，可以得到该等式约束二次凸优化问题的最优解。



通过解对偶问题求解原问题

□ 假设： x^* 是原问题的最优解， (λ^*, v^*) 为对偶问题最优解，且强对偶性成立，则

$$f_0(x^*) \\ = g(\lambda^*, v^*)$$

$$= \min_{x \in \mathcal{D}} f_0(x) + \sum_{i=1}^m \lambda_i^* f_i(x) + \sum_{i=1}^p v_i^* h_i(x)$$

$$= f_0(x^*) + \sum_{i=1}^m \lambda_i^* f_i(x^*) + \sum_{i=1}^p v_i^* h_i(x^*)$$

$$= f_0(x^*)$$

- 拉格朗日函数 $L(x, \lambda^*, v^*)$ 关于 x 求极小值时在 x^* 处取得最小值。

$$\min_{x \in \mathcal{D}} f_0(x) + \sum_{i=1}^m \lambda_i^* f_i(x) + \sum_{i=1}^p v_i^* h_i(x) \quad (2)$$

- 若优化问题（2）的解是原问题的可行解，则它就是原问题的最优解；如果它不是原问题可行解，则原问题不存在最优解；
- 对偶间隙为0，当对偶问题的求解比原问题更简单时，可通过先求解对偶问题得到 (λ^*, v^*) ，再求解优化问题（2）得到原问题的最优解。

例1：非线性规划问题

非线性规划问题
$$\begin{aligned} \min_x f_0(x) &= x_1^2 + x_2^2 \\ \text{s.t. } x_1 + x_2 &\geq 1 \end{aligned}$$

这里, $f_0(x) = x_1^2 + x_2^2$, $f(x) = 1 - x_1 - x_2$ 为凸函数

关于 x 的凸函数

- 拉格朗日函数 $L(x, \lambda) = x_1^2 + x_2^2 + \lambda(1 - x_1 - x_2)$
- 对偶函数 $g(\lambda) = \min_x x_1^2 + x_2^2 + \lambda(1 - x_1 - x_2) = \lambda - \frac{1}{2}\lambda^2$
- 对偶问题 $\max_{\lambda \geq 0} g(\lambda) = \max_{\lambda \geq 0} (\lambda - \frac{1}{2}\lambda^2) \Rightarrow$ 最优解 $\lambda^* = 1$
- 求解原非线性规划问题, 等价于求解

$$\min_x L(x, \lambda^*) = x_1^2 + x_2^2 + \lambda^*(1 - x_1 - x_2) = x_1^2 + x_2^2 - x_1 - x_2 + 1$$

$$\Rightarrow (x_1^*, x_2^*) = (0.5, 0.5)$$

通过解对偶问题求解原问题

□ **定理：** 对于凸优化问题，若 $\tilde{x}, \tilde{\lambda}, \tilde{v}$ 是任意满足KKT条件的点，则 $\tilde{x}, (\tilde{\lambda}, \tilde{v})$ 分别是原问题和对偶问题的最优解，并且对偶间隙为0。

$$\begin{array}{ll} \min_{x \in \mathcal{D}} & f_0(x) \quad \text{原凸优化问题} \\ \text{s.t.} & f_i(x) \leq 0, i = 1, 2, \dots, m \\ & h_i(x) = 0, i = 1, 2, \dots, p \end{array} \quad \xrightarrow{g(\lambda, v) = \inf_{x \in \mathcal{D}} [f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x)]} \quad \begin{array}{ll} \max_{\lambda, v} & g(\lambda, v) \quad \text{对偶问题 (凸优化问题)} \\ \text{s.t.} & \lambda \geq 0 \end{array}$$

- ✓ 若最优解是原问题可行解，
则其为原问题最优解
- ✓ 否则，原问题不存在最优解

$$\min_{x \in \mathcal{D}} f_0(x) + \sum_{i=1}^m \lambda_i^* f_i(x) + \sum_{i=1}^p v_i^* h_i(x)$$

求得对偶最优解 λ^*, v^*

例2：极大熵问题

- 原问题 $\min\{\sum_{i=1}^n x_i \log x_i \mid s.t. Ax \leq b, \sum_{i=1}^n x_i = 1\}, \quad \text{dom} f = R_{++}^n$
- 拉格朗日函数: $L(x, \lambda, v) = \sum_{i=1}^n (x_i \log x_i + (\lambda^T a_i + v)x_i) - \lambda^T b - v$, 这里, $A = (a_1, \dots, a_n)$
- 对偶问题: $\max_{\lambda \geq 0, v} g(\lambda, v) = -\lambda^T b - v - e^{-(v+1)} \sum_{i=1}^n e^{-\lambda^T a_i}$
- 由Slater条件知强对偶性成立, 因此, 存在对偶最优解 (λ^*, v^*) , 该点的拉格朗日函数为

$$L(x, \lambda^*, v^*) = \sum_{i=1}^n (x_i \log x_i + (\lambda^{*\top} a_i + v^*)x_i) - \lambda^{*\top} b - v^*$$

其在 $\text{dom} f$ 上严格凸且有下界, 因此有一个唯一的解 $x^* = [x_1^*, x_2^*, \dots, x_n^*]$, 其中 $x_i^* = \frac{1}{e^{a_i^\top \lambda^* + v^* + 1}}$
($i = 1, 2, \dots, n$)。

支撑向量机: Support Vector Machines (SVM)

- 两组样本点集合: $C_1 = \{x_i \in \mathbb{R}^n: i = 1, 2, \dots, m\}$, $C_2 = \{x_i \in \mathbb{R}^n: i = m + 1, m + 2, \dots, m + n\}$, 通过超平面区分学习满足以下不等式限制的变量 $w \in \mathbb{R}^n$ 和 $b \in \mathbb{R}$, 使得

$$w^\top x_i + b > 0, \quad (i = 1, 2, \dots, m)$$

$$w^\top x_j + b < 0, \quad (j = m + 1, m + 2, \dots, m + n)$$

- SVM: 最大化点到超平面的最小距离


$$\max_{w, b} \min\{\|x - x_k\|_2: w^\top x + b = 0, k = 1, 2, \dots, m + n\}$$

- 使距离超平面 $w^\top x_i + b = 0$ 最近的点分别位于两个超平面 $w^\top x_i + b = \pm 1$ 之上, 从而

$$w^\top x_i + b \geq 1, \quad (i = 1, 2, \dots, m)$$

$$w^\top x_j + b \leq -1, \quad (j = m + 1, m + 2, \dots, m + n)$$

- 超平面 $H_1 = \{z: w^\top z + b = 1\}$ 与超平面 $H_2 = \{z: w^\top z + b = -1\}$ 的欧氏距离等于 $\frac{2}{\|w\|_2}$ 。



支撑向量机: Support Vector Machines (SVM)

- 通过最大化Margin区分两组样本点集合 $C_1 = \{x_1, x_2, \dots, x_m\} \subseteq \mathbb{R}^d$ 和 $C_2 = \{x_{m+1}, x_{m+2}, \dots, x_{m+n}\} \subseteq \mathbb{R}^d$,

$$\min_{w \in \mathbb{R}^d, b \in \mathbb{R}} \frac{1}{2} \|w\|_2^2$$

$$\text{s.t. } w^\top x_i + b \geq 1, (i = 1, 2, \dots, m)$$


$$w^\top x_j + b \leq -1, (j = m + 1, m + 2, \dots, m + n)$$

正样本类别标签 $y_i = 1 (i = 1, 2, \dots, m)$,

负样本类别标签 $y_j = -1 (j = m + 1, m + 2, \dots, n)$

$$\min_{w \in \mathbb{R}^d, b \in \mathbb{R}} \frac{1}{2} \|w\|_2^2$$


$$\text{s.t. } y_k (w^\top x_k + b) \geq 1, (k = 1, 2, \dots, m + n).$$



支撑向量机: Support Vector Machines (SVM)

- 存在 (w, b) , 使得 $y_k(w^\top x_k + b) \geq 1, k = 1, 2, \dots, m + n$, 即样本被线性可分, 有

$$\begin{aligned} \min_{w \in \mathbb{R}^d, b \in \mathbb{R}} \quad & \frac{1}{2} \|w\|_2^2 \\ \text{s.t.} \quad & y_k(w^\top x_k + b) \geq 1, k = 1, 2, \dots, m + n. \end{aligned}$$



- 如果不存在 (w, b) , 使得 $y_k(w^\top x_k + b) \geq 1, k = 1, 2, \dots, m + n$, 即样本不是线性可分的。怎么办?
- 引入松弛变量 $\xi_k \geq 0$ 和惩罚因子 C , 使存在 (w, b) 满足 $y_k(w^\top x_k + b) \geq 1 - \xi_k (k = 1, 2, \dots, m + n)$, 则有

$$\begin{aligned} \min_{w \in \mathbb{R}^d, b \in \mathbb{R}, \xi_k (\forall k)} \quad & \frac{1}{2} \|w\|_2^2 + C \sum_{k=1}^{m+n} \xi_k \\ \text{s.t.} \quad & y_k(w^\top x_k + b) \geq 1 - \xi_k (k = 1, 2, \dots, m + n) \\ & \xi_k \geq 0 (k = 1, 2, \dots, m + n) \end{aligned}$$

支撑向量机: Support Vector Machines (SVM)

$$\begin{aligned} \min \quad & \frac{1}{2} \|w\|_2^2 + C \sum_{k=1}^{m+n} \xi_k \\ \text{s.t.} \quad & y_k (w^\top x_k + b) \geq 1 - \xi_k \quad (k = 1, 2, \dots, m+n) \\ & \xi_k \geq 0 \quad (k = 1, 2, \dots, m+n) \end{aligned}$$



$$\begin{aligned} \min \quad & \frac{1}{2} x^\top P x + c^\top x + d \\ \text{s.t.} \quad & G x \leq h \\ & \xi_k \geq 0 \quad (k = 1, 2, \dots, m+n) \end{aligned}$$

三个优化变量 $w \in \mathbb{R}^d$, $\xi = [\xi_1, \xi_2, \dots, \xi_{m+n}]^\top \in \mathbb{R}^{m+n}$, $b \in \mathbb{R}$.

- SVM优化问题实际上为二次规划问题（凸优化问题）

$$\begin{aligned} x &= \begin{bmatrix} w \\ \xi \\ b \end{bmatrix}, & P &= \begin{bmatrix} I & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}, & c &= \begin{bmatrix} 0 \\ C \cdot \mathbf{1} \\ 0 \end{bmatrix}, & G &= \begin{bmatrix} -\text{diag}(y)X & -I & -y \\ 0 & -I & 0 \end{bmatrix}, \\ y &= \begin{bmatrix} y_1 \\ \vdots \\ y_{m+n} \end{bmatrix}, & X &= \begin{bmatrix} x_1^\top \\ \vdots \\ x_{m+n}^\top \end{bmatrix}, & h &= \begin{bmatrix} -1 \\ 0 \end{bmatrix} \end{aligned}$$

支撑向量机: Support Vector Machines (SVM)

$$\begin{aligned} \min_{w, b, \xi_k (\forall k)} & \frac{1}{2} \|w\|_2^2 + C \sum_{k=1}^{m+n} \xi_k \\ \text{s. t.} & y_k (w^\top x_k + b) \geq 1 - \xi_k \quad (k = 1, 2, \dots, m+n) \\ & \xi_k \geq 0 \quad (k = 1, 2, \dots, m+n) \end{aligned}$$

不等式约束太多太复杂

- SVM优化问题为凸优化问题
- SVM优化问题满足Slater条件。

证明：如果令 $w = 0, b = 0, \xi_k = 2$ ，则有 $y_k (w^\top x_k + b) = 0 > 1 - \xi_k = 1 - 2 = -1$ ，不等式条件严格满足。

- SVM凸优化问题强对偶性成立，原问题和对偶问题有相同的最优解，因此可以转化为对偶问题求解。



支撑向量机: Support Vector Machines (SVM)

$$\begin{aligned} \min_{w, b, \xi_k (\forall k)} & \frac{1}{2} \|w\|_2^2 + C \sum_{k=1}^{m+n} \xi_k \\ \text{s. t.} & y_k (w^\top x_k + b) \geq 1 - \xi_k \quad (k = 1, 2, \dots, m+n) \\ & \xi_k \geq 0 \quad (k = 1, 2, \dots, m+n) \end{aligned}$$

- 拉格朗日函数:

$$L(w, b, \xi, \alpha, \beta) = \frac{1}{2} \|w\|_2^2 + C \sum_{k=1}^{n+m} \xi_k - \sum_{k=1}^{n+m} \alpha_k (y_k (w^\top x_k + b) - 1 + \xi_k) - \sum_{k=1}^{n+m} \beta_k \xi_k$$

- 拉格朗日对偶函数: $g(\alpha, \beta) = \min_{w, b, \xi} L(w, b, \xi, \alpha, \beta)$
- 拉格朗日对偶问题: $\max_{\alpha \geq 0, \beta \geq 0} g(\alpha, \beta)$



支撑向量机: Support Vector Machines (SVM)

- 拉格朗日对偶问题: $\max_{\alpha \geq 0, \beta \geq 0} g(\alpha, \beta)$

$$g(\alpha, \beta) = \min_{w, b, \xi} L(w, b, \xi, \alpha, \beta) = \frac{1}{2} \|w\|_2^2 + C \sum_{k=1}^{n+m} \xi_k - \sum_{k=1}^{n+m} \alpha_k (y_k (w^\top x_k + b) - 1 + \xi_k) - \sum_{k=1}^{n+m} \beta_k \xi_k$$

$$\begin{aligned} \frac{\partial L(w, b, \xi, \alpha, \beta)}{\partial w} = 0 & \Rightarrow w = \sum_{k=1}^{n+m} \alpha_k y_k x_k \\ \frac{\partial L(w, b, \xi, \alpha, \beta)}{\partial b} = 0 & \Rightarrow \sum_{k=1}^{n+m} \alpha_k y_k = 0 \\ \frac{\partial L(w, b, \xi, \alpha, \beta)}{\partial \xi} = 0 & \Rightarrow \alpha_k + \beta_k = C \end{aligned}$$

$$\min_{\alpha} \quad \frac{1}{2} \sum_{k=1}^{n+m} \sum_{s=1}^{n+m} \alpha_k \alpha_s y_k y_s x_i^\top x_j - \sum_{k=1}^{n+m} \alpha_k$$

$$s.t. \quad 0 \leq \alpha_i \leq C, i = 1, 2, \dots, m+n$$

$$\sum_{k=1}^{n+m} \alpha_k y_k = 0$$

凸优化问题

简单的不等式和等式约束



支撑向量机：Support Vector Machines (SVM)

作业：从优化建模的角度阐述SVM的前世今生

$$\begin{aligned} \min_{w, b, \xi_k (\forall k)} \quad & \frac{1}{2} \|w\|_2^2 + C \sum_{k=1}^n \xi_k \\ \text{s.t.} \quad & y_k (w^\top x_k + b) \geq 1 - \xi_k \quad (k = 1, 2, \dots, n) \\ & \xi_k \geq 0 \quad (k = 1, 2, \dots, n) \end{aligned}$$

