



西安交通大学
XI'AN JIAOTONG UNIVERSITY

第四章：等式约束凸优化问题



等式约束凸优化问题-问题描述

等式约束凸优化问题

$$\begin{array}{ll}\min & f(x) \\ \text{s. t.} & Ax = b\end{array}$$

- 函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 为二次连续可微凸函数，定义域 $\text{dom } f$;
- $A \in \mathbb{R}^{p \times n}$, $\text{rank}(A) = p < n$.
- $p^* = \inf \{f(x): Ax = b\} = f(x^*)$

等式约束个数少于变量数目，
并且等式约束互相独立



等式约束凸优化问题-问题描述

$$\begin{array}{ll} \min & f(x) \\ \text{s.t.} & Ax = b \end{array} \quad \begin{array}{l} \bullet \ f: \mathbb{R}^n \rightarrow \mathbb{R} \text{ 为二次连续可微凸函数} \\ \bullet \ A \in \mathbb{R}^{p \times n}, \text{ rank}(A) = p < n \end{array}$$

- $x^* \in \text{dom } f$ 是优化问题最优解的充要条件：存在 $v^* \in \mathbb{R}^p$ 满足：

KKT方程

- 线性原可行方程： $Ax^* = b$
- 线性/非线性对偶可行方程： $\nabla f(x^*) + A^\top v^* = 0$

求解等式约束的凸优化问题等价于确定KKT方程的解，即
含有 $n + p$ 个变量 x^*, v^* 的 $n + p$ 个方程的求解问题

等式约束凸优化问题-举例

$$\begin{aligned} \min f(x) &= \frac{1}{2}x^\top Px + q^\top x + r \quad (P \in S_+^n) \\ \text{s.t. } Ax &= b \end{aligned}$$

KKT方程

- 线性原可行方程: $Ax^* = b$
- 线性对偶可行方程: $\nabla f(x^*) + A^\top v^* = 0$

$n + p$ 个变量 x^*, v^* 的 $n + p$ 个线性方程的求解问题

KKT矩阵 $\leftarrow \begin{bmatrix} P & A^\top \\ A & 0 \end{bmatrix} \begin{bmatrix} x \\ v \end{bmatrix} = \begin{bmatrix} -q \\ b \end{bmatrix}$

- KKT矩阵非奇异（例如 P 对称正定），存在唯一最优的原对偶对 (x^*, v^*)
- KKT矩阵奇异，但方程有解，则任意解都构成最优对 (x^*, v^*)
- 若方程无解，则二次优化问题无下界或者无解



等式约束凸优化问题-求解

$$\begin{array}{ll} \min & f(x) \\ \text{s.t.} & Ax = b \end{array} \quad \begin{array}{l} \bullet f: \mathbb{R}^n \rightarrow \mathbb{R} \text{ 为二次连续可微凸函数} \\ \bullet A \in \mathbb{R}^{p \times n}, \text{ rank}(A) = p < n \end{array}$$

- $x^* \in \text{dom } f$ 是优化问题的最优解的充要条件：存在 $v^* \in \mathbb{R}^p$ 满足

$$\text{KKT方程} \begin{cases} \text{线性原可行方程: } Ax^* = b \\ \text{非线性对偶可行方程: } \nabla f(x^*) + A^T v^* = 0 \end{cases}$$



很少可以用解析的方法求解最优性条件.....

- 消除方法：消除等式约束，转换为等价的**无约束问题**；
- 对偶方法：利用**无约束优化方法**求解对偶问题（假设对偶函数是二次可微的），然后从对偶问题中复原等式约束优化问题的解。



消除等式约束

$\min f(x)$ • $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 二次连续可微凸函数
s.t. $Ax = b$ • $A \in \mathbb{R}^{p \times n}$, $\text{rank}(A) = p < n$
可行解集合: $\{x \in \text{dom } f | Ax = b\}$

• 参数化（仿射）可行解集: $\{x | Ax = b\} = \{Fz + \hat{x} | z \in \mathbb{R}^{n-p}\}$

✓ $\hat{x} \in \text{dom } f$ 可选用满足 $A\hat{x} = b$ 的任意特殊解;

✓ 消除矩阵 $F \in \mathbb{R}^{n \times (n-p)}$ 是值域 $R(F)$ 为 A 的零空间 $N(A)$ 的任何矩阵, 即

$$R(F) = \{Fz | z \in \mathbb{R}^{n-p}\} = N(A) = \{x | Ax = 0\} \longrightarrow AF = 0$$

• 消除等式约束后的优化问题

$$\min_{z \in \mathbb{R}^{n-p}} \tilde{f}(z) = f(Fz + \hat{x}) \iff \min \{f(x) | \text{s.t. } Ax = b\}$$

• 最优解 $z^* \in \mathbb{R}^{n-p}$ 确定原等式约束问题的最优解 $x^* = Fz^* + \hat{x}$, 即

$$\nabla \tilde{f}(z^*) = 0 \iff \nabla \tilde{f}(z^*) = F^\top \nabla f(Fz^* + \hat{x}) = F^\top \nabla f(x^*) = 0$$

回顾

$$\begin{array}{ll} \min & f(x) \\ \text{s.t.} & Ax = b \end{array} \longleftrightarrow \text{KKT方程} \begin{cases} Ax^* = b \\ \nabla f(x^*) + A^\top v^* = 0 \end{cases}$$

✓ 消除方法: $\min_{z \in \mathbb{R}^{n-p}} \tilde{f}(z) = f(Fz + \hat{x})$

参数化（仿射）可行集: $\{x | Ax = b\} = \{Fz + \hat{x} | z \in \mathbb{R}^{n-p}\}$

✓ $\hat{x} \in \text{dom } f$ 可选用满足 $A\hat{x} = b$ 的任意特殊解;

✓ 消除矩阵 $F \in \mathbb{R}^{n \times (n-p)}$ 是值域 $R(F)$ 为 A 的零空间 $N(A)$ 的任何矩阵, 即

$$R(F) = \{Fz | z \in \mathbb{R}^{n-p}\} = N(A) = \{x | Ax = 0\}$$

✓ 对偶方法: $\min_x f(x) + (v^*)^\top (Ax - b)$

回顾

$$\begin{array}{ll} \min & f(x) \\ \text{s.t.} & Ax = b \end{array}$$

$$\text{KKT方程} \begin{cases} Ax^* = b \\ \nabla f(x^*) + A^\top v^* = 0 \end{cases}$$

✓ 消除方法: $\min_{z \in \mathbb{R}^{n-p}} \tilde{f}(z) = f(Fz + \hat{x})$ 。参数化（仿射）可行集:

$$\{x | Ax = b\} = \{Fz + \hat{x} | z \in \mathbb{R}^{n-p}\}$$

- $\hat{x} \in \text{dom } f$ 可选用满足 $A\hat{x} = b$ 的任意特殊解;
- 消除矩阵 $F \in \mathbb{R}^{n \times (n-p)}$ 是值域 $R(F)$ 为 A 的零空间 $N(A)$ 的任何矩阵, 即

$$R(F) = \{Fz | z \in \mathbb{R}^{n-p}\} = N(A) = \{x | Ax = 0\}$$

✓ 对偶方法: $\min_x f(x) + (v^*)^\top (Ax - b)$

直接求解等式约束!

✓ 利用问题结构

选择消除矩阵

$$\min_{z \in \mathbb{R}^{n-p}} \tilde{f}(z) = f(Fz + \hat{x}) \Leftrightarrow \min \{f(x) | s.t. Ax = b\}$$

- $\mathbb{R}^{n \times (n-p)}$ 中任何满足 $R(F) = N(A)$ 的矩阵都可以用作消除矩阵。
- 若 $F \in \mathbb{R}^{n \times (n-p)}$ 是消除矩阵, $T \in \mathbb{R}^{(n-p) \times (n-p)}$ 是非奇异矩阵, 则 $\tilde{F} = FT$ 也是消除矩阵。

证明: $R(\tilde{F}) = R(F) = N(A)$

- 若 $\tilde{F}, F \in \mathbb{R}^{n \times (n-p)}$ 是任意两个消除矩阵, 则存在某非奇异矩阵 $T \in \mathbb{R}^{(n-p) \times (n-p)}$ 使得

$$\tilde{F} = FT$$

$$\min \{f(x) | s.t. Ax = b\} \Leftrightarrow \min_{z \in \mathbb{R}^{n-p}} f(Fz + \hat{x})$$

$$\Leftrightarrow \min_{z \in \mathbb{R}^{n-p}} f(\tilde{F}\tilde{z} + \hat{x}) = f(F(T\tilde{z}) + \hat{x})$$

改变消除矩阵

=

对无约束优化问题进行变量变换



$Ax = b$ 所有解的参数化形式

$$Ax = b \quad \longleftrightarrow \quad \{x | Ax = b\} = \{Fz + \hat{x} | z \in \mathbb{R}^{n-p}\}$$

- ✓ $A \in \mathbb{R}^{p \times n}$, $\text{rank}(A) = p < n$
- ✓ 对于任意 $b \in \mathbb{R}^p$, $Ax = b$ 至少存在一个解
- ✓ 如果已知 A 的一个 $p \times p$ 的非奇异矩阵, 可以直接求解不确定系统
- 假设: A 的前 p 个列向量线性无关, 记作 $A_1 \in \mathbb{R}^{p \times p}$, 则

$$Ax = [A_1 \quad A_2] \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = A_1 x_1 + A_2 x_2 = b$$

$$\begin{aligned} \rightarrow x_1 &= A_1^{-1}(b - A_2 x_2) = A_1^{-1}b - A_1^{-1}A_2 x_2 \quad \rightarrow \begin{cases} \hat{x}_2 = 0, \hat{x}_1 = A_1^{-1}b \\ x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} -A_1^{-1}A_2 \\ I \end{bmatrix} x_2 + \begin{bmatrix} A_1^{-1}b \\ 0 \end{bmatrix} \\ &= Fz + \hat{x} \end{cases} \end{aligned}$$



$Ax = b$ 所有解的参数化形式

$$Ax = b \quad \longleftrightarrow \quad \{x | Ax = b\} = \{Fz + \hat{x} | z \in \mathbb{R}^{n-p}\}$$

- ✓ $A \in \mathbb{R}^{p \times n}$, $\text{rank}(A) = p < n$
- ✓ 对于任意 $b \in \mathbb{R}^p$, $Ax = b$ 至少存在一个解
- ✓ 如果已知 A 的一个 $p \times p$ 的非奇异矩阵, 可以直接求解不确定系统
- 一般情况, $\text{rank}(A) = p$, 可以选出矩阵 A 的 p 个线性独立的列向量, 即存在排列矩阵 P 使得 $\tilde{A} = AP$ 的前 p 个列向量线性独立, 令

$$\tilde{A} = AP = [A_1 \quad A_2]$$

其中 $A_1 \in \mathbb{R}^{p \times p}$ 可逆, 方程 $\tilde{A}\tilde{x} = b$, $\tilde{x} = P^T x$, 则

$$\tilde{x} = \begin{bmatrix} -A_1^{-1}A_2 \\ I \end{bmatrix} \tilde{x}_2 + \begin{bmatrix} A_1^{-1}b \\ 0 \end{bmatrix} \quad \longrightarrow \quad x = P\tilde{x} = P \begin{bmatrix} -A_1^{-1}A_2 \\ I \end{bmatrix} z + P \begin{bmatrix} A_1^{-1}b \\ 0 \end{bmatrix} \\ = Fz + \hat{x}$$



消除等式约束-例子

- 受资源约束的最优配置

$$\min \sum_{i=1}^n f_i(x_i) \quad \text{s.t.} \quad \sum_{i=1}^n x_i = b$$

这里, $f_i: \mathbb{R} \rightarrow \mathbb{R}$ 二次可微凸函数, $b \in \mathbb{R}$ 为问题参数 (预算值)

令 $x_n = b - x_1 - x_2 - \cdots - x_{n-1}$, 选择

$$\hat{x} = be_n \in \mathbb{R}^n, \quad F = \begin{bmatrix} I \\ -\mathbf{1}^\top \end{bmatrix} \in \mathbb{R}^{n \times (n-1)}$$

则问题简化为

$$\min f_n(b - x_1 - x_2 - \cdots - x_{n-1}) + \sum_{i=1}^{n-1} f_i(x_i)$$

用对偶方法求解等式约束问题

$$\begin{array}{ll} \min f(x) & \bullet \quad f: \mathbb{R}^n \rightarrow \mathbb{R} \text{ 二次连续可微凸函数} \\ \text{s.t. } Ax = b & \bullet \quad A \in \mathbb{R}^{p \times n}, \text{ rank}(A) = p < n \end{array}$$

- 先求解等式约束问题的对偶问题，然后复原最优的原变量

$$\begin{aligned} \text{对偶函数: } g(v) &= -b^\top v + \inf_x (f(x) + v^\top Ax) \\ &= -b^\top v - \sup_x ((-A^\top v)^\top x - f(x)) \\ &= -b^\top v - f^*(-A^\top v) \end{aligned}$$

f^* 是 f 的共轭

$$\text{对偶问题: } \max_v -b^\top v - f^*(-A^\top v)$$

- 原问题存在最优解，该问题严格可行，Slater条件满足，从而强对偶性成立，即存在 v^* 满足 $g(v^*) = p^*$ ，再求解无约束最优化问题

$$\min_x f(x) + (v^*)^\top (Ax - b) \quad \Leftrightarrow \quad \nabla f(x) + A^\top v^* = 0$$



消除等式约束

$$\min_{z \in \mathbb{R}^{n-p}} \tilde{f}(z) = f(Fz + \hat{x}) \Leftrightarrow \min \{f(x) | \text{s.t. } Ax = b\}$$

- $v^* = -(AA^\top)^{-1}A\nabla f(x^*)$ 为原等式约束问题的一个最优对偶变量。

证明：对偶可行性条件

$$\nabla f(x^*) + A^\top v^* = \nabla f(x^*) + A^\top (-(AA^\top)^{-1}A\nabla f(x^*)) = 0$$



$$\begin{bmatrix} F^\top \\ A \end{bmatrix} \left(\nabla f(x^*) + A^\top (-(AA^\top)^{-1}A\nabla f(x^*)) \right) = 0$$

非奇异

$$F^\top \nabla f(x^*) = 0$$

$$AF = 0$$

$$F \in \mathbb{R}^{n \times (n-p)}$$

$$A \in \mathbb{R}^{p \times n}$$



例2：等式约束的解析中心

$$\min \{f(x) = -\sum_{i=1}^n \log x_i \mid s.t. Ax = b\}, \quad \text{dom} f = R_{++}^n$$

- 拉格朗日函数： $L(x, v) = -\sum_{i=1}^n \log x_i + v^\top (Ax - b)$

利用 $f^*(y) = \sum_{i=1}^n (-1 - \log(-y_i)) = -n - \sum_{i=1}^n \log(-y_i)$, $\text{dom} f^* = -R_{++}^n$

- 对偶问题：

$$\max_v g(v) = -b^\top v + n + \sum_{i=1}^n \log(A^\top v)_i$$

- 求解对偶可行性方程

$$\nabla f(x) + A^\top v = -(1/x_1, \dots, 1/x_n) + A^\top v = 0 \Rightarrow x_i(v) = \frac{1}{(A^\top v)_i}$$



等式约束凸优化问题

等式约束凸优化问题

$$\begin{array}{ll} \min & f(x) \\ \text{s.t.} & Ax = b \end{array}$$

$$\text{KKT方程} \begin{cases} Ax^* = b \\ \nabla f(x^*) + A^\top v^* = 0 \end{cases}$$

- 函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 为二次连续可微凸函数
- $A \in \mathbb{R}^{p \times n}$, $\text{rank}(A) = p < n$
- $p^* = \inf \{f(x) : Ax = b\} = f(x^*)$

✓ 消除方法: $\min_{z \in \mathbb{R}^{n-p}} \tilde{f}(z) = f(Fz + \hat{x})$

✓ 对偶方法: $\min_x f(x) + (v^*)^\top (Ax - b)$

破坏原问题结构

- 直接求解等式约束!

✓ 利用问题结构

✓ 可视为直接求解最优性条件(KKT方程)

回顾：无约束凸优化问题牛顿方法求解

$$\min f(x)$$

牛顿下降回溯直线搜索算法求解无约束凸优化问题

1. 给定初始点 $x^0 \in \text{dom } f$ ，误差阈值 $\varepsilon > 0$ ，令 $k = 0$
2. 计算Newton步径和增量

$$d_{nt}^k = -\nabla^2 f(x^k)^{-1} \nabla f(x^k); \quad \lambda(x^k)^2 = (d_{nt}^k)^\top \nabla^2 f(x^k) d_{nt}^k$$

3. 停止准则：若 $\frac{1}{2} \lambda(x^k)^2 \leq \varepsilon$ ，退出
4. 回溯直线搜索： $0 < \alpha < 0.5, 0 < \beta < 1, t^k = 1$

$$\text{While } f(x^k + t^k d_{nt}^k) > f(x^k) - \alpha t^k \lambda(x^k)^2 \\ t^k := \beta t^k$$

End

5. $x^{k+1} = x^k + t^k d_{nt}^k, k = k + 1$ ，回2

$$\begin{aligned} \min f(x) \\ \text{s.t. } Ax = b \end{aligned}$$

- 初始点必须可行： $x^0 \in \text{dom } f, Ax^0 = b$
- 根据等式约束的需要对牛顿方向的定义进行适当的修改，保证牛顿方向是可行方向，即 $Ad_x^k = 0$

牛顿方向——基于二阶近似的定义

$$\begin{array}{ll} \min & f(x) \\ \text{s.t.} & Ax = b \end{array} \quad \text{等式约束问题在可行点 } x \text{ 处的牛顿方向 } d_x?$$

- 等式约束的二次极小问题：目标函数 $f(x)$ 在 x 附近的二阶Taylor近似模型

$$\begin{array}{ll} \min_v & \hat{f}(x+v) = f(x) + \nabla f(x)^\top v + \frac{1}{2} v^\top \nabla^2 f(x) v \\ \text{s.t.} & A(x+v) = b \end{array} \quad \longrightarrow \quad Av = 0$$

- 假设KKT矩阵非奇异，则定义在 x 处的牛顿方向 d_x 为

以上二次问题的解，即

$$\begin{bmatrix} \nabla^2 f(x) & A^\top \\ A & 0 \end{bmatrix} \begin{bmatrix} d_x \\ w \end{bmatrix} = \begin{bmatrix} -\nabla f(x) \\ 0 \end{bmatrix}$$

这里， w 是该二次问题的最优对偶变量。

$$\begin{aligned} \min_x & f(x) = \frac{1}{2} x^\top P x + q^\top x + r \\ \text{s.t.} & Ax = b \\ \Leftrightarrow & \begin{bmatrix} P & A^\top \\ A & 0 \end{bmatrix} \begin{bmatrix} x^* \\ v^* \end{bmatrix} = \begin{bmatrix} -q \\ b \end{bmatrix} \end{aligned}$$

牛顿方向——基于二阶近似的定义

等式约束的二次极小问题


$$\begin{array}{ll} \min_v \hat{f}(x+v) = f(x) + \nabla f(x)^\top v + \frac{1}{2} v^\top \nabla^2 f(x) v & \Rightarrow \begin{bmatrix} \nabla^2 f(x) & A^\top \\ A & 0 \end{bmatrix} \begin{bmatrix} d_x \\ w \end{bmatrix} = \begin{bmatrix} -\nabla f(x) \\ 0 \end{bmatrix} \\ \text{s.t. } A(x+v) = b \end{array}$$

- 当目标函数为严格的二次函数，牛顿修正量 $x + d_x$ 是等式约束极小化问题的准确最优解， w 是原问题最优的对偶变量。
- 当函数 f 接近二次函数时，牛顿修正量 $x + d_x$ 应该是最优解 x^* 的一个很好的估计，而 w 则应该是最优的对偶变量 v^* 的一个很好的估计。

同牛顿方法求解无约束优化问题类似

牛顿方向——线性化最优性的解

- 牛顿方向 d_x 及相关变量 w 解释为最优性条件的线性近似方程组的解



可行下降方法

$$\begin{array}{ll} \min f(x) & \bullet f: \mathbb{R}^n \rightarrow \mathbb{R} \text{ 二次连续可微凸函数} \\ \text{s.t. } Ax = b & \bullet A \in \mathbb{R}^{p \times n}, \text{ rank}(A) = p < n \end{array}$$

- 如果 $Av = 0$, 则 $v \in \mathbb{R}^n$ 是一个可行方向
- 如果对于小的 $t > 0$, 有 $f(x + tv) < f(x)$, 则 v 是 f 在 x 处的一个下降方向
- 牛顿方向总是可行下降方向

$$\checkmark \text{ 可行: } \begin{bmatrix} \nabla^2 f(x) & A^\top \\ A & 0 \end{bmatrix} \begin{bmatrix} d_x \\ w \end{bmatrix} = \begin{bmatrix} -\nabla f(x) \\ 0 \end{bmatrix} \quad \Rightarrow \quad Ad_x = 0$$

$$\checkmark \text{ 下降: } \left. \frac{\partial f(x+td_x)}{\partial t} \right|_{t=0} = \boxed{\nabla f(x)^\top d_x = -\lambda(x)^2 < 0}$$

牛顿减少量

$$\begin{array}{ll} \min & f(x) \\ \text{s.t.} & Ax = b \end{array} \quad \begin{array}{l} \bullet \quad f: \mathbb{R}^n \rightarrow \mathbb{R} \text{ 二次连续可微凸函数} \\ \bullet \quad A \in \mathbb{R}^{p \times n}, \text{ rank}(A) = p < n \end{array}$$

- 等式约束优化问题牛顿减少量

$$\lambda(x) = (d_x^\top \nabla^2 f(x) d_x)^{\frac{1}{2}}$$

与无约束优化问题相同

基于二次模型对 $f(x) - p^*$ 做出的估计

函数 f 在 x 处的二次展开: $\hat{f}(x+v) = f(x) + \nabla f(x)^\top v + \frac{1}{2} v^\top \nabla^2 f(x) v$

$$\begin{aligned} f(x) - p^* &\approx f(x) - \inf\{\hat{f}(x+v): A(x+v) = b\} \\ &= \frac{1}{2} (\lambda(x))^2 \end{aligned}$$

- 函数 f 沿着方向 d_x 的方向导数为:

$$\left. \frac{\partial f(x+td_x)}{\partial t} \right|_{t=0} = \nabla f(x)^\top d_x = -\lambda(x)^2$$

与无约束优化问题相同



等式约束的牛顿方法

- 初始点必须可行: $Ax^0 = b$
- 牛顿方向必须是可行方向: $Ad_x^k = 0$

等式限制凸优化问题的牛顿下降回溯直线搜索算法

1. 初始可行点 $x^0 \in \text{dom } f$, $Ax^0 = b$, 误差阈值 $\varepsilon > 0$, $k = 0$
2. 确定牛顿方向和牛顿减少量

$$\begin{bmatrix} \nabla^2 f(x) & A^\top \\ A & 0 \end{bmatrix} \begin{bmatrix} d_x^k \\ w \end{bmatrix} = \begin{bmatrix} -\nabla f(x) \\ 0 \end{bmatrix}; \lambda(x^k)^2 = (d_x^k)^\top \nabla^2 f(x^k) d_x^k$$

3. 停止准则: 若 $\frac{1}{2}\lambda(x^k)^2 \leq \varepsilon$, 退出
4. 回溯直线搜索: $0 < \alpha < 0.5$, $0 < \beta < 1$, $t^k = 1$

$$\begin{array}{l} \text{While } f(x^k + t^k d_x^k) > \boxed{f(x^k) - \alpha t^k \lambda(x^k)^2} \\ \quad t^k := \beta t^k \\ \text{End} \end{array}$$

$f(x^k) + \alpha t^k \nabla f(x^k)^\top d_x^k$

5. $x^{k+1} = x^k + t^k d_x^k$, $k = k + 1$, 回2

$$\begin{array}{ll} \min & f(x) \\ \text{s.t.} & Ax = b \end{array}$$

注意:

- ✓ 所有迭代点都是可行的, 并满足 $f(x^{k+1}) < f(x^k)$;
- ✓ 牛顿方法需要每个 x 处的 KKT 矩阵可逆。

牛顿方法和消除法

- 等式约束问题的牛顿方法与简化后无约束问题牛顿方法的迭代过程完全一致

$$\begin{array}{ll}\min & f(x) \\ \text{s. t.} & Ax = b\end{array}$$

$$\begin{bmatrix} \nabla^2 f(x) & A^\top \\ A & 0 \end{bmatrix} \begin{bmatrix} d_x \\ w \end{bmatrix} = \begin{bmatrix} -\nabla f(x) \\ 0 \end{bmatrix}$$

$$\min_{z \in \mathbb{R}^{n-p}} \tilde{f}(z) = f(Fz + \hat{x})$$

这里, $R(F) = N(A)$, $\text{rank}(F) = n - p$ 且 $A\hat{x} = b$

$$\nabla \tilde{f}(z) = F^\top \nabla f(Fz + \hat{x}), \quad \nabla^2 \tilde{f}(z) = F^\top \nabla^2 f(Fz + \hat{x}) F$$

简化问题的牛顿方向:

$$\begin{aligned} d_z &= - \left(\nabla^2 \tilde{f}(z) \right)^{-1} \nabla \tilde{f}(z) \\ &= - (F^\top \nabla^2 f(x) F)^{-1} F^\top \nabla f(x) \end{aligned}$$

- d_x 有意义 (KKT矩阵可逆) $\Leftrightarrow d_z$ 有意义 ($\nabla^2 \tilde{f}(z)$ 可逆)
- 牛顿方向 d_z 对应于等式约束问题的方向是

$$Fd_z = - F(F^\top \nabla^2 f(x) F)^{-1} F^\top \nabla f(x)$$



牛顿方法和消除法

$$\min_{z \in \mathbb{R}^{n-p}} \tilde{f}(z) = f(Fz + \hat{x}) \Leftrightarrow \min \{f(x) | s.t. Ax = b\}$$

- $Fd_z = -F(F^\top \nabla^2 f(x) F)^{-1} F^\top \nabla f(x)$ 与 $\begin{bmatrix} \nabla^2 f(x) & A^\top \\ A & 0 \end{bmatrix} \begin{bmatrix} d_x \\ w \end{bmatrix} = \begin{bmatrix} -\nabla f(x) \\ 0 \end{bmatrix}$ 确定的等式约束优化问题的牛顿方向完全相同。

证明：令 $d_x = Fd_z$ ，构造 $w = -(AA^\top)^{-1}A(\nabla f(x) + \nabla^2 f(x)d_x)$ 。验证其能够满足

$$\nabla f^2(x)d_x + A^\top w + \nabla f(x) = 0, \quad Ad_x = 0 \quad (AF = 0)$$

$$\begin{bmatrix} F^\top \\ A \end{bmatrix} (\nabla f^2(x)d_x + A^\top w + \nabla f(x)) = \begin{bmatrix} F^\top \nabla f^2(x)d_x + F^\top A^\top w + F^\top \nabla f(x) \\ A \nabla f^2(x)d_x + AA^\top w + A \nabla f(x) \end{bmatrix} = 0$$

非奇异



牛顿方法和消除法

$$\min_{z \in \mathbb{R}^{n-p}} \tilde{f}(z) = f(Fz + \hat{x}) \Leftrightarrow \min \{f(x) | s. t. Ax = b\}$$

- $\tilde{f}$ 在 z 处的牛顿减少量 $\tilde{\lambda}(z)$ 和 f 在 x 处的牛顿减少量 $\lambda(x)$ 相等。

证明:

$$\begin{aligned}\tilde{\lambda}(z)^2 &= d_z^\top \nabla^2 \tilde{f}(z) d_z \\ &= d_z^\top F^\top \nabla^2 f(x) F d_z \\ &= d_x^\top \nabla^2 f(x) d_x \\ &= \lambda(x)^2\end{aligned}$$

$$\nabla^2 \tilde{f}(z) = F^\top \nabla^2 f(Fz + \hat{x}) F$$

$$d_x = F d_z$$



牛顿方法和消除法

$$\min_{z \in \mathbb{R}^{n-p}} \tilde{f}(z) = f(Fz + \hat{x}) \Leftrightarrow \min \{f(x) | s.t. Ax = b\}$$

总结：在已知 $Ax = b$ 的一个解的情况下，将等式约束变成无约束优化问题，并采用牛顿方法求解，等价于解下述线性方程组（其中 x 给定）确定搜索方向 d_x ，然后对原目标函数进行直线搜索

$$\begin{bmatrix} \nabla^2 f(x) & A^\top \\ A & 0 \end{bmatrix} \begin{bmatrix} d_x \\ v \end{bmatrix} = \begin{bmatrix} -\nabla f(x) \\ 0 \end{bmatrix}$$

停止准则同样可写成：
$$\frac{1}{2} d_z^\top \nabla^2 \tilde{f}(z) d_z = \frac{1}{2} d_x^\top \nabla^2 f(x) d_x \leq \varepsilon$$

已知可行点收敛性分析

等式约束问题的牛顿方法

$$\min \{f(x) | s.t. Ax = b\}$$

$$\begin{bmatrix} \nabla^2 f(x) & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} d_x \\ w \end{bmatrix} = \begin{bmatrix} -\nabla f(x) \\ 0 \end{bmatrix}$$

✓ $S = \{x | x \in \text{dom } f, f(x) \leq f(x^0), Ax = b\}$ 是闭集, 其中 $x^0 \in \text{dom } f, Ax^0 = b$;

✓ $\forall x \in S, \nabla^2 f(x) \leq MI$, 并且KKT满足

$$\left\| \begin{pmatrix} \nabla^2 f(x) & A^T \\ A & 0 \end{pmatrix}^{-1} \right\|_2 \leq K$$

类似于 $\|\nabla^2 f(x)^{-1}\|_2 \leq K, K = \frac{1}{m}$

✓ 存在 $L, \forall x, y \in S$ 满足

$$\|\nabla^2 f(x) - \nabla^2 f(y)\|_2 \leq L\|x - y\|_2$$

无约束凸优化问题牛顿方法总迭代次数

$$K \leq \frac{f(x^0) - p^*}{\gamma} + \log_2(\log_2(\varepsilon_0/\varepsilon))$$

简化后无约束问题牛顿方法

$$\min_{z \in R^{n-p}} \tilde{f}(z) = f(Fz + \hat{x})$$

这里, $R(F) = N(A), \text{rank}(F) = n - p$ 且 $A\hat{x} = b$

$$\nabla \tilde{f}(z) = F^T \nabla f(Fz + \hat{x}), \nabla^2 \tilde{f}(z) = F^T \nabla^2 f(Fz + \hat{x}) F$$

$$d_z = - \left(\nabla^2 \tilde{f}(z) \right)^{-1} \nabla \tilde{f}(z)$$

$$= - (F^T \nabla^2 f(x) F)^{-1} F^T \nabla f(x)$$

✓ $\tilde{S} = \{z | z \in \text{dom } \tilde{f}, \tilde{f}(z) \leq \tilde{f}(z^0)\}$ 是闭集;

✓ 存在 m, M 满足 $mI \leq \nabla^2 \tilde{f}(z) \leq MI, \forall z \in \tilde{S}$;

✓ 存在 $L, \forall x, y \in \tilde{S}$ 满足

$$\|\nabla^2 \tilde{f}(y) - \nabla^2 \tilde{f}(z)\|_2 \leq L\|y - z\|_2$$



不可行初始点的牛顿方向

$$\begin{aligned} \min f(x) & \quad \bullet \quad f: \mathbb{R}^n \rightarrow \mathbb{R} \text{ 为二次连续可微凸函数} \\ \text{s.t. } Ax = b & \quad \bullet \quad A \in \mathbb{R}^{p \times n}, \text{ rank}(A) = p < n \end{aligned}$$

- 不假定当前点 $x \in \text{dom } f$ 是可行的。找到一个不可行点处牛顿方向 d 使得 $x + d$ 近似满足最优性条件，即 $x + d \approx x^*$ 。
- 若当前点 x 满足 $Ax - b = 0$ ，则方向 $\diamond$ 与可行牛顿方向 d_x 相同，即 $d = d_x$ 。

$$\begin{bmatrix} \nabla^2 f(x) & A^\top \\ A & 0 \end{bmatrix} \begin{bmatrix} d_x \\ v \end{bmatrix} = \begin{bmatrix} -\nabla f(x) \\ 0 \end{bmatrix}$$

可行初始点的牛顿方向

等式约束优化的最优性条件

$$\begin{cases} Ax^* = b \\ \nabla f(x^*) + A^\top v^* = 0 \end{cases}$$

梯度一阶近似

$$\nabla f(x + d) \approx \nabla f(x) + \nabla^2 f(x)d$$

$$\begin{cases} A(x + d) = b \\ \nabla f(x) + \nabla^2 f(x)d + A^\top w = 0 \end{cases}$$

$$\begin{bmatrix} \nabla^2 f(x) & A^\top \\ A & 0 \end{bmatrix} \begin{bmatrix} d \\ w \end{bmatrix} = - \begin{bmatrix} \nabla f(x) \\ Ax - b \end{bmatrix}$$

不可行初始点的牛顿方向



作为原对偶牛顿方向的解释

$\min f(x)$ • $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 为二次连续可微凸函数
s.t. $Ax = b$ • $A \in \mathbb{R}^{p \times n}$, $\text{rank}(A) = p < n$

等式约束优化的最优性条件 $\begin{cases} Ax^* = b \\ \nabla f(x^*) + A^\top v^* = 0 \end{cases}$

- 基本想法：从任意 $x^0 \in \text{dom } f \subseteq \mathbb{R}^n$, $v^0 \in \mathbb{R}^p$ 开始求解最优性条件。
- 原对偶残差：关于 y 的函数 $r(y) = \begin{bmatrix} \nabla f(x) + A^\top v \\ Ax - b \end{bmatrix} \triangleq \begin{bmatrix} r_{dual}(y) \\ r_{pri}(y) \end{bmatrix}$, 这里 $y = \begin{pmatrix} x \\ v \end{pmatrix}$
- 原等式约束凸优化问题优化过程等价于：给定任意 y , 找到一个下降方向 $d_y = \begin{pmatrix} d_x \\ d_v \end{pmatrix}$, 使得 $y + d_y$ 满足最优性条件, 即 $r(y + d_y) = 0$ 。

总结：等式限制凸优化问题求解

$$\begin{array}{ll} \min & f(x) \\ \text{s. t.} & Ax = b \end{array}$$

KKT方程

$$\begin{cases} Ax^* = b \\ \nabla f(x^*) + A^T v^* = 0 \end{cases}$$

✓ 对偶方法: $\min_x f(x) + (v^*)^T (Ax - b)$

✓ 消除方法: $\min_{z \in \mathbb{R}^{n-p}} \tilde{f}(z) = f(Fz + \hat{x})$

牛顿方向:

$$d_z = - \left(\nabla^2 \tilde{f}(z) \right)^{-1} \nabla \tilde{f}(z)$$

$$= - (F^T \nabla^2 f(x) F)^{-1} F^T \nabla f(x)$$

$$d_x = F d_z, \quad \tilde{\lambda}(x) = \lambda(x)$$

梯度一阶近似

$$\nabla f(x + d) \approx \nabla f(x) + \nabla f^2(x) d$$

$$\begin{cases} A(x + d) = b \\ \nabla f(x) + \nabla f^2(x) d + A^T w = 0 \end{cases}$$

✓ 可行初始点牛顿方向:

$$\begin{bmatrix} \nabla^2 f(x) & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} d_x \\ w \end{bmatrix} = \begin{bmatrix} -\nabla f(x) \\ 0 \end{bmatrix}$$

✓ 不可行初始点的牛顿方向

$$\begin{bmatrix} \nabla^2 f(x) & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} d \\ w \end{bmatrix} = - \begin{bmatrix} \nabla f(x) \\ Ax - b \end{bmatrix}$$



等式约束问题的原对偶方法

等式约束问题的原对偶方法：同时修改原变量 x 和对偶变量 v 使最优性条件(近似)满足。

$$\begin{array}{l}
 \text{等式约束优化的最优性条件} \left\{ \begin{array}{l} Ax^* - b = 0 \\ \nabla f(x^*) + A^T v^* = 0 \end{array} \right. \xrightarrow[r(x, v) = (r_{\text{dual}}(x, v), r_{\text{pri}}(x, v))]{r: \mathbb{R}^n \times \mathbb{R}^p \rightarrow \mathbb{R}^n \times \mathbb{R}^p} \begin{bmatrix} r_{\text{dual}}(x, v) \\ r_{\text{pri}}(x, v) \end{bmatrix} = \begin{bmatrix} \nabla f(x) + A^T v \\ Ax - b \end{bmatrix} = r(y)
 \end{array}$$

对偶残差 原残差 原对偶残差

- 原对偶残差在当前估计点 y 附近的一阶Taylor近似为：

$$r(y + z) \approx r(y) + Dr(y)z, \quad Dr(y) = \begin{bmatrix} \nabla^2 f(x) & A^T \\ A & 0 \end{bmatrix} \in \mathbb{R}^{(n+p) \times (n+p)} \text{ 是 } r \text{ 在 } y \text{ 处的导数。}$$

$$r(y) + Dr(y)d_y = 0 \Rightarrow \begin{bmatrix} \nabla^2 f(x) & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} d_x \\ d_v \end{bmatrix} = - \begin{bmatrix} \nabla f(x) + A^T v \\ Ax - b \end{bmatrix} \Leftrightarrow d_y = \begin{bmatrix} d_x \\ d_v \end{bmatrix} = - \begin{bmatrix} \nabla^2 f(x) & A^T \\ A & 0 \end{bmatrix}^{-1} r(y) = - Dr(y)^{-1} r(y)$$

$$v^+ = v + d_v$$

$$\begin{bmatrix} \nabla^2 f(x) & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} d \\ w \end{bmatrix} = - \begin{bmatrix} \nabla f(x) \\ Ax - b \end{bmatrix}$$

不可行初始点的牛顿方向

$$\begin{bmatrix} \nabla^2 f(x) & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} d_x \\ v^+ \end{bmatrix} = - \begin{bmatrix} \nabla f(x) \\ Ax - b \end{bmatrix}$$

原对偶牛顿方向

$$\begin{array}{l} d = d_x \\ w = v^+ = v + d_v \end{array}$$

残差范数的缩减性质

$$\begin{bmatrix} \nabla^2 f(x) & A^\top \\ A & 0 \end{bmatrix} \begin{bmatrix} d \\ w \end{bmatrix} = - \begin{bmatrix} \nabla f(x) \\ Ax - b \end{bmatrix}$$

不可行初始点的牛顿方向

$$\begin{bmatrix} \nabla^2 f(x) & A^\top \\ A & 0 \end{bmatrix} \begin{bmatrix} d_x \\ v^+ \end{bmatrix} = - \begin{bmatrix} \nabla f(x) \\ Ax - b \end{bmatrix}$$

原对偶牛顿方向

$$\begin{aligned} d &= d_x \\ w &= v^+ = v + d_v \end{aligned}$$

- 不可行点处牛顿方向 d 不一定是 f 的下降方向。

$$\left. \frac{\partial f(x+td)}{\partial t} \right|_{t=0} = \nabla f(x)^\top d$$

$$= -d^\top (\nabla^2 f(x)d + A^\top w)$$

$$= -d^\top \nabla^2 f(x)d + (Ax - b)^\top w$$

- 残差范数沿牛顿方向下降

$$\left. \frac{d}{dt} \|r(y + td_y)\|_2^2 \right|_{t=0} = 2r(y)^\top Dr(y)d_y = -2r(y)^\top r(y) < 0$$



$$\left. \frac{d}{dt} \|r(y + td_y)\|_2 \right|_{t=0} = -\|r(y)\|_2 < 0$$

利用 $\|r(y)\|_2$ 检测不可行牛顿方法的进展

$$\begin{bmatrix} r_{dual}(x, v) \\ r_{pri}(x, v) \end{bmatrix} = \begin{bmatrix} \nabla f(x) + A^\top v \\ Ax - b \end{bmatrix} = r(y)$$

$$Dr(y) = \begin{bmatrix} \nabla^2 f(x) & A^\top \\ A & 0 \end{bmatrix}$$

$$d_y = \begin{bmatrix} d_x \\ d_v \end{bmatrix}$$

完整步经的可行性质

$$\begin{bmatrix} \nabla^2 f(x) & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} d \\ w \end{bmatrix} = - \begin{bmatrix} \nabla f(x) \\ Ax - b \end{bmatrix}$$

不可行初始点的牛顿方向

$$\begin{bmatrix} \nabla^2 f(x) & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} d_x \\ v^+ \end{bmatrix} = - \begin{bmatrix} \nabla f(x) \\ Ax - b \end{bmatrix}$$

原对偶牛顿方向

$$\begin{aligned} d &= d_x \\ w &= v^+ = v + d_v \end{aligned}$$

$$\begin{bmatrix} r_{dual}(x, v) \\ r_{pri}(x, v) \end{bmatrix} = \begin{bmatrix} \nabla f(x) + A^T v \\ Ax - b \end{bmatrix} = r(y)$$

$$Dr(y) = \begin{bmatrix} \nabla^2 f(x) & A^T \\ A & 0 \end{bmatrix}$$

$$d_y = \begin{bmatrix} d_x \\ d_v \end{bmatrix}$$

- 不可行点处牛顿方向 d 具有性质： $A(x + d) = b$

✓ 若沿不可行点处牛顿方向 d 搜索的步长为1，则下一个迭代点将是可行的

✓ 一旦 x 是可行点，以后的迭代牛顿方向就成为牛顿可行方向

- 阻尼步长对等式约束残差 r_{pri} 的影响：

选定 $t \in [0,1]$ ，下一个迭代点 $x^+ = x + td$ ，则由 $A(x + d) = b$ ，有

$$r_{pri}^+ = A(x + td) - b = (1 - t)(Ax - b) = (1 - t)r_{pri}$$

$$x^{i+1} = x^i + t^i d^i$$

$$r_{pri}^k = \left(\prod_{i=0}^{k-1} (1 - t^i) \right) r_{pri}^0$$

$$r_{pri}^i = Ax^i - b \quad (i = 0, 1, 2, \dots, k-1)$$

✓ 迭代过程中原问题的残差向量始终和初始残差向量方向相同，但每次都按比例缩减

✓ 一旦某个步长等于1，其后所有迭代点都是原问题的可行点

不可行初始点牛顿方法

牛顿下降回溯直线搜索算法（不可行初始点）

1. 初始点 $x^0 \in \text{dom } f, v^0$, 误差阈值 $\epsilon > 0, k = 0$

2. 停止准则: $Ax^k = b$ 且 $\|r(x^k, v^k)\|_2 \leq \epsilon$, 退出, 否则

3. 确定原对偶牛顿方向:
$$\begin{bmatrix} \nabla^2 f(x^k) & A^\top \\ A & 0 \end{bmatrix} \begin{bmatrix} d_x^k \\ d_v^k \end{bmatrix} = - \begin{bmatrix} \nabla f(x^k) + A^\top v^k \\ Ax^k - b \end{bmatrix}$$

4. 对原对偶残差 $\|r\|_2$ 进行回溯, 确定步长 t^k

$$0 < \alpha < 0.5, 0 < \beta < 1, t^k = 1,$$

While $\|r(x^k + td_x^k, v^k + td_v^k)\|_2 > (1 - \alpha t)\|r(x^k, v^k)\|_2$
 $t^k := \beta t^k$

End

5. $x^{k+1} = x^k + t^k d_x^k, v^{k+1} = v^k + t^k d_v^k, k = k + 1$, 回2

$$\begin{array}{ll} \min & f(x) \\ \text{s.t.} & Ax = b \end{array}$$

- 停止条件不仅要求原问题可行解被满足, 还要求原对偶残差的范数足够小
- 搜索方向包括额外的依赖原问题残差的修正值
- 直线搜索目标是残差的范数, 而不是函数 $f(x)$, 但是一定在有限次迭代后结束
- 一旦可行解满足, 可切换到可行初始点的牛顿方法, 即将直线搜索目标换成 f , 终止条件换成 $\frac{\lambda(x)^2}{2} \leq \epsilon$ 。
- 利用不可行初始点牛顿方法简化初始化

对原对偶残差 $\|r\|_2$ 进行回溯直线搜索

对目标函数 f 进行回溯直线搜索，确定步长 t^k ：

$$0 < \alpha < 0.5, 0 < \beta < 1, t^k = 1$$

While $f(x^k + t^k d_x^k) > f(x^k) + \alpha t^k \nabla f(x^k)^\top d_x^k$
 $t^k := \beta t^k$
End

对原对偶残差 $\|r\|_2$ 进行回溯直线搜索，确定步长 t^k ：

$$0 < \alpha < 0.5, 0 < \beta < 1, t^k = 1$$

While $\|r(x^k + t^k d_x^k, v^k + t^k d_v^k)\|_2 > (1 - \alpha t^k) \|r(x^k, v^k)\|_2$
 $t^k := \beta t^k$
End

令 $g(t) = f(x + td)$ ，回溯直线搜索
停止准则改写为

$$g(t^k) > g(0) + \alpha t^k g'(0)$$

令 $g(t) = \|r(y + td_y)\|_2$ ，则

- $(g(t))^2 = r(y + td_y)^\top r(y + td_y)$
- $g(t)g'(t) = r(y + td_y)^\top Dr(y + td_y)d_y$
- $g'(0) = -\|r(y)\|_2$

$$g(t^k) > g(0) + \alpha t^k g'(0)$$



课前回顾

$$\begin{array}{ll} \min & f(x) \\ \text{s.t.} & Ax = b \end{array} \quad \longleftrightarrow \quad \text{KKT方程} \quad \begin{cases} Ax^* = b \\ \nabla f(x^*) + A^T v^* = 0 \end{cases}$$

梯度一阶近似

$$\nabla f(x + d) \approx \nabla f(x) + \nabla^2 f(x)d$$

$$A(x + d) = b$$

$$\nabla f(x) + \nabla^2 f(x)d + A^T w = 0$$

✓ 可行初始点的牛顿方向

$$\begin{bmatrix} \nabla^2 f(x) & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} d_x \\ w \end{bmatrix} = \begin{bmatrix} -\nabla f(x) \\ 0 \end{bmatrix}$$

✓ 不可行初始点的牛顿方向

$$\begin{bmatrix} \nabla^2 f(x) & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} d \\ w \end{bmatrix} = - \begin{bmatrix} \nabla f(x) \\ Ax - b \end{bmatrix}$$

✓ 原对偶残差

$$r(y) = \begin{bmatrix} r_{dual}(x, v) \\ r_{pri}(x, v) \end{bmatrix} = \begin{bmatrix} \nabla f(x) + A^T v \\ Ax - b \end{bmatrix}$$

$$r(y + z) \approx r(y) + Dr(y)z = 0$$

$$\Rightarrow \begin{bmatrix} \nabla^2 f(x) & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} d_x \\ d_v \end{bmatrix} = - \begin{bmatrix} \nabla f(x) + A^T v \\ Ax - b \end{bmatrix}$$

$$v^+ = v + d_v$$

$$\begin{bmatrix} \nabla^2 f(x) & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} d_x \\ v^+ \end{bmatrix} = - \begin{bmatrix} \nabla f(x) \\ Ax - b \end{bmatrix}$$

$$\begin{aligned} d_y &= - \begin{bmatrix} \nabla^2 f(x) & A^T \\ A & 0 \end{bmatrix}^{-1} r(y) \\ &= - Dr(y)^{-1} r(y) \end{aligned}$$

回顾：牛顿方法和消除法

- 等式约束问题的牛顿方法与简化后无约束问题牛顿方法的迭代过程完全一致

$$\begin{array}{ll}\min & f(x) \\ \text{s.t.} & Ax = b\end{array}$$

可行初始点的牛顿方向

$$\begin{bmatrix} \nabla^2 f(x) & A^\top \\ A & 0 \end{bmatrix} \begin{bmatrix} d_x \\ w \end{bmatrix} = \begin{bmatrix} -\nabla f(x) \\ 0 \end{bmatrix}$$

$$\min_{z \in \mathbb{R}^{n-p}} \tilde{f}(z) = f(Fz + \hat{x})$$

简化问题的牛顿方向：

$$\begin{aligned} d_z &= - \left(\nabla^2 \tilde{f}(z) \right)^{-1} \nabla \tilde{f}(z) \\ &= - (F^\top \nabla^2 f(x) F)^{-1} F^\top \nabla f(x) \end{aligned}$$

- d_x 有意义 (KKT矩阵可逆) $\Leftrightarrow d_z$ 有意义 ($\nabla^2 \tilde{f}(z)$ 可逆)
- 牛顿方向 d_z 对应于等式约束问题的方向是

$$F d_z = - F (F^\top \nabla^2 f(x) F)^{-1} F^\top \nabla f(x)$$

- 停止准则相同，即 $\frac{1}{2} d_z^\top \nabla^2 \tilde{f}(z) d_z = \frac{1}{2} d_x^\top \nabla^2 f(x) d_x \leq \varepsilon$



等式限制凸优化问题牛顿算法对比

$$\begin{array}{ll}\min & f(x) \\ \text{s. t.} & Ax = b\end{array}$$

牛顿下降回溯直线搜索算法（不可行初始点）

1. 初始点 $x^0 \in \text{dom } f, v$, 误差阈值 $\epsilon > 0, k = 0$
2. 停止准则: $Ax^k = b$ 且 $\|r(x^k, v^k)\|_2 \leq \epsilon$, 退出, 否则
3. 确定原对偶牛顿方向
$$\begin{bmatrix} \nabla^2 f(x^k) & A^\top \\ A & 0 \end{bmatrix} \begin{bmatrix} d_x^k \\ d_v^k \end{bmatrix} = - \begin{bmatrix} \nabla f(x^k) + A^\top v \\ Ax^k - b \end{bmatrix}$$
4. 对原对偶残差 $\|r\|_2$ 进行回溯, 确定步长 t^k :
 $0 < \alpha < 0.5, 0 < \beta < 1, t^k = 1$
While $\|r(x^k + td_x^k, v^k + td_v^k)\|_2 > (1 - \alpha t)\|r(x^k, v^k)\|_2$
 $t^k := \beta t^k$
End
5. $x^{k+1} = x^k + t^k d_x^k, v^{k+1} = v^k + t^k d_v^k, k = k + 1$, 回3

牛顿下降回溯直线搜索算法（已知可行初始点）

1. 初始点 $x^0 \in \text{dom } f, Ax^0 = b$, 误差阈值 $\epsilon > 0, k = 0$
2. 确定牛顿方向和牛顿减少量
$$\begin{bmatrix} \nabla^2 f(x) & A^\top \\ A & 0 \end{bmatrix} \begin{bmatrix} d_x^k \\ w \end{bmatrix} = \begin{bmatrix} -\nabla f(x) \\ 0 \end{bmatrix}; \lambda(x^k)^2 = (d_x^k)^\top \nabla^2 f(x^k) d_x^k$$
3. 停止准则: 若 $\frac{1}{2}\lambda(x^k)^2 \leq \epsilon$, 退出
4. 回溯直线搜索: $0 < \alpha < 0.5, 0 < \beta < 1, t^k = 1$
While $f(x^k + t^k d_x^k) > f(x^k) - \alpha t^k \lambda(x^k)^2$
 $t^k := \beta t^k$
End
5. $x^{k+1} = x^k + t^k d_x^k, k = k + 1$, 回2

例子

等式约束解析中心点问题:
$$\begin{aligned} \min_x \quad & f(x) = -\sum_{i=1}^n \log x_i \\ \text{s.t.} \quad & Ax = b \end{aligned}$$

- 可行点出发牛顿方法: 首先计算满足 $Ax = b$ 的 $x^0 > 0$, 等价于求解一个标准形式的线性规划可行性问题
- 不可行初始点牛顿方法: 选取任意正分量的初始点, 如 $x^0 = \mathbf{1}$

对偶问题:
$$\max_v \quad g(v) = -b^\top v + n + \sum_{i=1}^n \log(A^\top v)_i$$

- 可行点出发牛顿方法: 首先计算满足 $A^\top v > 0$ 的 $v^0 > 0$, 等价于求解一组线性不等式
- 不可行初始点牛顿方法: 引入新变量 $y \in \mathbb{R}^n$ 将其表示为以下等式约束问题, 然后从任意正分量的 y^0 和任意的 v^0 开始应用不可行初始点牛顿方法求解

$$\begin{aligned} \max_{v,y} \quad & g(v) = -b^\top v + n + \sum_{i=1}^n \log y_i \\ \text{s.t.} \quad & y = A^\top v \end{aligned}$$

不可行初始点牛顿方法局限: 不能明确判断不存在严格可行解的情况

未知初始点牛顿方法的收敛性分析

$$r(y) = \begin{bmatrix} \nabla f(x) + A^\top v \\ Ax - b \end{bmatrix} \triangleq \begin{bmatrix} r_{dual}(y) \\ r_{pri}(y) \end{bmatrix}$$

$$Dr(y) = \frac{\partial r(y)}{\partial y^\top} = \begin{bmatrix} \nabla^2 f(x) & A^\top \\ A & 0 \end{bmatrix}$$

- 基本假设

$$\begin{array}{ll} \min & f(x) \\ \text{s. t.} & Ax = b \end{array}$$

1) $S = \{(x, v) | x \in \text{dom } f, \|r(x, v)\|_2 \leq \|r(x^0, v^0)\|_2\}$ 是闭集, 其中 $x^0 \in \text{dom } f$;

2) KKT的逆矩阵有界: $\forall (x, v) \in S, \|Dr(y)^{-1}\|_2 = \left\| \begin{bmatrix} \nabla^2 f(x) & A^\top \\ A & 0 \end{bmatrix}^{-1} \right\|_2 \leq K$

3) Lipschitz条件: 存在 L , $\forall (x, v), (\tilde{x}, \tilde{v}) \in S$ 满足

$$\|Dr(x, v) - Dr(\tilde{x}, \tilde{v})\|_2 \leq L\|(x, v) - (\tilde{x}, \tilde{v})\|_2$$

- 能够证明: $\text{dom } f$ 和 $\{z | Az = b\}$ 交集非空时, 存在一个最优解 (x^*, v^*)

未知初始点牛顿方法的收敛性分析

$$r(y) = \begin{bmatrix} \nabla f(x) + A^\top v \\ Ax - b \end{bmatrix}$$

- 令 $y = (x, v) \in S$, $\|r(y)\|_2 \neq 0$, 牛顿方向 $d_y = (d_x, d_z)$, 定义 $t_{max} = \inf\{t > 0 | y + td_y \notin S\}$, 从而 $\forall t \in [0, t_{max}]$, $y + td_y \in S$ 成立, 则以下关键不等式成立

$$\forall 0 \leq t \leq \min\{1, t_{max}\}, \quad \|r(y + td_y)\|_2 \leq (1 - t)\|r(y)\|_2 + \frac{1}{2}K^2Lt^2\|r(y)\|_2^2$$

- 主要推导过程:

$$r(y + td_y) = r(y) + \int_0^1 Dr(y + \tau td_y) td_y d\tau$$

$$Dr(y) = \frac{\partial r(y)}{\partial y^\top} = \begin{bmatrix} \nabla^2 f(x) & A^\top \\ A & 0 \end{bmatrix}$$

$$= r(y) + tDr(y)d_y + \int_0^1 (Dr(y + \tau td_y) - Dr(y)) td_y d\tau$$

$$= (1 - t)r(y) + \int_0^1 (Dr(y + \tau td_y) - Dr(y)) td_y d\tau \quad Dr(y)d_y = -r(y)$$

$$\left\| \int_0^1 (Dr(y + \tau td_y) - Dr(y)) td_y d\tau \right\|_2 \leq \|td_y\|_2 \int_0^1 L \|\tau td_y\|_2 d\tau \leq \frac{L}{2} t^2 \|Dr(y)^{-1} r(y)\|_2^2 \leq \frac{K^2 L t^2}{2} \|r(y)\|_2^2$$

$$\|r(y^k + td_y^k)\|_2 > (1 - \alpha t)\|r(y^k)\|_2$$

阻尼牛顿阶段: $\|r(y^k)\|_2 > \frac{1}{K^2 L}$

$$\forall 0 \leq t \leq \min\{1, t_{max}\}, \quad \|r(y + td_y)\|_2 \leq (1 - t)\|r(y)\|_2 + \frac{1}{2}K^2 L t^2 \|r(y)\|_2^2$$

- $\bar{t} = \frac{1}{K^2 L \|r(y)\|_2}$ ($\bar{t} < t_{max}$) 满足回溯直线搜索停止条件 $\|r(y + \bar{t}d_y)\|_2 \leq (1 - \alpha \bar{t})\|r(y)\|_2$

令 $\varphi(t) = (1 - t)\|r(y)\|_2 + \frac{1}{2}K^2 L t^2 \|r(y)\|_2^2$, 则其在 $t = 0$ 和它的最小解 $\bar{t} = \frac{1}{K^2 L \|r(y)\|_2} < 1$

($\bar{t} < t_{max}$) 之间单调递减, 从而

$$\begin{aligned} \varphi(\bar{t}) &= \min \varphi(t) = \|r(y)\|_2 - \frac{1}{2K^2 L} \\ &\leq \|r(y)\|_2 - \alpha \frac{1}{K^2 L} \quad 0 < \alpha < \frac{1}{2} \\ &= (1 - \alpha \bar{t})\|r(y)\|_2 \end{aligned}$$

- $\bar{t} = \frac{1}{K^2 L \|r(y)\|_2} < 1$ 满足回溯直线搜索停止的条件

阻尼牛顿阶段: $\|r(y^k)\|_2 > \frac{1}{K^2 L}$

$\bar{t} = \frac{1}{K^2 L \|r(y)\|_2}$ ($\bar{t} < t_{max}$) 满足回溯直线搜索停止条件 $\|r(y + \bar{t}d_y)\|_2 \leq (1 - \alpha\bar{t})\|r(y)\|_2$

- 阻尼牛顿阶段不可行初始点牛顿方法的一次迭代将把 $\|r(y)\|_2$ 至少减少一个确定的量

$$\forall t \geq \beta\bar{t}, \|r(y + td_y)\|_2 \leq (1 - \alpha t)\|r(y)\|_2$$

$$\begin{aligned}\Rightarrow \|r(y^k + t^k d_y^k)\|_2 &\leq (1 - \alpha t^k)\|r(y^k)\|_2 \\ &\leq (1 - \alpha\beta\bar{t})\|r(y^k)\|_2\end{aligned}$$

$$= \|r(y^k)\|_2 - \frac{\alpha\beta}{K^2 L}$$

每次将 $\|r(y^k)\|_2$ 至少减少 $\frac{\alpha\beta}{K^2 L}$

$$\Rightarrow \|r(y^k)\|_2 \leq \|r(y^0)\|_2 - \frac{k\alpha\beta}{K^2 L}$$

$$\Rightarrow \forall k \geq \frac{\|r(y^0)\|_2 K^2 L}{\alpha\beta}$$

阻尼过程迭代次数上界

二次收敛阶段: $\|r(y^k)\|_2 \leq \frac{1}{K^2 L}$

$$\forall 0 \leq t \leq \min\{1, t_{\max}\}, \quad \|r(y + td_y)\|_2 \leq (1 - t)\|r(y)\|_2 + \frac{1}{2}K^2 L t^2 \|r(y)\|_2^2$$

- 二次收敛阶段 $\|r(y^k)\|_2 \leq \frac{1}{K^2 L}$: $\forall 0 \leq t \leq \min\{1, t_{\max}\}$, 有

$$\|r(y + td_y)\|_2 \leq \left(1 - t + \frac{1}{2}t^2\right) \|r(y)\|_2, \quad t_{\max} = \inf\{t > 0 | y + td_y \notin S\}$$

此时 $t_{\max} > 1$, 否则, $\|r(y + t_{\max}d_y)\|_2 \leq \|r(y)\|_2$, 与 $t_{\max} = \inf\{t > 0 | y + td_y \notin S\}$ 矛盾, 从而

$$t = 1 \text{ 时, 有 } \|r(y + d_y)\|_2 \leq \frac{1}{2}\|r(y)\|_2 \leq (1 - \alpha)\|r(y)\|_2 \quad 0 < \alpha < \frac{1}{2}$$

- $t = 1$ 满足回溯直线搜索停止的条件, 并且此后所有的迭代满足 $\|r(y^k)\|_2 \leq \frac{1}{K^2 L}$, 取步长 $t = 1$

二次收敛阶段: $\|r(y^k)\|_2 \leq \frac{1}{K^2 L}$

$$\forall 0 \leq t \leq \min\{1, t_{max}\}, \quad \|r(y + td_y)\|_2 \leq (1-t)\|r(y)\|_2 + \frac{1}{2}K^2Lt^2\|r(y)\|_2^2$$

- 二次收敛阶段 $\|r(y^k)\|_2 \leq \frac{1}{K^2 L}$, $t = 1$, $y^{k+1} = y^k + d_y^k$, 有

$$\frac{K^2 L \|r(y^{k+1})\|_2}{2} \leq \left(\frac{K^2 L \|r(y^k)\|_2}{2} \right)^2$$

假设 y^l 后进入二次收敛阶段

$$\Rightarrow \frac{K^2 L \|r(y^{l+k})\|_2}{2} \leq \left(\frac{K^2 L \|r(y^l)\|_2}{2} \right)^{2^k} \leq \left(\frac{1}{2} \right)^{2^k}$$

$\|r(y)\|_2$ 相对0的
二次收敛过程



二次收敛阶段: $\|r(y^k)\|_2 \leq \frac{1}{K^2 L}$

$$d_y = - \begin{bmatrix} \nabla^2 f(x) & A^\top \\ A & 0 \end{bmatrix}^{-1} r(y) \\ = Dr(y)^{-1} r(y)$$

- 证明: 迭代序列 y^k 是一个Cauchy序列, 收敛, 所以之前假设意味着最优解 (x^*, v^*) 存在

假设 y^l 后进入二次收敛阶段, 即 $\|r(y^l)\|_2 \leq \frac{1}{K^2 L}$ 且 $y^{k+1} = y^k + d_y^k$, 从而

$$\begin{aligned} \|y^{l+k} - y^l\|_2 &\leq \|y^{l+k} - y^{l+k-1}\|_2 + \dots + \|y^{l+1} - y^l\|_2 \\ &= \|Dr(y^{l+k-1})^{-1} r(y^{l+k-1})\|_2 + \dots + \|Dr(y^l)^{-1} r(y^l)\|_2 \end{aligned}$$

$$\frac{K^2 L \|r(y^{k+1})\|_2}{2} \leq \left(\frac{K^2 L \|r(y^k)\|_2}{2} \right)^2$$

$$\leq K \left(\|r(y^{l+k-1})\|_2 + \dots + \|r(y^l)\|_2 \right) 2^{l-1}$$

$$\leq K \|r(y^l)\|_2 \sum_{i=0}^{k-1} \left(\frac{1}{2} \right)^{2^i}$$

$$\leq 2K \|r(y^l)\|_2 \quad \|r(y^l)\|_2 \text{ 收敛于 } 0$$

$$\begin{aligned} &\frac{K^2 L \|r(y^{l+k})\|_2}{2} \\ &\leq \left(\frac{K^2 L \|r(y^l)\|_2}{2} \right)^{2^k} \\ &\leq \left(\frac{1}{2} \right)^{2^k} \end{aligned}$$

因此, 迭代序列 y^k 是一个Cauchy序列且收敛到 $y^* = (x^*, v^*)$, 由 $r(y)$ 的连续性可知, y^* 的极限满足 $r(y^*) = 0$, 即存在最优解 (x^*, v^*) 。

例子：等式约束解析中心点问题

$$\begin{aligned} \min_x \quad & f(x) = -\sum_{i=1}^n \log x_i \\ \text{s.t.} \quad & Ax = b \end{aligned}$$

- 随机产生 $n = 100, m = 50$ ，相应问题可行且存在下界；
- 采用不可行初始点牛顿方法 $x^0 = 1, v^0 = 0$ ；
- 回溯直线搜索 $\alpha = 0.01, \beta = 0.5$




图 10.1 用不可行初始点 Newton 方法求解一个 100 个变量，50 个等式约束的解析中心点问题。图中给出了 $\|r_{\text{pri}}\|_2$ (实线) 和 $\|r_{\text{dual}}\|_2$ (虚线)。可行性在 8 次迭代后满足 (并一直保持)，大约 9 次迭代后开始二次收敛。

例子：等式约束解析中心点问题

$$\begin{aligned} \min_x \quad & f(x) = -\sum_{i=1}^n \log x_i \\ \text{s.t.} \quad & Ax = b \end{aligned}$$

- 随机产生 $n = 100, m = 50$ ，相应问题可行且存在下界；
- 采用不可行初始点牛顿方法 $x^0 = 1, v^0 = 0$ ；
- 回溯直线搜索 $\alpha = 0.01, \beta = 0.5$




图 10.2 相同例子的步长与迭代次数之间的关系。第 8 次迭代时选取了完整步长，自此以后始终保持了可行性。

一个不可行的例子

$$\begin{aligned} \min_x \quad & f(x) = -\sum_{i=1}^n \log x_i \\ \text{s.t.} \quad & Ax = b \end{aligned}$$

- 随机产生 $n = 100, m = 50$, 相应问题不可行, 即

$$\text{dom} f \cap \{z: Az = b\} = \emptyset$$




图 10.3 用不可行初始点 Newton 方法求解一个 100 个变量, 50 个等式约束的解析中心点问题, 其定义域 $\text{dom} f = \mathbf{R}_{++}^{100}$ 和 $\{z \mid Az = b\}$ 不相交。图中给出了 $\|r_{\text{pri}}\|_2$ (实线) 和 $\|r_{\text{dual}}\|_2$ (虚线)。在这种情况下, 残差不收敛于 0。

一个不可行的例子

$$\min_x f(x) = -\sum_{i=1}^n \log x_i$$

$$\text{s.t. } Ax = b$$

- 随机产生 $n = 100, m = 50$, 相应问题不可行, 即

$$\text{dom} f \cap \{z: Az = b\} = \emptyset$$




图 10.4 不可行实例的步长和迭代次数之间的关系。步长永远不等于 1, 并趋近于 0。

回顾：无约束牛顿下降回溯直线搜索算法

$$\min f(x)$$

$$\min \{f(x) | s.t. Ax = b\}$$

- 初始点必须可行: $Ax^0 = b$
- 牛顿方向必须是可行方向: $Ad_x^k = 0$

牛顿下降回溯直线搜索算法

1. 给定初始点 $x^0 \in \text{dom } f$, 误差阈值 $\varepsilon > 0$, 令 $k = 0$
2. 计算Newton步径和增量

$$d_{nt}^k = -\nabla^2 f(x^k)^{-1} \nabla f(x^k); \lambda(x^k)^2 = (d_{nt}^k)^\top \nabla^2 f(x^k) d_{nt}^k$$

3. 停止准则: 若 $\frac{1}{2}\lambda(x^k)^2 \leq \varepsilon$, 退出
4. 回溯直线搜索: $0 < \alpha < 0.5, 0 < \beta < 1, t^k = 1$

$$\text{While } f(x^k + t^k d_{nt}^k) > f(x^k) - \alpha t^k \lambda(x^k)^2$$

$$t^k := \beta t^k$$

End

$$5. x^{k+1} = x^k + t^k d_{nt}^k, k = k + 1, \text{ 回2}$$

假设: $\forall x, y \in S$, (1)存在 m, M 满足 $mI \leq \nabla^2 f(x) \leq MI$;
(2)存在 L 满足 $\|\nabla^2 f(y) - \nabla^2 f(x)\|_F \leq L\|y - x\|_2$

➤ 目标值与最优值间偏差的上界: $f(x) - p^* \leq \frac{1}{2m} \|\nabla f(x)\|_2^2$

➤ 每次迭代目标改进值下界

✓ 阻尼牛顿阶段 ($0 < \eta \leq \frac{m^2}{L}, \|\nabla f(x^k)\|_2 \geq \eta$)

$$f(x^{k+1}) - f(x^k) \leq -\gamma, \text{ 迭代次数} \leq \frac{f(x^0) - p^*}{\gamma}, \gamma = \alpha\beta\eta^2 \frac{m}{M^2}$$

✓ 二次收敛阶段 ($\|\nabla f(x^k)\|_2 \leq \eta \leq 3(1 - 2\alpha)\frac{m^2}{L}$)

$$\text{回溯搜索 } t^k = 1, \frac{L}{2m^2} \|\nabla f(x^{k+1})\|_2 \leq \left(\frac{L}{2m^2} \|\nabla f(x^k)\|_2 \right)^2$$

$$\text{迭代次数} \leq \log_2(\log_2(\epsilon_0/\epsilon)), \epsilon_0 = \frac{2m^3}{L^2}$$

➤ 算法收敛时, 迭代次数的上界

$$f(x^K) - p^* \leq \varepsilon \Rightarrow$$

$$K \geq 6 + \frac{M^2 L^2 / m^5}{\alpha\beta \min\{1, 9(1 - 2\alpha)^2\}} (f(x^0) - p^*)$$

作业1

$$\begin{array}{ll} \min & f(x) \\ \text{s.t.} & Ax = b \end{array} \quad \begin{array}{l} \bullet \ f: \mathbb{R}^n \rightarrow \mathbb{R} \text{ 为二次连续可微凸函数} \\ \bullet \ A \in \mathbb{R}^{p \times n}, \text{ rank}(A) = p < n \end{array}$$

- 总结等式约束凸优化问题的求解方法及相互联系



作业2

10.15 等式约束熵极大化。考虑等式约束熵极大化问题

$$\begin{aligned} & \text{minimize} && f(x) = \sum_{i=1}^n x_i \log x_i \\ & \text{subject to} && Ax = b, \end{aligned}$$

其中 $\text{dom } f = \mathbf{R}_{++}^n$, $A \in \mathbf{R}^{p \times n}$, $p < n$ 。(一些相关分析见习题 10.9。)

生成一个 $n = 100$, $p = 30$ 的问题实例, 随机选择 A (验证其为满秩阵), 随机选择一个正向量作为 $\hat{x}$ (例如, 其分量在区间 $[0, 1]$ 上均匀分布), 然后令 $b = A\hat{x}$ 。(于是, $\hat{x}$ 可行。)

采用以下方法计算该问题的解。

- (a) **标准 Newton 方法**。可以选用初始点 $x^{(0)} = \hat{x}$ 。
- (b) **不可行初始点 Newton 方法**。可以选用初始点 $x^{(0)} = \hat{x}$ (和标准 Newton 方法比较), 也可以选用初始点 $x^{(0)} = \mathbf{1}$ 。
- (c) **对偶 Newton 方法**, 即将标准 Newton 方法应用于对偶问题。

证实三种方法求得相同的最优点 (和 Lagrange 乘子)。比较三种方法每步迭代的计算量, 假设利用了相应的结构。(但在你的实现中不需要利用结构计算 Newton 步径。)



仿射不变性

等式约束优化问题中的牛顿方向和牛顿减少量是仿射不变的

$$\begin{array}{ll} \min & f(x) \\ \text{s.t.} & Ax = b \end{array}$$

f 在 x 处的牛顿方向 d_{nt}^x 满足

$$\begin{bmatrix} \nabla^2 f(x) & A^\top \\ A & 0 \end{bmatrix} \begin{bmatrix} d_{nt}^x \\ w \end{bmatrix} = \begin{bmatrix} -\nabla f(x) \\ 0 \end{bmatrix}$$

- $\forall T \in \mathbb{R}^{n \times n}$ 非奇异矩阵, 定义 $\bar{f}(y) = f(Ty)$, $x = Ty$, 有
 $\nabla \bar{f}(y) = T^\top \nabla f(x)$, $\nabla^2 \bar{f}(y) = T^\top \nabla^2 f(x) T$, $Ax = ATy = b$

$$T d_{nt}^y = d_{nt}^x, \quad w = \bar{w}$$

$$\begin{array}{ll} \min & \bar{f}(y) \\ \text{s.t.} & ATy = b \end{array}$$

$\bar{f}$ 在 y 处的牛顿方向 d_{nt}^y 满足

$$\begin{bmatrix} T^\top \nabla^2 f(Ty) T & T^\top A^\top \\ AT & 0 \end{bmatrix} \begin{bmatrix} d_{nt}^y \\ \bar{w} \end{bmatrix} = \begin{bmatrix} -T^\top \nabla f(Ty) \\ 0 \end{bmatrix}$$

等式限制时函数 f 和 $\bar{f}$ 的牛顿方向由相同的线性变换 $Ty = x$ 相联系, 且 $x + d_{nt}^x = T(y + d_{nt}^y)$