



西安交通大学

本科生中期进展报告

学号:	2223312202
姓名:	林圣翔
导师:	田锋教授
项目设计题目:	基于大语言模型生成式边信息的 隐私脱敏推荐系统研究
学科专业:	理科试验班（计算机 H）
学院:	电子与信息学部
填写时间:	2026 年 4 月 22 日

论文题目	基于大语言模型生成式边信息的隐私脱敏推荐系统研究
一、具体工作内容（已完成的主要工作及已取得的成绩。） 一、问题形式化与理论框架构建 明确定义了推荐系统输入端文本混淆的隐私保护问题，给出了基于条件熵和互信息的隐私度量标准，并提出了个体差异性（嵌入低相似度）与关系一致性（相对语义结构保持）两个核心优化目标。 二、方法设计与实现 1.设计了一套“核心词引导的渐进式生成式隐私保护框架”，包含核心词提取、核心词转移以及非核心词生成三大模块。 2.构建了结构化 Prompt 和两级缓存机制，保证上下文注入的连续性与一致性。 3.引入 GRPO（Group Relative Policy Optimization）作为策略优化算法，并设计了三个可动态加权的奖励函数：个体差异性奖励、类别有效性奖励、结构一致性奖励。 4.实现了从离散文本到连续嵌入空间再到离散文本的“离散→连续→离散”优化路径，在语义层面对两个核心目标进行联合优化。 三、隐私保护理论分析 完成了两个理论定理的推导与证明： 定理 1（隐藏上下文带来的熵增益）：证明了当攻击者无法观测隐藏上下文 C 时，条件熵 $H(X Z)$ 相比无上下文情况严格增加，且增益可表示为带权 Jensen-Shannon 散度。 定理 2（多峰采样的熵增益）：证明了在生成过程中引入潜在模式变量 M 可进一步降低互信息，并给出了熵增益的近似表达式。 结合 Fano 不等式，给出了攻击成功率与互信息上界之间的定量关系，为方法的安全性提供了理论支撑。 四、实验环境搭建与数据集处理 1.使用 MovieLens-1M 和 Amazon-Book 两个公开基准数据集，完成了数据预处理、正样本筛选（ML-1M 评分 ≥ 3，Amazon-Book 评分 ≥ 4）、物品边信息生成（利用 Qwen2.5-14B 生成多类别泛化描述并筛选属性词）。 2.实现了传统推荐模型（DeepFM、LightGCN、SASRec）与基于 LLM 的推荐模型（TallRec、LLaRA）等下游推荐模型进行推荐效果的评估。 3.搭建了 Vector2Text 攻击模型，并分别为两个数据集构造了无重叠的训练/验证集用于反演攻击评估。 五、基线对比与消融实验准备 1.选取了随机初始化、原始边信息、纯 LLM、InferDPT、Text2Text、Text2Text-UI 等多种基线方法。 2.规划了奖励函数权重、奖励函数存在与否、GRPO 模块移除等消融实验，并完成了相应代码实现。	

二、指导教师指导情况

第一周：问题定义

1.明确研究核心：将推荐系统输入端文本隐私保护形式化为“文本混淆”问题，指出攻击者可通过嵌入反演恢复原始文本。

2.强调需要同时满足“个体差异性”（嵌入低相似度）与“关系一致性”（语义结构保持）两个优化目标。

第二周：框架设计

1.认可“核心词引导的渐进式生成式隐私保护框架”的设计思路（核心词提取、转移、非核心词生成）。

2.强调“离散→连续→离散”优化路径的重要性。

第三周：代码实现指导

1.建议增加结构化 Prompt 和两级缓存机制（Per-word Cache + Global Recent Queue）以保证上下文连续性。

2.引入 GRPO（Group Relative Policy Optimization）作为策略优化算法，设计三个奖励函数：个体差异性奖励、类别有效性奖励、结构一致性奖励。

第四周：数据集处理与实验环境搭建指导

1.建议使用 MovieLens-1M 和 Amazon-Book 两个公开数据集。

2.指导利用 Qwen2.5-14B 生成物品边信息（多类别泛化描述并筛选属性词）。

3.对于数据集规模问题：建议先做时间段筛选，再按出现频率筛选（阈值设为 5 次），最后随机采样至 5000~8000 个物品，避免数据集过小或过于稀疏。

第五周：基线模型与实验公平性指导

1.基线模型选择：建议删除过旧的 NeuMF，增加 CL4Rec 或 DuoRec（基于 SASRec 的对比学习范式）。

2.对于隐私保护力度不统一的问题：建议扫描基线模型原仓库参数，取与本研究方法最接近的扰动幅度（平均余弦相似度），然后在论文中说明“本方法在更大扰动下仍取得更好推荐与防御效果”。

第六周：推荐模型评估与攻击实验指导

1.推荐效果评估：传统模型用 HR@K、NDCG@K (K=5,10)；TallRec（二分类任务）和 LLaRA（多选一任务）分开列表呈现。

2.攻击实验：使用 Vector2Text 攻击模型，评估嵌入反演的成功率（如词相似度、句子 BLEU 等）。

第七周：理论框架指导

建议从信息论角度建立隐私度量标准（条件熵、互信息），并推导两个理论定理（隐藏上下文的熵增益、多峰采样的熵增益）。

第八周：消融实验与参数敏感性实验指导

1.区分消融实验与参数敏感性实验：消融实验用于验证各模块（如奖励函数、GRPO 模块）的必要性；参数敏感性实验用于分析关键超参数（如奖励函数权重、生成步数）的影响。

2.消融实验建议选 2 个传统模型+1 个大模型推荐模型进行。

3.收敛性实验：单独展示训练步数与奖励值的关系。

4.对于奖励函数可视化：建议正文中每个奖励函数只放 1 张代表性图（如平均奖励曲线），附录可放更多细节。