



西安交通大学
XI'AN JIAOTONG UNIVERSITY

基于大语言模型生成式边信息的隐私脱敏推荐系统研究

中期答辩

精勤求学 敦笃励志 果毅力行 忠恕任事

汇报人：林圣翔
指导老师：田锋教授
汇报时间：2026. 4. 22


选题背景

在**推荐系统**中，利用大语言模型（LLMs）建模物品的语义边信息虽能有效提升性能，但会引入严重的隐私风险。攻击者可通过**嵌入反演攻击**从模型输出的嵌入向量中高精度还原原始文本内容，甚至进一步反推出用户对特定物品的偏好及其历史交互行为。

依赖可信下游模型 现有方法多聚焦于数据使用阶段的隐私保护（如差分隐私、联邦学习），而对数据收集端（用户本地）的直接防护关注不足，忽略了从源头进行隐私干预的能力。

扰动破坏语义结构与质量 输入层文本混淆方法仅对词序列进行独立扰动，未能建模物品间的语义关联，导致语义质量严重下降，破坏了推荐模型所需的结构信息。

在此背景下，如何构建一个既能有效保护用户隐私，又能维持推荐性能的新范式，成为一项关键而富有挑战性的研究方向。本研究提出一种**前置隐私保护**思路，在**数据预处理阶段**引入LLM驱动的“生成式混淆”机制，依托“离散→连续→离散”的优化路径，于连续语义空间中对语义迁移与分布保持进行联合优化，从而从表征源头干扰攻击信号，实现隐私与效能的兼顾。



问题定义

令 I 为物品集合，每个物品 $i \in I$ 由一组泛化的边信息（属性词）描述：

$$A_i = \{a_{i,1}, a_{i,2}, \dots, a_{i,m}\} \in W$$

其中 $W = \{w_1, w_2, \dots, w_n\}$ 为全体属性词构成的集合，且每个属性词 $w \in W$ 均关联一个类别标签 $c(w) \in C$ ， C 为预定义的类别集合。

为进行隐私保护的文本变换，我们引入以下基本符号：

原始词 $x \in X$ ：即属性词 W 且 $|X| < \infty$ ， $X = W$

隐藏上下文状态 $c \in C_{ctx}$ ：由全局缓存、历史最优变体等决定，攻击者不可见。

映射后文本 $z \in Z$ ：即变换后的属性词 $w' = f(w)$ 。

生成过程由条件分布 $P(z|x,c)$ 刻画，表示给定原词 x 和上下文 c 时生成 z 的概率。攻击者观察 Z （或先从嵌入反演得到 Z ），目标是估计 X 。隐私目标为最大化条件熵 $H(X|Z)$ 等价于最小化互信息 $I(X;Z)$

我们的核心目标是学习一个映射函数 $f: W \rightarrow W'$ ，对于每个原始属性词 $w \subseteq W$ ，生成其改写版本 $w' = f(w)$ ，从而得到变换后的物品边信息集合 $(A_i' = \{f(a) | a \in A_i\})$ 。该映射函数需同时满足以下两个目标：

个体差异性 对于任意 $w \subseteq W$ ，其改写版本 $w' = f(w)$ 在嵌入空间中的语义相似度应尽可能低：

$$\min_f \text{sim}(w, f(w))$$

以有效改变单个属性词的语义表征，阻断攻击者通过嵌入反演攻击还原原始信息。

关系一致性：对于任意两个原始属性词 $u, v \subseteq W$ ，其原始语义相似度 $\text{sim}(u, v)$ 与改写后的相似度 $\text{sim}(f(u), f(v))$ 应保持高度相关。即属性词之间的相对语义结构（相似性排序、类别关联以及整体分布）在变换后应得到最大程度的保留：

$$\text{corr}(\{\text{sim}(u, v)\}_{u, v \subseteq W}, \{\text{sim}(f(u), f(v))\}_{u, v \subseteq W}) \approx 1$$

总体框架


基于核心词引导的渐进式生成式隐私保护框架

首先识别并优先优化对全局结构影响最大的核心词，再以核心词映射作为锚点，逐步扩展到非核心词，从而实现高效且稳定的关系一致性保持。框架主要包含三个关键模块：

核心词提取模块：识别全局影响力最大的核心词集合。

核心词转移模块：通过Warmup和Generate Core Word两个子阶段为核心词找到高质量映射位置。

非核心词生成模块：利用已转移的核心词映射，为剩余非核心词生成变体，实现整体语义结构的逐步扩展。



GRPO优化框架

采用 **Group Relative Policy Optimization (GRPO)** 对 LLM 进行策略优化。GRPO 通过 group-sampling 机制天然产生多峰分布。

总奖励函数定义为三个子奖励的加权组合：

$$R_{\text{total}} = \lambda_1 \tilde{R}_{\text{diss}} + \lambda_2 \tilde{R}_{\text{cat}} + \lambda_3 \tilde{R}_{\text{struct}}$$

其中 $\tilde{R}$ 表示归一化后的子奖励。各原始子奖励的具体形式如下：

个体差异性奖励

$$R_{\text{diss}} = 1 - \cos(e(w_i), f(e(w_i)))$$

其中 $e(\cdot)$ 向量嵌入函数。

类别有效性奖励

设类别 (c) 的嵌入均值和协方差分别为 μ_c 和 Σ_c ，Mahalanobis 距离为 $d(\cdot, c)$ ，则奖励为：

$$R_{\text{cat}} = \exp\left(-\frac{|d(w_i', c_i) - d_{\text{orgi}}|}{d_{\text{orgi}}}\right)$$

结构一致性奖励

给定上下文示例集合 $\{w_j, w_j'\}_{j=1}^M$ ，构造原始相似度分布 P_{orig} 和改写后的相似度分布 P_{new} ，计算 Wasserstein 距离 DW 以及 Spearman 秩相关系数 ρ ，奖励定义为：

$$R_{\text{struct}} = \left(1 - \frac{DW}{D_{\text{MAX}}}\right) \cdot \frac{\rho + 1}{2}$$

每个子奖励先经过线性归一化映射到 $[0, 1]$ 区间，再使用动态权重加权求和得到。动态权重通过历史统计窗口和 sigmoid 调整机制自适应更新，并进行 L1 归一化以保持总奖励尺度的稳定性。

Prompt

Rewrite the term "{w}" (category: {c(w)}) into one new term. Strict rules:







- Must strictly belong to the "{c(w)}" category and sound completely natural.
- Use exactly 2 to 4 words, matching the original term's style, length, and rhythm.
- Zero overlap: Do not use any synonyms, rephrasing, similar forms, or parts of the original term.

Output exactly and only: <answer>new term</answer>

{context_str}

{history samples}

训练-生成过程



隐私保护理论分析

目标是**量化隐私保护强度**。

核心思想：

不阻止攻击者从输出 Z 做“嵌入反演”，而是无法从反演结果得到原始信息。

不确定性用条件熵 $H(X|Z)$ 或互信息 $I(X;Z)$ 来度量。

两个关键机制：隐藏上下文 C 和多峰生成模式 M 。

推导路径：

定理1： 证明隐藏上下文 C 如何降低 $I(X;Z)$ 。

链式法则展开 $H(Z, C|X)$

得到 $H(Z|X) = \mathbb{E}[H(Z|X, C)] + I(Z; C|X)$

代入 $I(X;Z) = H(Z) - H(Z|X)$

用 JS 散度下界 β 量化 $I(Z; C|X)$

定理2： 证明多峰生成模式 M 如何降低条件互信息 $I(X;Z|C)$ 。

链式法则展开 $H(M, Z|X, C)$

得到 $H(Z|X, C)$ 的精确分解式

下界 $\approx \sum \alpha_m H(P_m) + H(\alpha)$

压低了 $I(X;Z|C)$

攻击成功率： 将互信息上界转化为攻击成功率的上界。

Fano 不等式 $\rightarrow$ 攻击成功率上界

We quantify privacy via conditional entropy $H(X|Z)$ or mutual information $I(X;Z)$. Two mechanisms contribute: hidden context C and multimodal generation with latent mode M .

Theorem 1 (Hidden Context Entropy Gain). Let $Z \sim p(\cdot|x, c)$ with hidden c . Then

$$H(Z|X) = \mathbb{E}_c[H(Z|X, C)] + I(Z; C|X),$$

$$I(X; Z) = H(Z) - \mathbb{E}_c[H(Z|X, C)] - I(Z; C|X).$$

If for all x , $\text{JS}_{\pi(\cdot|x)}(p(\cdot|x, c)) \geq \beta$, then

$$I(X; Z) \leq H(Z) - \mathbb{E}_c[H(Z|X, C)] - \beta.$$

Proof. Chain rule on $H(Z, C|X)$:

$$H(Z, C|X) = H(C|X) + H(Z|X, C) = H(Z|X) + H(C|Z, X).$$

Hence $H(Z|X) = H(Z|X, C) + I(Z; C|X)$. The rest follows from $I(X; Z) = H(Z) - H(Z|X)$ and $I(Z; C|X) = \mathbb{E}_x[\text{JS}]$. $\square$

Theorem 2 (Multimodal Entropy Gain). Let $M \sim \alpha_{x,c}$ and $Z \sim P_M(\cdot|x, c)$. Then

$$H(Z|X, C) = \mathbb{E}_{X,C} \left[\sum_m \alpha_m H(P_m) + H(\alpha) - H(M|X, C, Z) \right].$$

With $\epsilon = \mathbb{E}[H(M|X, C, Z)]$, we have

$$I(X; Z|C) \leq H(Z|C) - \mathbb{E}_{X,C} \left[\sum_m \alpha_m H(P_m) + H(\alpha) \right] + \epsilon.$$

If modes are separable ($\epsilon \approx 0$) and weights uniform, gain $\approx \log K$.

Proof. Chain rule on $H(M, Z|X, C)$:

$$H(M, Z|X, C) = H(M|X, C) + H(Z|M, X, C) = H(Z|X, C) + H(M|Z, X, C).$$

Solve for $H(Z|X, C)$ and take expectation. The bound on $I(X; Z|C)$ follows from $I = H(Z|C) - H(Z|X, C)$. $\square$

Attack Success Rate. Combining both theorems yields an upper bound on $I(X; Z)$. By Fano's inequality,

$$P_{\text{succ}} \leq \frac{I(X; Z) + 1}{\log_2 |\mathcal{X}|}.$$

Plugging the bound gives the final success rate limitation.

数据集

Dataset	MovieLens-1M	Amazon-Book
users	6039	5921
Items	3534	5658
inters	575281	101305
sparsity	97.3044%	99.6616%

ML-1M 包含约 100 万条用户对电影的评分记录，我们取评分 ≥ 3 的交互作为正样本。

Amazon-Book 收录了用户对图书的评论与评分数据。预处理步骤如下：提取 2018-01-01 至 2018-03-31 内的用户-物品交互记录，迭代过滤掉交互频次低于 3 的用户与物品；从剩余物品中随机采样 10,000 个物品，仅保留与采样物品相关的交互，并再次执行频次不低于 3 的过滤，得到最终交互数据。我们取评分 ≥ 4 的交互作为正样本。

为构建物品的辅助边信息，我们利用 Qwen2.5-14B 模型依据物品标题生成多类别泛化描述，并进一步筛选出具有代表性和强区分能力的属性词作为最终使用的语义边信息。

为公平评估不同类型推荐模型在的表现，我们采用如下的数据集划分策略：

传统协同过滤模型（如 SASRec、LightGCN 等）采用 Target-Only Cold-Start 设置：仅保证测试集中的目标物品在训练集中未出现过，而用户的历史交互物品允许与训练集重叠。该设置保留了必要的协同信号，使得传统模型能够正常完成训练与推理。

基于大语言模型的推荐模型（如 TallRec、LLaRA）参考原论文的数据划分

若无特别说明，后续展示的结果基于 ML-1M 数据集（<https://grouplens.org/datasets/movielens/1m/>）。

数据集

基于大语言模型的提示工程，从物品名称中抽取多维度、细粒度的语义属性。输入为物品名称 $I=\{I_1, I_2, \dots\}$ ，输出为每个物品 i 对应的属性词集合 $A_i=\{a_{i,1}, a_{i,2}, \dots, a_{i,m}\}$ ，其中每个属性词 $w \in W$ 均关联一个类别标签 $c(w) \in C$ 。

Role: Film Database Administrator & Analyst

Task: Generate a pure JSON object with keywords for item_name across 9 fixed categories.

Rules:


3–5 specific, distinct English keywords per category

Avoid generic or overlapping terms

Output only the JSON (no explanations)

Categories: Genre, Actors, Country, Character, PlotAndTheme, Mood, Critical Acclaim, Production Quality, Soundtrack

每个物品ID映射到一个包含9个类别键的字典，形式化为：
 $\text{ItemEdges}[i] = \{G:[g_1, g_2, \dots], D:[d_1, d_2, \dots], \dots\}$ ，
由此构成初始边信息集合 $W_{\text{init}} = \bigcup_i A_i$ ，每个属性词 (a) 的类别标签 ($c(a)$) 由所属顶层键决定。



采用 Qwen2.5-14B-Instruct 作为主生成模型，其指令遵循能力强，能稳定处理复杂结构化输出。生成过程采用批量处理 (batch size = 32)，最大输入长度2048，生成长度512，温度 $T=0.3$ ，并使用贪心解码。

数据集

类别剪枝

全局统计

文档频率 $DF(w) = |\{m \in M: \exists c, w \in W_{m,c}\}|$

逆文档频率 $idf(w) = \ln \frac{|M|}{1+DF(w)}$

类别特征

类别 c 的关键词集合 $W_c = \bigcup_{m \in M} W_{m,c}$

类别分数 $score(c) = \frac{1}{|W_c|} \sum_{w \in W_c} idf(w)$

方差 $var(c) = \frac{1}{|W_c|} \sum_{w \in W_c} (idf(w) - score(c))^2$

语义嵌入 $v(c) = \frac{1}{|W_c|} \sum_{w \in W_c} f(w)$, 类别相似度 $sim(c, c') = \frac{v_c \cdot v_{c'}}{\|v_c\| \|v_{c'}\|}$

迭代剪枝

初始化 $C_{cur} = C$

当 $|C_{cur}| > k_{max}$ 时, 计算每个类别删除的优先级

语义冗余 $red(c) = \sum_{c' \neq c} \max(0, sim(c, c') - \theta)$

低区分度: 若 $var(c) < \varphi \cdot \text{avg}(var(c))$, 作为候选

兜底: 所有未覆盖类别按 $score(c)$ 排序

综合优先级为 $p(c) = \alpha \cdot red(c) - \beta \cdot score(c) - \gamma \cdot var(c)$



删除 $c^* = \text{argmax } p(c)$, 从 C_{cur} 移除, 重复至 $|C_{cur}| < k_{max}$

最终保留类别集 C^*

关键词剪枝

对每部电影 m 和每个保留类别 $c \in C^*$, 保留原关键词集合为 $W_{m,c}$ 中 $idf(w)$ 中最高的前 τ 个词

$$W_{m,c} = \text{top}_\tau(\text{arg max}_{w \in W_{m,c}} idf(w))$$



下游任务与评估

研究问题

RQ1: 词语质量 生成的混淆文本在语义保真度、流畅性与类别区分性等方面的表现如何?

RQ2: 推荐性能 不同方法生成的边信息对下游推荐任务性能的影响如何?

RQ3: 攻防效果 所提方法在抵御嵌入反演攻击方面的隐私保护能力如何?

基线方法

随机初始化 (Random): 使用随机生成的向量作为物品嵌入, 作为性能的下界参照。

原始边信息 (Description): 使用 Qwen3-4B 依据原始物品标题/描述生成的语义文本, 经筛选保留重要类别与强区分度样本后作为边信息。该设置可视为性能的上界参考。

纯LLM (LLM): 直接使用未经 GRPO 优化的 Qwen3-4B 模型生成的语义转换文本, 用于对比 GRPO 优化带来的性能增益。

InferDPT: 基于差分隐私的文本扰动方法。

Text2Text: 基于序列到序列的文本混淆方法。

Text2Text-UI: Text2Text 的改进版本。

推荐模型

传统协同过滤模型: DeepFM (结合因子分解机与深度神经网络)、LightGCN (简化图卷积网络)、SASRec (基于自注意力的序列推荐模型)。

基于大语言模型的推荐模型: TallRec (二分类LLM推荐框架) 与 LLaRA (候选键LLM推荐框架)。

攻击模型

为评估方法的隐私保护能力, 采用Vector2Text攻击框架, 通过对物品嵌入向量进行反演攻击以恢复其类别标签, 从而定量刻画隐私泄露程度。






下游任务与评估

词语质量

不同方法生成混淆文本的词语质量指标对比，包括 KL 散度、余弦相似度（CosSim）、斯皮尔曼相关系数（Spearman）、语义流畅性（SemFlu）、生成多样性（GVR）及负对数似然（NLL）。

指标	Valid	KL	CosSim	Spearman	SemFlu	GVR	NLL
Description	—	—	1.000	1.000	0.2199	0.5498	7.4174
LLM	—	—	—	—	—	—	—
InferDPT	—	7.7964	0.6032	0.0628	0.2199	0.6104	10.762
Text2Text	—	7.4404	0.2040	-0.0010	0.0886	0.1261	11.322
Text2Text-UI	—	5.3680	0.6958	0.2146	0.1774	0.2387	10.652
Ours	—	8.4230	0.5960	0.2683	0.2220	0.9727	7.8308





下游任务与评估

推荐性能

传统推荐模型（DeepFM、LightGCN、SASRec）：首先，将所有基线方法及本文方法生成的混淆文本通过 BERT-base-uncased 编码为 768 维文本嵌入，随后采用主成分分析（PCA）将其降维至 128 维，作为下游推荐模型的物品初始嵌入。

基于 LLM 的推荐模型（TallRec、LLaRA）：直接使用 BERT-base-uncased 将混淆文本编码为 768 维文本嵌入，再通过一个可学习的投影网络将其映射到 LLM 的文本嵌入空间。

在评价指标上，对于传统模型，采用 HR@10 和 NDCG@10；对于基于 LLM 的模型，TallRec 使用 AUC 评估，LLaRA 使用 HR@1 评估。

推荐模型	SASRec		LightGCN		DeepFM		TALLREC	LLARA
指标	HR@10	NDCG@10	HR@10	NDCG@10	HR@10	NDCG@10	auc	HR@1
Random	0.1304	0.0624	0.0571	0.1842	0.0553	0.1860	0.6828	0.21635
Description	0.1343	0.0650	0.0586	0.1878	0.0572	0.1934	0.6950	0.25410
LLM	—	—	—	—	—	—	—	—
InferDPT	0.1339	0.0648	0.0583	0.1861	0.0552	0.1972	0.6955	0.25367
Text2Text	0.1338	0.0645	0.0577	0.1863	0.0548	0.1933	0.6979	—
Text2Text-UI	0.1335	0.0645	0.0571	0.1816	0.0555	0.1986	0.6901	—
Ours	0.1346	0.0652	0.0585	0.1864	0.0581	0.1919	0.6993	0.23684

下游任务与评估

物品反演攻击 (Item Inversion Attack)

为评估方法的隐私保护能力，我们采用Vector2Text攻击框架，通过对物品嵌入向量进行反演攻击以恢复其类别标签，从而定量刻画隐私泄露程度。具体而言：对于ML-1M，我们从ML-25M和 ML-32M中筛选出80,000个电影标签作为攻击模型的训练与验证集，确保与ML-1M中的电影无重叠。对于Amazon-Book，我们从原始数据集中剔除实验所用物品后，另选 10,000 个物品的标签作为攻击模型的训练与验证集。与测试集嵌入的生成方式一致，我们同样使用 Qwen2.5-14B 为攻击训练集中的物品生成边信息，随后利用 BERT-base-uncased将其编码为向量嵌入。

EM：严格字符串完全匹配率（prediction 和 target 在标准化后完全一样才算对）

Levenshtein：基于编辑距离的相似度

Precision：标签级平均精确率（预测出的标签里，有多少比例是对的）

Recall：标签级平均召回率（目标标签里，有多少被预测命中）

F1：标签级平均 F1（Precision 和 Recall 的综合平衡指标）

Jaccard：标签集合的平均 Jaccard（交集/并集）

指标	EM	Levenshtein	Precision	Recall	F1	Jaccard
Description	0.0641	0.4523	0.2413	0.3638	0.2720	0.2116
Random	0.0252	0.03372	0.0313	0.1858	0.1441	0.0107
LLM	—	—	—	—	—	—
InferDPT	0.0319	0.3635	0.0663	0.0872	0.0711	0.0588
Text2Text	0.0252	0.3315	0.0630	0.0886	0.0678	0.0534
Text2Text-UI	0.0301	0.3652	0.0811	0.1159	0.0897	0.0707
Ours	0.0314	0.3655	0.0688	0.0882	0.0732	0.0608



下一阶段

理论推导：

- 在现有定性推导的基础上，引入奖励函数进行引导；
- 尝试将定性分析进一步拓展为定量推导

推荐性能：

- 在现有基础上对模型进行充分调参
- 增加能够利用边信息的传统推荐模型

基线模型：

- 尝试增加 1~2 个与现有方法类似的“文本到文本混淆”基线模型

可视化分析：

- 对分布变化进行转移可视化
- 对关键评价指标进行结果可视化

消融实验：

- 考察奖励函数权重的影响
- 验证奖励函数存在与否的作用
- 进行模块消融，例如移除 GRPO 优化部分

论文撰写

- 整理研究成果，完成毕业论文



西安交通大学
XI'AN JIAOTONG UNIVERSITY

感谢指导

欢迎各位老师的批评指正

基于大语言模型生成式边信息的隐私脱敏推荐系统研究

精勤求学 敦笃励志 果毅力行 忠恕任事

汇报人：林圣翔

指导老师：田锋教授

汇报时间：2026. 4. 22