



西安交通大学
XI'AN JIAOTONG UNIVERSITY

基于大语言模型生成式边信息的隐私脱敏推荐系统研究 开题报告

精勤求学 敦笃励志 果毅力行 忠恕任事

汇报人：林圣翔
指导老师：田锋教授
汇报时间：2026.1.13

选题背景


推荐系统依赖用户物品数据提升性能，却面临隐私泄露风险。以大语言模型（LLM）为代表的技术虽能通过**嵌入向量**增强语义理解，但其嵌入易受反演攻击与成员推断，可能**暴露用户敏感信息**。因此，在利用前沿技术的同时，构建有效的**隐私保护**机制已成为关键挑战。

基于**差分隐私**的方法通常在嵌入表示或梯度更新中引入噪声，以阻止攻击者从输出反推原始输入，但往往会损害模型性能。

联邦学习能避免原始数据出域，却受限于通信开销、设备异构性与数据非独立同分布等问题，难以大规模高效部署。

传统脱敏与匿名化方法在面对从模型输出逆向重构输入的新型攻击时，防护效果有限，且难以兼容隐私和性能的平衡。

在此背景下，如何构建一个既能有效保护用户隐私，又能维持推荐性能的新范式，成为一项关键而富有挑战性的研究方向。为应对这一挑战，本研究提出一种**前置隐私保护**的思路，将防护环节迁移至**数据预处理**阶段，并**引入大语言模型的生成与语义理解能力**。通过设计一种“生成式混淆”机制，对物品元信息进行**语义关系保持的变换**，旨在从表征源头干扰攻击的信号基础，从而构建一个兼顾隐私安全与推荐效能的防护框架。



相关领域研究现状

目前，在推荐系统中从数据层面出发兼顾用户隐私与推荐性能的研究有限，且大部分是出于基于交互历史的修改，和本研究更具参考意义的是**嵌入向量修改**和**LLM混淆文本生成**这两方面的工作。

研究领域		研究成果
推荐系统	基于物品元信息的数据合成	SampleLLM (WWW 2025) 提出一个两阶段框架，通过使用大语言模型和改进的采样方法，优化了面向推荐任务的表格数据合成质量，以解决现有方法在数据稀疏和语义理解上的不足。
	基于交互历史的修改	CLOUD (ACM TOIS 2025) 提出了一种基于协同混淆机制的隐私保护序列推荐方法，通过在推荐前向用户交互序列中插入不可区分的干扰项来保护用户隐私，同时保持推荐精度。
		DR4SR (KDD 2024) 提出了一种数据中心的顺序推荐开发范式，再生出具有优异跨架构泛化能力或针对特定模型优化的训练数据集，从而提升模型性能。
		STEAM (WWW 2023) 提出了一种自纠正顺序推荐系统，它通过纠正用户历史交互序列中的误点击和缺失物品来提升推荐准确性。
		DiffuRec (ACM TOIS 2024) 提出了一种基于分数扩散模型的推荐模块，利用扩散模型生成高质量的合成数据以替代或增强原始用户数据，在保护用户隐私的同时提升推荐系统的性能。
		UPC_SDG (SIGIR 2022) 提出了一种用户隐私可控的合成数据生成模型，它根据用户的隐私偏好生成合成交互数据，旨在提供隐私保障的同时，在数据和项目两个层面最大化合成数据的效用。
数据合成		表格数据合成 的常用流程与方法，可为本研究提供参考。

相关领域研究现状

研究领域		研究成果
嵌入 向量 修改	向量映射	Eguard (AAAI 2026) 提出了通过投影嵌入向量并优化文本互信息，来显著降低这种风险，同时保持LLM在下游任务（如情感分析、自然语言推理等）中的实用性。
		STEER (arXiv 2025) 通过嵌入空间对齐技术，允许用户使用本地模型生成的近似嵌入进行检索，从而在保护查询文本隐私的同时维持较高的检索准确性。
	向量扰动	REPET (JAMIA 2020) 将每个词令牌替换为嵌入空间中最近N个邻近词的随机一个（排除自身），利用词嵌入的语义属性（如分布假设），在保持下游NLP任务效用的同时，提高隐私保护。
		DP-Forward (CCS 2023) 通过在语言模型的前向传播中直接对输入数据的嵌入添加优化后的噪声，以本地差分隐私的方式高效保护数据，并能防御传统方法无法应对的推理阶段嵌入反演等攻击。
LLM 混淆 文本 生成	Prompt-based	EmojiPrompt (ACL 2025) 使用LLM进行生成式提示混淆，将私人数据从自然语言转换为非自然语言形式，从而对云端LLM和服务提供商隐藏敏感信息。通过语义对齐约束和本地差分隐私（LDP）后采样约束，实现原子级混淆。该方法在保持或提升任务性能的同时，有效抵抗恢复攻击。
		LLM-Anonymization (ICLR 2025) 利用LLM的推理能力，通过迭代prompt和in-context learning进行对抗性匿名化。无需fine-tuning，直接评估和优化文本。人类评估也验证了其有效性。
		IncogniText (arXiv 2025) 主要通过prompt驱动LLM检测间接泄漏并条件改写文本（随机化私人属性）。为实时/本地应用，可将能力distill到小型模型的LoRA参数（涉及instruction fine-tuning）。
		RUPTA (ACL 2025) 使用GPT-4/GPT-3.5 API作为评估器和优化器，通过迭代prompt进行lexicographic优化生成混淆文本。同时，支持将GPT-4能力distill到轻量学生模型（使用QLoRA、SFT和DPO微调）
	Fine-tuned local LLM	HaS (arXiv 2025) 使用本地小型LLM进行匿名化（Hide）和去匿名化（Seek），通过训练/微调两个模型（masker和reconstructor）来处理提示和响应。

研究意义

本研究提出了一种**前置式、语义层面的隐私保护**新思路，将防御重心迁移至数据预处理与表征生成阶段，突破传统隐私保护技术的局限。现有方法多集中于模型训练过程或输出扰动（如差分隐私），以及基于分布式学习的框架（如联邦学习）。本研究通过**利用大语言模型（LLM）强大的语义理解与可控生成能力**，实现隐私保护与语义效用的协同优化，从而丰富了隐私计算与可信人工智能在推荐系统领域的研究内涵与方法体系。


为缓解推荐系统商业化应用中日益严格的隐私合规要求（如GDPR、CCPA）与持续增长的业务性能需求之间的矛盾，提供了可行的技术路径。该方法无需依赖高昂的通信开销或复杂的多方协同训练机制，易于融入现有推荐数据流水线，**具备良好的工程落地潜力**。通过对物品边信息进行源头脱敏，能够系统性地降低后续嵌入生成、模型训练及服务部署等环节的隐私泄露风险，为构建全链路隐私安全的智能推荐服务提供了基础性支撑。

研究思路和方法

实验构成	设置细节
数据集	Amazon: 大型电商数据集, 涵盖包括Sports_and_Outdoors、Movies_and_TV等多种商品类别。
	Yelp: 本地商业服务点评数据集, 包含丰富的用户对商家的评分与互动记录。
	MovieLens 1M Dataset: 经典的电影评分数据集, 专门用于推荐系统算法的研究、评测与基准测试。
评估指标	推荐性能评估: 采用 归一化折扣累计增益 (NDCG) 和 命中率 (HR)
	隐私保护评估: 引入 替换率 (衡量原始数据被保护的程度)、 合成与真实数据间的语义相似度 (评估信息保真度), 以及 对抗反演攻击、属性推断攻击的成功率 (直接测试隐私泄露风险)。
竞争模型	选取当前前沿的嵌入向量修改以及LLM混淆文本生成的方法引入推荐系统作为基线进行对比, 主要包括: Eguard 、 DP-Forward 等。
	若干 基于LLM嵌入的推荐模型 用于推荐性能对比, 主要包括 TALLRec 、 LLaRA 等
问题	①引入LLM生成边信息的意义, 相比于传统向量扰动方法的优势。
	②是否能够有效的进行隐私保护同时兼顾推荐效果。
实验设置	① LLM引入的必要性验证 : 通过消融实验, 分析利用LLM理解物品元信息对生成高质量嵌入的关键作用。
	② 推荐性能对比 : 在严格控制隐私保护水平的前提下, 比较本研究模型与基线模型在NDCG、HR等指标上的性能。
	③ 隐私保护效果评估 : 从语义相似度及抗反演攻击能力多个维度, 系统评估本方法提供的隐私保护强度。

研究思路和方法

目标 针对每个原始语义生成对应语义簇，并满足以下约束：生成的语义簇应与原始语义保持一定距离，避免过度接近；若两个原始语义本身相似，则其对应语义簇应彼此接近，否则应相互远离。





研究思路和方法

➡ **Step 1** 利用大语言模型对物品的原始辅助信息进行**语义增强**。该方法通过对模型进行预训练与微调，旨在生成多个与原始信息语义高度一致、但表层表达丰富多样的高质量替代文本，从而实现对原始语义的强化与扩展。

➡ **Step 2** 设计并实现**单向非可逆的语义混淆映射**。将生成的语义变体通过特定变换函数，映射至向量空间中与原始位置相异但语义关联的区域，从而在表征层面实现有效的语义混淆。该过程旨在满足单向性与计算不可逆性。

➡ **Step 1 & Step 2** 在GRPO训练中，通过引入**全局感知机制**，以平衡个体差异与整体结构的一致性。首先基于数据集预计算全局相似性图用于后续动态锚点注入；在训练阶段，针对每个局部批次中的物品，将与其高度相似的外部锚点所对应的历史聚类中心作为约束注入到当前优化过程中。这一设计使得模型在局部批次内进行参数更新的同时，能够隐式地感知并维持全局结构的稳定性。后续可考虑引入**最优传输**的相关理论实现进一步优化。



预实验

TALLRec模型的训练 此处TALLRec模型的训练严格遵循原论文的实验方法，并基于其开源代码实现。在MovieLens 1M完整数据集上进行了训练，实验在**RTX 4090 (24GB显存)** 环境下完成。最终模型在验证集上取得了**0.7263**的准确率，成功复现了原论文的核心结果。

基于Attack-Recsys的反演攻击评估 按照原代码的设定，基于之前训练的TALLRec模型电影数据集上的反演攻击，实验在**vGPU-48GB显卡**上完成，由于训练时间有限（训练260轮的情况下），实验结果用户画像匹配度为**0.523**（原论文0.87），物品匹配度为**0.2377**（原论文0.6471），但可表明该攻击方法具备可行性。

基于数据集层面交互历史修改的推荐系统相关代码复现 复现了包括DR4SR (KDD 2024)、UPC_SDG (SIGIR 2022) 等相关开源代码，实验在**RTX 4090 (24GB显存)** 环境下完成，复现结果与原文**核心结论一致**，为后续对比实验奠定基础。

进度规划

研究综述与技术路线设计

(2025.12-2026.01, 基本完成)

通过系统调研推荐系统安全、隐私保护与对抗攻击等领域工作，厘清技术脉络与现存挑战。确立论文的核心路线以及具体技术路线，为后续研究提供理论依据与实践指引。

对比基线系统集成

(2026.02-2026.03, 预计2周)

为实现公平评估，复现并集成了多层次基线方法：原始编码、随机扰动、DP-Forward以及Eguard等生成式方法。所有基线均通过统一接口接入同一推荐骨干网络进行对比。

泛化性验证实验设计

(2026.04-2026.05, 预计3周)

为全面评估方法性能，选取涵盖不同领域及不同数据规模的多个公开数据集进行测试以及将设计的隐私保护模块适配并集成到多种基于边信息的主流推荐模型框架中。

核心方法框架实现

(2026.01-2026.02, 预计2周)

完成基于大语言模型的语义可控生成模块及配套训练流水线的开发。在基准数据集上实现了从原始边信息输入到脱敏文本输出的端到端流程，验证框架的可行性。

系统优化与超参数调优

(2026.03-2026.04, 预计3周)

在工程层面，将对已实现的代码进行模块化重构，以提升系统的可维护性与执行效率。在模型调优层面，调整学习率、隐私预算权重、生成模块的温度系数等关键超参数。

学术论文撰写与成果整理

(2026.05-2026.06, 预计2周)

依据学术规范，将研究过程、方法、实验与分析系统性地整理成文，完成了包含核心章节的完整论文稿件，并通过精细化图表与数据分析确保其达到毕业论文。



西安交通大学
XI'AN JIAOTONG UNIVERSITY

感谢指导

欢迎各位老师的批评指正

基于大语言模型生成式边信息的隐私脱敏推荐系统研究

精勤求学 敦笃励志 果毅力行 忠恕任事

汇报人：林圣翔

指导老师：田锋教授

汇报时间：2026. 1. 13