



西安交通大学
XI'AN JIAOTONG UNIVERSITY

基于大语言模型生成式边信息的隐私脱敏推荐系统研究

2022级本科生学位论文答辩

精勤求学 敦笃励志 果毅力行 忠恕任事

答辩人：林圣翔 班级：计试2201
学号：2223312202 指导老师：田锋教授

二〇二六年 六月

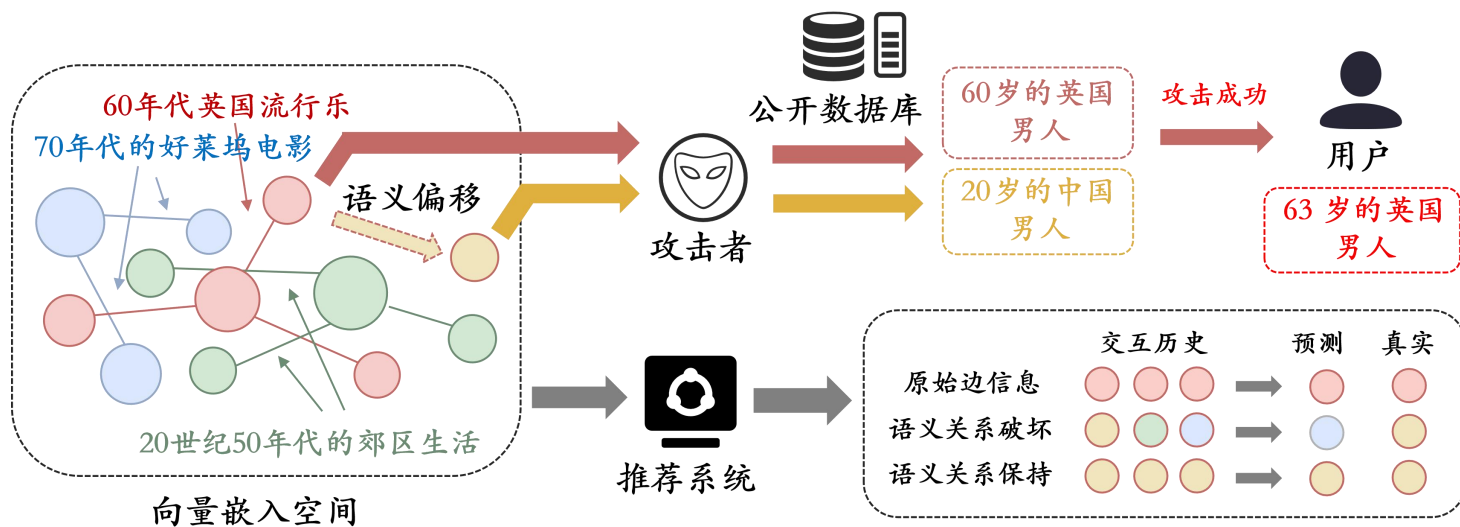
选题背景与调研

在**推荐系统**中，利用大语言模型建模物品的语义边信息虽能有效提升性能，但会引入严重的隐私风险。攻击者可通过**嵌入反演攻击**从模型输出的嵌入向量中高精度还原原始文本内容，甚至进一步反推出用户对特定物品的偏好及其历史交互行为。

在此背景下，如何构建一个既能有效保护用户隐私，又能维持推荐性能的新范式，成为一项关键而富有挑战性的研究方向。本研究提出一种**前置隐私保护**思路，在**数据预处理阶段**引入LLM驱动的“生成式混淆”机制，依托“离散→连续→离散”的优化路径，于连续语义空间中对语义迁移与分布保持进行联合优化，从而从表征源头干扰攻击信号，实现隐私与效能的兼顾。

→ **依赖可信下游模型** 现有方法多聚焦于数据使用阶段的隐私保护（如差分隐私、联邦学习），而对数据收集端（用户本地）的直接防护关注不足，**忽略了从源头进行隐私干预的能力**。

→ **扰动破坏语义结构与质量** 输入层文本混淆方法通过扰动原始文本以保护隐私，同时力图保留下游任务的效用，将扰动与下游表现相绑定，**与推荐任务不匹配**。



问题定义

背景与威胁模型

物品由属性词集描述 $A_i = \{a_{i,1}, a_{i,2}, \dots, a_{i,m}\} \in \mathcal{W}$ ，嵌入由预训练语言模型编码。

隐私目标 生成混淆词 z ，使得攻击者在已知模型、近邻图等全部辅助信息 O （含模型参数、近邻图、 z ）的情况下，仍难以推断 x 。

形式化为最大化条件熵 $H(X|Z, O)$ ，即最小化互信息 $I(X; Z | O)$ 。

模型学习目标

映射函数 $f: \mathcal{W} \rightarrow \mathcal{W}'$ ，对于每个原始属性词 $w \in \mathcal{W}$ ，生成其改写版本 $w' = f(w)$ ，从而得到变换后的物品边信息集合 $(A_i' = \{f(a) | a \in A_i\})$ 。该映射函数需同时满足以下两个目标：

个体差异性 最小化原始词与混淆词嵌入的相似度，使嵌入反演失效，

$$\min \mathbb{E}_{w \sim \mathcal{W}} [\text{sim}(e(w), e(f(w)))]$$

关系一致性 保持词间局部语义拓扑，确保下游可用性，

$$\max \text{Corr}(\text{sim}(u, v), \text{sim}(f(u), f(v)))$$

挑战与措施

传统离散词级扰动本质上是通过对原始信息的破坏实现隐私保护，无法联合优化这两个目标；


近期基于LLM的文本隐私保护方法沿袭语义保真范式，力图在隐藏特定隐私属性的同时尽可能保留字面含义；

本研究提出的“**关系保真**”范式：LLM从原始全局中继承局部保序约束，便可据此自主生成偏移后的物品语义表征，新的全局拓扑由这些局部关系聚合而成。

被动的约束性掩藏 → 参照原始拓扑的主动语义重构

总体框架

面向推荐系统边信息隐私脱敏的核心词引导渐进式混淆框架



该框架首先识别高结构影响力核心词并预构建静态语义近邻图，随后基于 GRPO 的多目标奖励优化探索核心词混淆变体作为拓扑锚点，最后依托该图将锚点映射渐进传播至全词汇表。

隐私保护理论分析

威胁模型与目标

- 白盒攻击者 已知模型参数、近邻图、混淆输出 z （统称 O ），不知生成轨迹 Γ
- 目标 最大化条件熵 $H(X|Z,O) \Leftrightarrow$ 最小化互信息 $I(X;Z|O)$

核心隐私来源：路径依赖轨迹

- 混淆过程依赖处理顺序、缓存、队列 $\rightarrow$ 隐藏轨迹 Γ
- 攻击者需对 Γ 边缘化，轨迹散度 $I(Z;\Gamma|X,O)$ 引入额外不确定性

信息泄露分解

$$I(X; Z|O) = H(Z|O) - \mathbb{E}[H(Z|X, O, \Gamma)] - I(Z; \Gamma|X, O)$$

- 增大轨迹散度、提升条件熵，可减少泄露

攻击成功概率上界

- 语义模式划分：权重 α_m ，模式内分布 p_m ，残余模糊度 ϵ
- $$P_{\text{succ}} \leq \frac{\epsilon - \mathbb{E}[H(\alpha) + \sum \alpha_m H(p_m)] + H(Z|O) - I(Z; \Gamma|X, O) + 1}{\log_2 |\mathcal{X}|}$$
- 降低攻击成功率的关键：增大模式权重熵 $H(\alpha)$ 、保持模式内熵、提高轨迹散度

三项奖励的信息论作用

- R_{dis} （个体差异性） $\rightarrow$ 提升 $H(\alpha)$ （语义多样性）
- R_{str} （结构一致性） $\rightarrow$ 调控 ϵ （结构模糊度）
- R_{con} （空间锚定） $\rightarrow$ 保持 $\sum \alpha_m H(p_m)$ （有效性）

下游表示层面的传递

$$I(X; h_{\text{item}}|C, O) \leq \rho_{\alpha} I(X; Z|O) + \eta + \delta$$

- 文本端隐私保护可有效压缩物品表示中的原始词信息

实验设置

数据集与预处理

- **MovieLens-1M** 评分 ≥ 4 为正样本；去重仅保留最新交互；受控稀疏化（每物品1个锚点交互 + 其余以0.4概率保留）。
- **Amazon-Book** 提取2018.01 - 03交互；迭代过滤交互数 < 3 的用户/物品；随机采样10,000物品后再次过滤 ≥ 3 ；评分 ≥ 4 为正样本。

边信息构建

对所有物品，我们使用Qwen2.5-14B由原始标题生成多类别泛化描述，然后通过以下步骤修剪冗余类别并保留有判别力的关键词：



- (1) 计算每个关键词的IDF；
- (2) 基于平均关键词IDF和成对嵌入相似度对每个类别评分；
- (3) 迭代移除冗余度高且得分低的类别；
- (4) 每物品每类别中保留前 τ 个关键词。

数据集信息统计

Dataset	MovieLens-1M	Amazon-Book
users	6038	5921
Items	3629	5658
inters	337,228	101,305
sparsity	98.46%	99.66%

边信息信息统计

MovieLens-1M		Amazon-Book	
类别属性	边信息数量	类别属性	边信息数量
PlotAndTheme	6384	PlotAndTheme	7637
Actors	5122	Author	6242
Soundtrack	4039	PublicationContext	4513
Production Quality	2893	ToneAndStyle	3725
Total	18398	Total	21678



实验设置

研究问题

- RQ1: 变体质量** 生成的混淆文本是否具有较高的有效性、自然性、多样性和局部结构保持能力？
- RQ2: 推荐性能** 不同方法生成的边信息对下游推荐任务性能的影响如何？
- RQ3: 防御效果** 所提方法在抵御嵌入反演攻击方面的隐私保护能力如何？

对比方法

None 完全放弃边信息。在推荐效用端提供性能下界参照。

Description 直接使用未经任何混淆的原始边信息文本。

InferDPT 一种面向隐私保护LLM推理的差分隐私文本扰动方法。此处直接使用其扰动输出，未经过额外LLM处理。

Text2Text 一种基于序列到序列框架的文本混淆方法，在局部差分隐私机制下对嵌入进行随机化扰动。

SanText+ 一种基于序列到序列框架改进版的文本混淆方法，通过优化候选替换词的语义适配度与隐私预算分配策略。

TextObfuscator (TOF) 一种基于规则的文本混淆工具，采用上下文感知的词级替换策略。

推荐模型

传统协同过滤模型：LightGCN（简化图卷积网络）、SASRec（基于自注意力的序列推荐）。

多模态推荐模型：FREEDOM（冻结模态图去噪）、LightGT（轻量级图Transformer推荐）

基于大语言模型的推荐模型：TallRec（二分类LLM推荐框架）与 LLaRA（候选键LLM推荐框架）。

攻击模型与隐私度量

为评估方法的隐私保护能力，采用**Vector2Text攻击框架**，从物品嵌入中恢复敏感类别标签，定量刻画隐私泄露程度。

本研究仔细调整各方法的超参数，使得所有方法在BERT嵌入空间中的原始嵌入与混淆嵌入的平均余弦相似度尽可能相近。所有评估均在此**对齐CosSim条件**下进行

对比实验与主要结果（词语质量）

不同方法生成混淆文本的词语质量指标对比

Dataset	Method	Valid [†]	CosSim [†]	KL [‡]	Spearman [†]	NLL [‡]	D-2 [‡]	D-1 [†]	LR [†]
MovieLens-1M	Description	–	1.0000	–	1.0000	1.9858	0.3958	0.1959	1.0000
	InferDPT	0.8276	0.6378	6.7429	0.0546	61.7860	0.5677	0.2708	0.7379
	Text2Text	0.9659	0.6246	6.1386	0.0857	39.8507	0.4446	0.3661	0.9674
	SanText+	0.9912	0.6266	8.7132	0.1612	3.5427	0.2668	0.1118	1.2536
	TOF	0.1000	0.6297	6.2628	0.0341	42.7631	0.5455	0.2585	1.0944
	Ours	0.9986	0.6293	7.9264	0.1981	5.7050	0.4257	0.1960	0.8758
Amazon-Book	Description	–	1.0000	–	1.0000	2.9403	0.3310	0.1539	1.0000
	InferDPT	0.8038	0.6762	6.2585	0.0538	50.2972	0.4773	0.2466	0.7777
	Text2Text	0.9719	0.6509	6.3891	0.0951	34.3471	0.3698	0.3242	0.9343
	SanText+	0.9899	0.6455	8.9465	0.1572	3.9354	0.2258	0.0992	0.9585
	TOF	0.9999	0.6668	6.2941	0.0359	42.5229	0.4624	0.2277	1.0812
	Ours	0.9983	0.6519	6.9642	0.1808	10.0452	0.3378	0.1661	0.9628

[†] For word-level metrics, [‡] For item description sentences.

本方法对几乎所有词都能生成有效变体，并在两个数据集上取得了最高的斯皮尔曼相关系数（MovieLens-1M上为0.198，Amazon-Book上为0.181），在保持局部语义拓扑方面显著优于所有基线方法。相比之下，SanText+的负对数似然较低，但因频繁出现特殊标记而导致多样性下降；而 InferDPT、Text2Text 和 TOF 生成的输出噪声较大，邻域一致性较弱。这些结果证实，在可比的扰动强度下，本方法能更好地在混淆、流畅性和关系语义保持之间取得平衡。

对比实验与主要结果（推荐性能）

不同方法生成混淆文本的推荐性能评估结果

Method	SASRec		LightGCN		FREEDOM		LightGT		TALLRec	LLaRA
	H@10	N@10	H@10	N@10	H@10	N@10	H@10	N@10	AUC	H@1
MovieLens-1M										
None	0.1116	0.0515	0.0814	0.0199	0.0793	0.0201	0.0758	0.0183	0.6828	0.21635
Description	0.1147	0.0524	0.0864	0.0212	0.0842	0.0205	0.0799	0.0199	0.6983	0.23509
InferDPT	0.1125	0.0516	0.0831	0.0201	0.0834	0.0204	0.0778	0.0194	0.6932	0.23422
Text2Text	0.1133	0.0522	0.0834	0.0201	0.0826	0.0202	0.0788	0.0195	0.6935	0.23250
SanText+	0.1139	0.0528	0.0837	0.0204	0.0829	0.0196	0.0796	0.0191	0.6928	0.22904
TOF	0.1134	0.0518	0.0824	0.0200	0.0816	0.0199	0.0753	0.0190	0.6877	0.23049
Ours	0.1144	0.0529	0.0861	0.0215	0.0837	0.0202	0.0806	0.0201	0.6999	0.23753
Amazon-Book										
None	0.1792	0.0877	0.0890	0.0399	0.0749	0.0319	0.0888	0.0394	0.7799	0.44844
Description	0.1866	0.0915	0.0937	0.0414	0.0781	0.0327	0.0920	0.0411	0.7963	0.52039
InferDPT	0.1821	0.0882	0.0924	0.0411	0.0747	0.0324	0.0895	0.0396	0.7928	0.52278
Text2Text	0.1772	0.0875	0.0914	0.0406	0.0722	0.0305	0.0905	0.0401	0.7903	0.51558
SanText+	0.1815	0.0893	0.0901	0.0406	0.0743	0.0312	0.0891	0.0402	0.7932	0.48681
TOF	0.1821	0.0885	0.0899	0.0407	0.0734	0.0312	0.0901	0.0404	0.7922	0.51079
Ours	0.1883	0.0921	0.0939	0.0412	0.0762	0.0328	0.0910	0.0403	0.7950	0.52518

本方法在两种数据集的所有模型类型上，均一致取得最佳或接近最佳的下游推荐结果。与使用原始描述的上界相比，性能下降极小，对传统协同过滤模型通常低于2%，表明边信息中的关键语义关系在很大程度上得以保留。而基线词元级方法则会降低嵌入质量，破坏隐式的物品间关系，导致推荐准确性较差。


对比实验与主要结果（防御效果）

不同方法生成混淆文本的防御效果对比


Method	MovieLens-1M					Amazon-Book				
	EM	Precision	Recall	F1	Jaccard	EM	Precision	Recall	F1	Jaccard
Description	0.0641	0.2413	0.3638	0.2720	0.2116	0.0988	0.1829	0.1836	0.1832	0.1551
InferDPT	0.0309	0.0676	0.0848	0.0703	0.0583	0.0480	0.0950	0.0955	0.0952	0.0795
Text2Text	0.0276	0.0593	0.0808	0.0646	0.0523	0.0324	0.0727	0.0730	0.0728	0.0594
SanText+	0.0276	0.0839	0.1252	0.0941	0.0711	0.0226	0.0599	0.0605	0.0601	0.0477
TOF	0.0301	0.0672	0.0912	0.0722	0.0586	0.0384	0.0887	0.0896	0.0890	0.0722
Ours	0.0309	0.0662	0.0913	0.0721	0.0593	0.0314	0.0925	0.0933	0.0928	0.0724

所有混淆方法相对原始描述基线均将攻击成功率降低超过50%，证实语义扰动可有效抵御反演攻击。尽管基线词元级方法能提供部分保护，但它们会损害词质量与推荐效用。相比之下，本方法在实现最先进防御性能的同时，完好保持了词质量，从而有效支撑推荐。


消融研究



相对于完整模型的归一化变体质量指标变化



推荐性能



嵌入反演防御

所有组件均至关重要：

去除GRPO的变体（w/o GRPO）降低了推荐性能并提高了攻击成功率，验证了基于分组的策略优化的收益。


去除上下文的变体（w/o context）严重削弱了语义保持能力，表明邻域感知生成对维持局部拓扑不可或缺。

去除个体差异性奖励的变体（w/o dissimilarity）使余弦相似度升高，说明语义偏移不足、隐私保护减弱。


去除结构一致性奖励的变体（w/o structural）同时损害了语义相关性与推荐效用，证实了保持局部语义排序的必要性。

去除语义锚定奖励的变体（w/o constraint）退化为单纯的翻译，导致攻击成功率高且语义不一致，凸显了约束奖励在防止退化捷径方面的关键作用。


参数敏感性研究（缓存大小）



不同缓存大小对应的物品
嵌入的t-SNE可视化



缓存大小对推荐性能的影响



缓存大小对嵌入反演防御的影响


不同缓存大小下生成词语的质量对比

Cache Size	Valid [†]	CosSim [†]	KL [‡]	Spearman [†]	NLL [‡]	D-2 [‡]	D-1 [†]	LR [†]
0	0.9982	0.6333	8.1727	0.0070	4.3177	0.3828	0.1430	0.9021
1000	0.9990	0.6290	7.9774	0.1771	4.3254	0.3996	0.1668	0.8787
2000	0.9991	0.6241	7.9014	0.1728	5.8615	0.4112	0.1783	0.8706
3000	0.9990	0.6178	7.7505	0.1672	6.7148	0.4327	0.2079	0.8439
4000	0.9994	0.6155	7.7191	0.1655	7.2066	0.4469	0.2278	0.8571
5000	0.9996	0.6120	7.7077	0.1653	8.0208	0.4456	0.2258	0.8619


[†] For word-level metrics, [‡] For item description sentences.

结果显示，过小的缓存会破坏拓扑结构，适中的缓存能提升Spearman相关系数以保持局部语义，而进一步增大缓存则会使两者略有下降，表明收益递减且早期低质量样本会引入轻微扰动。


参数敏感性研究（核心词数量）



不同核心词数量对应的物品
嵌入的t-SNE可视化



核心词数量对推荐性能的影响



核心词数量对嵌入反演防御的影响


不同核心词数量下生成词语的质量对比

Count	Valid [†]	CosSim [†]	KL [‡]	Spearman [†]	NLL [‡]	D-2 [‡]	D-1 [†]	LR [†]
1250	0.9951	0.6309	7.3785	0.2352	8.3621	0.4705	0.3270	0.7863
2500	0.9970	0.6442	7.5392	0.2353	6.9372	0.4261	0.2240	0.8422
5000	0.9986	0.6293	7.9264	0.1981	5.7050	0.4257	0.1960	0.8758
7500	0.9976	0.6228	7.7439	0.1650	6.8084	0.4333	0.2117	0.8518
10000	0.9986	0.6209	7.7050	0.1308	7.2492	0.4576	0.2323	0.8692


[†] For word-level metrics, [‡] For item description sentences.

少量核心词足以保持语义关系，而增加更多核心词会增加结构学习难度、降低性能，并使模型偏向于强调差异性。

参数敏感性研究（奖励权重）



不同奖励权重对应的物品嵌入的t-SNE可视化



不同奖励权重对推荐性能的影响 不同奖励权重对嵌入反演防御的影响


不同奖励权重下生成词语的质量对比

$(\lambda_{\text{dis}}, \lambda_{\text{str}}, \lambda_{\text{con}})$	Valid [†]	CosSim [†]	KL [‡]	Spearman [†]	NLL [‡]	D-2 [‡]	D-1 [†]	LR [†]
(1, 1, 1)	0.9991	0.6241	7.9014	0.1728	5.8615	0.4112	0.1783	0.8706
(2, 1, 1)	0.9995	0.5740	7.8329	0.1517	7.3188	0.4650	0.2788	0.8191
(3, 1, 1)	0.9986	0.5036	8.3222	0.1539	7.9570	0.5864	0.6248	0.7775
(1, 2, 1)	0.9986	0.6293	7.9264	0.1981	5.7050	0.4257	0.1960	0.8758
(1, 3, 1)	0.9976	0.6324	7.6278	0.2118	6.9764	0.4309	0.2107	0.8537
(1, 1, 2)	0.9945	0.6624	7.6043	0.1579	6.2802	0.4120	0.1855	0.8589
(1, 1, 3)	0.9797	0.7001	7.4114	0.1521	6.1095	0.4171	0.1913	0.8755


[†] For word-level metrics, [‡] For item description sentences.

结果表明，奖励权重驱动模型生成多样化变体，进而通过相似度调控隐私强度、通过结构保持调控推荐性能，两者经由语义约束实现平衡。


参数敏感性研究（补充观测）



缓存大小对推荐性能的影响



核心词数量对推荐性能的影响



不同奖励权重对推荐性能的影响

综合上述大量实验数据，当Spearman相关系数达到一定阈值后，其与后续推荐效果之间不再呈现强正相关关系。换言之，一旦局部语义骨架得到充分保留，进一步提升细粒度的语义保真度对推荐性能所带来的增益便趋于有限。这一现象支持了本研究提出的**“关系保真”原则**：有效的推荐并不要求字面意义上的语义保留，也不依赖全局精确的相对结构保持，而仅需维持局部的相对结构关系即可。剩余的性能增益很可能由推荐模型自身以及互补性的协同信号共同提供。由此可见，隐私保护与推荐效用并非不可调和的对抗目标；通过恰当的权重配置，二者可在“够用”的拓扑保持水平上实现有效解耦。

结论与展望

结论

范式转换 从“语义保真”转向“关系保真”——不要求字面含义保留，而要求维持词语局部相对语义拓扑，支撑推荐协作推理，从而将任务从被动的约束性掩藏，转变为参照原始拓扑的主动语义重构。

方法框架 面向推荐系统边信息隐私脱敏的核心词引导的渐进式混淆框架，GRPO优化锚点映射并平滑扩展至全词汇表；三项奖励协同平衡（差异性、结构一致性、语义锚定）。

信息论保障 轨迹泄露分解与语义模式熵分析揭示路径依赖带来的不确定性，给出攻击成功概率上界，并证明文本端隐私增益可传递至下游物品表示。

实验验证

- **生成质量**：局部结构保持显著最优，流畅性与多样性良好。
- **推荐性能**：多模型上与原始描述精度相当或更优，关系保真范式有效。
- **防御效果**：攻击成功率大幅降低，隐私-效用折中优于现有方法。
- **消融实验**：证实各模块协同不可或缺。
- **参数敏感性实验**：分析了关键参数对生成结果的影响。

展望

面向推荐任务的深度融合 设计敏感度感知的差异化隐私分配，优先保护稀有/高敏词；探索端到端联合优化，使混淆与推荐目标相互适应。

多模态边信息脱敏扩展 将“关系保真”推广至图像、音频等模态，实现跨模态敏感信息的保关系替换与混淆。

轻量化生成与部署优化 通过模型蒸馏等技术降低大模型调用延迟，满足在线低延迟需求。

防范混淆技术的滥用风险 加入输入过滤与输出合规检测，防止混淆功能被用于绕过内容审核。



西安交通大学
XI'AN JIAOTONG UNIVERSITY

感谢指导

欢迎各位老师的批评指正

基于大语言模型生成式边信息的隐私脱敏推荐系统研究

精勤求学 敦笃励志 果毅力行 忠恕任事

答辩人：林圣翔 班级：计试2201
学号：2223312202 指导老师：田锋教授

二〇二六年 六月