



西安交通大学

本科生项目设计报告

学号:	2223312202
姓名:	林圣翔
导师:	田锋教授
项目设计题目:	基于大语言模型生成式边信息的 隐私脱敏推荐系统研究
学科专业:	理科试验班（计算机 H）
学院:	电子与信息学部
填写时间:	2026 年 1 月 8 日

项目设计题目	基于大语言模型生成式边信息的隐私脱敏推荐系统研究
一、研究目的、意义与现状 (一) 研究目的 本研究旨在应对推荐系统在利用大语言模型（LLM）处理物品边信息时所面临的隐私泄露风险，探索一种新型的隐私保护范式。核心目的是设计并实现一种基于大语言模型的“生成式边信息混淆”机制，在数据预处理阶段对物品原始元信息（如标题、描述等）进行语义保持的智能变换。通过此机制，旨在从数据表征源头干扰和破坏潜在攻击者利用嵌入向量或模型输出进行反演攻击、成员推断等所依赖的语义信号与关联模式。通过构建一个将隐私保护内嵌于数据处理流水线的前置式防护框架，实现在有效保障用户隐私安全的前提下，维持乃至提升推荐系统性能的目标，为开发轻量化、可扩展的隐私安全推荐系统提供新的技术路径。 (二) 研究意义 本研究的理论意义在于突破传统隐私保护技术的局限。现有方法多集中于模型训练过程或输出扰动（如差分隐私），以及基于分布式学习的框架（如联邦学习）。与此不同，本研究提出了一种前置式、语义层面的隐私保护新思路，将防御重心迁移至数据预处理与表征生成阶段。通过利用大语言模型（LLM）强大的语义理解与可控生成能力，实现隐私保护与语义效用的协同优化，从而丰富了隐私计算与可信人工智能在推荐系统领域的研究内涵与方法体系。 在实践层面，本研究具有显著意义。它为应对推荐系统商业化应用中日益严格的隐私合规要求（如GDPR、CCPA）与持续增长的业务性能需求之间的矛盾，提供了可行的解决方案。该方法不依赖高昂的通信开销或复杂的协同训练机制，易于集成至现有推荐数据流水线，具有良好的工程落地潜力。通过对物品边信息进行源头脱敏，能够系统性地降低后续所有处理环节（包括嵌入生成、模型训练与服务部署）的隐私泄露风险，从而为构建全链路隐私安全的智能推荐服务提供了基础支撑。 (三) 研究现状 当前，在推荐系统中从数据层面兼顾用户隐私与推荐性能的研究相对有限，且多数工作集中在基于用户交互历史的修改。与本研究更具参考意义的主要是嵌入向量修改和 LLM 混淆文本生成这两个方向的工作。 推荐系统领域基于物品元信息的数据合成方面，SampleLLM（WWW 2025）提出了一个两阶段框架，借助大语言模型和改进的采样策略优化了面向推荐任务的表格数据合成质量，缓解了现有方法在数据稀疏和语义理解上的不足。而更多研究侧重于直接修改用户交互历史：例如 UPC_SDG（SIGIR 2022）引入了用户隐私偏好控制机制；DiffuRec（ACM TOIS 2024）利用扩散模型生成高质量的合成交互序列以替代真实数据；CLOUD（ACM TOIS 2025）则通过在序列中插入混淆项目，实现在保护用户隐私的同时不明显降低推荐精度。此外，如 DR4SR（KDD 2024）和 STEAM（WWW 2023）等工作虽旨在提升性能，但其序列修改思路也为隐私保护场景提供了启发。然而，这类方法主要作用于用户物品交互层面，未能深入利用物品本身丰富的文本语义信息，也未充分考虑由此可能引发的新型隐私风险。 基于嵌入向量修改的方法主要在模型特征空间层面实施保护，旨在阻断从嵌入反推原始信息的路径。具体可分为两类：一是向量映射，如 Eguard（AAAI 2026）通过投影变换并结合互信息优化来降低信息泄露风险，STEER（arXiv 2025）借助嵌入空间对齐实现隐私安全的检索；二是向量扰动，如 REPET（JAMIA 2020）通过替换为语义邻近的词嵌入实现扰动，DP-Forward（CCS 2023）则在前向传播过程中向嵌入添加满足本地差分隐私的优化噪声。这些方法在特征层面提供了一定保护，但通常作为模型训练或推理的中间环节，未直接关联到对原始文本数据的根本性语义转换，因而保护不够彻底。 基于大语言模型的混淆文本生成方法近年来随着 LLM 能力的发展成为新兴热点。现有工作主要沿	

两个方向展开。一是基于提示工程，通过精心设计的提示策略引导通用大模型实现隐私保护。例如，EmojiPrompt(ACL 2025)通过生成式提示将敏感信息转化为非自然语言形式；LLM-Anonymization(ICLR 2025)和 RUPTA(ACL 2025)采用迭代式提示进行对抗性评估与优化，以生成混淆文本；IncogniText(arXiv 2025)则通过条件化提示驱动模型检测间接隐私泄漏并随机化私有属性。值得注意的是，为了兼顾效果与效率，部分方法（如 IncogniText 和 RUPTA）支持将提示工程所激发的匿名化能力蒸馏至轻量级本地模型，形成了“提示创新——能力蒸馏”的混合范式。二是基于微调本地模型，通过训练专用的小型模型实现高效、可控的文本改写。例如，HaS(arXiv 2025)通过微调本地的小型 LLM，分别训练用于隐藏和还原信息的模型对，在端侧完成隐私处理。这些研究展现了 LLM 在语义层面实现隐私保护的潜力，但目前主要集中在通用文本（如社交媒体内容、医疗记录）的匿名化处理，尚未系统性地将其深度语义理解与生成能力应用于推荐系统场景，特别是对物品元信息进行既保护隐私又保持语义的智能混淆与脱敏。

综上所述，现有研究在行为序列扰动与嵌入空间保护方面已积累较多成果，LLM 文本混淆也开辟了新路径。然而，将 LLM 的深度语义能力系统应用于推荐系统数据预处理阶段，针对物品边信息构建生成式、语义保持的混淆脱敏机制，从而从数据源头为基于嵌入的推荐系统建立隐私防护框架的研究，目前仍属空白。本研究正是针对这一空白展开，旨在融合 LLM 的语义生成优势与推荐系统的隐私保护需求，探索一条兼顾安全与效用的新途径。

二、研究工作汇报（主要工作内容，包括技术路线和效果）

目前主要完成了相关领域的文献调研、技术路线设计以及初步的预实验，后续为项目的进度规划。
（一）研究综述与技术路线设计（2025.12-2026.01，基本完成）

围绕推荐系统安全、隐私保护及对抗攻击等领域展开系统文献调研，重点梳理隐私泄露路径、防护机制及其局限性、以及对抗攻击下模型脆弱性等关键问题。本文拟研究利用大语言模型实现“生成式混淆”机制，对物品元信息进行语义保持的变换，旨在从表征源头干扰反演攻击的信号基础。具体而言，针对每个原始语义生成对应语义簇，并满足以下约束：生成的语义簇应与原始语义保持一定距离，避免过度接近；若两个原始语义本身相似，则其对应语义簇应彼此接近，否则应相互远离。

为实现上述目标，本研究设计了一套基于 GRPO 的强化学习框架，并引入了全局感知机制，以平衡个体数据点的差异性与数据集整体结构的一致性。该机制通过预计算全局相似性信息，在局部批次训练中动态注入历史聚类中心作为约束，使模型在优化当前批次参数的同时，能够隐式感知并维持全局结构的稳定性，从而有效避免聚类中心漂移或结构失真。具体步骤如下：（1）在训练前对整个数据集进行一次性的预计算，构建全局相似性图（例如基于余弦相似度的 KNN 图），并通过预聚类得到历史聚类中心；（2）在训练过程中，从全局图中检索与当前批次物品高度相似的外部锚点，将其对应的历史聚类中心作为软约束注入损失函数，通过约束项控制其与当前嵌入的距离，从而隐式引导模型的优化方向朝向全局稳定结构。

在具体实现与验证方面，本研究将基于 MovieLens-1M 等数据集开展实验。推荐效果将通过归一化折扣累计增益（NDCG）和命中率（HR）等指标进行评估。隐私保护效果则从多个维度进行衡量：包括合成数据与真实数据间的语义相似度（用于评估信息保真度），以及模型抵御反演攻击和属性推断攻击的成功率（直接测试隐私泄露风险）。本研究将选取 TALLRec、LLaRA 等若干基于大语言模型嵌入的主流推荐模型作为下游任务模型，以进行全面的性能对比分析。此外，计划引入具体的实验设计主要包括：（1）通过消融实验，分析利用 LLM 深度理解物品元信息对于生成高质量混淆嵌入的关键作用，验证 LLM 引入的必要性；（2）在严格控制隐私保护水平的前提下，比较本研究提出的方法与基线模型在 NDCG、HR 等核心推荐指标上的性能差异；（3）从语义相似度及抗反演攻击能力等多个维度，系统评估本方法所能提供的隐私保护强度。

在预实验部分：（1）基于开源代码在 MovieLens 1M 数据集上复现 TALLRec 模型，验证准确率为

0.7263，结果基本与原文一致；（2）使用 Attack-Recsys 进行反演攻击评估，由于训练时间有限（训练 260 轮的情况下），实验结果用户画像匹配度为 0.523（原论文 0.87），物品匹配度为 0.2377（原论文 0.6471），但可表明该攻击方法具备可行性；（3）成功复现 DR4SR（KDD 2024）与 UPC_SDG（SIGIR 2022）等基于交互历史修改的推荐系统方法，结果与原文核心结论一致，为后续对比实验奠定基础。

（二）核心方法框架实现（2026.01-2026.02，预计 2 周）

本阶段的核心目标是构建并验证基于大语言模型的语义可控生成模块及其完整训练流程。为实现从物品原始边信息到生成式脱敏文本的端到端转换，计划采取渐进式的实现策略。（1）实现一个基础版本框架，重点在于完成核心架构设计并实现完整的训练流水线，包括：设计并实现完整的训练流水线，涵盖数据预处理、模型微调以及基于强化学习的优化策略。此阶段旨在完成基础功能的闭环验证，在选定的基准数据集上初步运行整个流程，以验证框架的基本可行性。（2）为改进基础版本在训练效果与生成稳定性方面的不足，引入全局感知机制。通过设计合理的多目标奖励函数与损失函数，在训练过程中实施考虑实现阶段性学习策略，实现训练过程的渐进、稳定优化，例如，初始阶段侧重于生成文本的语义质量，中期加强语义分布一致性的约束，后期则着重于增大生成语义与原始语义的差异以增强隐私保护。（3）为进一步提升混淆效果的精准性与理论严谨性，拟探索基于最优传输理论的优化方法。考虑将原始语义与生成语义簇之间的映射关系建模为一个最优传输问题，通过设计相应的传输代价（如语义距离、隐私度量），并利用 Sinkhorn 算法等高效求解，以理论驱动的方式优化生成过程，力求在复杂的语义约束下找到更优的隐私效用平衡点。

该阶段的主要技术难点在于：（1）奖励函数的设计，以量化并平衡“语义保持”与“隐私偏离”这对矛盾目标；（2）缓存机制的有效实现，确保其能真正提升训练效果和生成稳定性；（3）最优传输模型的合理集成，使其与现有的强化学习框架协同工作。完成本阶段工作，将为后续的系统对比评估与调优奠定坚实的技术基础。

（三）对比基线系统集成（2026.02-2026.03，预计 2 周）

为实现公平、全面的性能评估，本研究将选取并复现多层次代表性基线方法，涵盖直接编码、随机扰动、差分隐私（如 DP-Forward）以及生成式脱敏（如 Eguard）等不同技术路线的典型模型。所有选定的基线方法将严格依据其原始论文及官方开源代码进行复现，并通过与原文报告结果的比对以确保复现的正确性。所有基线方法将被封装为具有标准输入输出（如原始文本/嵌入→受保护文本/嵌入）的独立模块。这些模块将被集成至同一个主流的推荐系统骨干网络中，确保下游推荐任务、训练超参数、数据划分及评估流程完全一致。

（四）系统优化与超参数调优（2026.03-2026.04，预计 3 周）

本阶段旨在对所实现的方法进行系统性优化与精细化调优，主要围绕工程实现与模型参数两个层面展开，以提升系统的整体鲁棒性、效率及最终性能。

在工程实现优化层面，将对现有代码进行模块化重构与流程整合。具体包括：梳理并规范各功能模块（如数据加载器、生成模块、训练器、评估器）的接口与职责，实现高内聚、低耦合的代码结构；同时对数据处理、模型训练、评估验证的全流程进行性能剖析与优化，例如引入数据缓存、并行计算等技术，以显著提升实验迭代效率与系统的可维护性。在模型参数调优层面，将开展系统的超参数搜索与优化。关键调优对象包括：强化学习框架的学习率、隐私保护损失项的权衡权重、生成模块的温度系数以及聚类约束的强度系数等。调优过程将以验证集上的综合性能（兼顾推荐效用与隐私保护指标）为核心指导，采用网格搜索或贝叶斯优化等策略进行多轮迭代。目标在于找到一系列在不同隐私效用权衡偏好下的最优配置，从而确定模型的最佳工作点。

该阶段的工作成果将为后续与基线方法的公平性能比较，以及跨数据集、跨模型的泛化性验证，提供稳定、高效且经过充分优化的模型基础，确保实验结论的可靠性与说服力。

（五）泛化性验证实验设计（2026.04-2026.05，预计 3 周）

本阶段旨在通过系统性的实验设计，全面评估所提出方法的泛化能力与鲁棒性，确保研究结论具备坚实的可靠性与广泛的实用价值。验证工作将围绕以下两个核心维度展开：（1）选取涵盖不同领域及

不同数据规模的多个公开数据集进行测试，例如 Amazon、MovieLens-25M 等，通过在此类异构数据集上复现核心实验，可以系统评估方法在数据稀疏性、物品元信息模态和用户行为模式差异下的性能稳定性；（2）为证明方法不依赖于特定推荐架构，将把本文提出的隐私保护模块适配并集成到多种基于边信息的主流推荐模型框架中，计划选取的骨干模型包括但不限于可基于嵌入的序列推荐模型（如 TALLRec）、生成式推荐模型（如 LLaRA）以及其他基于边信息的推荐架构，通过在不同模型上保持相同的隐私保护前置处理，而后比较其下游推荐性能与隐私指标的变化，可以验证本方法作为通用预处理组件的有效性和兼容性。

通过上述跨数据集与跨模型的系统化实验，本研究将从多个角度充分验证方法的鲁棒性、稳定性及可迁移性，从而确保证据链的完整性，并有力支撑其在实际推荐系统中的应用潜力。

（六）学术论文撰写与成果整理（2026.05-2026.06，预计 2 周）

本阶段将依据学术规范，系统梳理研究全流程，撰写结构完整、逻辑清晰的学术论文。具体工作包括：围绕研究问题、文献综述、方法设计、实验设置、结果分析与讨论等核心章节展开论述，通过精准的数据呈现、深入的归因分析及合理的理论阐释，形成初稿；进一步优化图表绘制与文字表达，确保内容准确、表述严谨，并经过多次修订与完善，最终完成符合毕业论文格式与质量要求的正式稿件。